Как перестать бояться и полюбить формулы в стиле R

В `R` и `python` (пакет `statsmodels`) используется упрощенная версия нотации, впервые, по-видимому, предложенной Уилкинсоном и Роджерсом [1], описанной Чемберсом, Хасти и Преджибоном [2].

В `python` формулы записываются как обычные строковые значения в кавычках, но в `R` формулы — отдельный тип данных, кавычки для которого не нужны. Формула в общем виде представляет собой объясняемую часть — одну переменную или несколько — и объясняющую, разделенные знаком «тильда» `~`.

```
Y ~ X...
```

В нашем случае левая часть выражения чаще всего будет представлять собой одну переменную. С этим все просто.

С правой частью все сложнее и интереснее. Она, правая часть, состоит из элементов, разделенных знаками `+` и `-`. Элемент может представлять собой:

- Переменную, например `x`.
- Некоторую функцию от переменной или переменных, например `log(x)` в `R` или `np.log(x)` в `python`.
- Составной элемент, включающий в себя переменные и/или функции от переменных, например `x*z`. Обратите внимание, что это **не произведение**!

Вообще, в формулах вы будете видеть некоторые математические операторы, но следует помнить, что некоторые из них имеют значение и смысл **отличные** от традиционных! Рассмотрим их подробнее:

- `()` — скобки призваны группировать элементы и менять порядок обработки других символов. То есть, скобки работают как скобки.
- `+` — плюс в формулах обозначает добавление элемента в модель. Например, выражение `y ~ x + z` обозначает модель, в которой `y` является объясняемой переменной, а `x` и `z` — объясняющими.
- `-` — минус, как можно догадаться, обозначает удаление элемента из модели. На первый взгляд он не нужен: просто не добавляйте элемент! Но на самом деле, следующие из рассматриваемых операторов в результате своей работы могут создавать элементы, явно в форумле не описанные. Если эти элементы нам не нужны, то при помощи оператора `-` их можно убрать из модели.

  Также, минус можно использовать, чтобы убрать из формулы свободный член. При оценивании линейной модели он добавляется автоматически, его не надо добавлять вручную. Для его удаления достаточно добавить в формулу `-1` или `+0`.
- `:` — двоеточие обозначает член взаимодействия между двумя элементами, причем эти элементы сами могут быть членами взаимодействия. В качестве примера можно привести элементы `x:z` или `x:z:w`. Элементы, разделенные `:` могут быть не только переменными, но и функциями от них, например `x:sqrt(z)`.

Элементы, разделенные `:`, могут быть составными, в этом случае мы получим все попарные комбинации. Например, `(a + b):(c + d)` эквивалентно `a:c + a:d + b:c + b:d`.

- `*` — звездочка позволяет добавить в модель член взаимодействия вместе со всеми входящими в него элементами. То есть выражения `x*z` и `x + z + x:z` эквивалентны.
- `^` в `R` и `**` в `python` — показывает максимальную степень взаимодействия между элементами, где под степенью взаимодействия понимается число элементов в члене взаимодействия. Причем итоговая степень не будет превышать число элементов, входящих в выражение. Например:
  - `x^2` эквивалентно `x`.
  - `(x+z)^2` эквивалентно `x + z + x:z`.
  - `(a+b+c)^2` эквивалентно `a + b + c + a:b + b:c + a:c`.
  - `(a+b+c)^3` эквивалентно `a + b + c + a:b + b:c + a:c + a:b:c`.
- `%in%` в `R` — данный оператор означает, что элемент слева является вложенным в элемент справа. В большинстве случаев запись `x %in% y` эквивалентна `y:x`.
- `/` — краткая запись, `x / y` эквивалентно `y + x %in% y`.

Как мы видим, некоторые математические символы имеют другое значение. Если же нам нужно использовать их в формуле в **исходном** значении, то надо соответствующий элемент заключить в функцию `I()`. То есть `x*y` — это член взаимодействия плюс сами переменные

(`x + y + x:y`), а `I(x*y)` — произведение `x` и `y`, используемое в качестве переменной.

Следует отметить, что последние два оператора (`%in%` и `/`) в случае непрерывных переменных не имеют большого смысла, так как `:` для таких меременных имеет смысл их произведения. Но если мы будем использовать **факторные** переменные, принимающие строго фиксированное число значений, то в этом случае данные операторы будут полезны, так как они говорят `R` и `python`, в каком порядке надо выводить результаты в таблицах и как их надо группировать.

При этом следует помнить, что переменная принимающая строго фиксированное число значений, с точки зрения программы, является непрерывной. Чтобы указать на то, что ее следует трактовать как факторную, следует преобразовать ее в таковую при помощи функции `as.factor` в `R` или функции `C()` в `python`.

Библиография

[1] G. N. Wilkinson и C. E. Rogers, «Symbolic Description of Factorial Models for Analysis of Variance», *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, т. 22, вып. 3, сс. 392–399, 1973, doi: 10.2307/2346786.

[2] J. Chambers, T. Hastie, и D. Pregibon, «Statistical Models in S», в *Compstat*, K. Momirović и V. Mildner, Ред., Heidelberg: Physica-Verlag HD, 1990, сс. 317–321. doi: 10.1007/978-3-642-50096-1_48.