# Классическая линейная модель и свойства МНК-оценок

## Модель парной линейной регрессии

Модель **парной линейной регрессии** имеет вид (Носко 2021)

$$y_i = \beta_0 + \beta_1 x_i + u_i \tag{1}$$

где

- $y_i$ — *зависимая*, или *объясняемая*, или *эндогенная* переменная; очень редко встречается название *регрессанд*;
- $x_i$ — *объясняющая*, или *экзогенная* переменная; очень часто используется название *регрессор*;
- $u_i$ — случайная ошибка.

Случайная ошибка включается в себя *все* значимые, но не включенные в модель переменные.

Не стоит путать модель регрессии и **теоретическую линию регрессии**, имеющую вид

$$y = \beta_0 + \beta_1 x$$

и показывающую теоретическую связь между переменными в рамках всей генеральной совокупности.

Оценить коэффициенты $\beta_0$ и $\beta_1$ проще всего при помощи метода наименьших квадратов, решая задачу

$$\min_{\beta_0,\beta_1} \underbrace{\sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i)^2}_{Q}, \tag{2}$$

что приводит нас к условиям первого порядка

$$\frac{\partial Q}{\partial \beta_0}|_{\hat{\beta}_0,\hat{\beta}_1} = -2\sum_{i=1}^{N}\big(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i\big) = 0 \tag{3}$$

$$\frac{\partial Q}{\partial \beta_1}|_{\hat{\beta}_0,\hat{\beta}_1} = -2\sum_{i=1}^{N}\big(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i\big)x_i = 0 \tag{4}$$

Данные условия представляют собой систему из двух уравнений с двумя неизвестными, решение которого равно

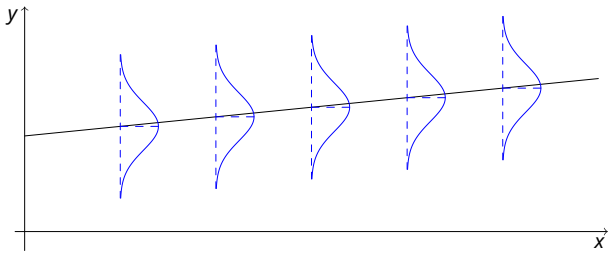
$$\hat{\beta}_1 = \frac{\sum_{i=1}^{N}(y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^{N}(x_i - \bar{x})^2} = \frac{s_{yx}}{s_x^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

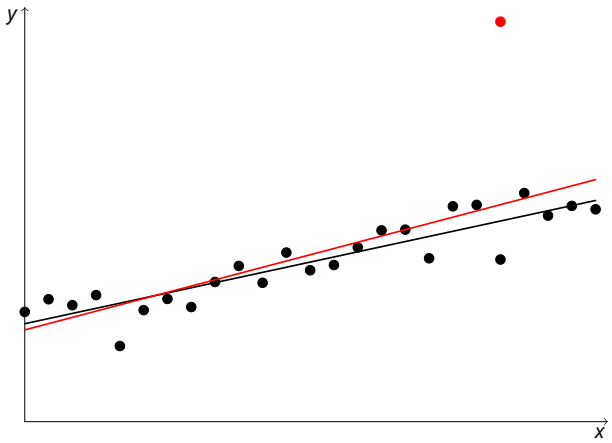
## Предпосылки МНК

1. Условное распределение $u_i$ относительно $X_i$ имеет нулевое среднее: $\mathrm{E}[u_i \mid x_i] = 0$;




2. Наблюдения $(y_i, x_i) \sim$ i.i.d.;

3. Большие выбросы маловероятны: $y_i$ и $x_i$ имеют ненулевые и конечные четвертые моменты.




При выполнении этих предположений оценки коэффициентов $\hat{\beta}_0$ и $\hat{\beta}_1$ будут асимптотически нормальными.

## Графическая интерпретация

Для графической интерпретации МНК представим оценку (1) в виде (Носко 2021)

$$\underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}}_{\mathbf{y}} = \hat{\beta}_0 \underbrace{\begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}}_{\mathbf{1}} + \hat{\beta}_1 \underbrace{\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}}_{\mathbf{x}} + \underbrace{\begin{pmatrix} \hat{u}_1 \\ \hat{u}_2 \\ \vdots \\ \hat{u}_N \end{pmatrix}}_{\hat{\mathbf{u}}} = \underbrace{\hat{\beta}_0 \mathbf{1} + \hat{\beta}_1 \mathbf{x}}_{\hat{\mathbf{y}}} + \hat{\mathbf{u}} = \hat{\mathbf{y}} + \hat{\mathbf{u}}$$

Нетрудно увидеть, что условия первого порядка (3) и (4) примут вид

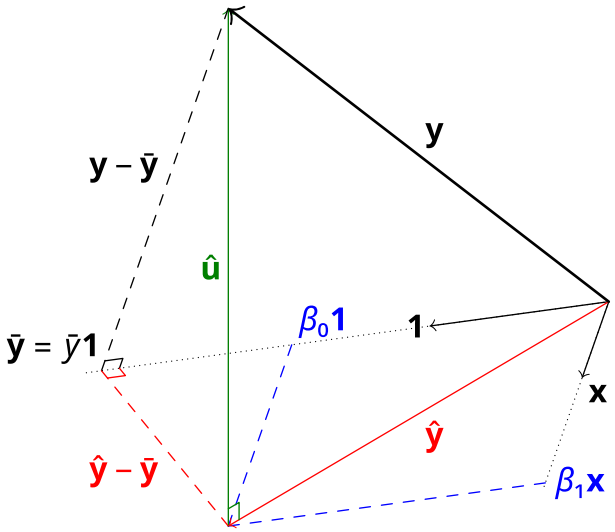
$$\langle \hat{\mathbf{u}}, \mathbf{1} \rangle = 0,$$
$$\langle \hat{\mathbf{u}}, \mathbf{x} \rangle = 0,$$

то есть вектор остатков ортогонален векторам $\mathbf{1}$ и $x$; таким образом он ортогонален и «плоскости», натянутой на эти векторы. Кроме того, во введенных обозначениях задача МНК представляет собой задачу поиска ортогональной проекции вектора $y$ на данную «плоскость».

Действительно, (2) примет вид

$$\min_{\beta_0,\beta_1} \left\| \mathbf{y} - \underbrace{\hat{\beta}_0 \mathbf{1} - \hat{\beta}_1 \mathbf{x}}_{\hat{\mathbf{y}}} \right\|^2,$$

из которой понятно, что $\hat{y}$ — ортогональная проекция $y$ на «плоскость».




# Модель множественной линейной регрессии

Очевидно, что модель парной регрессии в большинстве случаев не может удовлетворить исследователя. Более того, в такой модели крайне высока вероятность смещения из-за пропущенной переменной.

Модель **множественной линейной регрессии** имеет вид:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + ... + \beta_K x_{Ki} + u_i$$

Оценки коэффициентов получаются аналогично парному случаю:

$$\min_{\beta_0, \beta_1, ..., \beta_K} \underbrace{\sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_{1i} - ... - \beta_K x_{Ki})^2}_{Q}$$

Разумеется, что данную задачу можно решить «в лоб», найдя условия первого порядка в точке оптимума, приравняв их нулю и решив получившуюся систему уравнений. Однако уже для случая $K = 2$ получающиеся выражения становятся весьма громоздкими. Поэтому чаще всего работают с моделями в матричной форме (Магнус и др. 2021):

$$\underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}}_{\mathbf{y}} = \underbrace{\begin{pmatrix} 1 & x_{11} & x_{21} & ... & x_{K1} \\ 1 & x_{12} & x_{22} & ... & x_{K2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1N} & x_{2N} & ... & x_{italic(KN)} \end{pmatrix}}_{\mathbf{X}} \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_K \end{pmatrix}}_{\boldsymbol{\beta}} + \underbrace{\begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_N \end{pmatrix}}_{\mathbf{u}}$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$$

Сумма квадратов остатков примет вид $\hat{\mathbf{u}}'\hat{\mathbf{u}}$, а оценка вектора коэффициентов будет равна

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

*Доказательство.* Задача поиска оптимального вектора $\hat{\boldsymbol{\beta}}$ имеет вид

$$\min_{\boldsymbol{\beta}} \underbrace{(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})}_{\mathbf{Q}}$$

Найдем дифференциал этого выражения (Магнус и др. 2021; Pierse 2021a):

$$\begin{aligned}\mathrm{d}\mathbf{Q} &= \mathrm{d}[(\mathbf{Y}-\mathbf{X}\beta)'](\mathbf{Y}-\mathbf{X}\beta) + (\mathbf{Y}-\mathbf{X}\beta)'\,\mathrm{d}(\mathbf{Y}-\mathbf{X}\beta) = \\ &= [\,\mathrm{d}(\mathbf{Y}-\mathbf{X}\beta)'](\mathbf{Y}-\mathbf{X}\beta) + (\mathbf{Y}-\mathbf{X}\beta)'\,\mathrm{d}(\mathbf{Y}-\mathbf{X}\beta) = \\ &= (\mathbf{Y}-\mathbf{X}\beta)'\,\mathrm{d}(\mathbf{Y}-\mathbf{X}\beta) + (\mathbf{Y}-\mathbf{X}\beta)'\,\mathrm{d}(\mathbf{Y}-\mathbf{X}\beta) = \\ &= -2(\mathbf{Y}-\mathbf{X}\beta)'\mathbf{X}\,\mathrm{d}\beta\end{aligned}$$

При выводе мы воспользовались тем, что $\mathbf{Q}$ — скаляр, а значит скалярами являются и слагаемые в промежуточных выражениях. А для скаляра, очевидно, справедливо $x' = x$. Также мы считаем матрицы $\mathbf{Y}$ и $\mathbf{X}$ фиксированными в рамках имеющейся выборки.

Имеем, что в точке оптимума

$$\nabla\mathbf{Q} \propto (\mathbf{Y}-\mathbf{X}\beta)'\mathbf{X} = \mathbf{0}$$

откуда транспонированием и простыми преобразованиями и получаем искомую формулу. □

Нетрудно увидеть, что подобранные значения равны $\hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{H}\mathbf{y}$, а остатки — $\hat{\mathbf{u}} = \mathbf{y} - \hat{\mathbf{y}} = [\mathbf{I}_N - \mathbf{H}]\mathbf{y} = \mathbf{M}\mathbf{y}$. Также нетрудно увидеть, что

$$\begin{gathered}\mathbf{H}' = \mathbf{H} \quad \mathbf{M}' = \mathbf{M} \\ \mathbf{H}\mathbf{H} = \mathbf{H}\mathbf{M}\mathbf{M} = \mathbf{M} \\ \mathbf{M}\mathbf{H} = \mathbf{0} \quad \mathbf{H}\mathbf{M} = \mathbf{0} \\ \mathbf{H}\mathbf{X} = \mathbf{X}\ \mathbf{M}\mathbf{X} = \mathbf{0}\end{gathered}$$

Более того, так как матрица $\mathbf{M}$ идемпотентна, то $\operatorname{rank}\mathbf{M} = \operatorname{tr}\mathbf{M}$, то есть

$$\begin{aligned}\operatorname{tr}\mathbf{M} &= \operatorname{tr}\left(\mathbf{I}_N - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\right) = \\ &= \operatorname{tr}\mathbf{I}_N - \operatorname{tr}\left(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\right) = \\ &= N - \underbrace{\operatorname{tr}\left(\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\right)}_{\mathbf{I}_K} = N - K\end{aligned}$$

Этот факт позволяет получить несмещенную оценку $\sigma_u^2$ (Pierse 2021a):

$$\begin{aligned}\mathrm{E}(\hat{\mathbf{u}}'\hat{\mathbf{u}}|\,\mathbf{X}|) &= \operatorname{tr}[\mathrm{E}(\mathbf{u}'\mathbf{M}'\mathbf{M}\mathbf{u})\,\mathbf{X})] = \mathrm{E}[\operatorname{tr}(\mathbf{u}'\mathbf{M}\mathbf{u})\mid\mathbf{X}] = \\ &= \mathrm{E}[\operatorname{tr}(\mathbf{M}\mathbf{u}\mathbf{u}')\mid\mathbf{X}] = \sigma_u^2\operatorname{tr}\mathbf{M} = \sigma_u^2(N-K)\end{aligned}$$

$$\sigma_u^2 = \mathrm{E}\left(\frac{\hat{\mathbf{u}}'\hat{\mathbf{u}}}{N-K}\,\middle|\,\mathbf{X}\right)$$

## Расширенные предпосылки МНК

1. $\mathrm{E}(u_i \mid \mathbf{X}_i) = 0$.
2. $(\mathbf{X}_i, Y_i) \sim$ i.i.d.
3. $\mathbf{X}_i$ и $u_i$ имеют ненулевые конечные четвертые моменты.
4. $\mathbf{X}$ имеет полный ранг — нет совершенной мультиколлинеарности, то есть точной линейной зависимости между регрессорами.
5. $\mathrm{Var}(u_i \mid \mathbf{X}_i) = \sigma_u^2$ — гомоскедастичность.
6. $u_i \mid \mathbf{X}_i \sim N(0, \sigma_u^2)$.

# Свойства МНК оценок

1. $\hat{\beta}$ — несмещенная оценка;

2. $\frac{1}{N}\sum_{i=1}^{N}\hat{u}_i = 0$ — выборочное среднее остатков равно нулю;
3. $\frac{1}{N}\sum_{i=1}^{N}\hat{y}_i = \bar{y}$;
4. $\sum_{i=1}^{N}\hat{u}_i x_{ki} = 0, \forall k \in \{1, ..., K\}$.
5. $TSS = ESS + RSS$, где
   - $TSS = \sum_{i=1}^{N}(y_i - \bar{y})^2$ — полная сумма квадратов,
   - $ESS = \sum_{i=1}^{N}(\hat{y}_i - \bar{y})^2$ — объясненная сумма квадратов,
   - $RSS = \sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{N}\hat{u}_i^2$ — остаточная сумма квадратов или сумма квадратов остатков.

*Доказательство.*

$$
\begin{aligned}
TSS &= \sum_{i=1}^{N}(y_i - \bar{y})^2 = \sum_{i=1}^{N}[(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2 = \\
&= \sum_{i=1}^{N}(y_i - \hat{y}_i)^2 + \sum_{i=1}^{N}(\hat{y}_i - \bar{y})^2 + 2\sum_{i=1}^{N}(y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) = \\
&= RSS + ESS + 2\sum_{i=1}^{N}\hat{u}_i\hat{y}_i - 2\bar{y}\sum_{i=1}^{N}\hat{u}_i
\end{aligned}
$$

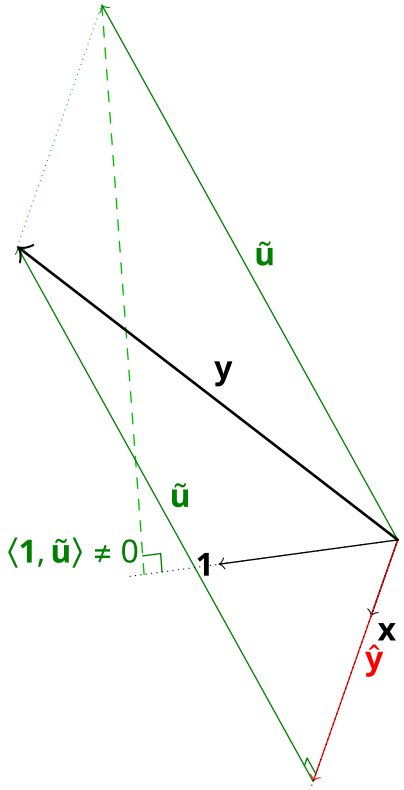
Последнее слагаемое равно нулю в силу второго свойства. Сумму в предпоследнем слагаемом можно представить в виде

$$\sum_{i=1}^{N}\hat{u}_i\left(\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + ... + \hat{\beta}_K x_{Ki}\right)$$

Раскрыв скобки и воспользовавшись вторым и четвертым свойствами, мы получим, что это слагаемое также равно нулю.

□

Важно отметить, что все перечисленные свойства, за исключением, разве что, четвертого, справедливы *только* при наличии в модели свободного члена!




# Теорема Гаусса-Маркова

## Одномерный случай

**Теорема 1 (Гаусса-Маркова).** *Если для всех* $i, j = 1, \ldots, n$ *выполняются условия Гаусса-Маркова:*

1. $\mathrm{E}(u_i \mid X_1, ..., X_n) = 0$,
2. $\mathrm{Var}(u_i \mid X_1, ..., X_n) = \sigma_u^2, 0 < \sigma_u^2 < \infty$,
3. $\mathrm{E}\big(u_i u_j \;\big|\; X_1, ..., X_n\big) = 0, i \neq j$, *то МНК оценка* $\hat{\beta}_1$ *является наилучшей (эффективной) линейной условно не смещенной оценкой (BLUE) (Gujarati и Porter 2009).*

- УГ-М (1) следует из предположений (1) и (2)
- УГ-М (2) следует из предположения (2) и предположения о гомоскедастичности ошибок
- УГ-М (3) следует из предположения (2)

*Доказательство.* Линейность:

$$\sum_{i=1}^{n}\big(X_i - \bar{X}\big) = 0 \Rightarrow$$

$$\sum_{i=1}^{n}\big(X_i - \bar{X}\big)\big(Y_i - \bar{Y}\big) = \sum_{i=1}^{n}\big(X_i - \bar{X}\big)Y_i \Rightarrow$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}\big(X_i - \bar{X}\big)\big(Y_i - \bar{Y}\big)}{\sum_{i=1}^{n}\big(X_i - \bar{X}\big)^2} = \frac{\sum_{i=1}^{n}\big(X_i - \bar{X}\big)Y_i}{\sum_{i=1}^{n}\big(X_i - \bar{X}\big)^2} = \sum_{i=1}^{n}\hat{a}_i Y_i$$

Условная несмещенность:

$$\begin{aligned}\mathrm{E}\big(\hat{\beta}_1 \;\big|\; X_1, ...\big) &= \beta_1 + \mathrm{E}\left(\frac{\sum_{i=1}^{n}\big(X_i - \bar{X}\big)u_i}{\sum_{i=1}^{n}\big(X_i - \bar{X}\big)^2} \;\middle|\; X_1, ...\right) = \\ &= \beta_1 + \frac{\sum_{i=1}^{n}\big(X_i - \bar{X}\big)\,\mathrm{E}(u_i \mid X_1, ...)}{\sum_{i=1}^{n}\big(X_i - \bar{X}\big)^2} = \\ &= \beta_1\end{aligned}$$

Эффективность: пусть $\tilde{\beta}_1$ — любая линейная условно несмещенная оценка $\beta_1$, то есть $\tilde{\beta}_1 = \sum_{i=1}^n a_i Y_i$ и $\mathrm{E}\,\tilde{\beta}_1 = \beta_1$. Тогда $\sum_{i=1}^n a_i = 0$, $\sum_{i=1}^n a_i X_i = 1$.

$$\tilde{\beta}_1 = \sum_{i=1}^n a_i Y_i = \beta_0 \sum_{i=1}^n a_i + \beta_1 \sum_{i=1}^n a_i X_i + \sum_{i=1}^n a_i u_i \Rightarrow$$

$$\mathrm{E}\big(\tilde{\beta}_1 \mid X_1, \ldots\big) = \beta_0 \underbrace{\sum_{i=1}^n a_i}_{=0} + \beta_1 \underbrace{\sum_{i=1}^n a_i X_i}_{=1} = \beta_1$$

$$\tilde{\beta}_1 - \beta_1 = \sum_{i=1}^n a_i u_i \Rightarrow$$

$$\mathrm{Var}\big(\tilde{\beta}_1 \mid X_1, \ldots\big) = \mathrm{E}\left[\left(\sum_{i=1}^n a_i u_i\right)^2 \,\middle|\, X_1, \ldots\right] =$$

$$= \sum_{i=1}^n \sum_{j=1}^n a_i a_j \,\mathrm{E}(u_i, u_j \mid X_1, \ldots) = \sigma_u^2 \sum_{i=1}^n a_i^2$$

Пусть $a_i = \hat{a}_i + d_i$. Тогда $\sum_{i=1}^n a_i^2 = \sum_{i=1}^n \hat{a}_i + 2\sum_{i=1}^n \hat{a}_i d_i + \sum_{i=1}^n d_i^2$.

$$\sum_{i=1}^n \hat{a}_i d_i = \sum_{i=1}^n \frac{\big(X_i - \bar{X}\big) d_i}{\sum_{i=1}^n \big(X_i - \bar{X}\big)^2} =$$

$$= \frac{\sum_{i=1}^n X_i d_i - \bar{X} \sum_{i=1}^n d_i}{\sum_{i=1}^n \big(X_i - \bar{X}\big)^2} =$$

$$= \frac{\left(\sum_{i=1}^n X_i a_i - \sum_{i=1}^n X_i \hat{a}_i\right) - \bar{X}\left(\sum_{i=1}^n a_i - \sum_{i=1}^n \hat{a}_i\right)}{\sum_{i=1}^n \left(X_i - \bar{X}\right)^2} = 0$$

$$\begin{aligned}
\operatorname{Var}\left(\tilde{\beta}_1 \mid X_1, \ldots\right) &= \sigma_u^2 \sum_{i=1}^n a_i^2 = \\
&= \sigma_u^2 \sum_{i=1}^n \hat{a}_i^2 + \sigma_u^2 \sum_{i=1}^n d_i^2 = \\
&= \operatorname{Var}\left(\hat{\beta}_1 \mid X_1, \ldots\right) + \sigma_u^2 \sum_{i=1}^n d_i^2 \Rightarrow \\
\operatorname{Var}\left(\tilde{\beta}_1 \mid X_1, \ldots\right) - \operatorname{Var}\left(\hat{\beta}_1 \mid X_1, \ldots\right) &= \sigma_u^2 \sum_{i=1}^n d_i^2 > 0
\end{aligned}$$

□

## Многомерный случай

**Теорема 1 (Гаусса-Маркова).** *Пусть*

1. $\mathrm{E}(\mathbf{U} \mid \mathbf{X}) = \mathbf{0}_N$.
2. $\mathrm{E}(\mathbf{U}\mathbf{U}' \mid \mathbf{X}) = \sigma_u^2 \mathbf{I}_N$.
3. $\mathbf{X}$ *имеет полный столбцовый ранг.*

*Тогда МНК оценка* $\hat{\beta}$ *является наилучшей (эффективной) линейной условно не смещенной оценкой (BLUE)(Носко 2021; Магнус и др. 2021; Pierse 2021a).*

*Доказательство.* Линейность $\hat{\beta}$ очевидна. Действительно, так как

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

то несложно увидеть, что каждый компонент $\hat{\beta}$ представляет собой линейную комбинацию $Y_i$ с весами, определяемыми матрицей $\mathbf{X}$. Также отметим, что

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{u}) = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$$

Несмещенность также несложно показать:

$$\begin{aligned}
\mathrm{E}\big(\hat{\beta} \mid \mathbf{X}\big) &= \mathrm{E}\big[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \mid \mathbf{X}\big] = \\
&= \mathrm{E}\big[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{u}) \mid \mathbf{X}\big] = \\
&= \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\underbrace{\mathrm{E}(\mathbf{u} \mid \mathbf{X})}_{=0} = \beta \quad \text{по 1-му условию}
\end{aligned}$$

Перейдем к эффективности. Пусть $\tilde{\beta}$ — **произвольная** линейная условно несмещенная оценка $\beta$. Ее можно представить в виде

$$\tilde{\beta} = (\mathbf{B} + \mathbf{C})\mathbf{Y}$$

где $\mathbf{B} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

Из несмещенности $\tilde{\beta}$

$$\beta = \mathrm{E}\big(\tilde{\beta} \mid \mathbf{X}\big) = (\mathbf{B} + \mathbf{C})\,\mathrm{E}(\mathbf{Y} \mid \mathbf{X}) = (\mathbf{B} + \mathbf{C})\mathbf{X}\beta = (\mathbf{I}_{K+1} + \mathbf{C}\mathbf{X})\beta$$

следует, что $\mathbf{C}\mathbf{X} = \mathbf{0}$, что означает, что $\mathbf{B}\mathbf{C}' = \mathbf{0}$.

Также отметим, что

$$\begin{aligned}
\tilde{\beta} &= (\mathbf{B} + \mathbf{C})\mathbf{Y} = (\mathbf{B} + \mathbf{C})(\mathbf{X}\beta + \mathbf{u}) = \\
&= \underbrace{\mathbf{B}\mathbf{X}}_{=\mathbf{I}_{K+1}}\beta + \underbrace{\mathbf{C}\mathbf{X}}_{=\mathbf{0}}\beta + (\mathbf{B} + \mathbf{C})\mathbf{u} = \\
&= \beta + (\mathbf{B} + \mathbf{C})\mathbf{u}
\end{aligned}$$

Ковариационная матрица $\hat{\beta}$ равна

$$\begin{aligned}\Sigma_{\hat{\beta}} = \mathrm{E}\Big[\big(\hat{\beta}-\beta\big)\big(\hat{\beta}-\beta\big)' \mid \mathbf{X}\Big] &= \mathrm{E}\big[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\mathbf{u}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mid \mathbf{X}\big] = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\underbrace{\mathrm{E}(\mathbf{u}\mathbf{u}' \mid \mathbf{X})}_{\Sigma_u=\sigma_u^2\mathbf{I}_N}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{I}_N\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}\end{aligned}$$

Ковариационная матрица $\tilde{\beta}$ равна

$$\begin{aligned}\Sigma_{\tilde{\beta}} = \mathrm{E}\Big[\big(\tilde{\beta}-\beta\big)\big(\tilde{\beta}-\beta\big)' \mid \mathbf{X}\Big] &= (\mathbf{B}+\mathbf{C})\underbrace{\mathrm{E}(\mathbf{u}\mathbf{u}' \mid \mathbf{X})}_{\Sigma_u=\sigma_u^2\mathbf{I}_N}(\mathbf{B}'+\mathbf{C}') = \\ &= \sigma_u^2(\mathbf{B}\mathbf{B}'+\mathbf{B}\mathbf{C}'+\mathbf{C}\mathbf{B}'+\mathbf{C}\mathbf{C}') = \\ &= \Sigma_{\hat{\beta}} + \sigma_u^2\mathbf{C}\mathbf{C}'\end{aligned}$$

Матрица $\mathbf{C}\mathbf{C}'$ — симметрична и положительно полуопределена, то есть $\forall \mathbf{x}$

$$\mathbf{x}\mathbf{C}\mathbf{C}'\mathbf{x} \geqslant 0$$

Это означает, что диагональные элементы матрицы неотрицательны. А так как на главных диагоналях ковариационных матриц располагаются дисперсии оценок отдельных коэффициентов, то это означает, что

$$\forall i \in \{0, 1, ..., k\}\ \mathrm{Var}\,\tilde{\beta}_i \geqslant \mathrm{Var}\,\hat{\beta}_i$$

□

# Критерии качества приближения данных моделью

**Стандартная ошибка регрессии (SER)**

$$SER = s_{\hat{u}}$$

где

$$s^2_{\hat{u}} = \frac{1}{n-k-1}\sum_{i=1}^{n}\hat{u}_i^2 = \frac{RSS}{n-k-1}$$

$SER$ — *standard error of the regression* это оценка стандартного отклонения случайных ошибок регрессии $\hat{u}_i$.

**Коэффициент детерминации регрессии $R^2$**

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS} = [\mathrm{Corr}(X, y)]^2$$

$R^2$ — доля выборочной дисперсии $Y_i$, объясненной (или предсказанной) $X_i$. $R^2$ всегда увеличивается при включении новых переменных в модель, так как $RSS$ всегда уменьшается.

**Скорректированный коэффициент детерминации $\bar{R}^2$**

$$\bar{R}^2 = 1 - \frac{n-1}{n-k-1}\frac{RSS}{TSS} = 1 - \frac{s^2_{\hat{u}}}{s^2_Y}$$

**Информационные критерии**

$$AIC = 2k - 2\ln\hat{L} \qquad AIC = 2k + N\ln\hat{\sigma}^2$$

$$BIC = k\ln N - 2\ln\hat{L} \quad BIC = \underbrace{k\ln N + N\ln\hat{\sigma}^2}_{\substack{\text{в линейной} \\ \text{нормальной регрессии}}}$$

# Тестирование гипотез

## Тестирование единичной гипотезы

Рассмотрим модель

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + ... + \beta_K x_{Ki} + u_i$$

Предположим, что мы хотим протестировать одиночную гипотезу для какого-то коэффициента

$$H_0 : \beta_j = \beta_{j,0}$$
$$H_a : \beta_j \neq \beta_{j,0}$$

где $j = 1, ..., K$. Для этого мы можем воспользоваться стандартным t-тестом.

1. Вычисляем стандартную ошибку $\mathrm{SE}\left(\hat{\beta}_j\right)$).
2. Вычисляем тестовую статистику $t^{\mathrm{act}} = \frac{\hat{\beta}_j - \beta_{j,0}}{\mathrm{SE}\left(\hat{\beta}_j\right)}$.
3. Отвергаем нулевую гипотезу на уровне значимости $\alpha$, если $|t^{\mathrm{act}}| > t^{\mathrm{crit}}_{1-\frac{\alpha}{2}}$. Или, эквивалентно, если $p$-значение меньше $\alpha$.

   Или, эквивалентно, если $\hat{\beta}_0$ не попадает в доверительный интервал $\left\{\hat{\beta}_j + -t^{\mathrm{crit}}_{1-\alpha/2} \times \mathrm{SE}\left(\hat{\beta}_j\right)\right\}$.

На больших выборках можно пользоваться критическими значениями для стандартного нормального распределения; на не очень больших выборках нужно использовать критические значения для распределения Стьюдента.

**Тестирование более сложных гипотез**

Допустим, что мы тестируем нулевую гипотезу $H_0 : \mathbf{w}'\boldsymbol{\beta} = w_0$.

Известно, что

$$\mathbf{w}'\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right) \sim N\left(0, \sigma_u^2 \mathbf{w}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{w}\right)$$

$$\frac{\mathbf{w}'\hat{\boldsymbol{\beta}} - \mathbf{w}'\boldsymbol{\beta}}{\sigma_u\sqrt{\mathbf{w}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{w}}} \sim N(0,1)$$

Из формулы (5) следует, что

$$\frac{\frac{\mathbf{w}'\hat{\boldsymbol{\beta}} - \mathbf{w}'\boldsymbol{\beta}}{\sigma_u\sqrt{\mathbf{w}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{w}}}}{\sqrt{\frac{1}{N-K}(N-K)\frac{\hat{\sigma}_u^2}{\sigma_u^2}}} = \frac{\mathbf{w}'\boldsymbol{\beta} - w_0}{\hat{\sigma}_u\sqrt{\mathbf{w}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{w}}} \sim t_{N-K}$$

Если $\mathbf{w} = \mathbf{e}_j = \Big(0, ..., 0, \underbrace{1}_{j}, 0, ..., 0\Big)'$, то полученная формула примет вид

$$\frac{\hat{\beta}_j}{\mathrm{SE}\left(\hat{\beta}_j\right)} \sim t_{N-K}$$

## Тестирование совместных гипотез

**Совместная гипотеза** накладывает условия (ограничения) на два (или более) коэффициента регрессии. Первой мыслью может быть использование индивидуальных t-статистик для тестирования ограничений. Рассмотрим вопрос, стоит ли отвергать ли совместную гипотезу на уровне 5%, если каждая индивидуальная $t$-статистика превышает 1.96 по модулю.

Пусть $t_1$ и $t_2$ — индивидуальные $t$-статистики, для простоты независимо распределенные:

$$t_1 = \frac{\hat{\beta}_1 - 0}{SE\left(\hat{\beta}_1\right)} \text{ и } t_2 = \frac{\hat{\beta}_2 - 0}{SE\left(\hat{\beta}_2\right)}$$

Предлагаемая выше процедура тестирования предлагает отвергать

$$H_0 : \beta_1 = \beta_2 = 0$$

если

$$|t_1| > 1{,}96 \text{ и/или } |t_2| > 1{,}96$$

Вероятность некорректно отвергнуть $H_0$ на 5%-м уровне значимости, когда она верна, в такой процедуре равна

$$\begin{aligned}\mathrm{P}_{H_0}(|t_1| > 1{,}96 \text{ и/или } |t_2| > 1{,}96) &= 1 - \mathrm{P}_{H_0}(|t_1| \leqslant 1{,}96 \text{ и } |t_2| \leqslant 1{,}96) = \\ &= 1 - \mathrm{P}_{H_0}(|t_1| \leqslant 1{,}96) \times \mathrm{P}_{H_0}(|t_2| \leqslant 1{,}96) = \\ &= 1 - 0{,}95^2 = 0{,}0975 = 9{,}75\ \%\end{aligned}$$

- Предложенная процедура (на основе $t$-статистик) имеет неправильный размер критерия ($\neq 5\%$).
- Этот размер критерия зависит от корреляции между $t_1$ и $t_2$ и, следовательно, между $\hat{\beta}_1$ и $\hat{\beta}_2$.

Возможным решением является использование поправки Бонферрони: вместо $\alpha$ в качестве уровня значимости следует использовать $\frac{\alpha}{q}$.

**Проверка совместных гипотез: F-статистика**

$F$-статистика позволяет проверять одновременно все ограничения совместной гипотезы. Для случая гомоскедастичных ошибок $F$ -статистику можно вычислить следующим образом (Носко 2021):

- Оцените две регрессии: регрессию «с ограничениями» (т.е. в предположениях нулевой гипотезы) и регрессию «без ограничений» (в предположениях альтернативной).
- Вычислите $R^2_{\text{R}}$ и $R^2_{\text{UR}}$, соответственно, или $RSS_{\text{R}}$ и $RSS_{\text{UR}}$. Тогда

$$F = \frac{(R^2_{\text{UR}} - R^2_{\text{R}})/q}{(1 - R^2_{\text{UR}})/(n - k_{\text{UR}} - 1)} = \frac{(RSS_{\text{R}} - RSS_{\text{UR}})/q}{RSS_{\text{UR}}/(n - k_{\text{UR}} - 1)}$$

  - $R^2_{\text{R}}, R^2_{\text{UR}}$ — $R^2$ в регрессиях с ограничениями и без.
  - $RSS_{\text{R}}, RSS_{\text{UR}}$ — RSS в регрессиях с ограничениями и без.
  - $q$ — число ограничений в нулевой гипотезе.
  - $k_{\text{UR}}$ — число объясняющих переменных (без константы) в модели без ограничений.

$F$-статистика для случая гомоскедастичных ошибок отвергает нулевую гипотезу, когда включение в модель двух (или больше) новых переменных увеличивает коэффициент детерминации «достаточно» для того, чтобы качество регрессии улучшилось «достаточно». $F$ -статистика для случая гомоскедастичных ошибок асимптотически

распределена как $\chi^2_q/q$[1]:

| $q$ | 5% |
|---|---|
| 1 | 3.84 |
| 2 | 3.00 |
| 3 | 2.60 |
| 4 | 2.37 |
| 5 | 2.21 |

**F-статистика в матричной форме**

Допустим, что мы тестируем нулевую гипотезу $H_0 : \mathbf{R}\beta = \mathbf{r}$.

Известно, что

$$\mathbf{R}\hat{\beta} - \mathbf{r} = \mathbf{R}\left(\hat{\beta} - \beta\right) \sim N\left(0, \sigma_u^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right)$$

Существует матрица $\mathbf{Q}$ такая, что $\left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} = \mathbf{Q}'\mathbf{Q}$, и что

$$\boldsymbol{\xi} = \mathbf{Q}\mathbf{R}\left(\hat{\beta} - \beta\right) \sim N(0, \mathbf{I}_N)$$

Поэтому при справедливости нулевой гипотезы (Магнус и др. 2021; Pierse 2021a)

$$\frac{\boldsymbol{\xi}'\boldsymbol{\xi}}{\sigma_u^2} = \frac{\left(\mathbf{R}\hat{\beta} - \mathbf{r}\right)' \mathbf{Q}'\mathbf{Q}\mathbf{R}\left(\mathbf{R}\hat{\beta} - \mathbf{r}\right)}{\sigma_u^2} =$$

$$= \frac{\left(\mathbf{R}\hat{\beta} - \mathbf{r}\right)' \left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} \left(\mathbf{R}\hat{\beta} - \mathbf{r}\right)}{\sigma_u^2} =$$

[1] Если ошибки на самом деле гетероскедастичны, то асимптотическое распределение $F$-статистики для случая гомоскедастичных ошибок не является $\chi^2_q/q$.

$$= \frac{\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)' \mathbf{R}' \left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} \mathbf{R}\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)}{\sigma_u^2} =$$

$$= \frac{\mathbf{u}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}' \left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}}{\sigma_u^2} \sim \chi_q^2$$

Это следует из идемпотентности матрицы в числителе.

С другой стороны,

$$\frac{\hat{\mathbf{u}}'\hat{\mathbf{u}}}{\sigma_u^2} = \frac{\mathbf{u}'\mathbf{M}\mathbf{u}}{\sigma_u^2} = \frac{(N-K)\hat{\sigma}_u^2}{\sigma_u^2} \sim \chi^2_{N-K} \tag{5}$$

откуда получим

$$F = \frac{\frac{1}{q}\frac{\boldsymbol{\xi}'\boldsymbol{\xi}}{\sigma_u^2}}{\frac{1}{N-K}\frac{(N-K)\hat{\sigma}_u^2}{\sigma_u^2}} = \frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)' \left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)}{q\hat{\sigma}_u^2}$$

Если ошибки гетероскедастичны, то асимптотическое распределение $F$-статистики для случая гомоскедастичных ошибок не является $\chi_q^2/q$. Устойчивая к гетероскедастичности $F$-статистика (статистика Вальда) имеет вид

$$F = \frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)' \left(\mathbf{R}\hat{\boldsymbol{\Sigma}}_{\hat{\beta}}\mathbf{R}'\right)^{-1} \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)}{q} \sim \chi_q^2/q$$

$$W = \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)' \left(\mathbf{R}\hat{\boldsymbol{\Sigma}}_{\hat{\beta}}\mathbf{R}'\right)^{-1} \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right) = qF \sim \chi_q^2$$

где $\mathbf{R}$ — матрица ограничений, $\mathbf{r}$ — вектор свободных членов ограничений, $\hat{\boldsymbol{\Sigma}}_{\hat{\beta}}$ — ковариационная матрица вектора $\hat{\boldsymbol{\beta}}$.

Для того, чтобы $F$-статистика была *точной*, нужно, чтобы:

1. ошибки $u_i$ были гомоскедастичны, т.е. $\mathrm{Var}(u_i \mid X_1, ..., X_k) = \mathrm{const}$.
2. ошибки $u_1, ..., u_n$ были нормально распределены.

В случае ненормальности ошибок регрессии статистика будет *асимптотической*.

Исследователи часто используют $F$-распределение на небольших выборках, так как оно имеет большие критические значения и является более консервативным.

## Фиктивные регрессоры

Пусть $X_i$ обозначает бинарную переменную. Рассмотрим регрессию $Y_i = \beta_0 + \beta_1 X_i + u_i$. Пусть $\bar{Y}_0$ означает выборочное среднее для наблюдений с $X = 0$, а $\bar{Y}_1$ обозначает выборочное среднее для наблюдений с $X = 1$. Покажем, что $\hat{\beta}_0 = \bar{Y}_0$, $\hat{\beta}_0 + \hat{\beta}_1 = \bar{Y}_1$ и $\hat{\beta}_1 = \bar{Y}_1 - \bar{Y}_0$.

$$\sum X_i = n_1$$

$$\bar{X} = \frac{n_1}{n}$$

$$\sum \left(X_i - \bar{X}\right)^2 = \sum X_i^2 - n\bar{X}^2 = n_1 - n\frac{n_1^2}{n^2} - \frac{n_0 n_1}{n}$$

$$\sum (X_i - \bar{X})(Y_i - \bar{Y}) = \sum X_i (Y_i - \bar{Y}) = \sum X_i Y_i - \bar{Y} \sum X_i =$$

$$= n_1 \bar{Y}_1 - n_1 \bar{Y}$$

$$\hat{\beta}_1 = \frac{n_1 (\bar{Y}_1 - \bar{Y})}{\frac{n_0 n_1}{n}} = \frac{n}{n_0} (\bar{Y}_1 - \bar{Y}) = \frac{n}{n_0} \left(\bar{Y}_1 - \frac{n_1}{n} \bar{Y}_1 - \frac{n_0}{n} \bar{Y}_0\right) =$$

$$= \frac{n}{n_0}\left(\frac{n_0}{n}\bar{Y}_1 - \frac{n_0}{n}\bar{Y}_0\right) = \bar{Y}_1 - \bar{Y}_0$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1\bar{X} = \bar{Y} - \left(\bar{Y}_1 - \bar{Y}_0\right)\frac{n_1}{n} =$$

$$= \frac{n_1}{n}\bar{Y}_1 + \frac{n_0}{n}\bar{Y}_0 - \frac{n_1}{n}\bar{Y}_1 - \frac{n_1}{n}\bar{Y}_0 = \bar{Y}_0$$

# Нелинейные модели

$$Y_i = f(X_{1i}, ..., X_{ki}) + u_i, i = 1, ..., n$$

$f(X_{1i}, ..., X_{ki})$ — **теоретическая функция нелинейной регрессии.** Например:

$$f(Income_i) = \beta_0 + \beta_1 Income_i + \beta_2\ Income$$

## Величина изменения $Y$

$$\Delta Y = f(X_1 + \Delta X_1, X_2, ..., X_k) - f(X_1, X_2, ..., X_k)$$

Пусть $\hat{f}(X_1, X_2, ..., X_k)$ — предсказанное значение $Y$, полученное на основе оценки $\hat{f}$ функции теоретической регрессии. Тогда

$$\Delta\hat{Y} = \hat{f}(X_1 + \Delta X_1, X_2, ..., X_k) - \hat{f}(X_1, X_2, ..., X_k)$$

## Логарифмические регрессии

Дальнейшие выкладки опираются на следующее:

$$\ln(x + \Delta x) - \ln(x) \approxeq \frac{\Delta x}{x}, \text{если } \frac{\Delta x}{x} \text{ мало}$$

$\frac{\Delta x}{x}$ — процентное изменение $x$, деленное на 100.

**Линейно-логарифмическая модель** 1%-ное изменение $X$ приводит к изменению $Y$ на $\frac{1}{100}\beta_1$.

$$Y_i = \beta_0 + \beta_1 \ln(X_i) + u_i, i = 1, ..., n$$

**Логарифмически-линейная модель** Единичное изменение $X$ (то есть $\Delta X = 1$) приводит к изменению $Y$ на $100\beta_1\%$.

$$\ln Y_i = \beta_0 + \beta_1 X_i + u_i, i = 1, ..., n$$

Важно понимать, что так как $\Delta \ln Y = \ln \frac{Y + \Delta Y}{Y}$ лишь примерно равно $\frac{\Delta Y}{Y}$, то приведенная выше интерпретация справедлива только в случае *малых* значений $\beta_1$.

| $\Delta \ln Y$ | $\exp\{\Delta \ln Y\} = \frac{Y+\Delta Y}{Y}$ | $\Delta \ln Y$ | $\exp\{\Delta \ln Y\} = \frac{Y+\Delta Y}{Y}$ |
|---|---|---|---|
| 0.01 | 1.01005 | 0.1 | 1.10520 |
| 0.02 | 1.02020 | 0.2 | 1.22140 |
| 0.03 | 1.03046 | 0.3 | 1.35000 |
| 0.05 | 1.05127 | 0.5 | 1.65000 |
| 0.09 | 1.09417 | 1.0 | 2.71828 |

**Линейная в логарифмах** 1%-ное изменение $X$ (то есть $\Delta X = 1$) приводит к изменению $Y$ на $\beta_1\%$.

$$\ln Y_i = \beta_0 + \beta_1 \ln X_i + u_i, i = 1, ..., n$$

| Модель регрессии по $X$ | Теоретическая модель | Эластичность $\mathrm{E}(Y \mid X)$ |
|---|---|---|
| Линейная | $Y = \beta_0 + \beta_1 X + u$ | $\frac{\beta_1 \Delta X}{\beta_0 + \beta_1 X}$ |

| | | |
|---|---|---|
| Линейно-логарифмическая | $Y = \beta_0 + \beta_1 \ln X + u$ | $\frac{\beta_1}{\beta_0 + \beta_1 \ln X}$ |
| Логарифмически-линейная | $\ln Y = \beta_0 + \beta_1 X + u$ | $\beta_1 \Delta X$ |
| Линейная в логарифмах | $\ln Y = \beta_0 + \beta_1 \ln X + u$ | $\beta_1$ |

**Используя критерии качества подгонки моделей, можно сравнивать модели, у которых одинаковый $Y$!**

- Можно сравнивать логарифмически-линейную и линейную в логарифмах модель.
- Можно сравнивать линейно-логарифмическую и полиномиальные модели.

# Библиография

[1] В. П. Носко, *Эконометрика. Книга 1*. в Академический учебник. Москва: Издательский дом «Дело» РАНХиГС, 2021.

[2] Я. Магнус, П. Катышев, и А. Пересецкий, *Эконометрика. Начальный курс. Учебник. 9-е издание*, 9-е изд., испр. Москва: Издательский дом «Дело» РАНХиГС, 2021.

[3] R. G. Pierse, «OLS Estimation With Matrix Algebra». 2021a г.

[4] D. N. Gujarati и D. C. Porter, *Basic Econometrics*, 5. ed. в The McGraw-Hill Series Economics. Boston, Mass.: McGraw-Hill Irwin, 2009.

[5] R. G. Pierse, «GLS Estimation and the SURE Model». 2021b г.

# A Регрессия по частям

Этот дополнительный материал будет полезным для рассмотрения некоторых последующих тем. Смысл данного метода в том, что мы оцениваем коэффициенты модели не разом, а по очереди.

Рассмотрим модель (Pierse 2021b)

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{u} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \mathbf{u} = (\mathbf{X}_1 \quad \mathbf{X}_2)\begin{pmatrix}\beta_1 \\ \beta_2\end{pmatrix} + \mathbf{u}$$

где $\mathbf{X}_1$ и $\mathbf{X}_2$ представляют собой разбиение матрицы $\mathbf{X}$ по столбцам, причем столбцы в этих матрицах (а) не пересекаются, и (б) включают в себя все столбцы исходной матрицы. Для дальнейшего повествования нам понадобятся формулы для матрицы, обратной к блочной:

$$\begin{pmatrix}\mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D}\end{pmatrix}^{-1} = \begin{pmatrix}\tilde{\mathbf{A}} & -\tilde{\mathbf{A}}\mathbf{B}\mathbf{D}^{-1} \\ -\mathbf{D}^{-1}\mathbf{C}\tilde{\mathbf{A}} & \mathbf{D}^{-1} + \mathbf{D}^{-1}\mathbf{C}\tilde{\mathbf{A}}\mathbf{B}\mathbf{D}^{-1}\end{pmatrix} = \tag{6}$$

$$= \begin{pmatrix}\mathbf{A}^{-1} + \mathbf{A}^{-1}\mathbf{B}\tilde{\mathbf{D}}\mathbf{C}\mathbf{A}^{-1} & -\mathbf{A}^{-1}\mathbf{B}\tilde{\mathbf{D}} \\ -\tilde{\mathbf{D}}\mathbf{C}\mathbf{A}^{-1} & \tilde{\mathbf{D}}\end{pmatrix} \tag{7}$$

где $\tilde{\mathbf{A}} = (\mathbf{A} - \mathbf{B}\mathbf{D}^{-1}\mathbf{C})^{-1}$, $\tilde{\mathbf{D}} = (\mathbf{D} - \mathbf{C}\mathbf{A}^{-1}\mathbf{B})^{-1}$.

Очевидно, что формула (6) справедлива в случае, когда матрица $\mathbf{D}$ обратима, а формула (7) — когда обратима матрица $\mathbf{A}$.

Оценка $\hat{\beta}$ равна

$$\begin{pmatrix}\hat{\beta}_1 \\ \hat{\beta}_2\end{pmatrix} = (\mathbf{X}'\mathbf{X})^{-1}\begin{pmatrix}\mathbf{X}_1\mathbf{y} \\ \mathbf{X}_2\mathbf{y}\end{pmatrix}$$

Найдем $\hat{\beta}_1$. Так как

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} \mathbf{X}_1'\mathbf{X}_1 & \mathbf{X}_1'\mathbf{X}_2 \\ \mathbf{X}_2'\mathbf{X}_1 & \mathbf{X}_2'\mathbf{X}_2 \end{pmatrix}$$

то

$$(\mathbf{X}'\mathbf{X})^{-1} = \begin{pmatrix} \tilde{\mathbf{X}} & -\tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1} \\ -(\mathbf{X}_2'\mathbf{X}_2)\mathbf{X}_2'\mathbf{X}_1\tilde{\mathbf{X}} & (\mathbf{X}_2'\mathbf{X}_2)^{-1} + (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1\tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1} \end{pmatrix}$$

где

$$\tilde{\mathbf{X}} = \left[\mathbf{X}_1'\mathbf{X}_1 - \mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1\right]^{-1} =$$

$$= \left\{ \mathbf{X}_1' \underbrace{\left[\mathbf{I}_N - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\right]}_{\mathbf{M}_2} \mathbf{X}_1' \right\}^{-1}$$

Таким образом

$$\begin{aligned} \hat{\boldsymbol{\beta}}_1 &= \tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{y} - \tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{y} = \\ &= \tilde{\mathbf{X}}\mathbf{X}_1'\left[\mathbf{I}_N - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\right]\mathbf{y} = \\ &= (\mathbf{X}_1'\mathbf{M}_2\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{M}_2\mathbf{y} = \\ &= (\mathbf{X}_1'\mathbf{M}_2\mathbf{M}_2\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{M}_2\mathbf{M}_2\mathbf{y} = \\ &= \left(\hat{\mathbf{X}}_1'\hat{\mathbf{X}}_1\right)^{-1}\hat{\mathbf{X}}_1'\hat{\mathbf{y}} \end{aligned}$$

где $\hat{\mathbf{X}}_1$ и $\hat{\mathbf{y}}$ — остатки регрессий $\mathbf{X}_1$ и $\mathbf{y}$ на $\mathbf{X}_2$, соответственно.

Аналогично показывается, что

$$\hat{\boldsymbol{\beta}}_2 = (\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{y}$$

# В Распределение хи-квадрат

Рассмотрим вектор $\mathbf{x}$ длины $p$ такой, что $\mathbf{x} \sim N\big(\mathbf{0}, \mathbf{I}_p\big)$. Тогда случайная величина $\mathbf{x}'\mathbf{x}$ будет иметь распределение хи-квадрат с $p$ степенями свободы $\chi^2_p$.

Более того, если $\mathbf{x} \sim N\big(\mathbf{0}, q^2\mathbf{I}_p\big)$, то

$$\frac{\mathbf{x}'\mathbf{x}}{q^2} \sim \chi^2_p$$

Пусть $\mathbf{A}$ — симметричная идемпотентная матрица ранга $r$. Тогда (Pierse 2021b)

$$\frac{\mathbf{x}'\mathbf{A}\mathbf{x}}{q^2} \sim \chi^2_r$$

*Доказательство*. Матрица $\mathbf{A}$ может быть спектрально разложена:

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}'$$

где $\mathbf{V}$ — матрица собственных векторов такая, что $\mathbf{V}'\mathbf{V} = \mathbf{I}_p$, $\mathbf{\Lambda}$ — диагональная матрица с собственными значениями на главной диагонали.

Отсюда

$$\mathbf{x}'\mathbf{A}\mathbf{x} = \mathbf{x}'\mathbf{V}\mathbf{\Lambda}\mathbf{V}'\mathbf{x} = \mathbf{z}'\mathbf{\Lambda}\mathbf{z}$$

причем $\mathbf{z} \sim N(\mathbf{0}, q^2\mathbf{V}'\mathbf{V}) = N\big(\mathbf{0}, q^2\mathbf{I}_p\big)$. С другой стороны, так как $\mathbf{A}$ симметрична и идемпотентна, то ее собственные значения могут принимать значения только $0$ или $1$, причем число значений, равных $1$, равно рангу матрицы.

Таким образом

$$\mathbf{z}'\mathbf{\Lambda}\mathbf{z} = \sum_{i=1}^{p} \lambda_i z_i^2 = \sum_{i=1}^{r} z_i^2 = \mathbf{z}_1'\mathbf{z}_1$$

откуда следует

$$\frac{\mathbf{x}'\mathbf{A}\mathbf{x}}{q^2} = \frac{\mathbf{z}_1'\mathbf{z}_1}{q^2} \sim \chi_r^2$$

□