Классическая линейная модель и свойства МНК-оценок

Модель парной линейной регрессии

Модель **парной линейной регрессии** имеет вид (Носко 2021)

$$y_i = \beta_0 + \beta_1 x_i + u_i \tag{1}$$

где

- y_i — *зависимая*, или *объясняемая*, или *эндогенная* переменная; очень редко встречается название *регрессанд*;
- x_i — *объясняющая*, или *экзогенная* переменная; очень часто используется название *регрессор*;
- u_i — случайная ошибка.

Случайная ошибка включается в себя *все* значимые, но не включенные в модель переменные.

Не стоит путать модель регрессии и **теоретическую линию регрессии**, имеющую вид

$$y = \beta_0 + \beta_1 x$$

и показывающую теоретическую связь между переменными в рамках всей генеральной совокупности.

Оценить коэффициенты β_0 и β_1 проще всего при помощи метода наименьших квадратов, решая задачу

$$\min_{\beta_0,\beta_1} \underbrace{\sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_i)^2}_{Q}, \tag{2}$$

что приводит нас к условиям первого порядка

$$\frac{\partial Q}{\partial \beta_0}\Big|_{\hat{\beta}_0,\hat{\beta}_1} = -2\sum_{i=1}^{N}\left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i\right) = 0 \tag{3}$$

$$\frac{\partial Q}{\partial \beta_1}\Big|_{\hat{\beta}_0,\hat{\beta}_1} = -2\sum_{i=1}^{N}\left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i\right)x_i = 0 \tag{4}$$

Данные условия представляют собой систему из двух уравнений с двумя неизвестными, решение которого равно

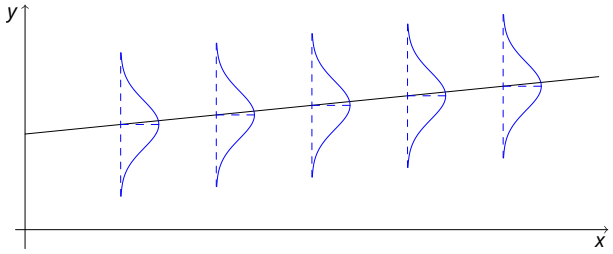
$$\hat{\beta}_1 = \frac{\sum_{i=1}^{N}(y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^{N}(x_i - \bar{x})^2} = \frac{s_{yx}}{s_x^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

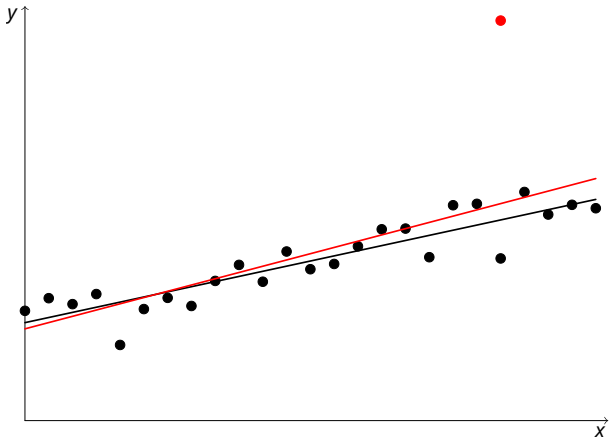
$$\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

Предпосылки МНК

1. Условное распределение u_i относительно X_i имеет нулевое среднее: $\mathrm{E}[u_i \mid x_i] = 0$;



2. Наблюдения (y_i, x_i) ~ i.i.d.;
3. Большие выбросы маловероятны: y_i и x_i имеют ненулевые и конечные четвертые моменты.



При выполнении этих предположений оценки коэффициентов $\hat{\beta}_0$ и $\hat{\beta}_1$ будут асимптотически нормальными.

Графическая интерпретация

Для графической интерпретации МНК представим оценку (1) в виде (Носко 2021)

$$\underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}}_{\mathbf{y}} = \hat{\beta}_0 \underbrace{\begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}}_{\mathbf{1}} + \hat{\beta}_1 \underbrace{\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}}_{\mathbf{x}} + \underbrace{\begin{pmatrix} \hat{u}_1 \\ \hat{u}_2 \\ \vdots \\ \hat{u}_N \end{pmatrix}}_{\hat{\mathbf{u}}} = \underbrace{\hat{\beta}_0 \mathbf{1} + \hat{\beta}_1 \mathbf{x}}_{\hat{\mathbf{y}}} + \hat{\mathbf{u}} = \hat{\mathbf{y}} + \hat{\mathbf{u}}$$

Нетрудно увидеть, что условия первого порядка (3) и (4) примут вид

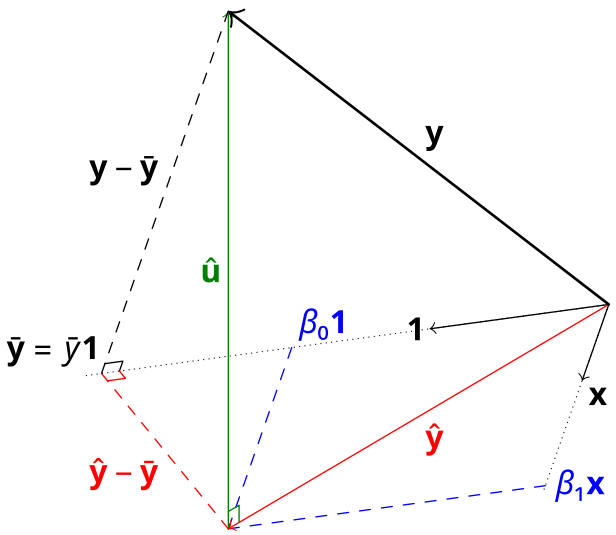
$$\langle \hat{\mathbf{u}}, \mathbf{1} \rangle = 0,$$
$$\langle \hat{\mathbf{u}}, \mathbf{x} \rangle = 0,$$

то есть вектор остатков ортогонален векторам **1** и *x*; таким образом он ортогонален и «плоскости», натянутой на эти векторы. Кроме того, во введенных обозначениях задача МНК представляет собой задачу поиска ортогональной проекции вектора *y* на данную «плоскость».

Действительно, (2) примет вид

$$\min_{\beta_0,\beta_1} \left\| \mathbf{y} - \underbrace{\hat{\beta}_0 \mathbf{1} - \hat{\beta}_1 \mathbf{x}}_{\hat{\mathbf{y}}} \right\|^2,$$

из которой понятно, что $\hat{y}$ — ортогональная проекция *y* на «плоскость».



Модель множественной линейной регрессии

Очевидно, что модель парной регрессии в большинстве случаев не может удовлетворить исследователя. Более того, в такой модели крайне высока вероятность смещения из-за пропущенной переменной.

Модель **множественной линейной регрессии** имеет вид:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \ldots + \beta_K x_{Ki} + u_i$$

Оценки коэффициентов получаются аналогично парному случаю:

$$\min_{\beta_0,\beta_1,\ldots,\beta_K} \underbrace{\sum_{i=1}^{N} (y_i - \beta_0 - \beta_1 x_{1i} - \ldots - \beta_K x_{Ki})^2}_{Q}$$

Разумеется, что данную задачу можно решить «в лоб», найдя условия первого порядка в точке оптимума, приравняв их нулю и решив получившуюся систему уравнений. Однако уже для случая $K = 2$ получающиеся выражения становятся весьма громоздкими. Поэтому чаще всего работают с моделями в матричной форме (Магнус и др. 2021):

$$\underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}}_{\mathbf{y}} = \underbrace{\begin{pmatrix} 1 & x_{11} & x_{21} & \dots & x_{K1} \\ 1 & x_{12} & x_{22} & \dots & x_{K2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1N} & x_{2N} & \dots & x_{italic(KN)} \end{pmatrix}}_{\mathbf{X}} \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_K \end{pmatrix}}_{\boldsymbol{\beta}} + \underbrace{\begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_N \end{pmatrix}}_{\mathbf{u}}$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$$

Сумма квадратов остатков примет вид $\hat{\mathbf{u}}'\hat{\mathbf{u}}$, а оценка вектора коэффициентов будет равна

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Доказательство. Задача поиска оптимального вектора $\hat{\boldsymbol{\beta}}$ имеет вид

$$\min_{\boldsymbol{\beta}} \underbrace{(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})}_{Q}$$

Найдем дифференциал этого выражения (Магнус и др. 2021; Pierse 2021a):

$$\begin{aligned} d\mathbf{Q} &= d\big[(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\big](\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) + (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\, d(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \\ &= \big[\, d(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\big](\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) + (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\, d(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \\ &= (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\, d(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) + (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\, d(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \\ &= -2(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\mathbf{X}\, d\boldsymbol{\beta} \end{aligned}$$

При выводе мы воспользовались тем, что $\mathbf{Q}$ — скаляр, а значит скалярами являются и слагаемые в промежуточных выражениях. А для скаляра, очевидно, справедливо

$x' = x$. Также мы считаем матрицы $\mathbf{Y}$ и $\mathbf{X}$ фиксированными в рамках имеющейся выборки.

Имеем, что в точке оптимума

$$\nabla \mathbf{Q} \propto (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\mathbf{X} = \mathbf{0}$$

откуда транспонированием и простыми преобразованиями и получаем искомую формулу. □

Нетрудно увидеть, что подобранные значения равны $\hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{H}\mathbf{y}$, а остатки — $\hat{\mathbf{u}} = \mathbf{y} - \hat{\mathbf{y}} = [\mathbf{I}_N - \mathbf{H}]\mathbf{y} = \mathbf{M}\mathbf{y}$. Также нетрудно увидеть, что

$$\mathbf{H}' = \mathbf{H} \quad \mathbf{M}' = \mathbf{M}$$
$$\mathbf{H}\mathbf{H} = \mathbf{H}\mathbf{M}\mathbf{M} = \mathbf{M}$$
$$\mathbf{M}\mathbf{H} = \mathbf{0} \quad \mathbf{H}\mathbf{M} = \mathbf{0}$$
$$\mathbf{H}\mathbf{X} = \mathbf{X} \quad \mathbf{M}\mathbf{X} = \mathbf{0}$$

Более того, так как матрица $\mathbf{M}$ идемпотентна, то $\operatorname{rank}\mathbf{M} = \operatorname{tr}\mathbf{M}$, то есть

$$\begin{aligned}\operatorname{tr}\mathbf{M} &= \operatorname{tr}\left(\mathbf{I}_N - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\right) = \\ &= \operatorname{tr}\mathbf{I}_N - \operatorname{tr}\left(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\right) = \\ &= N - \underbrace{\operatorname{tr}\left(\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\right)}_{\mathbf{I}_K} = N - K\end{aligned}$$

Этот факт позволяет получить несмещенную оценку σ_u^2 (Pierse 2021a):

$$\mathrm{E}(\hat{\mathbf{u}}'\hat{\mathbf{u}} \mid \mathbf{X}) = \operatorname{tr}[\mathrm{E}(\mathbf{u}'\mathbf{M}'\mathbf{M}\mathbf{u})\,\mathbf{X})] = \mathrm{E}[\operatorname{tr}(\mathbf{u}'\mathbf{M}\mathbf{u}) \mid \mathbf{X}] =$$

$$= \mathrm{E}[\mathrm{tr}(\mathbf{M}\mathbf{u}\mathbf{u}') \mid \mathbf{X}] = \sigma_u^2 \,\mathrm{tr}\,\mathbf{M} = \sigma_u^2(N-K)$$

$$\sigma_u^2 = \mathrm{E}\left(\frac{\hat{\mathbf{u}}'\hat{\mathbf{u}}}{N-K} \,\middle|\, \mathbf{X}\right)$$

Расширенные предпосылки МНК

1. $\mathrm{E}(u_i \mid \mathbf{X}_i) = 0$.
2. $(\mathbf{X}_i, Y_i) \sim$ i.i.d.
3. $\mathbf{X}_i$ и u_i имеют ненулевые конечные четвертые моменты.
4. $\mathbf{X}$ имеет полный ранг — нет совершенной мультиколлинеарности, то есть точной линейной зависимости между регрессорами.
5. $\mathrm{Var}(u_i \mid \mathbf{X}_i) = \sigma_u^2$ — гомоскедастичность.
6. $u_i \mid \mathbf{X}_i \sim N(0, \sigma_u^2)$.

Свойства МНК оценок

1. $\hat{\boldsymbol{\beta}}$ — несмещенная оценка;
2. $\frac{1}{N}\sum_{i=1}^{N} \hat{u}_i = 0$ — выборочное среднее остатков равно нулю;
3. $\frac{1}{N}\sum_{i=1}^{N} \hat{y}_i = \bar{y}$;
4. $\sum_{i=1}^{N} \hat{u}_i x_{ki} = 0, \forall k \in \{1, \ldots, K\}$.
5. $TSS = ESS + RSS$, где

- $TSS = \sum_{i=1}^{N} (y_i - \bar{y})^2$ — полная сумма квадратов,
- $ESS = \sum_{i=1}^{N} (\hat{y}_i - \bar{y})^2$ — объясненная сумма квадратов,
- $RSS = \sum_{i=1}^{N} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{N} \hat{u}_i^2$ — остаточная сумма квадратов или сумма квадратов остатков.

Доказательство.

$$TSS = \sum_{i=1}^{N} (y_i - \bar{y})^2 = \sum_{i=1}^{N} [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2 =$$

$$= \sum_{i=1}^{N} (y_i - \hat{y}_i)^2 + \sum_{i=1}^{N} (\hat{y}_i - \bar{y})^2 + 2\sum_{i=1}^{N} (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) =$$

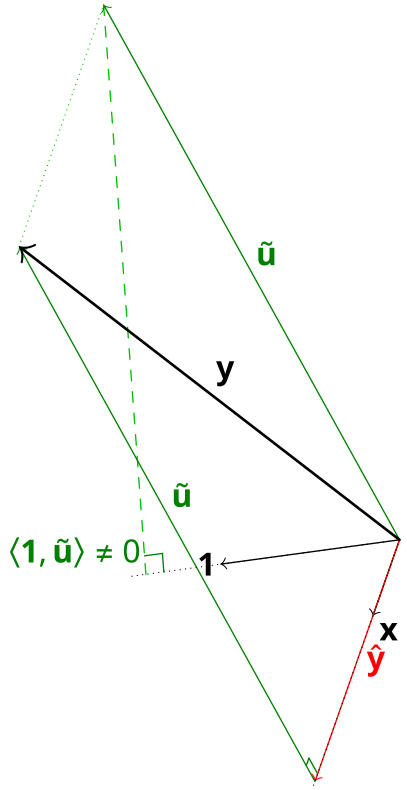
$$= RSS + ESS + 2\sum_{i=1}^{N} \hat{u}_i \hat{y}_i - 2\bar{y}\sum_{i=1}^{N} \hat{u}_i$$

Последнее слагаемое равно нулю в силу второго свойства. Сумму в предпоследнем слагаемом можно представить в виде

$$\sum_{i=1}^{N} \hat{u}_i \left(\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \ldots + \hat{\beta}_k x_{ki}\right)$$

Раскрыв скобки и воспользовавшись вторым и четвертым свойствами, мы получим, что это слагаемое также равно нулю. □

Важно отметить, что все перечисленные свойства, за исключением, разве что, четвертого, справедливы *только* при наличии в модели свободного члена!



Теорема Гаусса-Маркова

Одномерный случай

Теорема 1 (Гаусса-Маркова). *Если для всех* $i, j = 1, \ldots, n$ *выполняются условия Гаусса-Маркова:*

1. $\mathrm{E}(u_i \mid X_1, \ldots, X_n) = 0$,
2. $\mathrm{Var}(u_i \mid X_1, \ldots, X_n) = \sigma_u^2, 0 < \sigma_u^2 < \infty$,

3. $\mathrm{E}(u_i u_j \mid X_1, \ldots, X_n) = 0, i \neq j$, *то МНК оценка* $\hat{\beta}_1$ *является наилучшей (эффективной) линейной условно не смещенной оценкой (BLUE) (Gujarati и Porter 2009).*

- УГ-М (1) следует из предположений (1) и (2)
- УГ-М (2) следует из предположения (2) и предположения о гомоскедастичности ошибок
- УГ-М (3) следует из предположения (2)

Доказательство. Линейность:

$$\sum_{i=1}^{n}(X_i - \bar{X}) = 0 \Rightarrow$$

$$\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y}) = \sum_{i=1}^{n}(X_i - \bar{X})Y_i \Rightarrow$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2} = \frac{\sum_{i=1}^{n}(X_i - \bar{X})Y_i}{\sum_{i=1}^{n}(X_i - \bar{X})^2} = \sum_{i=1}^{n}\hat{a}_i Y_i$$

Условная несмещенность:

$$\mathrm{E}(\hat{\beta}_1 \mid X_1, \ldots) = \beta_1 + \mathrm{E}\left(\frac{\sum_{i=1}^{n}(X_i - \bar{X})u_i}{\sum_{i=1}^{n}(X_i - \bar{X})^2} \,\middle|\, X_1, \ldots\right) =$$

$$= \beta_1 + \frac{\sum_{i=1}^{n}(X_i - \bar{X})\,\mathrm{E}(u_i \mid X_1, \ldots)}{\sum_{i=1}^{n}(X_i - \bar{X})^2} =$$

$$= \beta_1$$

Эффективность: пусть $\tilde{\beta}_1$ — любая линейная условно несмещенная оценка β_1, то есть $\tilde{\beta}_1 = \sum_{i=1}^n a_i Y_i$ и $\mathrm{E}\,\tilde{\beta}_1 = \beta_1$. Тогда $\sum_{i=1}^n a_i = 0$, $\sum_{i=1}^n a_i X_i = 1$.

$$\tilde{\beta}_1 = \sum_{i=1}^n a_i Y_i = \beta_0 \sum_{i=1}^n a_i + \beta_1 \sum_{i=1}^n a_i X_i + \sum_{i=1}^n a_i u_i \Rightarrow$$

$$\mathrm{E}\left(\tilde{\beta}_1 \mid X_1, \ldots\right) = \beta_0 \underbrace{\sum_{i=1}^n a_i}_{=0} + \beta_1 \underbrace{\sum_{i=1}^n a_i X_i}_{=1} = \beta_1$$

$$\tilde{\beta}_1 - \beta_1 = \sum_{i=1}^n a_i u_i \Rightarrow$$

$$\mathrm{Var}\left(\tilde{\beta}_1 \mid X_1, \ldots\right) = \mathrm{E}\left[\left(\sum_{i=1}^n a_i u_i\right)^2 \,\middle|\, X_1, \ldots\right] =$$

$$= \sum_{i=1}^n \sum_{j=1}^n a_i a_j \,\mathrm{E}\left(u_i, u_j \mid X_1, \ldots\right) = \sigma_u^2 \sum_{i=1}^n a_i^2$$

Пусть $a_i = \hat{a}_i + d_i$. Тогда $\sum_{i=1}^n a_i^2 = \sum_{i=1}^n \hat{a}_i + 2\sum_{i=1}^n \hat{a}_i d_i + \sum_{i=1}^n d_i^2$.

$$\sum_{i=1}^n \hat{a}_i d_i = \sum_{i=1}^n \frac{\left(X_i - \bar{X}\right) d_i}{\sum_{i=1}^n \left(X_i - \bar{X}\right)^2} =$$

$$= \frac{\sum_{i=1}^n X_i d_i - \bar{X} \sum_{i=1}^n d_i}{\sum_{i=1}^n \left(X_i - \bar{X}\right)^2} =$$

$$= \frac{\left(\sum_{i=1}^n X_i a_i - \sum_{i=1}^n X_i \hat{a}_i\right) - \bar{X}\left(\sum_{i=1}^n a_i - \sum_{i=1}^n \hat{a}_i\right)}{\sum_{i=1}^n \left(X_i - \bar{X}\right)^2} = 0$$

$$\mathrm{Var}\left(\tilde{\beta}_1 \mid X_1, \ldots\right) = \sigma_u^2 \sum_{i=1}^n a_i^2 =$$

$$= \sigma_u^2 \sum_{i=1}^{n} \hat{a}_i^2 + \sigma_u^2 \sum_{i=1}^{n} d_i^2 =$$

$$= \mathrm{Var}\left(\hat{\beta}_1 \mid X_1, \ldots\right) + \sigma_u^2 \sum_{i=1}^{n} d_i^2 \Rightarrow$$

$$\mathrm{Var}\left(\tilde{\beta}_1 \mid X_1, \ldots\right) - \mathrm{Var}\left(\hat{\beta}_1 \mid X_1, \ldots\right) = \sigma_u^2 \sum_{i=1}^{n} d_i^2 > 0$$

□

Многомерный случай

Теорема 1 (Гаусса-Маркова). *Пусть*

1. $\mathrm{E}(\mathbf{U} \mid \mathbf{X}) = \mathbf{0}_N$.
2. $\mathrm{E}(\mathbf{U}\mathbf{U}' \mid \mathbf{X}) = \sigma_u^2 \mathbf{I}_N$.
3. $\mathbf{X}$ *имеет полный столбцовый ранг.*

Тогда МНК оценка $\hat{\boldsymbol{\beta}}$ *является наилучшей (эффективной) линейной условно не смещенной оценкой (BLUE)(Носко 2021; Магнус и др. 2021; Pierse 2021a).*

Доказательство. Линейность $\hat{\boldsymbol{\beta}}$ очевидна. Действительно, так как

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

то несложно увидеть, что каждый компонент $\hat{\boldsymbol{\beta}}$ представляет собой линейную комбинацию Y_i с весами, определяемыми матрицей $\mathbf{X}$. Также отметим, что

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$$

Несмещенность также несложно показать:

$$\begin{aligned}
\mathrm{E}\left(\hat{\boldsymbol{\beta}} \mid \mathbf{X}\right) &= \mathrm{E}\left[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \mid \mathbf{X}\right] = \\
&= \mathrm{E}\left[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) \mid \mathbf{X}\right] = \\
&= \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\underbrace{\mathrm{E}(\mathbf{u} \mid \mathbf{X})}_{=0} = \boldsymbol{\beta} \quad \text{по 1-му условию}
\end{aligned}$$

Перейдем к эффективности. Пусть $\tilde{\boldsymbol{\beta}}$ — **произвольная** линейная условно несмещенная оценка $\boldsymbol{\beta}$. Ее можно представить в виде

$$\tilde{\boldsymbol{\beta}} = (\mathbf{B} + \mathbf{C})\mathbf{Y}$$

где $\mathbf{B} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

Из несмещенности $\tilde{\boldsymbol{\beta}}$

$$\boldsymbol{\beta} = \mathrm{E}\left(\tilde{\boldsymbol{\beta}} \mid \mathbf{X}\right) = (\mathbf{B} + \mathbf{C})\,\mathrm{E}(\mathbf{Y} \mid \mathbf{X}) = (\mathbf{B} + \mathbf{C})\mathbf{X}\boldsymbol{\beta} = (\mathbf{I}_{K+1} + \mathbf{C}\mathbf{X})\boldsymbol{\beta}$$

следует, что $\mathbf{C}\mathbf{X} = \mathbf{0}$, что означает, что $\mathbf{B}\mathbf{C}' = \mathbf{0}$.

Также отметим, что

$$\begin{aligned}
\tilde{\boldsymbol{\beta}} &= (\mathbf{B} + \mathbf{C})\mathbf{Y} = (\mathbf{B} + \mathbf{C})(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) = \\
&= \underbrace{\mathbf{B}\mathbf{X}}_{=\mathbf{I}_{K+1}}\boldsymbol{\beta} + \underbrace{\mathbf{C}\mathbf{X}}_{=0}\boldsymbol{\beta} + (\mathbf{B} + \mathbf{C})\mathbf{u} = \\
&= \boldsymbol{\beta} + (\mathbf{B} + \mathbf{C})\mathbf{u}
\end{aligned}$$

Ковариационная матрица $\hat{\boldsymbol{\beta}}$ равна

$$\Sigma_{\hat{\boldsymbol{\beta}}} = \mathrm{E}\left[\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)' \mid \mathbf{X}\right] = \mathrm{E}\left[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\mathbf{u}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mid \mathbf{X}\right] =$$

$$= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\underbrace{\mathrm{E}(\mathbf{u}\mathbf{u}' \mid \mathbf{X})}_{\Sigma_u=\sigma_u^2\mathbf{I}_N}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} =$$

$$= \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{I}_N\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} =$$

$$= \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}$$

Ковариационная матрица $\tilde{\boldsymbol{\beta}}$ равна

$$\Sigma_{\tilde{\boldsymbol{\beta}}} = \mathrm{E}\left[(\tilde{\boldsymbol{\beta}} - \boldsymbol{\beta})(\tilde{\boldsymbol{\beta}} - \boldsymbol{\beta})' \mid \mathbf{X}\right] = (\mathbf{B} + \mathbf{C})\underbrace{\mathrm{E}(\mathbf{u}\mathbf{u}' \mid \mathbf{X})}_{\Sigma_u=\sigma_u^2\mathbf{I}_N}(\mathbf{B}' + \mathbf{C}') =$$

$$= \sigma_u^2(\mathbf{B}\mathbf{B}' + \mathbf{B}\mathbf{C}' + \mathbf{C}\mathbf{B}' + \mathbf{C}\mathbf{C}') =$$

$$= \Sigma_{\hat{\boldsymbol{\beta}}} + \sigma_u^2\mathbf{C}\mathbf{C}'$$

Матрица $\mathbf{C}\mathbf{C}'$ — симметрична и положительно полуопределена, то есть $\forall \mathbf{x}$

$$\mathbf{x}\mathbf{C}\mathbf{C}'\mathbf{x} \geqslant 0$$

Это означает, что диагональные элементы матрицы неотрицательны. А так как на главных диагоналях ковариационных матриц располагаются дисперсии оценок отдельных коэффициентов, то это означает, что

$$\forall i \in \{0, 1, \ldots, k\} \operatorname{Var} \tilde{\beta}_i \geqslant \operatorname{Var} \hat{\beta}_i$$

□

Критерии качества приближения данных моделью

Стандартная ошибка регрессии (SER)

$$SER = s_{\hat{u}}$$

где

$$s^2_{\hat{u}} = \frac{1}{n-k-1}\sum_{i=1}^{n}\hat{u}_i^2 = \frac{RSS}{n-k-1}$$

SER — standard error of the regression это оценка стандартного отклонения случайных ошибок регрессии $\hat{u}_i$.

Коэффициент детерминации регрессии R^2

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS} = [\text{Corr}(X, y)]^2$$

R^2 — доля выборочной дисперсии Y_i, объясненной (или предсказанной) X_i. R^2 всегда увеличивается при включении новых переменных в модель, так как RSS всегда уменьшается.

Скорректированный коэффициент детерминации $\bar{R}^2$

$$\bar{R}^2 = 1 - \frac{n-1}{n-k-1}\frac{RSS}{TSS} = 1 - \frac{s^2_{\hat{u}}}{s^2_Y}$$

Информационные критерии

$$AIC = 2k - 2\ln\hat{L} \qquad AIC = 2k + N\ln\hat{\sigma}^2$$

$$BIC = k\ln N - 2\ln\hat{L} \; BIC = \underbrace{k\ln N + N\ln\hat{\sigma}^2}_{\text{в линейной нормальной регрессии}}$$

Тестирование гипотез

Тестирование единичной гипотезы

Рассмотрим модель

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \ldots + \beta_K x_{Ki} + u_i$$

Предположим, что мы хотим протестировать одиночную гипотезу для какого-то коэффициента

$$H_0 : \beta_j = \beta_{j,0}$$
$$H_a : \beta_j \neq \beta_{j,0}$$

где $j = 1, \ldots, K$. Для этого мы можем воспользоваться стандартным t-тестом.

1. Вычисляем стандартную ошибку $\mathrm{SE}\left(\hat{\beta}_j\right)$.
2. Вычисляем тестовую статистику $t^{\mathrm{act}} = \frac{\hat{\beta}_j - \beta_{j,0}}{\mathrm{SE}\left(\hat{\beta}_j\right)}$.
3. Отвергаем нулевую гипотезу на уровне значимости α, если $|t^{\mathrm{act}}| > t^{\mathrm{crit}}_{1-\frac{\alpha}{2}}$. Или, эквивалентно, если p-значение меньше α. Или, эквивалентно, если $\hat{\beta}_0$ не попадает в доверительный интервал $\left\{\hat{\beta}_j + -t^{\mathrm{crit}}_{1-\alpha/2} \times \mathrm{SE}\left(\hat{\beta}_j\right)\right\}$.

На больших выборках можно пользоваться критическими значениями для стандартного нормального распределения; на не очень больших выборках нужно использовать критические значения для распределения Стьюдента.

Тестирование более сложных гипотез

Допустим, что мы тестируем нулевую гипотезу H_0 : $\mathbf{w}'\boldsymbol{\beta} = w_0$.

Известно, что

$$\mathbf{w}'\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right) \sim N\left(0, \sigma_u^2 \mathbf{w}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{w}\right)$$

$$\frac{\mathbf{w}'\hat{\boldsymbol{\beta}} - \mathbf{w}'\boldsymbol{\beta}}{\sigma_u\sqrt{\mathbf{w}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{w}}} \sim N(0,1)$$

Из формулы (5) следует, что

$$\frac{\frac{\mathbf{w}'\hat{\boldsymbol{\beta}} - \mathbf{w}'\boldsymbol{\beta}}{\sigma_u\sqrt{\mathbf{w}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{w}}}}{\sqrt{\frac{1}{N-K}(N-K)\frac{\hat{\sigma}_u^2}{\sigma_u^2}}} = \frac{\mathbf{w}'\boldsymbol{\beta} - w_0}{\hat{\sigma}_u\sqrt{\mathbf{w}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{w}}} \sim t_{N-K}$$

Если $\mathbf{w} = \mathbf{e}_j = \left(0, \ldots, 0, \underset{j}{1}, 0, \ldots, 0\right)'$, то полученная формула примет вид

$$\frac{\hat{\beta}_j}{\mathrm{SE}\left(\hat{\beta}_j\right)} \sim t_{N-K}$$

Тестирование совместных гипотез

Совместная гипотеза накладывает условия (ограничения) на два (или более) коэффициента регрессии. Первой мыслью может быть использование индивидуальных t-статистик для тестирования ограничений. Рассмотрим вопрос, стоит ли отвергать ли совместную гипотезу на уровне

5%, если каждая индивидуальная t-статистика превышает 1.96 по модулю.

Пусть t_1 и t_2 — индивидуальные t-статистики, для простоты независимо распределенные:

$$t_1 = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)} \text{ и } t_2 = \frac{\hat{\beta}_2 - 0}{SE(\hat{\beta}_2)}$$

Предлагаемая выше процедура тестирования предлагает отвергать

$$H_0 : \beta_1 = \beta_2 = 0$$

если

$$|t_1| > 1{,}96 \text{ и/или } |t_2| > 1{,}96$$

Вероятность некорректно отвергнуть H_0 на 5%-м уровне значимости, когда она верна, в такой процедуре равна

$$\begin{aligned} \mathrm{P}_{H_0}(|t_1| > 1{,}96 \text{ и/или } |t_2| > 1{,}96) &= 1 - \mathrm{P}_{H_0}(|t_1| \leqslant 1{,}96 \text{ и } |t_2| \leqslant 1{,}96) = \\ &= 1 - \mathrm{P}_{H_0}(|t_1| \leqslant 1{,}96) \times \mathrm{P}_{H_0}(|t_2| \leqslant 1{,}96) = \\ &= 1 - 0{,}95^2 = 0{,}0975 = 9{,}75\ \% \end{aligned}$$

- Предложенная процедура (на основе t-статистик) имеет неправильный размер критерия ($\neq 5\%$).
- Этот размер критерия зависит от корреляции между t_1 и t_2 и, следовательно, между $\hat{\beta}_1$ и $\hat{\beta}_2$.

Возможным решением является использование поправки Бонферрони: вместо α в качестве уровня значимости следует использовать $\frac{\alpha}{q}$.

Проверка совместных гипотез: F-статистика

F-статистика позволяет проверять одновременно все ограничения совместной гипотезы. Для случая гомоскедастичных ошибок *F*-статистику можно вычислить следующим образом (Носко 2021):

- Оцените две регрессии: регрессию «с ограничениями» (т.е. в предположениях нулевой гипотезы) и регрессию «без ограничений» (в предположениях альтернативной).
- Вычислите R^2_{R} и R^2_{UR}, соответственно, или RSS_{R} и RSS_{UR}. Тогда

$$F = \frac{\left(R^2_{\text{UR}} - R^2_{\text{R}}\right)/q}{\left(1 - R^2_{\text{UR}}\right)/(n - k_{\text{UR}} - 1)} = \frac{(RSS_{\text{R}} - RSS_{\text{UR}})/q}{RSS_{\text{UR}}/(n - k_{\text{UR}} - 1)}$$

  - $R^2_{\text{R}}, R^2_{\text{UR}}$ — R^2 в регрессиях с ограничениями и без.
  - $RSS_{\text{R}}, RSS_{\text{UR}}$ — RSS в регрессиях с ограничениями и без.
  - q — число ограничений в нулевой гипотезе.
  - k_{UR} — число объясняющих переменных (без константы) в модели без ограничений.

F-статистика для случая гомоскедастичных ошибок отвергает нулевую гипотезу, когда включение в модель двух (или больше) новых переменных увеличивает коэффициент детерминации «достаточно» для того, чтобы качество регрессии улучшилось «достаточно». *F*-статистика для случая гомоскедастичных ошибок асимптотически распределена как χ^2_q/q[1]:

q	5%
1	3.84
2	3.00
3	2.60
4	2.37
5	2.21

F-статистика в матричной форме

Допустим, что мы тестируем нулевую гипотезу H_0 : $\mathbf{R\beta} = \mathbf{r}$.

Известно, что

$$\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r} = \mathbf{R}\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right) \sim N\left(0, \sigma_u^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right)$$

Существует матрица $\mathbf{Q}$ такая, что $\left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} = \mathbf{Q}'\mathbf{Q}$, и что

[1]Если ошибки на самом деле гетероскедастичны, то асимптотическое распределение *F*-статистики для случая гомоскедастичных ошибок не является χ^2_q/q.

$$\boldsymbol{\xi} = \mathbf{QR}\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right) \sim N(0, \mathbf{I}_N)$$

Поэтому при справедливости нулевой гипотезы (Магнус и др. 2021; Pierse 2021a)

$$\begin{aligned}
\frac{\boldsymbol{\xi}'\boldsymbol{\xi}}{\sigma_u^2} &= \frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)'\mathbf{Q}'\mathbf{QR}\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)}{\sigma_u^2} = \\
&= \frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)'\left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1}\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)}{\sigma_u^2} = \\
&= \frac{\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)'\mathbf{R}'\left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1}\mathbf{R}\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)}{\sigma_u^2} = \\
&= \frac{\mathbf{u}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1}\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}}{\sigma_u^2} \sim \chi_q^2
\end{aligned}$$

Это следует из идемпотентности матрицы в числителе.

С другой стороны,

$$\frac{\hat{\mathbf{u}}'\hat{\mathbf{u}}}{\sigma_u^2} = \frac{\mathbf{u}'\mathbf{M}\mathbf{u}}{\sigma_u^2} = \frac{(N-K)\hat{\sigma}_u^2}{\sigma_u^2} \sim \chi_{N-K}^2 \tag{5}$$

откуда получим

$$F = \frac{\frac{1}{q}\frac{\boldsymbol{\xi}'\boldsymbol{\xi}}{\sigma_u^2}}{\frac{1}{N-K}\frac{(N-K)\hat{\sigma}_u^2}{\sigma_u^2}} = \frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)'\left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1}\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)}{q\hat{\sigma}_u^2}$$

Если ошибки гетероскедастичны, то асимптотическое распределение F-статистики для случая гомоскедастичных ошибок не является χ_q^2/q. Устойчивая к гетероскедастичности F-статистика (статистика Вальда) имеет вид

$$F = \frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)'\left(\mathbf{R}\hat{\boldsymbol{\Sigma}}_{\hat{\beta}}\mathbf{R}'\right)^{-1}\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)}{q} \sim \chi^2_q/q$$

$$W = \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)'\left(\mathbf{R}\hat{\boldsymbol{\Sigma}}_{\hat{\beta}}\mathbf{R}'\right)^{-1}\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right) = qF \sim \chi^2_q$$

где $\mathbf{R}$ — матрица ограничений, $\mathbf{r}$ — вектор свободных членов ограничений, $\hat{\boldsymbol{\Sigma}}_{\hat{\beta}}$ — ковариационная матрица вектора $\hat{\boldsymbol{\beta}}$.

Для того, чтобы F-статистика была *точной*, нужно, чтобы:

1. ошибки u_i были гомоскедастичны, т.е. $\text{Var}(u_i \mid X_1, \ldots, X_k) = \text{const}$.
2. ошибки $u_1, \ldots, u_n$ были нормально распределены.

В случае ненормальности ошибок регрессии статистика будет *асимптотической*.

Исследователи часто используют F-распределение на небольших выборках, так как оно имеет большие критические значения и является более консервативным.

Фиктивные регрессоры

Пусть X_i обозначает бинарную переменную. Рассмотрим регрессию $Y_i = \beta_0 + \beta_1 X_i + u_i$. Пусть $\bar{Y}_0$ означает выборочное среднее для наблюдений с $X = 0$, а $\bar{Y}_1$ обозначает выбо-

рочное среднее для наблюдений с $X = 1$. Покажем, что $\hat{\beta}_0 = \bar{Y}_0$, $\hat{\beta}_0 + \hat{\beta}_1 = \bar{Y}_1$ и $\hat{\beta}_1 = \bar{Y}_1 - \bar{Y}_0$.

$$\sum X_i = n_1$$

$$\bar{X} = \frac{n_1}{n}$$

$$\sum \left(X_i - \bar{X}\right)^2 = \sum X_i^2 - n\bar{X}^2 = n_1 - n\frac{n_1^2}{n^2} - \frac{n_0 n_1}{n}$$

$$\sum \left(X_i - \bar{X}\right)\left(Y_i - \bar{Y}\right) = \sum X_i\left(Y_i - \bar{Y}\right) = \sum X_i Y_i - \bar{Y}\sum X_i =$$

$$= n_1\bar{Y}_1 - n_1\bar{Y}$$

$$\hat{\beta}_1 = \frac{n_1\left(\bar{Y}_1 - \bar{Y}\right)}{\frac{n_0 n_1}{n}} = \frac{n}{n_0}\left(\bar{Y}_1 - \bar{Y}\right) = \frac{n}{n_0}\left(\bar{Y}_1 - \frac{n_1}{n}\bar{Y}_1 - \frac{n_0}{n}\bar{Y}_0\right) =$$

$$= \frac{n}{n_0}\left(\frac{n_0}{n}\bar{Y}_1 - \frac{n_0}{n}\bar{Y}_0\right) = \bar{Y}_1 - \bar{Y}_0$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1\bar{X} = \bar{Y} - \left(\bar{Y}_1 - \bar{Y}_0\right)\frac{n_1}{n} =$$

$$= \frac{n_1}{n}\bar{Y}_1 + \frac{n_0}{n}\bar{Y}_0 - \frac{n_1}{n}\bar{Y}_1 - \frac{n_1}{n}\bar{Y}_0 = \bar{Y}_0$$

Нелинейные модели

$$Y_i = f(X_{1i}, ..., X_{ki}) + u_i, i = 1, ..., n$$

$f(X_{1i}, ..., X_{ki})$ — **теоретическая функция нелинейной регрессии**. Например:

$$f(Income_i) = \beta_0 + \beta_1 Income_i + \beta_2\, Income$$

Величина изменения Y

$$\Delta Y = f(X_1 + \Delta X_1, X_2, ..., X_k) - f(X_1, X_2, ..., X_k)$$

Пусть $\hat{f}(X_1, X_2, ..., X_k)$ — предсказанное значение Y, полученное на основе оценки $\hat{f}$ функции теоретической регрессии. Тогда

$$\Delta \hat{Y} = \hat{f}(X_1 + \Delta X_1, X_2, ..., X_k) - \hat{f}(X_1, X_2, ..., X_k)$$

Логарифмические регрессии

Дальнейшие выкладки опираются на следующее:

$$\ln(x + \Delta x) - \ln(x) \cong \frac{\Delta x}{x}, \text{если } \frac{\Delta x}{x} \text{ мало}$$

$\frac{\Delta x}{x}$ — процентное изменение x, деленное на 100.

Линейно-логарифмическая модель 1%-ное изменение X приводит к изменению Y на $\frac{1}{100}\beta_1$.

$$Y_i = \beta_0 + \beta_1 \ln(X_i) + u_i, i = 1, ..., n$$

Логарифмически-линейная модель Единичное изменение X (то есть $\Delta X = 1$) приводит к изменению Y на $100\beta_1$%.

$$\ln Y_i = \beta_0 + \beta_1 X_i + u_i, i = 1, ..., n$$

Важно понимать, что так как $\Delta \ln Y = \ln \frac{Y + \Delta Y}{Y}$ лишь примерно равно $\frac{\Delta Y}{Y}$, то приведенная выше интерпретация справедлива только в случае *малых* значений β_1.

$\Delta \ln Y$	$\exp\{\Delta \ln Y\} = \frac{Y+\Delta Y}{Y}$	$\Delta \ln Y$	$\exp\{\Delta \ln Y\} = \frac{Y+\Delta Y}{Y}$
0.01	1.01005	0.1	1.10520
0.02	1.02020	0.2	1.22140
0.03	1.03046	0.3	1.35000
0.05	1.05127	0.5	1.65000
0.09	1.09417	1.0	2.71828

Линейная в логарифмах 1%-ное изменение X (то есть $\Delta X = 1$) приводит к изменению Y на β_1%.

$$\ln Y_i = \beta_0 + \beta_1 \ln X_i + u_i, i = 1, ..., n$$

Модель регрессии по X	Теоретическая модель	Эластичность $E(Y \mid X)$
Линейная	$Y = \beta_0 + \beta_1 X + u$	$\frac{\beta_1 \Delta X}{\beta_0 + \beta_1 X}$
Линейно-логарифмическая	$Y = \beta_0 + \beta_1 \ln X + u$	$\frac{\beta_1}{\beta_0 + \beta_1 \ln X}$
Логарифмически-линейная	$\ln Y = \beta_0 + \beta_1 X + u$	$\beta_1 \Delta X$
Линейная в логарифмах	$\ln Y = \beta_0 + \beta_1 \ln X + u$	β_1

Используя критерии качества подгонки моделей, можно сравнивать модели, у которых одинаковый Y!

- Можно сравнивать логарифмически-линейную и линейную в логарифмах модель.
- Можно сравнивать линейно-логарифмическую и полиномиальные модели.

Библиография

[1] В. П. Носко, *Эконометрика. Книга 1*. в Академический учебник. Москва: Издательский дом «Дело» РАНХиГС, 2021.

[2] Я. Магнус, П. Катышев, и А. Пересецкий, *Эконометрика. Начальный курс. Учебник. 9-е издание*, 9-е изд., испр. Москва: Издательский дом «Дело» РАНХиГС, 2021.

[3] R. G. Pierse, «OLS Estimation With Matrix Algebra». 2021a г.

[4] D. N. Gujarati и D. C. Porter, *Basic Econometrics*, 5. ed. в The McGraw-Hill Series Economics. Boston, Mass.: McGraw-Hill Irwin, 2009.

[5] R. G. Pierse, «GLS Estimation and the SURE Model». 2021b г.

A Регрессия по частям

Этот дополнительный материал будет полезным для рассмотрения некоторых последующих тем. Смысл данного метода в том, что мы оцениваем коэффициенты модели не разом, а по очереди.

Рассмотрим модель (Pierse 2021b)

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{u} = \begin{pmatrix}\mathbf{X}_1 & \mathbf{X}_2\end{pmatrix}\begin{pmatrix}\boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_2\end{pmatrix} + \mathbf{u}$$

где $\mathbf{X}_1$ и $\mathbf{X}_2$ представляют собой разбиение матрицы $\mathbf{X}$ по столбцам, причем столбцы в этих матрицах (а) не пересекаются, и (б) включают в себя все столбцы исходной матрицы. Для дальнейшего повествования нам понадобятся формулы для матрицы, обратной к блочной:

$$\begin{pmatrix}\mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D}\end{pmatrix}^{-1} = \begin{pmatrix}\tilde{\mathbf{A}} & -\tilde{\mathbf{A}}\mathbf{B}\mathbf{D}^{-1} \\ -\mathbf{D}^{-1}\mathbf{C}\tilde{\mathbf{A}} & \mathbf{D}^{-1} + \mathbf{D}^{-1}\mathbf{C}\tilde{\mathbf{A}}\mathbf{B}\mathbf{D}^{-1}\end{pmatrix} = \tag{6}$$

$$= \begin{pmatrix}\mathbf{A}^{-1} + \mathbf{A}^{-1}\mathbf{B}\tilde{\mathbf{D}}\mathbf{C}\mathbf{A}^{-1} & -\mathbf{A}^{-1}\mathbf{B}\tilde{\mathbf{D}} \\ -\tilde{\mathbf{D}}\mathbf{C}\mathbf{A}^{-1} & \tilde{\mathbf{D}}\end{pmatrix} \tag{7}$$

где $\tilde{\mathbf{A}} = \left(\mathbf{A} - \mathbf{B}\mathbf{D}^{-1}\mathbf{C}\right)^{-1}$, $\tilde{\mathbf{D}} = \left(\mathbf{D} - \mathbf{C}\mathbf{A}^{-1}\mathbf{B}\right)^{-1}$.

Очевидно, что формула (6) справедлива в случае, когда матрица $\mathbf{D}$ обратима, а формула (7) — когда обратима матрица $\mathbf{A}$.

Оценка $\hat{\boldsymbol{\beta}}$ равна

$$\begin{pmatrix}\hat{\boldsymbol{\beta}}_1 \\ \hat{\boldsymbol{\beta}}_2\end{pmatrix} = (\mathbf{X}'\mathbf{X})^{-1}\begin{pmatrix}\mathbf{X}_1\mathbf{y} \\ \mathbf{X}_2\mathbf{y}\end{pmatrix}$$

Найдем $\hat{\boldsymbol{\beta}}_1$. Так как

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix}\mathbf{X}_1'\mathbf{X}_1 & \mathbf{X}_1'\mathbf{X}_2 \\ \mathbf{X}_2'\mathbf{X}_1 & \mathbf{X}_2'\mathbf{X}_2\end{pmatrix}$$

то

$$(\mathbf{X}'\mathbf{X})^{-1} = \begin{pmatrix} \tilde{\mathbf{X}} & -\tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1} \\ -(\mathbf{X}_2'\mathbf{X}_2)\mathbf{X}_2'\mathbf{X}_1\tilde{\mathbf{X}} & (\mathbf{X}_2'\mathbf{X}_2)^{-1} + (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1\tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1} \end{pmatrix}$$

где

$$\tilde{\mathbf{X}} = \left[\mathbf{X}_1'\mathbf{X}_1 - \mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1\right]^{-1} =$$

$$= \left\{\mathbf{X}_1'\underbrace{\left[\mathbf{I}_N - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\right]}_{\mathbf{M}_2}\mathbf{X}_1'\right\}^{-1}$$

Таким образом

$$\begin{aligned} \hat{\boldsymbol{\beta}}_1 &= \tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{y} - \tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{y} = \\ &= \tilde{\mathbf{X}}\mathbf{X}_1'\left[\mathbf{I}_N - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\right]\mathbf{y} = \\ &= (\mathbf{X}_1'\mathbf{M}_2\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{M}_2\mathbf{y} = \\ &= (\mathbf{X}_1'\mathbf{M}_2\mathbf{M}_2\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{M}_2\mathbf{M}_2\mathbf{y} = \\ &= \left(\hat{\mathbf{X}}_1'\hat{\mathbf{X}}_1\right)^{-1}\hat{\mathbf{X}}_1'\hat{\mathbf{y}} \end{aligned}$$

где $\hat{\mathbf{X}}_1$ и $\hat{\mathbf{y}}$ — остатки регрессий $\mathbf{X}_1$ и $\mathbf{y}$ на $\mathbf{X}_2$, соответственно.

Аналогично показывается, что

$$\hat{\boldsymbol{\beta}}_2 = (\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{y}$$

В Распределение хи-квадрат

Рассмотрим вектор $\mathbf{x}$ длины p такой, что $\mathbf{x} \sim N(\mathbf{0}, \mathbf{I}_p)$. Тогда случайная величина $\mathbf{x}'\mathbf{x}$ будет иметь распределение хи-квадрат с p степенями свободы χ^2_p.

Более того, если $\mathbf{x} \sim N(\mathbf{0}, q^2\mathbf{I}_p)$, то

$$\frac{\mathbf{x}'\mathbf{x}}{q^2} \sim \chi^2_p$$

Пусть $\mathbf{A}$ — симметричная идемпотентная матрица ранга r. Тогда (Pierse 2021b)

$$\frac{\mathbf{x}'\mathbf{A}\mathbf{x}}{q^2} \sim \chi^2_r$$

Доказательство. Матрица $\mathbf{A}$ может быть спектрально разложена:

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}'$$

где $\mathbf{V}$ — матрица собственных векторов такая, что $\mathbf{V}'\mathbf{V} = \mathbf{I}_p$, $\mathbf{\Lambda}$ — диагональная матрица с собственными значениями на главной диагонали.

Отсюда

$$\mathbf{x}'\mathbf{A}\mathbf{x} = \mathbf{x}'\mathbf{V}\mathbf{\Lambda}\mathbf{V}'\mathbf{x} = \mathbf{z}'\mathbf{\Lambda}\mathbf{z}$$

причем $\mathbf{z} \sim N(\mathbf{0}, q^2\mathbf{V}'\mathbf{V}) = N(\mathbf{0}, q^2\mathbf{I}_p)$. С другой стороны, так как $\mathbf{A}$ симметрична и идемпотентна, то ее собственные значения могут принимать значения только 0 или 1, причем число значений, равных 1, равно рангу матрицы.

Таким образом

$$\mathbf{z}'\mathbf{\Lambda}\mathbf{z} = \sum_{i=1}^{p} \lambda_i z_i^2 = \sum_{i=1}^{r} z_i^2 = \mathbf{z}_1'\mathbf{z}_1$$

откуда следует

$$\frac{\mathbf{x}'\mathbf{A}\mathbf{x}}{q^2} = \frac{\mathbf{z}_1'\mathbf{z}_1}{q^2} \sim \chi_r^2$$

□