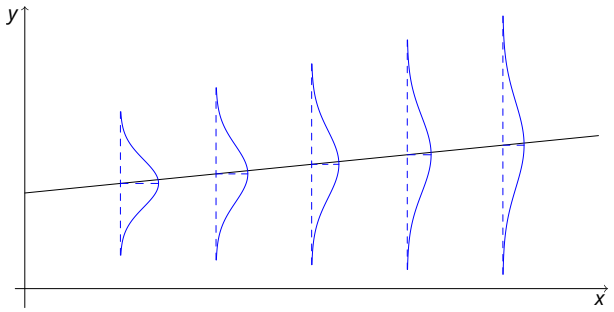
Нарушение условий теоремы Гаусса-Маркова

Гетероскедастичность

Случайная ошибка u_i называется **гомоскедастичной**, если условная дисперсия u_i относительно X_i постоянна для $i = 1, ..., n$ (то есть $\mathrm{Var}[u_i \mid X_i = x] = \mathrm{const}, i = 1, ..., n$). В противном случае ошибка называется **гетероскедастичной**.



Важно отметить, что МНК оценки коэффициентов являются несмещенными, состоятельными и асимптотически нормальными как в случае гомоскедастичности, так и в случае гетероскедастичности ошибок. Но они эффективны *только* в случае гомоскедастичности ошибок!

Для борьбы с гетероскедастичностью можно:

- провести моделирование с учетом отличия дисперсии (взвешенный МНК, ВМНК);
- воспользоваться стандартными ошибками, устойчивыми к гетероскедастичности.

Взвешенный МНК

Если ошибки модели гетероскедастичны, то ковариационная матрица ошибок будет иметь следующий вид:

$$\mathrm{Var}(\mathbf{u}) = \mathbf{\Sigma} = \sigma^2 \begin{pmatrix} k_1^2 & 0 & \cdots & 0 \\ 0 & k_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \vdots & k_N^2 \end{pmatrix} = \sigma^2 \mathbf{V} \neq \sigma^2 \mathbf{I}_N, k_i^2 > 0 \forall i$$

Условие положительности диагональных элементов позволяет обратить матрицу $\mathbf{V}$ и ввести матрицу $\mathbf{L}$ такую, что $\mathbf{L}'\mathbf{L} = \mathbf{V}^{-1}$

$$\mathbf{L} = \begin{pmatrix} \frac{1}{k_1} & 0 & \cdots & 0 \\ 0 & \frac{1}{k_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{k_N} \end{pmatrix}$$

Таким образом, домножив слева обе стороны модели на матрицу $\mathbf{L}$, мы получим

$$\mathbf{Ly} = \mathbf{LX}\beta + \mathbf{Lu}$$

Очевиднно, что ошибки в данной взвешенной модели будут гомоскедастичными.

Доступный ВМНК

Главной проблемой обычного ВМНК является то, что нам нужно знать ковариационную матрицу ошибок $\mathbf{\Sigma}$. Нетрудно догадаться, что в общем случае мы ее не знаем. В этом случае прибегают в доступному (feasible) ВМНК:

1. Оцените интересующую вас при помощи МНК и получите остатки $\hat{u}_i, i = 1, ..., N$.
2. Оцените предполагаемую модель функции условной дисперсии $\mathrm{Var}[u_i \mid X_i]$: оцените регрессию $\hat{u}_i^2$ на набор переменных, от которых, по вашему мнению, она зависит.
3. Используйте оцененную вспомогательную для расчета предсказанных значений функции условной дисперсии $\widehat{\mathrm{Var}}[u_i \mid X_i]$.
4. Умножьте зависимую переменную и регрессоры (в том числе и свободный член) на величину, обратную квадратному корню из оцененной функции условной дисперсии $\widehat{\mathrm{Var}}[u_i \mid X_i]$.
5. Оцените коэффициенты полученной взвешенной регрессии при помощи МНК; оценки являются ВМНК–оценками.

Робастные стандартные ошибки

В реальности исследователи не так часто используют взвешенный МНК, так как вопрос о том, какую спецификацию выбрать для модели дисперсии, является весьма нетривиальным. Более распространенной практикой является использование состоятельных оценок стандартных ошибок, устойчивых к гетероскедастичности. Использование этих ошибок является компромиссом между удобством и эффективностью: полученные оценки все еще не самые эффективные, тем не менее остаточная неэффективность достаточно мала, чтобы не сильно влиять на статистические выводы.

Простейший вариант робастных стандартных ошибок был предложен Уайтом[1] (White 1980). Напомним, что при условии гомоскедастичности ковариационная матрица остатков регрессии равна (Магнус и др. 2021; Pierse 2021)

$$\begin{aligned}\mathrm{E}\big(\hat{\mathbf{u}}\hat{\mathbf{u}}'|\,\mathbf{X}|\big) &= \mathrm{E}\Big[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\mathbf{u}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\Big)\,\mathbf{X}\Big] = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\,\mathrm{E}(\mathbf{u}\mathbf{u}'\mid\mathbf{X})\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{I}_N\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}\end{aligned}$$

При нарушении условия гомоскедастичности упрощения, подобные таковым в формуле выше, уже невозможны, и ковариационная матрица примет вид

$$\mathrm{E}(\hat{\mathbf{u}}\hat{\mathbf{u}}'\mid\mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Sigma}_{\mathbf{u}}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

Уайт предложил следующую оценку для $\boldsymbol{\Sigma}_{\mathbf{u}}$

$$\hat{\boldsymbol{\Sigma}}_{\mathbf{u}} = \mathrm{diag}\{\hat{u}_1^2, \hat{u}_2^2, ..., \hat{u}_N^2\}$$

$$\hat{\boldsymbol{\Sigma}}_{\mathbf{u}}^{\mathrm{HC}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\,\mathrm{diag}\{\hat{u}_1^2, \hat{u}_2^2, ..., \hat{u}_N^2\}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

Тестирование гетероскедастичности

1. График остатков $\hat{u}_i$.
2. График стандартизованных остатков $c_i = \frac{\hat{u}_i}{s_{\hat{u}}}$ от
    - оцененных значений $\hat{Y}_i$,
    - отдельных объясняющих переменных,

[1] В современных пакетах эти ошибки часто фигурируют под обозначением `HC0`.

  - номера наблюдения (в последовательные моменты времени с равными интервалами).

Графические методы позволяют выявить:

- график от $\hat{Y}_i$
  - выбросы,
  - возможную гетероскедастиность,
  - неправильную спецификацию модели,
- график от X возможную нелинейность,
- график от номера наблюдения
  - изменение дисперсии ошибок,
  - пропуск переменных,
  - автокоррелированность ошибок.

Тест Голдфельда-Квандта

1. Упорядочиваем наблюдения по предполагаемому возрастанию дисперсий ошибок (по предполагаемой переменной).
2. Отбрасываем r центральных наблюдений.
3. Оцениваем выбранную модель отдельно на первом и последнем интервале.
4. Вычисляем статистику $F^{\text{act}} = \frac{SSR_2}{SSR_1}$.
5. Отвергаем $H_0 : \text{Var}[u_i \mid X_i] = \text{const}, i = 1, ..., n$ на уровне значимости α, если $F^{\text{act}} > F_{1-\alpha}(\frac{n-r}{2} - 2; \frac{n-r}{2} - 2)$.

Тест Глейзера

$$\text{Var}[u_i \mid X_i] = \theta_0 + \theta_1 X_i^{\gamma}$$

1. Оцениваем регрессию при помощи МНК и вычисляем остатки $\hat{u}_i, i = 1, ..., n$.
2. Оцениваем регрессию $|\hat{u}_i|$ на константу и X_i^γ, специфицировав значение γ.
3. Отвергаем $H_0 : \theta_1 = 0$ в пользу $H_a : \theta_1 \neq 0$ на 5% уровне значимости, если $\left|t^{act}\right| > 1{,}96$.

Тест Бройша-Пагана

Суть теста состоит в оценивании вспомогательной регрессии для остатков модели с последующим тестированием коэффициентов при переменных из матрицы Z на совместное равенство нулю.

$$
\begin{aligned}
y &= \mathbf{X}'\beta + u \\
\hat{u}^2 &= \gamma_0 + \mathbf{Z}'\gamma + \nu \\
nR^2 &\sim \chi^2(p)
\end{aligned}
$$

Тест Уайта

Аналогичен тесту Бройша-Пагана за исключением того, что во вспомогательную регрессию включаются не только вспомогательные переменные, но и их попарные произведения.

$$
\begin{aligned}
y &= \mathbf{X}'\beta + u \\
\hat{u}^2 &= \gamma_0 + \mathbf{Z}'\gamma + \sum_i \sum_{j \geqslant i} \gamma_{ij} z_i z_j + \nu \\
nR^2 &\sim \chi^2(p)
\end{aligned}
$$

Автокорреляция

Важное замечание: об автокорреляции имеет смысл говорить только тогда, когда данные имеют *четкий порядок*! Для межобъектных данных говорить об автокорреляции нет никакого смысла!

Автокорреляция, как понятно из названия, это наличие корреляции между текущим значением и прошлыми значениями ошибки. Проще говоря, автокорреляция означает, что ковариационная матрица ошибок перестает быть диагональной

$$\mathbf{u} \sim N(\mathbf{0}, \mathbf{\Sigma})$$

Автокорреляция не приводит к смещению или несостоятельности оценок, но они перестают быть эффективными. Аналогично ВМНК мы можем найти разложение обратной матрицы $\mathbf{\Sigma}^{(-1=\mathbf{L}'\mathbf{L}}$ и преобразовать с его помощью нашу модель

$$\mathbf{L}\mathbf{y} = \mathbf{L}\mathbf{X}\beta + \mathbf{L}\mathbf{u}$$

Оценка вектора коэффициентов будет равна

$$\begin{aligned}\hat{\beta} &= [(\mathbf{L}\mathbf{X})'\mathbf{L}\mathbf{X}]^{-1}(\mathbf{L}\mathbf{X})'\mathbf{L}\mathbf{y} = \\ &= (\mathbf{X}'\mathbf{L}'\mathbf{L}\mathbf{X})^{-1}\mathbf{X}'\mathbf{L}'\mathbf{L}\mathbf{y} = \\ &= \left(\mathbf{X}'\mathbf{\Sigma}^{-1}\mathbf{X}\right)^{-1}\mathbf{X}'\mathbf{\Sigma}^{-1}\mathbf{y}\end{aligned}$$

Данный метод называется **обобщенным МНК**.

Процедура Кохрейна-Оркатта

Рассмотрим пример, когда ошибки регрессии следуют процессу авторегрессии первого порядка

$$u_t = \rho u_{t-1} + \varepsilon_t, \quad |\rho| < 1$$
$$\mathbf{u} = \rho \mathbf{u}_{-1} + \boldsymbol{\varepsilon}$$
$$\mathbf{u}_{-1} = \begin{pmatrix} u_0 \\ u_1 \\ \vdots \\ u_{T-1} \end{pmatrix}$$

причем $\operatorname{Var} \boldsymbol{\varepsilon} = \sigma_\varepsilon^2 \mathbf{I}_T$, $u_0 = 0$.

Кохрейн и Оркатт (Cochrane и Orcutt 1949) предложили следующий способ устранения авторегрессии первого порядка. Сначала следует преобразовать все переменные в модели следующим образом:

$$y_t^* = y_t - \rho y_{t-1}$$
$$x_{kt}^* = x_{kt} - \rho x_{k,t-1}$$
$$1^* = 1 - \rho$$
$$u_t^* = u_t - \rho u_{t-1} = \varepsilon_t$$
$$t \in [2, T]$$

Полученные переменные нужно подставить в модель вместо исходных

$$y_t^* = \mathbf{X}^* \boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

где $\mathbf{X}^* = \left[1^*, x_{1,\ldots}^*, \ldots, x_{k,\ldots}^*\right]$.

Предполагается, что полученные оценки будут более эффективными, чем в МНК без коррекции. Однако нужно отметить, что в

исходной формулировке процедуры первое наблюдение теряется. Кадияла (Kadiyala 1968) показал, что это приводит к тому, что обычная МНК оценка зачастую оказывается более эффективной, чем оценка по процедуре Кохрейна-Оркатта: для специального случая $\mathbf{X} = \mathbf{1}_T$ и $0 \leqslant \rho < 1$ МНК оценка эффективнее скорректированной. Для преодоления этого, Прайс и Уинстен (Prais и Winsten 1954) предложили сохранять первое наблюдение, домножая значения всех переменных в первый момент времени, включая константу, на $\sqrt{1-\rho^2}$. На самом деле эта поправка возникает естественным образом при рассмотрении ковариационной матрицы ошибок (Kadiyala 1968)

$$\mathbf{\Sigma_u} = \mathrm{E}[\mathbf{uu}'] = \underbrace{\frac{\sigma_\varepsilon^2}{1-\rho^2}}_{\sigma_u^2} \begin{pmatrix} 1 & \rho & \rho^2 & \cdots & \rho^{T-1} \\ \rho & 1 & \rho & \cdots & \rho^{T-2} \\ \rho^2 & \rho & 1 & \cdots & \rho^{T-3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho^{T-1} & \rho^{T-2} & \rho^{T-3} & \cdots & 1 \end{pmatrix} = \sigma_u^2 \mathbf{R} \tag{1}$$

$$\mathbf{R}^{-1} = \frac{1}{1-\rho^2} \begin{pmatrix} 1 & -\rho & 0 & \cdots & 0 & 0 \\ -\rho & 1+\rho^2 & -\rho & \cdots & 0 & 0 \\ 0 & -\rho & 1+\rho^2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 1+\rho^2 & -\rho \\ 0 & 0 & 0 & \cdots & -\rho & 1 \end{pmatrix} \tag{2}$$

Матрица $\mathbf{R}^{-1}$ может быть единственным образом разложена следующим образом

$$\mathbf{R}^{-1} = \mathbf{L}'\mathbf{L}$$

где $\mathbf{L}$ — нижнетреугольная матрица вида

$$\mathbf{L} = \frac{1}{\sqrt{1-\rho^2}} \begin{pmatrix} \sqrt{1-\rho^2} & 0 & 0 & \cdots & 0 & 0 \\ -\rho & 1 & 0 & \cdots & 0 & 0 \\ 0 & -\rho & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & -\rho & 1 \end{pmatrix} \tag{3}$$

Домножив все члены модели слева на эту матрицу, получим

$$\mathbf{Ly} = \mathbf{LX}\beta + \mathbf{Lu}$$

Отметим, что, во-первых, множитель $\frac{1}{\sqrt{1-\rho^2}}$ *de facto* сокращается; во-вторых, нетрудно заметить, что домножение на $\mathbf{L}$ равносильно процедуре Кохрейна-Оркатта с поправкой Прайса-Уинстена.

Оценка ОМНК будет равна

$$\begin{aligned} \hat{\beta}_{GLS} &= (\mathbf{X'L'LX})^{-1}\mathbf{X'L'Ly} = \\ &= (\mathbf{X'R}^{-1}\mathbf{X})^{-1}\mathbf{X'R}^{-1}\mathbf{y} = \\ &= (\mathbf{X'}\boldsymbol{\Sigma}_{\mathbf{u}}^{-1}\mathbf{X})^{-1}\mathbf{X'}\boldsymbol{\Sigma}_{\mathbf{u}}^{-1}\mathbf{y} \end{aligned}$$

Робастные стандартные ошибки

Аналогично ситуации гетероскедастичности можно не проводить коррекцию модели, а ограничиться робастными оценками Ньюи-Веста (Newey и West 1987)

$$\hat{\boldsymbol{\Sigma}}^{\text{HAC}} = \hat{\boldsymbol{\Omega}}_0 + \sum_{i=1}^{L} \underbrace{\left(1 - \frac{i}{L+1}\right)}_{w_i} \left(\hat{\boldsymbol{\Omega}}_i + \hat{\boldsymbol{\Omega}}_i'\right)$$

где L — ширина окна расчета, $\hat{\mathbf{\Omega}}_j = \frac{1}{T}\sum_{t=j+1}^{T} \hat{u}_t \hat{u}_{t-j} \mathbf{X}'_{t,\dots} \mathbf{X}_{t-j,\dots}$, $\mathbf{X}_{t,\dots}$ — t-я стока матрицы $\mathbf{X}$.

Ньюи и Вест показали, что использование весов Бартлетта, впрочем как и использование весов вообще, гарантирует положительную полуопределенность $\hat{\mathbf{\Sigma}}^{\text{NW}}$. Они также показали состоятельность оценки $\hat{\mathbf{\Sigma}}^{\text{NW}}$.

Использованные в формуле веса

$$w_i = \begin{cases} 1 - |x|, |x| \leqslant 1 \\ 0 \qquad \text{иначе} \end{cases}$$

где $x = \frac{i}{L+1}$, — это веса Бартлетта. Эндрюс отмечает, что есть и другие варианты весов, например

Tuckey-Hanning $w_i = \begin{cases} \frac{1+\cos(\pi x)}{2}, |x| \leqslant 1 \\ 0 \qquad\qquad \text{иначе} \end{cases}$;

Parzen $w_i = \begin{cases} 1-6x^2+6|x|^3, |x| \leqslant \frac{1}{2} \\ 2(1-|x|)^3, \qquad |x| \leqslant 1 \\ 0 \qquad\qquad\quad \text{иначе} \end{cases}$;

QS $w_i = \frac{25}{12\pi^2 x^2}\left[\frac{\sin(6\pi x/2)}{6\pi x/2 - \cos(6\pi x/2)}\right]$.

Оптимальное значение параметра L зависит от того, какие веса используются для расчета ковариационной матрицы. В работе (Newey и West 1994) приведены формулы, полученные Монте-Карло моделированием:

- Для весов Бартлетта можно воспользоваться правилом Шверта (Schwert 1988) $\left\lfloor \gamma \left(\frac{T}{100} \right)^{\frac{1}{4}} \right\rfloor$ или Ньюи-Веста $\left\lfloor \gamma \left(\frac{T}{100} \right)^{\frac{2}{9}} \right\rfloor$. Параметр γ равен 4 или 12.
- Для весов Парцена Ньюи-Вест предлагают $\left\lfloor \gamma \left(\frac{T}{100} \right)^{\frac{4}{25}} \right\rfloor$. Параметр γ равен 4 или 12.
- Для весов QS предлагается $\left\lfloor 4 \left(\frac{T}{100} \right)^{\frac{2}{25}} \right\rfloor$.

Тестирование автокоррелированности

1. Анализ графика остатков или стандартизованных остатков.
2. Анализ коррелограммы.

Тест Дарбина-Уотсона

Тест Дарбина-Уотсона можно применять только при выполнении следующих условий:

- Применяется только для тестирования автокорреляции первого порядка

$$u_t = \rho u_{t-1} + \nu_t$$

- В регрессии должен присутствовать свободный член.
- В регрессии не должно быть лаговых значений регрессора.
- Не должно быть пропусков в переменных.

Для выполнения теста следует выполнить следующие шаги:

1. Оцениваем регрессию при помощи МНК и вычисляем остатки $\hat{u}_i, i = 1, ..., n$.

2. Вычисляем статистику $DW = \frac{\sum_{i=2}^{T}(\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{i=1}^{T}\hat{u}_t^2}$.

3. Отвергаем $H_0 : \rho = 0$ в пользу $H_a : \rho > 0$ на уровне значимости α если $DW < d_{L\alpha}$; не отвергаем, если $DW > d_{U\alpha}$.

Отрезок $d_{L\alpha} < DW < d_{U\alpha}$ представляет собой область неопределенности. Для тестирования нулевой гипотезы против альтернативы $H_a : \rho < 0$ критические значения рассчитываются по формулам $d^*_{L\alpha} = 4 - d_{L\alpha}$ и $d^*_{U\alpha} = 4 - d_{U\alpha}$.

Следует отметить, что DW лежит в интервале от 0 до 4.

Тест Бройша-Годфри

Процедура теста сжато описывается формулами

$$y = X'\beta + u$$

$$\hat{u}_t = X'\beta + \sum_{i=1}^{p}\gamma_i\hat{u}_{t-i} + \nu_t$$

$$nR^2 \sim \chi^2(p)$$

Суть теста состоит в оценивании вспомогательной регрессии для остатков модели с последующим тестированием коэффициентов при лагах остатков на совместное равенство нулю.

Мультиколлинеарность

Совершенная (строгая, полная) мультиколлинеарность наличие *точной* линейной зависимости между регрессорами. Если она есть, то МНК-оценки получить невозможно: деление на ноль в формулах для расчета МНК-коэффициентов или, что эквивалентно,

вырожденность матрицы $\mathbf{X}'\mathbf{X}$. Так как это, как правило, ошибка спецификации модели, нужно изменить набор объясняющих переменных в регрессии.

Несовершенная мультиколлинеарность (также неполная, частичная, нестрогая) две или более объясняющие переменные или их линейные комбинации сильно коррелированы между собой. С математической точки зрения никакой проблемы нет, и оценки МНК могут быть рассчитаны. Более того, при выполнении прочих предпосылок МНК оценки коэффициентов при коррелированных переменных не смещены, но и не эффективны.

К причинам мультиколлинеарности можно отнести:

- Ошибочное включение в уравнение регрессии двух или более линейно зависимых переменных.
- Две (или более) объясняющие переменные могут быть слабо коррелированными в генеральной совокупности, но сильно коррелированными в конкретной выборке.
- В модель включается объясняющая переменная, сильно коррелированная с зависимой переменной (такая переменная называется **доминирующей**).

Важно понимать, что мультиколлинеарность не является редким явлением; в модели множественной регрессии практически всегда присутствует мультиколлинеарность. Поэтому мы реагируем на мультиколлинеарность, если есть явные сильные признаки ее присутствия.

Совершенная мультиколлинеарность

Пусть

$$Y_i = \beta_0 X_{0i} + \beta_1 X_{1i} + u_i$$
$$X_{1i} = \lambda X_{0i}$$

где $X_{0i=1}, i = 1, ..., n$ — постоянный регрессор.

Тогда

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} \left(X_{1i} - \bar{X}\right) Y_i}{\sum_{i=1}^{n} \left(X_{1i} - \bar{X}\right)^2} = \frac{\sum_{i=1}^{n} (\lambda - \lambda) Y}{\sum_{i=1}^{n} (\lambda - \lambda)^2}$$

Последствия мультиколлинеарности

- Оценки коэффициентов не являются смещенными.
- Стандартные ошибки оценок коэффициентов завышены, а соответствующие t-статистики занижены.
- Неустойчивость оценок: включение нового регрессора сильно меняет оценки коэффициентов.
- Трудности с интерпретацией коэффициентов при коррелированных коэффициентах.
- Общее качество уравнения, а также оценки переменных, не связанных мультиколлинеарностью, остаются незатронутыми.
- Чем сильнее мультиколлинеарность, тем больше последствия.

Тестирование мультиколлинеарности

VIF — фактор обесценения (возрастания) дисперсии (Variance Inflation Factor).

1. Пусть

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{(ki+u_i, i=1,\ldots,n}$$

2. Оценим регрессию j-го регрессора на все остальные и получим коэффициент детерминации R_j^2.
3. Вычислим

$$VIF\left(X_j\right) = \frac{1}{1 - R_j^2}$$

Если $VIF\big(X_j\big) > 10$, то можем говорить о мультиколлинеарности.

Библиография

[1] H. White, «A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity», *Econometrica*, т. 48, вып. 4, сс. 817–838, 1980, doi: 10.2307/1912934.

[2] Я. Магнус, П. Катышев, и А. Пересецкий, *Эконометрика. Начальный курс. Учебник. 9-е издание*, 9-е изд., испр. Москва: Издательский дом «Дело» РАНХиГС, 2021.

[3] R. G. Pierse, «OLS Estimation With Matrix Algebra». 2021 г.

[4] D. Cochrane и G. H. Orcutt, «Application of Least Squares Regression to Relationships Containing Auto-Correlated Error Terms», *Journal of the American Statistical Association*, т. 44, вып. 245, сс. 32–61, 1949, doi: 10.2307/2280349.

[5] K. R. Kadiyala, «A Transformation Used to Circumvent the Problem of Autocorrelation», *Econometrica*, т. 36, вып. 1, сс. 93–96, 1968, doi: 10.2307/1909605.

[6] S. J. Prais и C. B. Winsten, «Trend Estimators and Serial Correlation», Chicago, Cowles Commission Discussion Paper 383, 1954.

[7] W. K. Newey и K. D. West, «A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix», *Econometrica*, т. 55, вып. 3, сс. 703–708, 1987, doi: 10.2307/1913610.

[8] W. K. Newey и K. D. West, «Automatic Lag Selection in Covariance Matrix Estimation», *The Review of Economic Studies*, т. 61, вып. 4, сс. 631–653, окт. 1994, doi: 10.2307/2297912.

[9] G. W. Schwert, «Tests For Unit Roots: A Monte Carlo Investigation», вып. 73. National Bureau of Economic Research, декабрь 1988 г. doi: 10.3386/t0073.

[10] M. Taboga, «Variance Inflation Factor», в *Lectures on Probability Theory and Mathematical Statistics*, Kindle Direct Publishing, 2021.

A Вывод формулы (1)

Для начала найдем формулу для определителя матрицы $\underset{T\times T}{\mathbf{R}}$. Заметим, что если мы отсечем первый столбец и строку, то мы получим аналогичную матрицу, но на единицу меньшего размера.

Обозначим искомый определитель $|\mathbf{R}| = D_T$. Воспользуемся разложением определителя по первой строке:

$$D_T = \sum_{i=1}^{T} (-1)^{1+i} \rho^{i-1} M_{1,i}$$

где $M_{1,i}$ — минор, полученный исключением 1 строки и i-го столбца. Нетрудно заметить, что единственные ненулевые миноры — это

$$M_{1,1} = D_{T-1}$$
$$M_{1,2} = \rho D_{T-1}$$

Таким образом

$$D_T = (1-\rho^2) D_{T-1}$$

Так как $D_1 = 1$, то рекурсивной подстановкой получим

$$D_T = (1-\rho^2)^{T-1} \tag{4}$$

Перейдем к расчету обратной матрицы. Согласно формуле для обратной матрицы нам нужно рассчитать все алгебраические дополнения для элементов матрицы $\mathbf{R}$. Так как матрица симметрична, то будем рассматривать элементы не ниже главной диагонали. Рассмотрим дополнения для элементов главной диагонали, равные $M_{j,j}$

$$M_{1,1} = D_{T-1} = (1-\rho^2)^{T-2}$$

$$M_{j,j} = \left|\begin{array}{cccc:ccc} 1 & \rho & \cdots & \rho^{j-2} & \rho^j & \rho^{j+1} & \cdots \\ \rho & 1 & \cdots & \rho^{j-3} & \rho^{j-1} & \rho^j & \cdots \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots \\ \rho^{j-2} & \rho^{j-3} & \cdots & 1 & \rho^2 & \rho^3 & \cdots \\ \hdashline \rho^j & \rho^{j-1} & \cdots & \rho^2 & & & \\ \rho^{j+1} & \rho^j & \cdots & \rho^3 & & D_{T-j} & \\ \vdots & \vdots & \ddots & \vdots & & & \end{array}\right|$$

Данный минор проще всего искать разложением по первой строке. Нетрудно увидеть, что удалением первой строки и столбца мы получим структурно аналогичный минор; обозначим его $M^*_{j,j}$. Удалив

первую строку и второй столбец мы получим тот же минор, но домноженный на ρ.

Удаление последующих столбцов будет давать нам миноры, у которых первые два столбца будут линейно зависимы, то есть равные нулю.

Итого

$$M_{j,j} = (1-\rho^2)M^*_{j,j}$$

Так как минор $M^*_{j,j}$ структурно аналогичен $M_{j,j}$, то к нему можно применить то же преобразование.

Нетрудно увидеть, что

$$M_{j,j} = (1-\rho^2)^{j-2} M^{*\dots*}_{j,j}$$

$$M^{*\dots*}_{j,j} = \left|\begin{array}{c:ccc} 1 & \rho^2 & \rho^3 & \cdots \\ \hdashline \rho^2 & & & \\ \rho^3 & & D_{T-j} & \\ \vdots & & & \end{array}\right|$$

и что $M^{*\dots*}_{j,j} = (1-\rho^4)D_{T-j}$.

Итого

$$M_{j,j} = (1-\rho^2)^{j-2}(1-\rho^4)(1-\rho^2)^{T-j-1} = (1+\rho^2)(1-\rho^2)^{T-2}$$

откуда получим, что

$$\left[\mathbf{R}^{-1}\right]_{1,1} = \frac{1}{1-\rho^2}$$

$$\left[\mathbf{R}^{-1}\right]_{j,j} = \frac{M_{j,j}}{D_T} = \frac{1+\rho^2}{1-\rho^2}$$

$$\left[\mathbf{R}^{-1}\right]_{T,T} = \frac{1}{1-\rho^2}$$

Рассмотрим дополнения для элементов первой субдиагонали, равные $-M_{j,j+1}$

$$M_{j,j+1} = \left|\begin{array}{ccccc:ccc} 1 & \rho & \rho^2 & \cdots & \rho^j & \rho^{j+1} & \rho^{j+2} & \cdots \\ \rho & 1 & \rho & \cdots & \rho^{j-1} & \rho^j & \rho^{j+1} & \cdots \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots \\ \rho^{j-2} & \rho^{j-3} & \cdots & 1 & \rho & \rho^3 & \rho^4 & \cdots \\ \hdashline \rho^j & \rho^{j-1} & \rho^{j-2} & \cdots & \rho & \rho & \rho^2 & \cdots \\ \rho^{j+1} & \rho^j & \rho^{j-1} & \cdots & \rho^2 & & D_{T-j-1} & \\ \vdots & \vdots & \vdots & \ddots & \vdots & & & \end{array}\right|$$

Данный минор проще всего искать разложением по первой строке. Нетрудно увидеть, что удалением первой строки и столбца мы получим структурно аналогичный минор; обозначим его $M^*_{j,j+1}$.

Удалив первую строку и второй столбец мы получим тот же минор, но домноженный на ρ.

Удаление последующих столбцов будет давать нам миноры, у которых первые два столбца будут линейно зависимы, то есть равные нулю.

Итого

$$M_{j,j+1} = (1-\rho^2)M^*_{j,j+1}$$

Повторяя это $j-2$ раза получим

$$M_{j,j+1} = (1-\rho^2)^{j-2}M^{*\ldots*}_{j,j+1}$$

$$M^{*\dots*}_{j,j+1} = \left|\begin{array}{c:ccc} \rho & \rho & \rho^2 & \dots \\ \rho^2 & & D_{T-j-1} & \\ \vdots & & & \end{array}\right| = \rho D_{T-j}$$

Итого

$$M_{j,j+1} = \rho(1-\rho^2)^{j-2} D_{T-j} = \rho(1-\rho^2)^{T-2}$$

откуда имеем

$$\left[\mathbf{R}^{-1}\right]_{j,j+1} = -\frac{M_{j,j+1}}{D_T} = -\frac{\rho}{1-\rho^2}, \quad j \in [1, T-1]$$

Рассмотрим дополнения для элементов прочих субдиагоналей, равных $(-1)^{2j+k} M_{j,j+k}$

$$M_{j,j+k} = \left|\begin{array}{ccccccc:ccc} 1 & \rho & \dots & \rho^{j-1} & \rho^j & \dots & \rho^{j+k-2} & \rho^{j+k} & \rho^{j+k+1} & \dots \\ \rho & 1 & \dots & \rho^{j-2} & \rho^{j-1} & \dots & \rho^{j+k-3} & \rho^{j+k-1} & \rho^{j+k} & \dots \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots \\ \rho^{j-2} & \rho^{j-3} & \dots & 1 & \rho & \dots & \rho^k & \rho^{k+2} & \rho^{k+3} & \dots \\ \hdashline \rho^j & \rho^{j-1} & \dots & \rho^2 & \rho & \dots & \rho^{k-2} & \rho^k & \rho^{k+1} & \dots \\ \rho^{j+1} & \rho^j & \dots & \rho^3 & \rho^2 & \dots & \rho^{k-3} & \rho^{k-1} & \rho^k & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots & \dots & \ddots & \vdots & \vdots & \ddots \end{array}\right|$$

Для этого минора справедлива та же логика, что и для предыдущих случаев.

В итоге мы придем к минору

$$M^{*\dots*}_{j,j+k} = \begin{vmatrix} \rho & 1 & \dots & \rho^{k-2} & \rho^k & \rho^{k+1} & \dots \\ \rho^2 & \rho & \dots & \rho^{k-3} & \rho^{k-1} & \rho^k & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots \end{vmatrix} = 0$$

поскольку первые два столбца линейно зависимы.

Итого, объединив все результаты, получим матрицу $\mathbf{R}^{-1}$.

B Вывод формулы (3)

Обозначим элементы матрицы $\mathbf{L}$ как $l_{i,j}$. Очевидно, что по определению $l_{i,j} = 0$ для $i < j$.

Перемножим $\mathbf{L}'$ и $\mathbf{L}$ и приравняем соответствующие элементы. Получим

$$
\begin{aligned}
l_{T,T}^2 &= \frac{1}{1-\rho^2} & l_{T,T} &= \frac{1}{\sqrt{1-\rho^2}} \\
l_{T,T}l_{T,T-1} &= -\frac{\rho}{1-\rho^2} & l_{T,T-1} &= -\frac{\rho}{\sqrt{1-\rho^2}} \\
l_{T,T}l_{T,T-2} &= 0 & l_{T,T-2} &= 0 \\
&\vdots & &\vdots \\
l_{T-1,T-1}^2 + l_{T,T-1}^2 &= \frac{1+\rho^2}{1-\rho^2} & l_{T-1,T-1} &= \frac{1}{\sqrt{1-\rho^2}} \\
l_{T-1,T-1}l_{T-1,T-2} + l_{T,T-1}l_{T,T-2} &= -\frac{\rho}{1-\rho^2} & l_{T-1,T-2} &= -\frac{\rho}{\sqrt{1-\rho^2}} \\
l_{T-1,T-1}l_{T-1,T-3} + l_{T,T-1}l_{T,T-3} &= 0 & l_{T-1,T-3} &= 0 \\
&\vdots & &\vdots \\
l_{1,1}^2 + l_{2,1}^2 &= \frac{1}{1-\rho^2} & l_{1,1} &= 1
\end{aligned}
$$

C Вывод формулы для VIF

На прошлой лекции мы увидели, что при выполнении условий теоремы Гаусса-Маркова

$$\operatorname{Var}\left(\hat{\beta} \,\middle|\, \mathbf{X}\right) = \sigma_u^2 (\mathbf{X}'\mathbf{X})^{-1}$$

откуда $\operatorname{Var}\left(\hat{\beta}_k \,\middle|\, \mathbf{X}\right) = \sigma_u^2 \left[(\mathbf{X}'\mathbf{X})^{-1}\right]_{kk}$.

Перестановкой столбцов матрицы $\mathbf{X}$ поставим k-й регрессор на первое место. Предположим также, что он центрирован. Воспользовавшись формулами для регрессии по частям, получим (Taboga 2021)

$$\left[(\mathbf{X}'\mathbf{X})^{-1}\right]_{11} = (\mathbf{X}_1'\mathbf{M}_{-1}\mathbf{X}_1)^{-1} = *$$

Так как $\mathbf{X}_1$ — вектор-столбец, то $\left[(\mathbf{X}'\mathbf{X})^{-1}\right]_{11}$ — скаляр, то есть

$$\begin{aligned} * &= \frac{1}{\mathbf{X}_1'\mathbf{M}_{-1}\mathbf{X}_1} = \\ &= \frac{1}{\mathbf{X}_1'\mathbf{M}_{-1}\mathbf{M}_{-1}\mathbf{X}_1} = \\ &= \frac{1}{(\mathbf{M}_{-1}\mathbf{X}_1)'\mathbf{M}_{-1}\mathbf{X}_1} = \frac{1}{\eta'\eta} \end{aligned}$$

где η — остатки регрессии $\mathbf{X}_1$ на $\mathbf{X}_{-1}$ (все остальные регрессоры).

Тогда, помня, что $\mathbf{X}_1$ центрирован, получим, что коэффициент детерминации в регрессии $\mathbf{X}_1$ на $\mathbf{X}_{-1}$ равен

$$R_1^2 = 1 - \frac{\eta'\eta}{\mathbf{X}_1'\mathbf{X}_1}$$

$$\eta'\eta = \mathbf{X}_1'\mathbf{X}_1(1 - R_1^2)$$

$$\frac{1}{\eta'\eta} = (\mathbf{X}_1'\mathbf{X}_1)^{-1}\frac{1}{1 - R_1^2}$$

То есть

$$\operatorname{Var}\left(\hat{\beta}_1 \,\middle|\, \mathbf{X}\right) = \sigma_u^2 (\mathbf{X}_1' \mathbf{X}_1)^{-1} \frac{1}{1 - R_1^2}$$

При этом, если $\mathbf{X}_1$ ортогонален $\mathbf{X}_{-1}$, то есть $\mathbf{X}_{(1)'}\mathbf{X}_{(-1=0}$, то

$$\operatorname{Var}\left(\hat{\beta}_1 \,\middle|\, \mathbf{X}\right) = \sigma_u^2 (\mathbf{X}_1' \mathbf{X}_1)^{-1}$$

То есть VIF равен отношению дисперсии оценки коэффициента при интересующей нас переменной к гипотетической дисперсии, если бы переменная была бы ортогональной другим регрессорам.

Для практических расчетов удобно использовать эквивалентную формулу

$$VIF_k = \frac{\operatorname{Var}\left(\hat{\beta}_k \,\middle|\, \mathbf{X}\right)}{\sigma_u^2 (\mathbf{X}_k' \mathbf{X}_k)^{-1}} = \frac{\sigma_u^2 \left[(\mathbf{X}'\mathbf{X})^{-1}\right]_{kk}}{\sigma_u^2 (\mathbf{X}_k' \mathbf{X}_k)^{-1}} = \frac{\left[(\mathbf{X}'\mathbf{X})^{-1}\right]_{kk}}{(\mathbf{X}_k' \mathbf{X}_k)^{-1}}$$