Контрольные и инструментальные переменные

Выбор спецификации модели множественной регрессии

Наша цель — получить несмещенные оценки интересующего нас коэффициента (в нашем случае: несмещенные оценки влияния изменения размера класса на результаты тестов) при постоянстве факторов, на которые мы не можем влиять (в нашем случае: насколько вовлечены в процесс образования родители, посещают ли дети музеи с родителями и т.д.).

В наблюдаемых (не экспериментальных) данных u_i зависит от всех прочих факторов.

- Если мы можем наблюдать эти прочие факторы (в нашем случае: доля детей, для которых английский язык не является родным), то мы включаем эту переменную в регрессию.
- **Очень часто мы не наблюдаем прочие факторы** (в нашем случае: насколько родители вовлечены в образовательный процесс)

Что же делать?

Контрольные переменные

В этом случае можно включить **«контрольные переменные»**, которые коррелированы с пропущенными факторами, влияющими на зависимую переменную, но сами факторами, влияющими на зависимую переменную, могут не являться.

Контрольная переменная W это переменная, которая коррелирована с пропущенным фактором («контролирует на него») в регрессии Y на X, но сама не обязательно влияет на Y (вызывает изменения в Y).

Три характеристики эффективности контрольной переменной:

1. Эффективная контрольная переменная при включении в регрессию делает интересующую нас переменную не коррелированной со случайной ошибкой.
2. В предположении постоянства контрольной(ых) переменной(ых) интересующая нас переменная «как бы» случайно задана.
3. Среди объектов с одинаковыми значениями контрольной(ых) переменной(ых), интересующая нас переменная не коррелирована с пропущенными факторами, влияющими на Y.

Контрольная переменная не обязательно оказывает влияние на зависимую переменную, поэтому коэффициент при ней не имеет стандартной интерпретации.

Пример 1.

$$\widehat{TestScore} = \underset{(5.6)}{700.2} - \underset{(0.27)}{1.00}\, STR - \underset{(0.033)}{0.122}\, PctEL - \underset{(0.024)}{0.547}\, LchPct,\ R^2 = 0.773$$

- *STR* — переменная, которая нас интересует.
- *PctEL* — % школьников в округе, для которых английский язык не является родным; возможно, оказывает прямое влияние (учиться сложнее!). Но это также и контрольная переменная: иммигранты, как правило, не богаты и часто у них нет больших возможностей для получения дополнительного образования ⇒ *PctEL* коррелирована с влияющей переменной. *PctEL — одновременно и контрольная переменная, и, возможно, влияющая переменная*.
- *LchPct* — % школьников в округе, которые получают бесплатный или субсидированный обед (дети из малообеспеченных семей). Может оказывать влияние на зависимую переменную (сытый ребенок лучше учится); она также коррелирована с переменной, характеризующей возможность доп. образования ⇒ *LchPct — одновременно и контрольная переменная, и, возможно, влияющая переменная*.

Имеет ли коэффициент при LchPct стандартную интерпретацию? Если да, то мы можем улучшить результаты тестов просто отменив бесплатные обеды и считая $LchPct = 0$! Влияние отмены бесплатных обедов может быть просто проверено: достаточно провести случайный эксперимент.

Коэффициент при контрольной переменной может быть смещен $\Rightarrow$ 1 предположение МНК $E[u_i \mid X_{1i}, \ldots, X_{ki}] = 0$ не выполняется: например, коэффициент при *LchPct* может быть коррелирован с такой детерминантой результатов тестов как возможность получения доп. образования $\Rightarrow$ смещение из-за пропущенной переменной!!! Но то что *LchPct* коррелирован с этой пропущенной переменной, делает ее хорошей контрольной переменной!

Независимость условного среднего

Исходя из определения контрольной переменной, при ее использовании 1 предположение МНК не выполняется! Что делать?

Пусть X_i — интересующая нас переменная, а W_i — контрольная переменная (или переменные). W_i — **эффективная контрольная переменная**, если выполняется условие независимости условного среднего.

Независимость условного среднего При наличии эффективной контрольной переменной условное среднее u_i **не зависит** от интересующей нас переменной

$$\mathrm{E}[u_i \mid X_i, W_i] = \mathrm{E}[u_i \mid W_i]$$

Если W_i — контрольная переменная, то условие независимости условного среднего заменяет первое предположение МНК и становится 1 - м предположением МНК для случая наличия контрольной переменной в модели.

Рассмотрим модель

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 W_i + u_i$$

где X_i — интересующая нас переменная, а W_i — эффективная контрольная переменная.

Теорема 1. *При выполнении условия независимости условного среднего и 2–4 предположений МНК:*

- β_1 *имеет причинно - следственную интерпретацию,*
- $\hat{\beta}_1$ *не смещена,*
- $\hat{\beta}_2$*, в общем случае, смещена.*

Доказательство.

1. β_1 имеет причинно - следственную интерпретацию: Ожидаемое изменение Y — результат изменения X при постоянстве W, т.е.

$$\mathrm{E}[Y \mid X = x + \Delta x, W = w] - \mathrm{E}[Y \mid X = x, W = w] =$$

$$= \{\beta_0 + \beta_1(x + \Delta x) + \beta_2 w + \mathrm{E}[u \mid X = x + \Delta x, W = w]\} -$$
$$- \{\beta_0 + \beta_1 x + \beta_2 w + \mathrm{E}[u \mid X = x, W = w]\} =$$
$$= \beta_1 \Delta x + \{\mathrm{E}[u \mid X = x + \Delta x, W = w] - \mathrm{E}[u \mid X = x, W = w]\}$$
$$= \beta_1 \Delta x$$

где последнее равенство следует из условия независимости условного среднего.

2. $\hat{\beta}_1$ не смещена, $\hat{\beta}_2$, в общем случае, смещена: Рассмотрим модель

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 W_i + u_i \qquad (1)$$

где u_i удовлетворяет условию независимости условного среднего.

Пусть (для удобства) $\mathrm{E}[u_i \mid X_i, W_i] = \mathrm{E}[u_i \mid W_i] = \gamma_0 + \gamma_2 W_i$. Пусть

$$\nu_i = u_i - \mathrm{E}[u_i \mid X_i, W_i]$$

Тогда $\mathrm{E}[\nu_i \mid X_i, W_i] = 0$.

$$u_i = \mathrm{E}[u_i \mid X_i, W_i] + \nu_i = \gamma_0 + \gamma_2 W_i + \nu_i \qquad (2)$$

Подставляя (2) в (1) получаем

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 W_i + \gamma_0 + \gamma_2 W_i + \nu_i$$

Тогда

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 W_i + u_i =$$
$$= \beta_0 + \beta_1 X_i + \beta_2 W_i + \gamma_0 + \gamma_2 W_i + \nu_i =$$
$$= (\beta_0 + \gamma_0) + \beta_1 X_i + (\beta_2 + \gamma_2) W_i + \nu_i =$$

$$= \delta_0 + \beta_1 X_i + \delta_2 W_i + \nu_i$$

Так как $\mathrm{E}[\nu_i \mid X_i, W_i] = 0$, то уравнение (3) удовлетворяет первому условию МНК $\Rightarrow$ МНК оценки δ_0, β_1 и δ_2 не смещены. Так как регрессоры в (1) и (3) одинаковы, то

$$\mathrm{E}\left[\hat{\beta}_1\right] = \beta_1 \text{ и } \mathrm{E}\left[\hat{\beta}_2\right] = \delta_2 = \beta_2 + \gamma_2 \neq \beta_2$$

□

Таким образом, если W — такая переменная, что выполняется условие независимости условного среднего, то:

1. МНК оценка влияния интересующей нас переменной — $\hat{\beta}_1$ — не смещена.
2. МНК оценка коэффициента при контрольной переменной — $\hat{\beta}_2$ — смещена. Это смещение следует из коррелированности контрольной переменной с пропущенной переменной, поэтому имеем смещение из-за пропущенной переменной.

Экзогенность и эндогенность

Экзогенная переменная переменная, которая не коррелирует со случайной ошибкой (определяется вне модели).

Эндогенная переменная переменная, которая коррелирует со случайной ошибкой (определяется внутри модели).

Смещение из-за пропущенной переменной

Смещение вследствие пропущенных переменных — это смещение в МНК-оценке, которое появляется, если регрессор X коррелирован с пропущенной переменной. Для того, чтобы смещение возникло, должны быть выполнены два условия:

1. Объясняющая переменная X коррелирована с пропущенной переменной,
2. Пропущенная переменная влияет на зависимую переменную Y.

Пример 1. [Процент изучающих английский язык] Коррелирован с соотношением учеников и учителей, влияет на результаты тестов ⇒ Возникает смещение.

Пример 2. [Время проведения теста] Не коррелирован с соотношением учеников и учителей, влияет на результаты тестов ⇒ Смещение не возникает.

Пример 3. [Парковочное пространство на одного ученика] Коррелирован с соотношением учеников и учителей, не влияет на результаты тестов ⇒ Смещение не возникает.

Вспомним, что

$$\hat{\beta}_1 = \beta_1 + \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})u_i}{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Из 2 и 3 предположений МНК и ЗБЧ следует, что

$$\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 \xrightarrow{p} \sigma_x^2$$

$$\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})u_i \xrightarrow{p} \mathrm{Cov}(u_i, x_i) = \rho_{xu}\sigma_u\sigma_x$$

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 + \frac{\rho_{xu}\sigma_u\sigma_x}{\sigma_x^2} = \beta_1 + \underbrace{\rho_{xu}\frac{\sigma_u}{\sigma_x}}_{\substack{\text{величина} \\ \text{смещения}}}$$

где $\rho_{xu} = \mathrm{Corr}(u_i, x_i)$.

- Смещение из-за пропущенных переменных является проблемой, независимо от его величины.
- Величина смещения зависит от величины корреляции.
- Направление смещения зависит от знака корреляции.

Смещение из-за ошибок измерения

Данные ошибки возникают по причине

- ошибок ввода данных,
- ошибок обработки данных,
- «неудобных» вопросов или намеренной лжи.

Ошибки в регрессоре

Введем так называемую *Классическую модель с ошибками измерения*:

$$y_i = \beta_0 + \beta_1 x_i + u_i$$
$$\tilde{x}_i = x_i + \omega_i$$
$$\text{Corr}(\omega_i, x_i) = 0$$
$$\text{Corr}(\omega_i, u_i) = 0$$

Во - первых, если X измерена с ошибкой, то в реальности мы оцениваем следующую модель

$$y_i = \beta_0 + \beta_1 \tilde{x}_i + \underbrace{\beta_i(x_i - \tilde{x}_i) + u_i}_{\nu_i = -\beta_1 \omega_i + u_i}$$

Вспомним, что

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})\nu_i}{\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})^2} = \beta_1 + \frac{\frac{1}{n}\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})\nu_i}{\frac{1}{n}\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})^2}$$

Во - вторых, из свойств оценок следует, что

$$\frac{1}{n}\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})\nu_i \xrightarrow{p} \text{Cov}(\nu, \tilde{x}) = -\beta_1 \sigma_\omega^2$$
$$\frac{1}{n}\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})^2 \xrightarrow{p} \sigma_{\tilde{x}}^2 = \sigma_x^2 + \sigma_\omega^2$$

Отсюда

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 - \beta_1 \frac{\sigma_\omega^2}{\sigma_x^2 + \sigma_\omega^2}$$

То есть $\hat{\beta}_1$ смещена вниз относительно β_1, разумеется, по абсолютному значению.

Как можно это исправить:

- Найти точную меру x;
- Регрессия с инструментальными переменными. В основе лежит использование другой переменной, которая коррелирована с фактическим значением, но некоррелирована с ошибками измерения.
- Разработка математической модели с ошибками измерения и, если возможно, в использовании полученных формул для коррекции оценок.

Ошибки в регрессанде

Пусть

$$\tilde{y}_i = y_i + \omega_i$$
$$\mathrm{E}(\omega_i) = 0$$
$$(\omega_i, x_i) \sim \text{i.i.d.}$$
$$\mathrm{E}(\omega \mid x_i) = 0$$

Тогда

$$\tilde{y}_i = \beta_0 + \beta_1 x_i + \underbrace{u_i + \omega_i}_{\nu_i}$$

Отсюда имеем

$$\mathrm{E}(\omega_i \mid x_i) = 0 \Rightarrow \mathrm{E}(\nu_i \mid x_i) = \mathrm{E}(u_i \mid x_i) + \mathrm{E}(\omega_i \mid x_i) = 0$$

То есть $\hat{\beta}_1$ — несмещенная оценка. Но

$$\mathrm{Var}(\nu_i) = \mathrm{Var}(u_i) + \mathrm{Var}(\omega_i) > \mathrm{Var}(u_i)$$

То есть $\hat{\beta}_1$ — не эффективная оценка.

Смещение из-за одновременной причинности

Одной из причин возникновения эндогенности является ситуация, когда не только X влияет на Y, но и наоборот. Данная ситуация называется «одновременной причинностью». В этом случае возникает корреляция между регрессором и ошибкой и, соответственно, смещение.

Рассмотрим следующую модель

$$\begin{cases} y_i = \beta_0 + \beta_1 x_i + u_i \\ x_i = \gamma_0 + \gamma_1 y_i + \nu_i \end{cases}$$

$$\mathrm{Cov}(u_i, \nu_i) = 0$$

Отсюда нетрудно получить

$$\begin{aligned} \mathrm{Cov}(x_i, u_i) &= \mathrm{Cov}(\gamma_0 + \gamma_1 y_i + \nu_i, u_i) = \\ &= \mathrm{Cov}(\gamma_1(\beta_0 + \beta_1 x_i + u_i), u_i) = \\ &= \gamma_1 \beta_1 \,\mathrm{Cov}(x_i, u_i) + \gamma_1 \sigma_u^2 \end{aligned}$$

то есть

$$\mathrm{Cov}(x_i, u_i) = \frac{\gamma_1}{1 - \gamma_1 \beta_1} \sigma_u^2$$

Поэтому

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 + \frac{\gamma_1}{1 - \gamma_1 \beta_1} \frac{\sigma_u^2}{\sigma_x^2}$$

Как можно это исправить:

- Регрессия с инструментальными переменными.
- Системы одновременных уравнений.
- Случайный управляемый эксперимент.

Метод инструментальных переменных

Предложен Филиппом Райтом (Wright 1928). Позволяет получить *состоятельные* оценки коэффициентов при наличии корреляции между регрессором и случайной ошибкой.

Парная регрессия с инструментальной переменной

$$y_i = \beta_0 + \beta_1 x_i + u_i, i = 1, \dots, n$$
$$\text{Corr}(u_i, x_i) \neq 0$$

$\hat{\beta}_1$ — смещенная и несостоятельная оценка β_1. Что можно сделать?

Райт предложил ввести *инструмент* z_i, позволяющий «изолировать» часть x_i, коррелированную с u_i. Инструментальная переменная z_i называется *подходящей* или *допустимой*, если она удовлетворяет условиям:

1. релевантности, то есть инструмент должен быть коррелирован с эндогенной переменной: $\text{Corr}(z_i, x_i) \neq 0$;

2. экзогенности, то есть инструмент не должен быть коррелирован со случайной ошибкой: $\text{Corr}(u_i, z_i) = 0$.

Двухшаговый МНК

Шаг 1 Разложим x_i на 2 части: коррелированную и некоррелированную с ошибкой.

$$x_i = \pi_0 + \pi_1 z_i + \nu_t$$

$$\hat{x}_i = \hat{\pi}_0 + \hat{\pi}_1 z_i$$

Так как $\text{Corr}(u_i, z_i) = 0$, и поскольку $\hat{x}_i$ полностью определяется z_i, имеем $\text{Corr}(u_i, \hat{x}_i) = 0$. Отметим, что

$$\hat{\pi}_1 = \frac{\sum_{i=1}^{N}(z_i - \bar{z})(x_i - \bar{x})}{\sum_{i=1}^{N}(z_i - \bar{z})^2}$$

$$\hat{x}_i = \bar{x} + \hat{\pi}_1(z_i - \bar{z})$$

$$\bar{\hat{x}} = \bar{x}$$

Шаг 2 Заменим в исходной модели x_i на $\hat{x}_i$

$$y_i = \beta_0 + \beta_1 \hat{x}_i + u_i$$

Так как $\hat{x}_i$ не коррелирует с ошибкой, то для данной регрессии будут выполняться все предпосылки МНК. Имеем

$$\hat{\beta}_1^{\text{TSLS}} = \frac{\sum_{i=1}^{N}(\hat{x}_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{N}(\hat{x}_i - \bar{x})^2} =$$

$$= \frac{\sum_{i=1}^{N}[\hat{\pi}_1(z_i - \bar{z})](y_i - \bar{y})}{\sum_{i=1}^{N}[\hat{\pi}_1(z_i - \bar{z})]^2} =$$

$$= \frac{\sum_{i=1}^{N}(z_i - \bar{z})(y_i - \bar{y})}{\hat{\pi}_1 \sum_{i=1}^{N}(z_i - \bar{z})^2} =$$

$$= \frac{\sum_{i=1}^{N}(z_i - \bar{z})^2 \sum_{i=1}^{N}(z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^{N}(z_i - \bar{z})(x_i - \bar{x}) \sum_{i=1}^{N}(z_i - \bar{z})^2} =$$

$$= \frac{\sum_{i=1}^{N}(z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^{N}(z_i - \bar{z})(x_i - \bar{x})} = \frac{s_{zy}}{s_{zx}}$$

Выборочное распределение оценки

Для случая *парной* регрессии с *одним* допустимым инструментом в больших выборках имеем

$$\hat{\beta}_1^{\text{TSLS}} = \frac{s_{zy}}{s_{zx}} \xrightarrow{p} \frac{\text{Cov}(z_i, y_i)}{\text{Cov}(z_i, x_i)} = \beta_1$$

На больших выборках $\hat{\beta}_1^{\text{TSLS}} \sim N\left(\beta_1, \sigma^2_{\hat{\beta}_1^{\text{TSLS}}}\right), \sigma^2_{\hat{\beta}_1^{\text{TSLS}}} = \frac{1}{n}\frac{\text{Var}[(z_i - \mu_z)u_i]}{[\text{Cov}(z_i, x_i)]^2} \Rightarrow$ можем использовать t - статистики и т.д.

Обобщенная регрессия с инструментальными переменными

Также как и в случае парной регрессии, мы можем перейти к модели с несколькими регрессорами и инструментальными переменными.

$$y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_{m_x} x_{m_x i} + \beta_{m_x+1} w_{1i} + \cdots + \beta_{m_x+m_w} w_{m_w i} + u_i, i = 1, \ldots, n$$

- y_i — зависимая переменная,
- $x_{1i}, \ldots, x_{m_x i}$ — эндогенные регрессоры, которые могут коррелировать с u_i,

- $w_{1i}, \ldots, w_{m_w i}$ — экзогенные регрессоры, не коррелированные с u_i,
- u_i — ошибка регрессии,
- $z_{1i}, \ldots, z_{m_z i}$ — инструментальные переменные.

Если

- $m_z = m_x$ — коэффициенты регрессии *точно определены*,
- $m_z > m_x$ — коэффициенты регрессии *переопределены*,
- $m_z < m_x$ — коэффициенты регрессии *недоопределены*.

Мы можем оценивать обобщенную регрессию с инструментальными переменными, только если коэффициенты точно или переопределены, в противном случае мы получим модель с мультиколлинеарностью.

Инструменты z_{ji} для допустимости должны удовлетворять двум требованиям:

1. релевантность — переменные $\hat{x}_{1i}, \ldots, \hat{x}_{m_x i}, w_{1i}, \ldots, w_{m_w i}$ и константа не должны быть совершенно мультиколлинеарными,
2. экзогенность — инструменты не должны быть коррелированы с ошибкой: $\mathrm{Corr}(u_i, z_{ji}) = 0$.

Если $k = 1$, то для релевантности необходимо, чтобы в регрессии первого шага был хотя бы один ненулевой коэффициент.

Двухшаговый МНК

Шаг 1 «очистка» эндогенных переменных: оцениваем при помощи МНК регрессии **каждого** x_{ji} на константу, все инструменты z_{ji} и все экзогенные переменные w_{ji}. В результате получаем «очищенные» подобранные значения $\hat{x}_{ji}$. На практике производится оценивание модели вида

$$\mathbb{X} = \mathbb{Z}\mathbf{\Pi} + \mathbf{e}$$

где $\mathbb{X} = [\mathbf{X}, \mathbf{W}]$ — матрица, включающая в себя эндогенные $\mathbf{X}$ и *экзогенные* переменные $\mathbf{W}$ (в том числе свободный член); $\mathbb{Z} = [\mathbf{W}, \mathbf{Z}]$ — матрица, включающая в себя экзогенные (в том числе свободный член) и инструментальные переменные. Включение экзогенных переменных в матрицу $\mathbf{X}$ не противоречит приведенному выше описанию первого шага, так как при получении МНК - оценок

$$\hat{\mathbf{\Pi}} = (\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}'\mathbb{X}$$

в соответствующем столбце матрицы оцененных коэффициентов $\hat{\mathbf{\Pi}}$ будут нули с единственной единицей, соответствующей экзогенной переменной. Это видно на следующем простейшем примере[1]:

[1] К сожалению, Numpy поддерживает и поощряет неаккуратное отношение к размерностям перемножаемых массивов. В частности, в нашем случае на определенном этапе мы перемножаем двумерную матрицу с одномерным массивом, получая на выходе одномерный

```
import numpy as np
np.random.seed(31415926)

# 150 нормально распределенных значений с дисперсией
0.01.
u = np.random.normal(size=150, scale=0.1)

# Матрица 150 x 3, первый столбец состоит из единиц,
# второй и третий столбцы --- N(0, 1).
Z = np.empty((150, 3))
Z[:, 0] = 1.
Z[:, 1:] = np.random.normal(size=(150, 2))

# Матрица 150 x 3.
# Второй и третий столбцы Z и X совпадают.
# Первый столбец равен:
# X = 0.5 + 1. * Z[1] + 2. * Z[2] + u
X = Z.copy()
X[:, 0] = Z @ np.array([0.5, 1, 2]) + u

print(np.round(np.linalg.inv(Z.T @ Z) @ Z.T @ X, 6))
```

```
[[ 0.499924 -0.       -0.      ]
 [ 1.000069  1.        0.      ]
 [ 1.988546  0.        1.      ]]
```

Обратите внимание на оцененные коэффициенты, близкие к заданным нами, в первом столбце и нули с единицами во втором и третьем столбцах. Подобранные значения равны

массив. Это может помочь вам «выстрелить себе в ногу» , будьте внимательны!

$$\hat{\mathbb{Z}} = \mathbb{Z}\hat{\mathbf{\Pi}} = \mathbb{Z}(\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}'\mathbb{X} = \mathbf{P}_{\mathbb{Z}}\mathbb{X}$$

Отметим, что матрица $\mathbf{P}_{\mathbb{Z}}$ симметрична и идемпотентна, то есть

$$\mathbf{P}_{\mathbb{Z}}\mathbf{P}_{\mathbb{Z}} = \mathbb{Z}(\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}'\mathbb{Z}(\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}' = \\ = \mathbb{Z}(\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}' = \mathbf{P}_{\mathbb{Z}}$$

что интуитивно понятно: так как матрица $\mathbf{P}_{\mathbb{Z}}$ дает проекцию на подпростанство, определяемое $\mathbb{Z}$, то $\mathbf{P}_{\mathbb{Z}}\mathbf{P}_{\mathbb{Z}}$ является попыткой построить проекцию проекции, равную себе самой.

Шаг 2 при помощи МНК оцениваем

$$y_i = \beta_0 + \beta_1\hat{x}_{1i} + \cdots + \beta_{m_x}\hat{x}_{m_x i} + \beta_{m_x+1}w_{1i} + \cdots + \beta_{k+r}w_{ri} + u_i$$

или

$$\mathbf{y} = \hat{\mathbb{Z}}\boldsymbol{\beta} + \mathbf{u}$$

С учетом сказанного выше оценка $\hat{\boldsymbol{\beta}}^{\text{TSLS}}$ равна

$$\hat{\boldsymbol{\beta}}^{\text{TSLS}} = \left(\hat{\mathbb{X}}'\hat{\mathbb{Z}}\right)^{-1}\hat{\mathbb{X}}'\mathbf{y} = \\ = (\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbb{X})^{-1}\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbf{y} = *$$

Если модель определена *точно*, то матрицы $\mathbb{X}'\mathbb{Z}$ и $\mathbb{Z}'\mathbb{X}$ квадратные и, следовательно, потенциально обратимые. В этом случае выражение для $\hat{\boldsymbol{\beta}}^{\text{TSLS}}$ можно упростить

$$* = \left[\mathbb{X}'\mathbb{Z}(\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}'\mathbb{Z}\right]^{-1}\mathbb{X}'\mathbb{Z}(\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}'\mathbf{y} =$$

$$= (\mathbb{Z}'\mathbb{X})^{-1}(\mathbb{Z}'\mathbb{Z})(\mathbb{X}'\mathbb{Z})^{-1}(\mathbb{X}'\mathbb{Z})(\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}'\mathbf{y} =$$
$$= (\mathbb{Z}'\mathbb{X})^{-1}\mathbb{Z}'\mathbf{y}$$

Ковариационная матрица $\hat{\boldsymbol{\beta}}^{\text{TSLS}}$ примерно равна (Цыплаков 2007)

$$\operatorname{Var}\hat{\boldsymbol{\beta}}^{\text{TSLS}} \approx \hat{\sigma}_u^2\left(\hat{\mathbb{X}}'\hat{\mathbb{Z}}\right)^{-1} = \hat{\sigma}_u^2(\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbb{X})^{-1}$$

где $\hat{\sigma}_u^2$ — оценка дисперсии $\operatorname{Var}[u]_t$. Для оценивания $\hat{\sigma}_u^2$ нельзя использовать остатки второго шага 2МНК, остатки нужно рассчитывать самостоятельно как $\hat{\mathbf{u}} = \mathbf{y} - \mathbb{X}\hat{\boldsymbol{\beta}}^{\text{TSLS}}$.

На больших выборках имеем

$$\hat{\boldsymbol{\beta}}^{\text{TSLS}} = (\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbb{X})^{-1}\mathbb{X}'\mathbf{P}_{\mathbb{Z}}(\mathbb{X}\boldsymbol{\beta} + \mathbf{u}) = \boldsymbol{\beta} + (\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbb{X})^{-1}\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbf{u}$$

$$\frac{1}{n}\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbb{X} \xrightarrow[n\to\infty]{p} \boldsymbol{\Sigma}_{\hat{X}}$$

$$\frac{1}{n}\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbf{u} \xrightarrow[n\to\infty]{p} \boldsymbol{\Sigma}_{\hat{X}u} = \mathbf{0}$$

$$\hat{\boldsymbol{\beta}}^{\text{TSLS}} \xrightarrow[n\to\infty]{p} = \boldsymbol{\beta}$$

Предположения обобщенной регрессии с инструментальными переменными

1. $\mathrm{E}\left[u_i \mid w_{1i}, \ldots, w_{m_w i}\right] = 0$;
2. $\left(x_{1i}, \ldots, x_{m_x i}, w_{1i}, \ldots, w_{m_w i}, z_{1i}, \ldots, z_{m_z i}, y_i\right) \sim$ i.i.d.;
3. Большие выбросы маловероятны: $x_{ij}, y_i, z_{ij}, w_{ij}$ имеют ненулевые конечные четвертые моменты;

4. **Выполняются условия допустимости инструментов.**

При выполнении этих предположений IV-оценки коэффициентов состоятельны и нормально распределены в больших выборках.

Тестирование

Тестирование гипотез о коэффициентах

Для тестирования гипотез о коэффициентах, в силу того, что оценки имеют асимптотически нормальное распределение, можно использовать статистику Вальда (Цыплаков 2007)

$$W = (\mathbf{R}\boldsymbol{\beta}_{\text{IV}} - \mathbf{r})'\left[\mathbf{R}\,\widehat{\text{Var}}(\boldsymbol{\beta}_{\text{IV}})\mathbf{R}'\right]^{-1}(\mathbf{R}\boldsymbol{\beta}_{\text{IV}} - \mathbf{r}) \sim \chi^2_r$$

где $\widehat{\text{Var}}\left(\hat{\boldsymbol{\beta}}_{\text{IV}}\right) = \hat{\sigma}^2_u(\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbb{X})^{-1} = \hat{\sigma}^2_u\left(\hat{\mathbb{X}}'\hat{\mathbb{X}}\right)^{-1}$, r — число ограничений.

Если $r = 1$, то удобнее воспользоваться z - статистикой, имеющей асимптотически нормальное распределение. Например, для гипотезы $\beta_j = \beta_j^*$

$$z = \frac{\beta_j - \beta_j^*}{\sqrt{\widehat{\text{Var}}\,(\boldsymbol{\beta}_{\text{IV}})_{jj}}} \sim N(0,1)$$

Тестирование спецификации — тест Дарбина-Ву-Хаусмана

Очевидно, что если в модели нет эндогенных регрессоров, то использование метода инструментальных переменных лишено смысла, так как обычные МНК оценки будут более точными. В этом случае, записав регрессии первого шага как

$$\mathbf{x} = \mathbf{z}^*\mathbf{\Pi} + \mathbf{v}$$

где $\mathbf{x}$, $\mathbf{z}^*$, $\mathbf{v}$ — соответствующие друг-другу строки соответствующих матриц. Отсюда следует, что если $\mathbf{x}$ не коррелирует с u, то $\mathsf{E}[\mathbf{v}u] = \mathbf{0}$. Из последнего следует, что в модели

$$u = \mathbf{v}\boldsymbol{\tau} + \zeta$$

$\boldsymbol{\tau} = \mathbf{0}$. Итого имеем

$$y = \mathbf{x}\boldsymbol{\beta}^x + \mathbf{w}\boldsymbol{\beta}^w + \mathbf{v}\boldsymbol{\tau} + \zeta = \mathbf{x}^*\boldsymbol{\beta} + \mathbf{v}\boldsymbol{\tau} + \zeta$$

Таким образом, тестирование спецификации можно провести по следующей процедуре (Цыплаков 2007):

1. Оценим регрессию $\mathbf{X}$ на $\mathbb{Z}$ и получаем остатки $\hat{\mathbf{V}} = \mathbf{M}_{\mathbb{Z}}\mathbf{X}$;
2. Строим регрессию $\mathbf{y} = \mathbb{X}\boldsymbol{\beta} + \hat{\mathbf{V}}\boldsymbol{\tau} + \boldsymbol{\zeta}$ и тестируем при помощи стандартной F - статистики гипотезу $\boldsymbol{\tau} = \mathbf{0}$. Если мы не можем отвергнуть эту гипотезу, то следует использовать обычный МНК.

В изначальном своем виде статистика теста имеет вид (Hausman 1978)

$$H = \left(\hat{\boldsymbol{\beta}}_{\text{IV}} - \hat{\boldsymbol{\beta}}_{\text{OLS}}\right)' \widehat{\text{Var}}\left(\hat{\boldsymbol{\beta}}_{\text{IV}} - \hat{\boldsymbol{\beta}}_{\text{OLS}}\right)^{-1}\left(\hat{\boldsymbol{\beta}}_{\text{IV}} - \hat{\boldsymbol{\beta}}_{\text{OLS}}\right) \sim \chi^2_{m_x}$$

Оценка $\widehat{\text{Var}}\left(\hat{\boldsymbol{\beta}}_{\text{IV}} - \hat{\boldsymbol{\beta}}_{\text{OLS}}\right)$ имеет вид

$$\widehat{\text{Var}}\left(\hat{\boldsymbol{\beta}}_{\text{IV}} - \hat{\boldsymbol{\beta}}_{\text{OLS}}\right) = \widehat{\text{Var}}\left(\hat{\boldsymbol{\beta}}_{\text{IV}}\right) - \widehat{\text{Var}}\left(\hat{\boldsymbol{\beta}}_{\text{OLS}}\right)$$

Оценки ковариационных матриц можно рассчитать по формулам

$$\widehat{\text{Var}}\left(\hat{\boldsymbol{\beta}}_{\text{OLS}}\right) = \hat{\sigma}^2_u(\mathbb{X}'\mathbb{X})^{-1}$$

$$\widehat{\text{Var}}\left(\hat{\boldsymbol{\beta}}_{\text{IV}}\right) = \hat{\sigma}^2_u(\mathbb{X}'\mathbf{P}_{\mathbb{Z}}\mathbb{X})^{-1} = \hat{\sigma}^2_u\left(\hat{\mathbb{X}}'\hat{\mathbb{X}}\right)^{-1}$$

где $\hat{\sigma}^2_u$ — оценка дисперсии ошибок, рассчитанная либо на основе МНК оценок (что является более предпочтительным способом), либо на основе IV-оценок.

Тестирование слабых инструментов

Слабые инструменты — объясняющие малую часть изменений X. В этом случае 2МНК оценки имеют смещение и не имеют нормального распределения. Если в модели всего *один* эндогенный регрессор, то для проведения теста на слабость инструментов достаточно провести тестирование гипотезы о равенстве нулю всех коэффициентов при инструментах в регрессии первого шага 2МНК.

Если соответствующая F - статистика *меньше* 10, то набор инструментов — слабый (Цыплаков 2007).

Если же эндогенных инструментов *больше* одного, то рассмотрения отдельных регрессий первого шага может оказаться недостаточно. Для этого случая Крэг и Дональд (Cragg и Donald 1993) предложили рассматривать собственные значения следующей матрицы (Цыплаков 2007):

$$\hat{\mathbf{\Sigma}}_{ee}^{-1/2}\mathbf{X}'(\mathbf{M}_{\mathbf{W}} - \mathbf{M}_{\mathbb{Z}})\mathbf{X}\hat{\mathbf{\Sigma}}_{ee}^{-1/2}/m \tag{3}$$

где $\hat{\mathbf{\Sigma}}_{ee} = \dfrac{\mathbf{X}'\mathbf{M}_{\mathbb{Z}}\mathbf{X}}{N - (m_z + m_w)}$ — ковариационная матрица регрессий первого шага 2МНК, не включающих экзогенные регрессоры в качестве объясняемых переменных. В работе Стока и Його (Stock и Yogo 2005) приведена эквивалентная формула

$$\hat{\mathbf{\Sigma}}_{ee}^{-1/2}\mathbf{X}^{\perp\prime}\mathbf{P}_{Z^{\perp}}\mathbf{X}^{\perp}\hat{\mathbf{\Sigma}}_{ee}^{-1/2} \tag{4}$$

где элементы с индексом $\perp$ являются остатками соответствующих регрессий на $\mathbf{W}$. Тестовой статистикой в этом случае является *минимальное* собственное значение матрицы, критические значения для которой приведены в (Stock и Yogo 2005).

Тестирование сверхидентифицирующих ограничений — тест Саргана

Пусть $\hat{u}_i^{TSLS}$ — остатки 2МНК регрессии, полученные с использованием $\mathbb{X}$,

$$\hat{\mathbf{u}}^{TSLS} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}^{TSLS}$$

Оценим вспомогательную регрессию

$$\hat{\mathbf{u}}^{TSLS} = \mathbb{Z}\begin{pmatrix}\boldsymbol{\gamma}\\ \boldsymbol{\delta}\end{pmatrix} + \mathbf{e} = \mathbf{W}\boldsymbol{\gamma} + \mathbf{Z}\boldsymbol{\delta} + \mathbf{e}$$

Рассмотрим F - статистику для тестирования ограничения $\boldsymbol{\delta} = \mathbf{0}$. Тогда

$$J = m_z F \sim \chi^2(m_z - m_x)$$

является статистикой для тестирования сверхидентифицирующих ограничений, $m_z - m_x$ — «степень сверхидентификации» (Картаев 2019). Другой возможной статистикой является (Verbeek 2017)

$$J = TR^2 \sim \chi^2(m_z - m_x)$$

где R^2 — коэффициент детерминации оцененной выше вспомогательной регрессии.

Если значение той или иной статистики «слишком большое», то это означает, что *некоторые* из использованных инструментов на самом деле *эндогенны*. Очевидно, что тест можно провести только в случае *переопределенной* модели.

Библиография

[1] P. G. Wright, *The Tariff on Animal and Vegetable Oils*, вып. 26. Macmillan, 1928.

[2] А. Цыплаков, «Экскурс в мир инструментальных переменных», *Квантиль*, т. 2, сс. 21–48, мар. 2007.

[3] J. A. Hausman, «Specification Tests in Econometrics», *Econometrica*, т. 46, вып. 6, сс. 1251–1271, 1978, doi: 10.2307/1913827.

[4] J. G. Cragg и S. G. Donald, «Testing Identifiability and Specification in Instrumental Variable Models», *Econometric Theory*, т. 9, вып. 2, сс. 222–240, апр. 1993, doi: 10.1017/S0266466600007519.

[5] J. H. Stock и M. Yogo, «Testing for weak instruments in Linear Iv regression», в *Identification and Inference for Econometric Models: Essays in Honor of Thomas Rothenberg*, D. W. K. Andrews, Ред., Cambridge University Press, 2005, сс. 80–108. doi: 10.1017/CBO9780511614491.006.

[6] Ф. С. Картаев, *Введение в эконометрику*. Москва: Экономический факультет МГУ имени М. В. Ломоносова, 2019.

[7] M. Verbeek, *A Guide to Modern Econometrics*, Fifth edition. Hoboken, NJ: Wiley, 2017.

А Доказательство эквивалентности формул (3) и (4)

В данных формулах множитель $\hat{\mathbf{\Sigma}}_{ee}^{-1/2}$ совпадает, поэтому, для краткости, опустим его. Рассмотрим

$$\mathbf{M_W} - \mathbf{M}_{\mathbb{Z}} = \mathbf{P}_{\mathbb{Z}} - \mathbf{P}_{W}$$

Значение $\mathbf{P}_{W}$ найти очень легко

$$\mathbf{P}_{W} = \mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'$$

Рассмотрим P_{Z}

$$= \mathbb{Z}(\mathbb{Z}'\mathbb{Z})^{-1}\mathbb{Z}' =$$

$$= (\mathbf{W} \quad \mathbf{Z})\begin{pmatrix}\mathbf{W}'\mathbf{W} & \mathbf{W}'\mathbf{Z}\\ \mathbf{Z}'\mathbf{W} & \mathbf{Z}'\mathbf{Z}\end{pmatrix}^{-1}\begin{pmatrix}\mathbf{W}'\\ \mathbf{Z}'\end{pmatrix} =$$

$$= (\mathbf{W} \quad \mathbf{Z})\begin{pmatrix}(\mathbf{W}'\mathbf{W})^{-1} + (\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1} & -(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\\ -(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1} & (\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\end{pmatrix}\begin{pmatrix}\mathbf{W}'\\ \mathbf{Z}'\end{pmatrix} =$$

$$= \mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}' + \mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}' - \mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}' -$$
$$-\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}' + \mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'$$

$$\begin{aligned}\mathbf{M_W} - \mathbf{M}_{\mathbb{Z}} &= \mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}' - \mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}' -\\ &\quad -\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}' + \mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}' =\\ &= \mathbf{M_W}\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}' - \mathbf{M_W}\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{P}_{W} =\\ &= \mathbf{M_W}\mathbf{Z}(\mathbf{Z}'\mathbf{M_W}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{M_W} =\\ &= \mathbf{M_W}\mathbf{Z}^{\perp}(\mathbf{Z}^{\perp\prime}\mathbf{Z}^{\perp})^{-1}\mathbf{Z}^{\perp\prime}\mathbf{M_W} =\\ &= \mathbf{M_W}\mathbf{P}_{Z^{\perp}}\mathbf{M_W} \qquad (5)\end{aligned}$$

Последние преобразования основаны на свойстве идемпотентности матрицы $\mathbf{M_W}$. Если подставить (5) в (3) мы получим (4).