Модели дискретного выбора

Рассмотрим модели, в которых объясняемая переменная может принимать два значения (или несколько значений).

Линейная модель вероятности

Простейшая модель, имеющая вид

$$\mathbf{y} = \mathbf{X\beta} + \mathbf{u}$$

где $\mathbf{y}$ принимает значения 0 или 1, и $\mathrm{E}(\mathbf{u}) = \mathbf{0}$.

Условное математическое ожидание i-го наблюдения равно

$$\mathrm{E}(\mathbf{y}_i \mid \mathbf{x}_i) = \mathbf{x}_i'\boldsymbol{\beta}$$

Данное математическое ожидание следует интерпретировать как вероятность $\mathrm{P}(y_i = 1)$ (Pierse 2021).

В этом месте возникает первая проблема линейной модели:

> Линейная модель вероятности не может гарантировать того, что условное математическое ожидание будет ограничено между 0 и 1!

Более того, так как y_i принимает только два значения: 0 и 1 — то ошибка u_i также принимает только два значения

$$u_i = \begin{cases} -\mathbf{x}_i'\boldsymbol{\beta} & \text{если } y_i = 0 \\ 1 - \mathbf{x}_i'\boldsymbol{\beta} & \text{если } y_i = 1 \end{cases}$$

Из условия $\mathrm{E}(u_i) = 0$ следует, что

$$\mathrm{P}(-\mathbf{x}_i'\boldsymbol{\beta}) + (1 - p)(1 - \mathbf{x}_i'\boldsymbol{\beta}) = 0$$
$$1 - p - \mathbf{x}_i'\boldsymbol{\beta} = 0$$
$$\mathrm{P} = 1 - \mathbf{x}_i'\boldsymbol{\beta}$$

то есть $\mathrm{P}(-\mathbf{x}_i'\boldsymbol{\beta}) = 1 - \mathbf{x}_i'\boldsymbol{\beta}$ и $\mathrm{P}(1 - \mathbf{x}_i'\boldsymbol{\beta}) = \mathbf{x}_i'\boldsymbol{\beta}$. Отсюда легко увидеть, что

$$\begin{aligned} \mathrm{Var}[u_i] &= \sum u_i^2 \, \mathrm{P}(u_i) = \\ &= (-\mathbf{x}_i'\boldsymbol{\beta})^2(1 - \mathbf{x}_i'\boldsymbol{\beta}) + (1 - \mathbf{x}_i'\boldsymbol{\beta})^2\mathbf{x}_i'\boldsymbol{\beta} = \\ &= \mathbf{x}_i'\boldsymbol{\beta}(1 - \mathbf{x}_i'\boldsymbol{\beta}) \end{aligned}$$

то есть дисперсия ошибки *гетероскедастична*, и МНК оценки будут неэффективными.

Если рассмотреть подобранные значения

$$\hat{y}_i = \mathbf{x}_i'\hat{\boldsymbol{\beta}}$$

то оценкой дисперсии $\mathrm{Var}[u_i]$ будет $\hat{\sigma}_i^2 = \hat{y}_i(1 - \hat{y}_i)$. Используя эти оценки, можно построить матрицу

$$\mathbf{L} = \begin{pmatrix} \frac{1}{\hat{\sigma}_1} & & \\ & \ddots & \\ & & \frac{1}{\hat{\sigma}_N} \end{pmatrix}$$

которую следует использовать для доступного ВМНК.

> Как уже было сказано ранее, линейная модель вероятности не может гарантировать того, что условное математическое ожидание будет ограничено между 0 и 1. Нетрудно убедиться, что в этом случае $\hat{\sigma}_i^2 < 0$.

Пробит, логит и другие подобные модели

Давайте рассмотрим немного другой подход к проблеме. Предположим, что у нас есть некоторая *латентная*[1] переменная $\mathbf{y}^*$, для которой построена модель регрессии

$$\mathbf{y}^* = \mathbf{X\beta} + \mathbf{u} \tag{1}$$

При этом *наблюдаемая* переменная $\mathbf{y}$ связана с ней следующим простым соотношением

$$\mathbf{y} = \begin{cases} 1 & \text{если } \mathbf{y}^* > 0, \\ 0 & \text{если } \mathbf{y}^* \leqslant 0 \end{cases} = \mathbb{I}[\mathbf{y}^* > 0] \tag{2}$$

Как отмечает Пирс (Pierse 2021), у нас нет никаких оснований считать, что $\mathbf{u}$ и, соответственно, $\mathbf{y}^*$ не имеют какого-либо непрерывного распределения F. Более того, так как формула (2) не зависит от масштаба переменной $\mathbf{y}^*$, то мы можем принять любую удобную для нас нормировку, например $\mathrm{Var}[u_i] = 1$.

[1] Скрытая и ненаблюдаемая.

Из формул (1) и (2) следует, что

$$\begin{aligned} P_i = \mathrm{P}(y_i = 1) &= \mathrm{P}(y_i^* > 0) = \\ &= \mathrm{P}(u_i > -\mathbf{x}_i'\boldsymbol{\beta}) = \\ &= 1 - \mathrm{P}(u_i \leqslant -\mathbf{x}_i'\boldsymbol{\beta}) = \\ &= 1 - F(-\mathbf{x}_i'\boldsymbol{\beta}) \end{aligned}$$

где F — кумулятивная функция распределения[2]

$$F(x) = \int_{-\infty}^{x} f(u)\,\mathrm{d}u$$

Если в качестве распределения ошибок используется какое-либо симметричное распределение — нормальное, Стьюдента и так далее — то последняя формула упрощается до

$$\mathrm{P}(y_i = 1) = F(\mathbf{x}_i'\boldsymbol{\beta})$$

В свете сказанного выше понятно, что y_i имеет биномиальное распределение, а функция правдоподобия будет иметь вид

$$L(\mathbf{y}) = \prod_{y_i=1} P_i \prod_{y_i=0} (1 - P_i)$$

Если **u** будет иметь (Носко 2021)

- нормальное распределение с

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} \exp\left\{-\frac{u^2}{2}\right\} \mathrm{d}u,$$

[2]Мы ее знаем как просто функцию распределения.

то полученная модель будет называться *пробит моделью*;

- логистическое распределение с

$$\Lambda(x) = \frac{\exp\{x\}}{1 + \exp\{x\}} = \frac{1}{1 + \exp\{-x\}},$$

то полученная модель будет называться *логит моделью*;

- распределение Гомпертца с

$$G(x) = 1 - \exp\{-e^x\},$$

то полученная модель будет называться *гомпит моделью*.

Интерпретация коэффициентов

Так как описанный выше модели являются нелинейными по параметрам, то их интерпретация в традиционном смысле будет затруднительной.

Рассмотрим пробит модель

$$P_i = \mathrm{P}(y_i = 1) = \Phi(\mathbf{x}_i'\boldsymbol{\beta})$$

Посчитаем предельный эффект от изменения регрессора x_{ij}

$$\frac{\partial P_i}{\partial x_{ij}} = \varphi(\mathbf{x}_i'\boldsymbol{\beta})\beta_j$$

Нетрудно увидеть, что, во-первых, он не равен β_j как в случае с линейными моделями, и, во-вторых, предельный эффект зависит от того, в какой точке он считается.

Рассмотрим теперь логит модель

$$P_i = \mathrm{P}(y_i = 1) = \Lambda(\mathbf{x}_i'\boldsymbol{\beta})$$

которая несложными преобразованиями приводится к следующему виду

$$\ln \frac{P_i}{1 - P_i} = \mathbf{x}_i'\boldsymbol{\beta}$$

то есть натуральный логарифм *соотношения шансов* в для логит модели линеен относительно $\mathbf{x}_i$. Предельный эффект же для логит модели равен

$$\begin{aligned}
\frac{\partial P_i}{\partial x_{ij}} &= \lambda(\mathbf{x}_i'\boldsymbol{\beta})\beta_j = \frac{\partial}{\partial x_{ij}}\left[\frac{\exp\{\mathbf{x}_i'\boldsymbol{\beta}\}}{1 + \exp\{\mathbf{x}_i'\boldsymbol{\beta}\}}\right] = \\
&= \frac{\exp\{\mathbf{x}_i'\boldsymbol{\beta}\}(1 + \exp\{\mathbf{x}_i'\boldsymbol{\beta}\})\beta_j - \exp\{\mathbf{x}_i'\boldsymbol{\beta}\}^2\beta_j}{(1 + \exp\{\mathbf{x}_i'\boldsymbol{\beta}\})^2} = \\
&= \frac{\exp\{\mathbf{x}_i'\boldsymbol{\beta}\}}{(1 + \exp\{\mathbf{x}_i'\boldsymbol{\beta}\})^2}\beta_j = \frac{1}{1 + \exp\{\mathbf{x}_i'\boldsymbol{\beta}\}}\left(1 - \frac{1}{1 + \exp\{\mathbf{x}_i'\boldsymbol{\beta}\}}\right)\beta_j = \\
&= P_i(1 - P_i)\beta_j
\end{aligned}$$

Меры качества моделей

Для рассмотрения мер качества подгонки введем, для начала, способ расчета подобранных значений. Носко отмечает (Носко 2021), что наиболее естественным является

$$\hat{y}_i = \begin{cases} 1, F(\mathbf{x}_i'\boldsymbol{\beta}) > \frac{1}{2}, \\ 0, F(\mathbf{x}_i'\boldsymbol{\beta}) \leqslant \frac{1}{2} \end{cases}$$

Рассмотрим классическую формулу для коэффициента детерминации

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

В рамках рассматриваемой нами модели нетрудно увидеть, что $\bar{y} = \frac{n_1}{N}$, где n_1 — число наблюдений, для которых $y_i = 1$. Если раскрыть в знаменателе скобки, то мы получим

$$\begin{aligned} \sum_{i=1}^N (y_i - \bar{y})^2 &= \sum_{i=1}^N y_i^2 - 2\sum_{i=1}^N y_i\bar{y} + \sum_{i=1}^N \bar{y}^2 = \\ &= n_1 - 2\bar{y}\sum_{i=1}^N y_i + N\left(\frac{n_1}{N}\right)^2 = \\ &= n_1 - 2\frac{n_1^2}{N} + \frac{n_1^2}{N} = \frac{n_0 n_1}{N} \end{aligned}$$

Подставив это значение в формулу для R^2, получим коэффициент детерминации Эфрона (Efron 1978)

$$R^2 = 1 - \frac{N}{n_0 n_1}\sum_{i=1}^N (y_i - \hat{y}_i)^2$$

С другой стороны, вспомним, что рассматриваемые модели оцениваются при помощи метода максимального правдоподобия, поэтому хотелось бы как-то использовать

этот факт. В стандартной линейной регрессии (Baguley 2012; Pierse 2021)

$$R^2 = 1 - \left(\frac{L_0}{L}\right)^{2/N} \tag{3}$$

где L — максимум функции правдоподобия для модели, а L_0 — максимум функции правдоподобия для модели, в которой единственным регрессором является константа.

Однако в моделях бинарного выбора $L_0 \leqslant L \leqslant 1$, поэтому $R^2 \leqslant 1 - L_0^{2/N}$, и нам необходимо как-то перемасштабировать эту меру.

Крэгг и Улер (Cragg и Uhler 1970) предложили следующую меру

$$R^2_{\text{pseudo}} = \frac{L^{2/N} - L_0^{2/N}}{\left(1 - L_0^{2/N}\right)L^{2/N}},$$

которая, на самом деле, представляет собой формулу (3), деленную на $1 - L_0^{2/N}$.

МакФадден (McFadden 1974) предложил другую меру

$$R^2_{\text{McFadden}} = 1 - \frac{\ln L}{\ln L_0}$$

Разумеется, что можно использовать информационные критерии

$$AIC = -\frac{2L}{N} + \frac{2p}{N}$$

$$BIC = -\frac{2L}{N} + \frac{p \ln p}{N}$$

$$HQIC = -\frac{2L}{N} + \frac{2p \ln \ln N}{N}$$

Дискретные модели

Порядковые модели

Предположим теперь, что

$$y_i = \begin{cases} 1, & y_i^* \leqslant \gamma_{i,1}, \\ \vdots & \vdots \\ k, & \gamma_{i,k-1} < y_i^* \leqslant \gamma_{i,k}, \\ \vdots & \vdots \\ K, & \gamma_{i,K-1} < y_i^* \end{cases}$$

где $\gamma_{i,1} < \ldots < \gamma_{i,k} < \ldots < \gamma_{i,K-1}$ — пороговые значения, в общем случае ненаблюдаемые.

Для простоты предположим, что пороговые значения одинаковы для всех наблюдений, то есть $\gamma_{i,k} = \gamma_k, \forall i$. Для возможности идентификации всех параметров модели обычно также вводится нормализация $\mathrm{Var}[u_i] = 1$, а также $\gamma_1 = 0$.

В этом случае имеем вероятности

$$\mathrm{P}(y_i = 1) = \mathrm{P}(y_i^* \leqslant 0) = F(-\mathbf{x}_i'\boldsymbol{\beta}),$$

$$\mathrm{P}(y_i = 2) = \mathrm{P}(0 < y_i^* \leqslant \gamma_2) = F(\gamma_2 - \mathbf{x}_i'\boldsymbol{\beta}) - F(-\mathbf{x}_i'\boldsymbol{\beta}),$$

$$\mathrm{P}(y_i = 3) = \mathrm{P}(\gamma_2 < y_i^* \leqslant \gamma_3) = F(\gamma_3 - \mathbf{x}_i'\boldsymbol{\beta}) - F(\gamma_2 - \mathbf{x}_i'\boldsymbol{\beta}),$$

$$\ldots$$

на основе которых можно записать функцию правдоподобия

$$L = \prod_{y_i=1} \mathrm{P}(y_i = 1) \ldots \prod_{y_i=K} \mathrm{P}(y_i = K)$$

Мультиномиальные модели

В предыдущем случае значения y_i были упорядочены, примером могут служить шкалы «от одного до пяти». Однако бывают ситуации, когда варианты невозможно упорядочить, например, профессии.

Для внесения порядка в эту ситуацию считают, что каждой альтернативе j индивидом i назначается функция полезности U_{ij}, равная

$$U_{ij} = \mathbf{x}'_{ij}\boldsymbol{\beta} + \varepsilon_{ij},$$

где значения регрессоров могут зависеть не только от наблюдения, но и от альтернативы. В данной постановке задачи индивид i выбирает альтернативу j с вероятностью

$$\mathrm{P}(y_i = j) = \mathrm{P}\big(U_{ij} = \max\{U_{i1}, \ldots, U_{iK}\}\big)$$

Как отмечает Носко (Носко 2021), в явном виде эту вероятность выразить довольно сложно. Однако, если ошибки ε_{ij} имеют одинаковое логарифмическое распределение Вейбулла (или распределение Гумпеля)

$$F(x) = \exp\{-e^{-x}\},$$

то искомая вероятность будет иметь весьма простой вид

$$\mathrm{P}(y_i = j) = \frac{\exp\{\mathbf{x}_{ij}'\boldsymbol{\beta}\}}{\sum_j \exp\{\mathbf{x}_{ij}'\boldsymbol{\beta}\}},$$

где для нормализации модели считается, что $\mathbf{x}_{i1} = \mathbf{0}$.

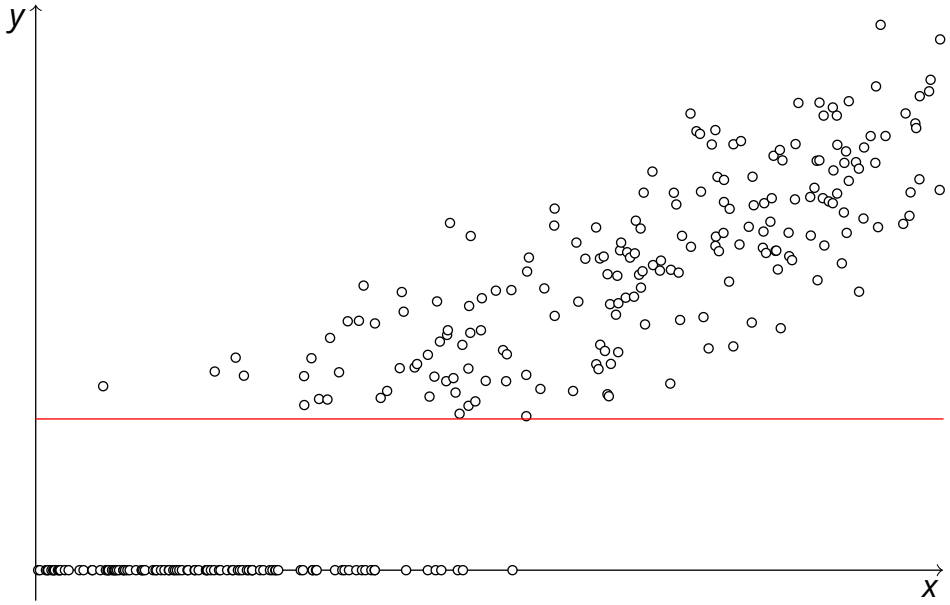
Если $K = 2$, то модель превращается в логит модель.

Урезанные и цензурированные модели

Цензурированные модели

Рассмотрим задачу, которую решал Тобин (Tobin 1958): он исследовал расходы домохозяйств на покупку автомобиля. Для некоторых семей эти расходы были равны 0, то есть был отказ от покупки автомобиля.

$$p_i = \begin{cases} p_i^* & \text{если семья имеет автомобиль} \\ 0 & \text{иначе} \end{cases}$$



В этом случае оценки регрессий расходов на доходы будут смещенными и несостоятельными: подобранное значение в модели регрессии показывает цену, которую семья готова заплатить на своем уровне доходов, однако нулевое значение может означать, что на рынке просто *нет* автомобилей по такой цене.

Предположим, что i-я семья покупает автомобиль по цене p_i^* если последняя превышает минимально возможную стоимость γ автомобиля на рынке (первичном и вторичном), т.е. если $p_i^* > \gamma$. Для остальных семей известно, что $p_i^* \leqslant \gamma$. Такие данные называют «цензурированными» на уровне γ, причем наблюдаемой является переменная

$$p_i^c = \begin{cases} p_i^* & \text{если } p_i^* > \gamma \\ \gamma & \text{если } p_i^* \leqslant \gamma \end{cases}$$

Данную переменную можно скорректировать на значение γ и получить

$$y_t = \begin{cases} p_i^* - \gamma & \text{если } p_i^* > \gamma \\ 0 & \text{если } p_i^* \leqslant \gamma \end{cases} = \begin{cases} y_i^* & \text{если } y_i^* > 0 \\ 0 & \text{если } y_i^* \leqslant 0 \end{cases}$$

где y_i^* — латентная переменная, для которой можно построить **стандартную тобит-модель**

$$\mathbf{y}^* = \mathbf{X\beta} + \mathbf{u} \tag{4}$$
$$\mathrm{E}(y_i^* \mid \mathbf{x}_i) = \mathbf{x}_i'\boldsymbol{\beta}$$
$$y_i^* \sim N(\mathbf{x}_i'\boldsymbol{\beta}, \sigma^2)$$

Усеченная регрессия

Предположим, что для расчетов используются только те наблюдения, для которых $y_i > 0$

$$\mathbf{y} = \mathbf{X\beta} + \mathbf{u}$$

В такой модели для $w > 0$ имеем

$$\mathrm{P}(y_i \leqslant w) = \mathrm{P}(y_i^* \leqslant w \mid y_i^* > 0) = \frac{\mathrm{P}(0 < y_i^* \leqslant w)}{\mathrm{P}(y_i^* > 0)}$$

$$\mathrm{P}(0 < y_i^* \leqslant w) = \mathrm{P}\left(\frac{-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma} < \frac{y_i^* - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma} \leqslant \frac{w - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) =$$
$$= \Phi\left(\frac{w - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) - \Phi\left(\frac{-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)$$

$$\mathrm{P}(y_i^* > 0) = 1 - \mathrm{P}\left(\frac{y_i^* - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma} \leqslant \frac{-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) = 1 - \Phi\left(\frac{-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) = \Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)$$

Отсюда можно найти, что (Носко 2021; Магнус и др. 2021)

$$p_y(w) = \frac{\mathrm{d}\,\mathrm{P}(y_i \leqslant w)}{\mathrm{d}w} = \frac{1}{\sigma}\frac{\varphi\left(\frac{w-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}{\Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}$$

$$\mathrm{E}(y_i \mid \mathbf{x}_i) = \int_0^\infty w p_y(w)\,\mathrm{d}w = \\ = \frac{1}{\sigma\Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}\int_0^\infty w\varphi\left(\frac{w-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\mathrm{d}w$$

$$\int_0^\infty w\varphi\left(\frac{w-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\mathrm{d}w = \mathbf{x}_i'\boldsymbol{\beta}\int_0^\infty \varphi\left(\frac{w-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\mathrm{d}w + \sigma\int_0^\infty \frac{w-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\varphi\left(\frac{w-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\mathrm{d}w = \\ = \sigma\mathbf{x}_i'\boldsymbol{\beta}\int_{-\mathbf{x}_i'\boldsymbol{\beta}/\sigma}^\infty \varphi(t)\,\mathrm{d}t + \sigma^2\int_{-\mathbf{x}_i'\boldsymbol{\beta}/\sigma}^\infty t\varphi(t)\,\mathrm{d}t = \\ = \sigma\mathbf{x}_i'\boldsymbol{\beta}\left[1-\Phi\left(-\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\right] + \frac{\sigma^2}{\sqrt{2\pi}}\int_{-\mathbf{x}_i'\boldsymbol{\beta}/\sigma}^\infty t\exp\left\{-\frac{t^2}{2}\right\}\mathrm{d}t \\ = \mathbf{x}_i'\boldsymbol{\beta}\sigma\Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) - \frac{\sigma^2}{\sqrt{2\pi}}\exp\left\{-\frac{t^2}{2}\right\}\Bigg|_{-\mathbf{x}_i'\boldsymbol{\beta}/\sigma}^\infty = \\ = \mathbf{x}_i'\boldsymbol{\beta}\sigma\Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) + \frac{\sigma^2}{\sqrt{2\pi}}\exp\left\{-\frac{(-\mathbf{x}_i'\boldsymbol{\beta}/\sigma)^2}{2}\right\} = \\ = \mathbf{x}_i'\boldsymbol{\beta}\sigma\Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) + \sigma^2\varphi\left(-\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)$$

Откуда

$$\mathrm{E}(y_i \mid \mathbf{x}_i) = \mathbf{x}_i'\boldsymbol{\beta} + \sigma\frac{\varphi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}{\Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)} > \mathbf{x}_i'\boldsymbol{\beta} \qquad (5)$$

Учет нулевых значений

Ту же модель можно оценить и иным способом, учитывая неполные наблюдения. Объясняемой переменной в рамках данного подхода будет

$$y_t = \begin{cases} \mathbf{x}_i'\boldsymbol{\beta} & \text{если } \mathbf{x}_i'\boldsymbol{\beta} + u_i > 0 \\ 0 & \text{если } \mathbf{x}_i'\boldsymbol{\beta} + u_i \leqslant 0 \end{cases}$$

В этом случае имеем, что

$$\mathrm{P}(y_i = 0 \mid \mathbf{x}_i) = \mathrm{P}(u_i \leqslant -\mathbf{x}_i'\boldsymbol{\beta}) = \Phi\left(-\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) = 1 - \Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)$$

$$\mathrm{P}(y_i > 0 \mid \mathbf{x}_i) = \Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)$$

$$\mathrm{P}(y_i \leqslant w \mid \mathbf{x}_i) = \mathrm{P}\left(\frac{y_i - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma} \leqslant \frac{w - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) = \Phi\left(\frac{w - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)$$

Отсюда мы можем найти математическое ожидание y_i:

$$\mathrm{E}(y_i \mid \mathbf{x}_i) = 0 \times \mathrm{P}(y_i = 0 \mid \mathbf{x}_i) + \int_0^\infty w\varphi\left(\frac{w - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\mathrm{d}w \times \mathrm{P}(y_i > 0 \mid \mathbf{x}_i) =$$

$$= \int_0^\infty w\varphi\left(\frac{w - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\mathrm{d}w \times \Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) =$$

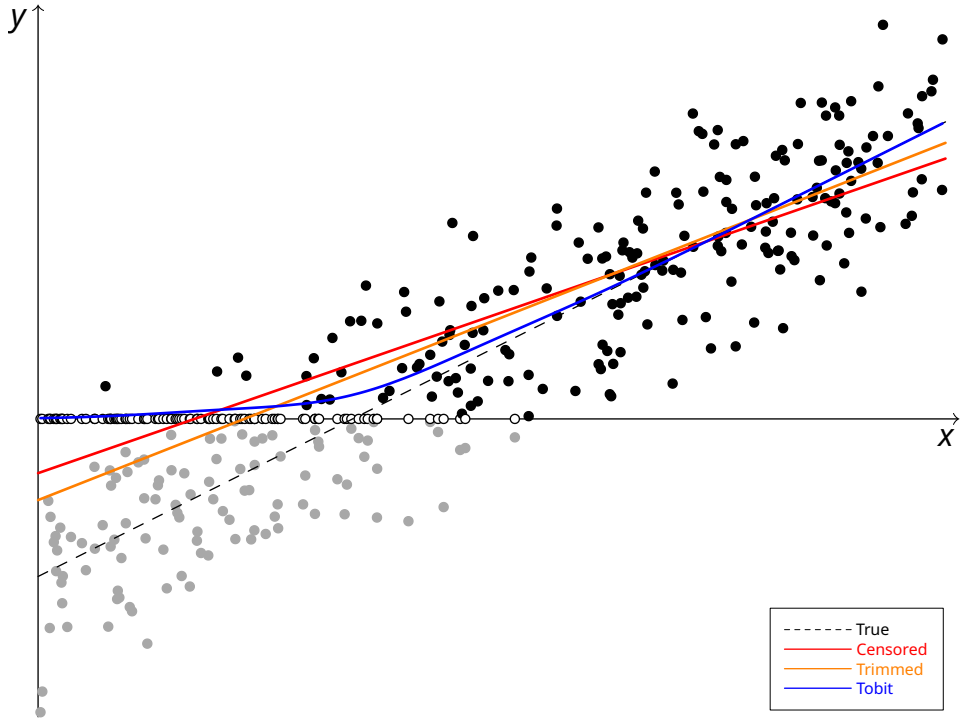
$$= \left[\mathbf{x}_i'\boldsymbol{\beta} + \sigma\frac{\varphi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}{\Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}\right] \times \Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right) \qquad (6)$$

Из полученного выражения понятно, что оценка модели

$$\mathbf{y} = \mathbf{x}_i'\boldsymbol{\beta} + \mathbf{u} \tag{7}$$

будет смещена и несостоятельна, так как $\mathrm{E}(\mathbf{u}) \neq 0$.

На следующем рисунке это наглядно показано. Черные и серые закрашенные кружки обозначают наблюдения (x_i, y_i^*), незакрашенные кружки показывают цензурированные наблюдения $(x_i, 0)$ для $y_i^* < 0$. Черная штриховая линия показывает «истинную» линию регрессии (4), красная линия — подобранную линию регрессии (7), а синяя — график $\mathrm{E}(y_i \mid \mathbf{x}_i)$, построенный по формуле (6). Видно, что красная линия смещена относительно истинной линии. Синяя линия, в свою очередь, по мере удаления от области с цензурированными значениями стремится к истинной линии.



Для получения оценок следует воспользоваться методом максимального правдоподобия. Функция правдоподобия имеет вид

$$L = \prod_{y_i=0}\left[1 - \Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\right]\prod_{y_i>0}\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{-\frac{(y_i - \mathbf{x}_i'\boldsymbol{\beta})^2}{2\sigma^2}\right\}$$

Предельный эффект объясняющих факторов будет равен

$$\frac{\partial\,\mathrm{E}(y_i \mid \mathbf{x}_i)}{\partial \mathbf{x}_i} = \Phi\left(\frac{\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\boldsymbol{\beta}$$

Усеченные модели

Рассмотрим еще один вариант: ситуацию, когда при определенных условиях наблюдения вообще недоступны. Представим себе обычную модель

$$\mathbf{y} = \mathbf{X\beta} + \mathbf{u}, \mathbf{u} \sim N(\mathbf{0}, \sigma^2\mathbf{I})$$

и пусть нам доступны только те наблюдения, для которых $y_i > a$. Тогда из (5) следует

$$\mathrm{E}(y_i \mid y_i > a) = \mathbf{x}_i'\boldsymbol{\beta} + \sigma\frac{\varphi\left(\frac{a-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}{\Phi\left(\frac{a-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)} =$$

$$= \mathbf{x}_i'\boldsymbol{\beta} + \sigma\lambda\left(\frac{a-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)$$

то есть если для данной урезанной выборки оценить модель при помощи МНК, то оценки будут смещены, поскольку мы получим, что $\mathrm{E}(u_i \mid \mathbf{x}_i) = \sigma\lambda(\ldots)$. Поэтому состоятельные оценки можно получить при помощи метода максимального правдоподобия

$$\mathrm{P}(y_i \mid y_i > a) = \frac{1}{\sigma}\frac{\varphi\left(\frac{y_i-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}{1-\Phi\left(\frac{a-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)}$$

$$L = \frac{1}{\sigma^N}\left[1-\Phi\left(\frac{a-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)\right]^N \prod_i \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{-\frac{(y_i-\mathbf{x}_i'\boldsymbol{\beta})^2}{2\sigma^2}\right\}$$

Библиография

[1] R. G. Pierse, «Limited Dependent Variable Models: Logit and Probit». 2021 г.

[2] В. П. Носко, *Эконометрика. Книга 2*. в Академический учебник. Москва: Издательский дом «Дело» РАНХиГС, 2021.

[3] B. Efron, «Regression and ANOVA with Zero-One Data: Measures of Residual Variation», *Journal of the American Statistical Association*, т. 73, вып. 361, сс. 113–121, мар. 1978, doi: 10,1080/01621459,1978.10480013.

[4] T. Baguley, «Online Supplement 4: Pseudo-R2 and Related Measures.», в *Serious Stats: A Guide to Advanced Statistics for the Behavioral Sciences*, Basingstoke: Palgrave, 2012.

[5] J. G. Cragg и R. S. Uhler, «The Demand for Automobiles», *The Canadian Journal of Economics / Revue canadienne d'Economique*, т. 3, вып. 3, сс. 386–406, 1970, doi: 10,2307/133656.

[6] D. McFadden, «The Measurement of Urban Travel Demand», *Journal of Public Economics*, т. 3, вып. 4, сс. 303–328, ноя. 1974, doi: 10,1016/0047-2727(74)90003-6.

[7] J. Tobin, «Estimation of Relationships for Limited Dependent Variables», *Econometrica*, т. 26, вып. 1, сс. 24–36, 1958, doi: 10,2307/1907382.

[8] Я. Магнус, П. Катышев, и А. Пересецкий, *Эконометрика. Начальный курс. Учебник. 9-е издание*, 9-е изд., испр. Москва: Издательский дом «Дело» РАНХиГС, 2021.

A Математическое ожидание усеченного нормального распределения

Пусть $y^* \sim N(\mu, \sigma^2)$. Тогда случайная величина

$$y = \begin{cases} y^* & \text{если } y_t \in [a, b] \\ 0 & \text{иначе} \end{cases}$$

будет иметь усеченное нормальное распределение.

Из определения плотности следует, что

$$f(x) = \begin{cases} \frac{1}{\sigma} \frac{\varphi\left(\frac{x-\mu}{\sigma}\right)}{\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)} & \text{если } x \in [a, b] \\ 0 & \text{иначе} \end{cases}$$

Отсюда

$$\begin{aligned} \mathrm{E}\, y &= \int_{-\infty}^{\infty} x f(x)\, \mathrm{d}x = \int_{a}^{b} x f(x)\, \mathrm{d}x = \\ &= \frac{1}{\sigma} \frac{1}{\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)} \underbrace{\int_{a}^{b} x \varphi\left(\frac{x-\mu}{\sigma}\right) \mathrm{d}x}_{Q} = * \end{aligned}$$

Рассмотрим интеграл Q

$$Q = \int_a^b (x \pm \mu)\varphi\left(\frac{x-\mu}{\sigma}\right)\mathrm{d}x =$$

$$= \mu\int_a^b \varphi\left(\frac{x-\mu}{\sigma}\right)\mathrm{d}x + \sigma\int_a^b \frac{x-\mu}{\sigma}\varphi\left(\frac{x-\mu}{\sigma}\right)\mathrm{d}x =$$

$$= \left|t = \frac{x-\mu}{\sigma} \quad x = \mu + \sigma t \quad \mathrm{d}x = \sigma\,\mathrm{d}t\right| =$$

$$= \sigma\mu\int_{\frac{a-\mu}{\sigma}}^{\frac{b-\mu}{\sigma}} \varphi(t)\,\mathrm{d}t + \sigma^2\int_{\frac{a-\mu}{\sigma}}^{\frac{b-\mu}{\sigma}} t\varphi(t)\,\mathrm{d}t =$$

$$= \sigma\mu\int_{\frac{a-\mu}{\sigma}}^{\frac{b-\mu}{\sigma}} \mathrm{d}\Phi(t) - \frac{\sigma^2}{\sqrt{2\pi}}\int_{\frac{a-\mu}{\sigma}}^{\frac{b-\mu}{\sigma}} \mathrm{d}\exp\left\{-\frac{t^2}{2}\right\} =$$

$$= \sigma\mu\left[\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)\right] + \sigma^2\left[\frac{\exp\left\{-\frac{((b-\mu)/\sigma)^2}{2}\right\}}{\sqrt{2\pi}} - \frac{\exp\left\{-\frac{((a-\mu)/\sigma)^2}{2}\right\}}{\sqrt{2\pi}}\right] =$$

$$= \sigma\mu\left[\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)\right] + \sigma^2\left[\varphi\left(\frac{b-\mu}{\sigma}\right) - \varphi\left(\frac{a-\mu}{\sigma}\right)\right]$$

Здесь мы воспользовались тем, что $\mathrm{d}e^{-\frac{t^2}{2}} = -te^{-\frac{t^2}{2}}\,\mathrm{d}t$. Откуда получим

$$* = \mu + \sigma\frac{\varphi\left(\frac{b-\mu}{\sigma}\right) - \varphi\left(\frac{a-\mu}{\sigma}\right)}{\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)}$$