Методы оценивания

Зямалов В.Е.

Основные источники: учебники Хаяши (Хайяши 2017; Hayashi 2000) и Гамильтона (Hamilton 1994).

Хаяши выделяет два класса так называемых «экстремальных» оценок:

- М-оценки, получаемые из задачи, целевая функция которой имеет вид

$$Q_T(\theta) = \frac{1}{T}\sum_{t=1}^{T} m(y_t \mid \theta)$$

  где $m(y_t \mid \theta)$ — некоторая функция $\mathbf{Y} \times \Theta \to \mathbb{R}$.
- GMM, получаемые из задачи, целевая функция которой имеет вид

$$Q_T(\theta) = -\frac{1}{2}\mathbf{g}_T(\theta)'\widehat{\mathbf{W}}\mathbf{g}_T(\theta)$$

  где $\mathbf{g}_T(\theta) = \frac{1}{T}\sum_{t=1}^{T}\mathbf{g}(y_t \mid \theta)$.

Метод максимального правдоподобия

Рассмотрим следующую задачу. У нас есть некоторый набор наблюдений $\{y_t\}$, полученный из генеральной совокупности с набором некоторых параметров θ, которые нам нужно оценить.

Для решения этой задачи можно воспользоваться **методом максимального правдоподобия**. Предположим, что наблюдения являются независимыми и одинаково распределенными, причем вид распределения нам **известен**[1]. Для данных наблюдений можно записать плотность распределения каждого из них с учетом значений вектора параметров θ — $f(y_t; \theta)$.

Так как все наблюдения считаются независимыми, то достаточно легко можно вычислить совместную плотность распределения всего набора наблюдений

$$f(y_1, y_2, \ldots, y_T \mid \theta) = \prod_{t=1}^{T} f(y_t \mid \theta)$$

Полученное выражение и задает нам **функцию правдоподобия**. Формально можно записать, что

$$L(\theta \mid \mathbf{y}) = \mathrm{P}(\mathbf{y} \mid \theta)$$

что означает, что значение функции правдоподобия, вычисленной на данном наборе параметров с учетом текущей выборки, численно совпадает с вероятностью получить данную выборку при данном наборе параметров.

Оптимальной оценкой θ

$$\arg\max_{\theta \in \Theta} L(\theta \mid \mathbf{y})$$

[1]Это утверждение приведено в учебнике (Хайяши 2017), хотя, как мы увидим далее, это не обязательное требование. Главное, чтобы мы **знали** распределения отдельных наблюдений.

Для упрощения функцию правдоподобия часто берут в логарифмах

$$l(\theta \mid \mathbf{y}) = \sum_{t=1}^{T} \ln f(y_t \mid \theta)$$

Необходимым условием экстремума для решения задачи является равенство нулю градиента функции правдоподобия

$$\nabla l(\theta \mid \mathbf{y}) \mid_{\theta=\hat{\theta}} = \frac{tiall}{\partial \theta}\left(\hat{\theta}\right) = \mathbf{0}$$

Достаточным условием является отрицательная определенность матрицы Гессе

$$H(\theta \mid \mathbf{y}) = \left(\frac{\partial^2 l}{\partial \theta \partial \theta'}\right)(\theta \mid \mathbf{y})$$

Как отмечает Хаяши (Хайяши 2017), при выполнении достаточно простых условий ML-оценки являются состоятельными:

- функция правдоподобия должна быть вогнутой на пространстве параметров Θ;
- функция правдоподобия измерима на пространстве данных для любого $\theta \in \Theta$.
- стационарный процесс $\{y_t\}$ эргодичен.

Линейная регрессия

Рассмотрим пример оценивания линейной регрессии (Магнус и др. 2021).

Допустим, что мы ищем оценку параметров модели

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t$$

Предположим, что выполняются все предпосылки МНК, а также дополнительное предположение гауссовости случайных ошибок

$$\varepsilon_t \sim \text{iid } N(0, \sigma^2)$$

что эквивалентно[2]

$$y_t \sim N(\beta_0 + \beta_1 x_t, \sigma^2)$$

Для решения данной задачи имеет смысл рассмотреть так называемый **условный метод максимального правдоподобия**. Смысл метода заключается в том, что исходный набор наблюдений разбивается на две части, причем исследователя интересует влияние одной части данных — в нашем случае x_t — на условное матожидание других — y_t. Плотность можно разложить следующим образом

$$f(y_t, x_t \mid \theta, \psi) = f(y_t \mid x_t; \theta) f(x_t; \psi)$$

где ψ — параметры распределения x_t.

В итоге функция правдоподобия примет вид

[2] В примере подразумевается детерминированность x_t.

$$l(\theta \mid y_t, x_t) = \frac{1}{T}\sum_{t=1}^{T} \ln f(y_t \mid x_t; \theta) + \frac{1}{T}\sum_{t=1}^{T} f(x_t; \psi)$$

Очевидно, что при поиске оптимального значения $\hat{\theta}$ максимизироваться будет только первая часть; вторая часть игнорируется.

Вернемся к примеру. Запишем функцию правдоподобия

$$L(\beta_0, \beta_1, \sigma^2 \mid y_1, \ldots, y_T) = \mathrm{P}(y_1, \ldots, y_T \mid x_1, \ldots, x_T, \beta_0, \beta_1, \sigma^2) =$$

$$= (2\pi)^{-T/2}(\sigma^2)^{-T/2} \exp\left(-\frac{1}{2\sigma^2}\sum_{t=1}^{T}(y_t - \beta_0 - \beta_1 x_t)^2\right)$$

или

$$\ln L(\beta_0, \beta_1, \sigma^2 \mid y_1, \ldots, y_T) =$$

$$= -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}\sum_{t=1}^{T}(y_t - \beta_0 - \beta_1 x_t)^2$$

Найдем необходимые условия первого порядка максимизации функции

$$\frac{\partial \ln L}{\partial \beta_0} = \frac{1}{\sigma^2}\sum_{t=1}^{T}(y_t - \beta_0 - \beta_1 x_t) = 0$$

$$\frac{\partial \ln L}{\partial \beta_1} = \frac{1}{\sigma^2}\sum_{t=1}^{T} x_t(y_t - \beta_0 - \beta_1 x_t) = 0$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2}\frac{1}{\sigma^2} + \frac{1}{2\sigma^4}\sum_{t=1}^{T}(y_t - \beta_0 - \beta_1 x_t)^2 = 0$$

Нетрудно заметить, что данные уравнения дают нам оценки

$$\hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}$$

$$\hat{\beta}_1 = \frac{\sum (x_t - \overline{x})(y_t - \overline{y})}{\sum (x_t - \overline{x})^2}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum e_t^2$$

То есть полученные оценки коэффициентов совпадают с МНК оценками. При этом оценка σ^2 оказывается состоятельной, но смещенной.

AR(p)

Рассмотрим функцию правдоподобия для процесса AR(p)

$$Y_t = c + a_1 Y_{t-1} + \ldots + a_p Y_{t-p} + \varepsilon_t$$

где $\varepsilon \sim \mathrm{WN}(0, \sigma^2)$. Оцениваемый вектор параметров $\theta = (c, a_1, \ldots, a_p, \sigma^2)$.

Очевидно, что с описанием данного процесса есть сложность, связанная с первыми p наблюдениями. Гамильтон (Hamilton 1994) использует способ разделения функции на две части. Первая часть определяет первые p наблюдений как реализацию p-мерной Гауссовой случайной величины с математическим ожиданием

$$\mu = \frac{c}{1 - \sum_{i=1}^{p} a_i}$$

Ковариационная матрица $(y_1, ..., y_p)$ равна

$$\sigma^2 \mathbf{V}_p = \begin{bmatrix} \mathrm{E}(Y_1 - \mu)^2 & \mathrm{E}(Y_1 - \mu)(Y_2 - \mu) & \cdots & \mathrm{E}(Y_1 - \mu)(Y_p - \mu) \\ \mathrm{E}(Y_2 - \mu)(Y_1 - \mu) & \mathrm{E}(Y_2 - \mu)^2 & \cdots & \mathrm{E}(Y_2 - \mu)(Y_p - \mu) \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{E}(Y_p - \mu)(Y_1 - \mu) & \mathrm{E}(Y_p - \mu)(Y_2 - \mu) & \cdots & \mathrm{E}(Y_p - \mu)^2 \end{bmatrix} =$$

$$= \begin{bmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{p-1} \\ \gamma_1 & \gamma_0 & \cdots & \gamma_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{p-1} & \gamma_{p-2} & \cdots & \gamma_0 \end{bmatrix}$$

Отсюда совместная плотность первых p наблюдений равна

$$f_{Y_p, Y_{p-1}, ..., Y_1}(y_p, ..., y_1; \theta) =$$

$$= (2\pi)^{-p/2} \mid \sigma^{-2} \mathbf{V}_p^{-1} \mid^{1/2} \exp\left[-\frac{1}{2\sigma^2} (\mathbf{y}_p - \boldsymbol{\mu}_p)' \mathbf{V}_p^{-1} (\mathbf{y}_p - \boldsymbol{\mu}_p) \right] =$$

$$= (2\pi)^{-p/2} (\sigma^{-2})^{p/2} \mid \mathbf{V}_p^{-1} \mid^{1/2} \exp\left[-\frac{1}{2\sigma^2} (\mathbf{y}_p - \boldsymbol{\mu}_p)' \mathbf{V}_p^{-1} (\mathbf{y}_p - \boldsymbol{\mu}_p) \right]$$

(Galbraith и Galbraith 1974) показали, что элемент ij матрицы $\mathbf{V}_p^{-1}$ равен

$$v^{ij} = v^{ji} = \left[\sum_{k=0}^{i-1} a_k a_{k+j-i} - \sum_{k=p+1-j}^{p+i-j} a_k a_{k+j-i} \right]$$

причем $a_0 = -1$[3].

Для оставшейся части выборки поступают следующим образом. Для наблюдения t математическое ожидание зависит **только** от предыдущих p наблюдений, то есть

$$\mathrm{E}(Y_t \mid Y_{t-1}, \ldots, Y_1) = \mathrm{E}\left(Y_t \mid Y_{t-1}, \ldots, Y_{t-p}\right) = a_0 + \sum_{i=1}^{p} a_i y_{t-i}$$

При этом дисперсия равна σ^2. Поэтому для второй части плотность Y_t имеет вид

$$f_{Y_t \mid Y_{t-1},\ldots,Y_{t-p}}(y_t \mid y_{t-1}, \ldots, y_{t-p}; \theta) = \\ = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{\left(y_t - a_0 - \sum_{i=1}^{p} a_i y_{t-i}\right)^2}{2\sigma^2}\right]$$

А совокупная плотность **всей** выборки равна

$$f_{Y_T,\ldots,Y_1}(y_T, \ldots, y_1; \theta) = \\ = f_{Y_p,Y_{p-1},\ldots,Y_1}(y_p, \ldots, y_1; \theta) \times \prod_{t=p+1}^{T} f_{Y_t \mid Y_{t-1},\ldots,Y_{t-p}}(y_t \mid y_{t-1}, \ldots, y_{t-p}; \theta)$$

А функция правдоподобия

$$\ln L(\theta \mid \mathbf{y}) = -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln\left(\sigma^2\right) + \frac{1}{2}\ln\left|\mathbf{V}_p^{-1}\right| - \\ -\frac{1}{2\sigma^2}\left(\mathbf{y}_p - \boldsymbol{\mu}_p\right)'\mathbf{V}_p^{-1}\left(\mathbf{y}_p - \boldsymbol{\mu}_p\right) - \\ - \sum_{t=p+1}^{T} \frac{\left(y_t - a_0 - \sum_{i=1}^{p} a_i y_{t-i}\right)^2}{2\sigma^2}$$

[3] В исходном тексте свободный член в модели обозначается как c, чтобы избежать коллизии с v^{ij}.

Если проигнорировать первые p наблюдений, что допускается на больших выборках, то функция правдоподобия примет вид

$$\ln L(\theta \mid y_T, \ldots, y_{p+1}) =$$

$$= -\frac{T-p}{2}\ln(2\pi) - \frac{T-p}{2}\ln(\sigma^2) - \sum_{t=p+1}^{T}\frac{\left(y_t - a_0 - \sum_{i=1}^{p} a_i y_{t-i}\right)^2}{2\sigma^2}$$

Эта функция дает нам в итоге МНК-оценки коэффициентов. Оценка σ^2 равна

$$\hat{\sigma}^2 = \frac{1}{T-p}\sum_{t=p+1}^{T} e_t^2$$

MA(1)

Рассмотрим процесс

$$Y_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}$$

где $\varepsilon \sim \mathrm{WN}(0, \sigma^2)$. Оцениваемый вектор параметров $\theta = (\mu, \theta, \sigma^2)$.

Если бы мы точно знали ε_{t-1}, то

$$Y_t \mid \varepsilon_{t-1} \sim N(\mu + \theta\varepsilon_{t-1}, \sigma^2)$$

$$f_{Y_t \mid \varepsilon_{t-1}} = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left[-\frac{(y_t - \mu - \theta\varepsilon_{t-1})^2}{2\sigma^2}\right]$$

Далее следим за руками. Предположим, что мы **знаем**, что $\varepsilon_0 = 0$. Тогда

$$Y_1 \mid \varepsilon_0 \sim N(\mu, \sigma^2)$$

Более того, мы **достоверно**[4] знаем $\varepsilon_1 = y_1 - \mu$; это позволяет нам записать

$$f_{Y_2 \mid Y_1, \varepsilon_0} = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_2 - \mu - \theta\varepsilon_1)^2}{2\sigma^2}\right]$$

Вообще, знание $\varepsilon_0 = 0$ позволяет нам достоверно рассчитать $\{\varepsilon_t\}$. Так как $\varepsilon_t = y_t - \mu - \theta\varepsilon_{t-1}$, то итоговая функция правдоподобия имеет вид

$$\ln L(\theta) = -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln(\sigma^2) - \sum_{t=1}^{T}\frac{\varepsilon_t^2}{2\sigma^2}$$

Кстати, именно на данном этапе проявляется роль обратимости MA-процесса: если $|\theta| \ll 1$, то эффект весьма произвольного выбора ε_0 крайне быстро затухает.

Если при численном решении задачи получается значение $\hat{\theta}$ больше 1, то оно должно быть отброшено, а процесс подбора начат заново с $1/\hat{\theta}$ в качестве начального значения.

С другой стороны мы можем записать точное значение функции правдоподобия **без** волюнтаристических предположений. Ковариационная матрица выборки из процесса MA(1)

[4] С точностью до **неизвестного** параметра μ.

$$\mathbf{\Omega} = \mathrm{E}(\mathbf{Y} - \boldsymbol{\mu})(\mathbf{Y} - \boldsymbol{\mu})'$$

имеет вид

$$\mathbf{\Omega} = \sigma^2 \begin{bmatrix} (1+\theta^2) & \theta & 0 & \cdots & 0 \\ \theta & (1+\theta^2) & \theta & \cdots & 0 \\ 0 & \theta & (1+\theta^2) & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & (1+\theta^2) \end{bmatrix}$$

А функция правдоподобия

$$\ln L(\theta) = -\frac{T}{2}\ln(2\pi) - \frac{1}{2}\ln|\,\mathbf{\Omega}\,| - \frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})'\mathbf{\Omega}^{-1}(\mathbf{y} - \boldsymbol{\mu}) \qquad (1)$$

Треугольное разложение

Гамильтон (Hamilton 1994) рассматривает следующую модификацию (1). Известно[5], что любая симметрическая положительно определенная матрица $\mathbf{\Omega}$ единственным образом раскладывается следующим образом

$$\mathbf{\Omega} = \mathbf{ADA}'$$

где $\mathbf{A}$ — нижняя унитреугольная матрица[6], $\mathbf{D}$ — диагональная матрица.

Из этого разложения следует, что

$$|\mathbf{\Omega}| = |\mathbf{A}| \times |\mathbf{D}| \times |\mathbf{A}'| = |\mathbf{D}|$$

Также можно ввести следующие переменные

$$\overline{\mathbf{y}} = \mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu})$$

[5] См. (Hamilton 1994, стр. 87).

[6] Треугольная матрица с единицами на главной диагонали.

С учетом этого (1) примет вид

$$\ln L(\theta) = -\frac{T}{2}\ln(2\pi) - \frac{1}{2}\ln|\,\mathbf{D}\,| - \frac{1}{2}\bar{\mathbf{y}}'\mathbf{D}^{-1}\bar{\mathbf{y}}$$

Если обратить внимание на то, что

$$\mathbf{ADA}' = \underbrace{\mathbf{AD}^{1/2}}_{\mathbf{L}}\underbrace{\mathbf{D}^{1/2}\mathbf{A}'}_{\mathbf{L}'}$$

где **L** — матрица разложения Холецкого, $\mathbf{D}^{1/2}$ — матрица, состоящая из корней элементов матрицы **D**, и ввести переменную

$$\tilde{\mathbf{y}} = \mathbf{L}^{-1}(\mathbf{y} - \boldsymbol{\mu})$$

то (1) примет вид

$$\ln L(\theta) = -\frac{T}{2}\ln(2\pi) - \ln|\,\mathbf{L}\,| - \frac{1}{2}\tilde{\mathbf{y}}'\tilde{\mathbf{y}}$$

ARMA(p, q)

Как ни странно, но ARMA(p, q) по построению функции правдоподобия ближе к процессам скользящего среднего. Если взять начальные значения $\mathbf{y}_0 = \left(y_0, y_{-1}, \ldots, y_{-p+1}\right)'$ и $\boldsymbol{\varepsilon}_0 = \left(\varepsilon_0, \varepsilon_{-1}, \ldots, \varepsilon_{-q+1}\right)'$, то последовательность $\{\varepsilon_t\}$ может быть «достоверно» рассчитана

$$\varepsilon_t = y_t - a_0 - \sum_{i=1}^{p} a_i y_{t-i} - \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}$$

что дает нам

$$\ln L(\theta) = \ln f_{Y_T, Y_{T-1}, \ldots, Y_1 | Y_0, \varepsilon_0}(y_t, \ldots, y_1 \mid \mathbf{y}_0, \boldsymbol{\varepsilon}_0; \theta) =$$
$$= -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln(\sigma^2) - \sum_{t=1}^{T}\frac{\varepsilon_t^2}{2\sigma^2}$$

В качестве начальных значений можно взять:

- математические ожидания, то есть

$$y_t = \frac{a_0}{1 - \sum_{i=1}^{p} a_i}, t = 0, -1, \ldots, -p+1$$
$$\varepsilon_t = 0 \qquad t = 0, -1, \ldots, -q+1$$

- Бокс и Дженкинс (Box и др. 2016) предложили брать в качестве $\mathbf{y}_0$ первые p значений y_t, а в качестве $\boldsymbol{\varepsilon}_0$ — $\varepsilon_t = 0, t = p, \ldots, p - q + 1$. Понятно, что расчет последовательности $\{\varepsilon_t\}$ будет проходить на наблюдениях $p + 1, \ldots, T$; соответствующим образом меняется функция правдоподобия

$$\ln L(\theta) = \ln f_{Y_T, Y_{T-1}, \ldots, Y_{p+1} | Y_0, \varepsilon_0}\left(y_t, \ldots, y_{p+1} \mid \mathbf{y}_0, \boldsymbol{\varepsilon}_0; \theta\right) =$$
$$= -\frac{T-p}{2}\ln(2\pi) - \frac{T-p}{2}\ln(\sigma^2) - \sum_{t=p+1}^{T}\frac{\varepsilon_t^2}{2\sigma^2}$$

GMM

Обобщенный метод моментов является, как понятно из названия, обобщением метода моментов. Опишем этот метод согласно обзорной работе Хансена (Hansen 2007).

Методы оценивания

Рассмотрим наши данные, которые являются конечной реализацией процесса $\{y_t\}_{t=1}^{T}$. Сама модель определяется следующим простым выражением

$$\mathrm{E}\, f(y_T; \beta_0) = 0$$

где $\beta_0 \in \mathbb{P} \subset \mathbb{R}^k$ — истинные значения параметров модели[7], а $f(\ldots)$ — вектор-функция, имеющая r компонент.

Для того, чтобы решение задачи было единственным, необходимо выполнение условия

$$\mathrm{E}\, f(y_t; \beta) = 0 \Leftrightarrow \beta = \beta_0$$

$f(\ldots)$ называют моментной функцией. Реальное оценивание производится на выборочном аналоге матожидания

$$g_T(\beta) = \frac{1}{T} \sum_{t=1}^{T} f(y_t; \beta)$$

В литературе показано, что

$$\sqrt{T} g_T(\beta_0) \xrightarrow{d} N(0, V)$$

где

$$V = \sum_{j=-\infty}^{\infty} \mathrm{E}\left[f(y_t; \beta_0) f\left(y_{t+j}; \beta_0\right)' \right]$$

То есть V — спектральная плотность на нулевой частоте. Если

[7]Обычно к GMM прибегают в случае полупараметрических моделей, когда функцию правдоподобия записать «затруднительно».

- $r < k$, то модель недоопределена; оценки в данном случае получить нельзя.
- $r = k$, то модель определена точно; у модели **может** быть решение. Это традиционный метод моментов.
- $r > k$, то модель переопределена; в общем случае решения также нет. Но возможно найти не точное, а максимально к нему приближенное решение. Это и есть обобщенный метод моментов.

Оценивание модели

Одним из подходов к оцениванию является минимизация квадратичной формы

$$J(\beta) = g_T(\beta)'\mathbf{W}g_T(\beta)$$

то есть оценка равна

$$b_{GMM} = \arg\min_{\beta \in \mathbb{P}} J(\beta)$$

Данный подход обосновывается тем, что $J(\beta)$ является выборочным аналогом

$$\mathrm{E}\, f(y_t; \beta)'\mathbf{W}\,\mathrm{E}\, f(y_t; \beta)$$

Полученная оценка является состоятельной; в работе (Hansen 1982) было показано, что если процесс порождения данных стационарен и эргодичен, то выполняется специальная форма закона больших чисел, по которой

$$\sup_{\beta \in \mathbb{P}} | \; g_T(\beta) - \mathrm{E}\, f(y_t; \beta) \; | = 0$$

причем $\mathbb{P}$ компактно[8]. Свойство компактности важно для «хорошего» поведения функции «вдали» от β_0.

В качестве $\mathbf{W}$ часто предпочитают брать $\mathbf{V}^{-1}$, так как в этом случае

$$T g_T(\beta)' \mathbf{V}^{-1} g_T(\beta) \xrightarrow{d} \chi^2(r)$$

Оценкой ковариационной матрицы b_{GMM} является (L. Mátyás 1999, гл. 2)

$$\hat{\Sigma}_{b_{GMM}} = \frac{1}{T\left[F_T' \mathbf{V}_T^{-1} F_T\right]^{-1}}$$

$$F_T = \frac{1}{T} \sum_{t=1}^{T} \frac{\partial f(y_t; \beta)}{\partial \beta'} \Big|_{\beta = b_{GMM}}$$

а $\mathbf{V}_T$ — оценка $\mathbf{V}$.

На практике для оценивания модели используется следующая последовательная процедура:

1. Задайте начальное значение $\mathbf{W}_0$. Удобно для этой цели взять единичную матрицу.
2. Минимизируйте $J(\beta; \mathbf{W}_0)$

$$b_1 = \arg\min_{\beta \in \mathbb{P}} g_T(\beta)' \mathbf{W}_0 g_T(\beta)$$

3. Найдите новое значение $\mathbf{W}_1$

[8]Компактное пространство — топологическое пространство, в любом покрытии которого открытыми множествами найдётся конечное подпокрытие.

$$\mathbf{W}_1 = \left\{ \frac{1}{T} \sum_{t=1}^{T} g_T(b_1) g_T(b_1)' \right\}^{-1}$$

4. Повторяйте шаги 2–3 до достижения сходимости.

Примеры

Линейная регрессия

Рассмотрим пример линейной регрессии

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \ldots + \beta_k x_{k,t} + \varepsilon_t$$

где выполняются все предпосылки МНК и условия теоремы Гаусса-Маркова.

Из курса эконометрики известно, что для МНК оценок модели[9] выполняется

$$\sum_{t=1}^{T} x_{j,t} e_t = \sum_{t=1}^{T} x_{j,t} \left(y_t - \hat{\beta}_0 - \sum_{i=1}^{k} \beta_i x_{i,t} \right) = 0,\ j = 1, \ldots, k$$

Очевидно, что в качестве моментных функций можно взять

$$x_{j,t} \left(y_t - \hat{\beta}_0 - \sum_{i=1}^{k} \beta_i x_{i,t} \right)$$

[9] В том числе **без** свободного члена.

Инструментальные переменные

Из теории метода инструментальных переменных известно, что инструменты должны удовлетворять двум свойствам:

1. релевантности, то есть $\mathrm{Cov}(z_t, x_t) \neq 0$,
2. экзогенности, то есть $\mathrm{Cov}(z_t, \varepsilon_t) = 0$.

Выборочный аналог второго свойства принимает вид

$$\sum_{t=1}^{T} z_t(y_t - \beta_0 - \beta_1 x_t) = 0$$

То есть в качестве моментных функций можно взять

$$z_t(y_t - \beta_0 - \beta_1 x_t)$$

ARMA(2, 1)

Взято из блога *Янга (Аллена) Вонга*. Рассмотрим модель ARMA(2,1)

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \underbrace{\varepsilon_t + \theta_1 \varepsilon_t}_{\nu_t}$$

где $\varepsilon_t \sim \mathrm{WN}(0, 1)$.

Данная модель дает нам следующие кандидаты в моментные функции:

1. $\mathrm{E}(\nu_t) = 0$;
2. $\mathrm{Var}(\nu_t) = \left(1 + \theta_1^2\right)$;
3. $\mathrm{Cov}(\nu_t, \nu_{t-1}) = \theta_1$;
4. $\mathrm{Cov}\left(\nu_t, \nu_{t-j}\right) = 0$, $j \geqslant 2$.

Если ограничиться этими условиями, то $f(y_t; \beta)$ можно записать в виде

$$f(y_t; \beta) = \begin{bmatrix} y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2} \\ (y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2})^2 - (1 + \theta_1^2) \\ (y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2})(y_{t-1} - \alpha_1 y_{t-2} - \alpha_2 y_{t-3}) - \theta_1 \\ (y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2})(y_{t-2} - \alpha_1 y_{t-3} - \alpha_2 y_{t-4}) \end{bmatrix}$$

Откуда

$$\mathrm{E}\, f\left(y_t, \hat{\beta}\right) = 0$$

Для расчета ковариационной матрицы и для целей процедуры оценивания рассчитаем частные производные $f(y_t; \beta)$:

$$\frac{\partial f}{\partial \theta'} = \begin{bmatrix} \mathcal{E}_1 & \mathcal{E}_2 & \mathcal{E}_3 \end{bmatrix}$$

$$\mathcal{E}_1 = \begin{bmatrix} -y_{t-1} \\ -2y_{t-1}(y_t - \alpha_1 y_{t-1} - \alpha_2 x_{t-2}) \\ -y_{t-1}(y_{t-1} - \alpha_1 y_{t-2} - \alpha_2 y_{t-3}) - y_{t-2}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \\ -y_{t-1}(y_{t-2} - \alpha_1 y_{t-3} - \alpha_2 y_{t-4}) - y_{t-3}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \end{bmatrix}$$

$$\mathcal{E}_2 = \begin{bmatrix} -y_{t-2} \\ -2y_{t-2}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \\ -y_{t-2}(y_{t-1} - \alpha_1 y_{t-2} - \alpha_2 y_{t-3}) - y_{t-3}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \\ -y_{t-2}(y_{t-2} - \alpha_1 y_{t-3} - \alpha_2 y_{t-4}) - y_{t-4}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \end{bmatrix}$$

$$\mathcal{E}_3 = \begin{bmatrix} 0 \\ -2\theta_1 \\ -1 \\ 0 \end{bmatrix}$$

Библиография

[1] Ф. Хайяши, *Эконометрика*. в Серия «Академический учебник» / Российская академия народного хозяйства и государственный службы при Президенте Российской Федерации. Москва: Дело, 2017. Просмотрено: 11 январь 2025 г. [Онлайн]. Доступно на: https://search.rsl.ru/ru/record/01008862921

[2] F. Hayashi, *Econometrics*. Princeton: Princeton University Press, 2000.

[3] J. D. Hamilton, *Time Series Analysis*. Princeton, N.J: Princeton University Press, 1994.

[4] Я. Магнус, П. Катышев, и А. Пересецкий, *Эконометрика. Начальный курс. Учебник. 9-е издание*, 9-е изд., испр. Москва: Издательский дом «Дело» РАНХиГС, 2021.

[5] R. F. Galbraith и J. I. Galbraith, «On the Inverses of Some Patterned Matrices Arising in the Theory of Stationary Time Series », *Journal of Applied Probability*, т. 11, вып. 1, сс. 63–71, 1974, doi: 10.2307/3212583.

[6] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, и G. M. Ljung, *Time Series Analysis: Forecasting and Control*, Fifth edition. в Wiley series in probabilit and statistics. Hoboken, New Jersey: John Wiley & Sons, Inc, 2016.

[7] L. P. Hansen, «Generalized Method of Moments Estimation», в *The New Palgrave Dictionary of Economics*,

S. N. Durlauf и L. E. Blume, Ред., Basingstoke, Hampshire: Palgrave Macmillan, 2007. [Онлайн]. Доступно на: https://home.uchicago.edu/~lhansen/palgrave.pdf

[8] L. P. Hansen, «Large Sample Properties of Generalized Method of Moments Estimators», *Econometrica*, т. 50, вып. 4, сс. 1029–1054, 1982, doi: 10.2307/1912775.

[9] L. Mátyás, Ред., *Generalized Method of Moments Estimation*. USA: Cambridge University Press, 1999.