Лекция 6

Модели с переключением режимов

Зямалов В.Е.

Подробнее можно посмотреть в [Enders, 2015, гл. 7].

1 Линейные модели

Рассмотрим простую AR(1) модель

$$y_t = a_0 + a_1 y_{t-1} + \varepsilon_t, 0 < a_1 < 1$$

Обозначив математическое ожидание y_t как $\bar{y} = \frac{a_0}{1-a_1}$, можно переписать это уравнение как

$$y_t - \bar{y} = a_1 (y_{t-1} - \bar{y}) + \varepsilon_t$$

Если $y_t \neq \bar{y}$, то a_1-я часть отклонения перейдет в следующий период. Причем отметим, что вне зависимости ни от каких условий, в следующий период перейдет именно a_1-я часть отклонения y_t от своего математического ожидания.

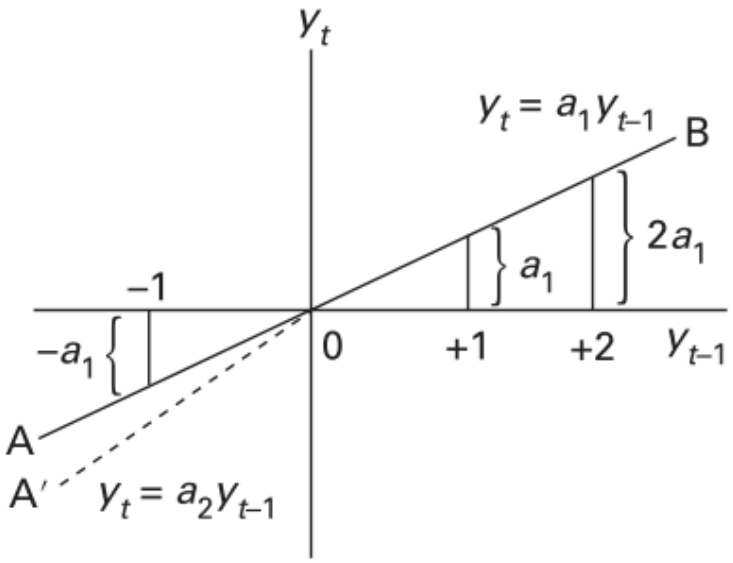


Рис. 1: Нелинейность модели

Однако имеются свидетельства того, что переходящая часть может зависеть от

знака отклонения!

$$y_t - \bar{y} = \begin{cases} a_1 (y_{t-1} - \bar{y}) + \varepsilon_t & y_{t-1} > \bar{y} \\ a_2 (y_{t-1} - \bar{y}) + \varepsilon_t & y_{t-1} \leqslant \bar{y} \end{cases}$$

1.1 NLAR модель

Рассмотрим простейший[1] вид модели, который может моделировать подобное поведение — нелинейную AR (NLAR) модель

$$y_t = f(y_{t-1}, y_{t-2}, \dots) + \varepsilon_t$$

где $f(\dots)$ — некоторая скалярная нелинейная функция.

Очевидно, что данная модель обладает крайне большой гибкостью, позволяющей моделировать самое разное поведение. Однако, не менее очевидно, что оценивать данную модель может быть крайне сложно; так как оценивание будет проводиться либо методом максимального правдоподобия, либо нелинейным МНК, то вид функции может привести к катастрофическому усложнению вычислительных процедур.

Также, если функциональная форма $f(\dots)$ неизвестна, то сложно разделить нелинейность в параметрах от нелинейности в переменных. Для статистических тестов может быть сложным увидеть разницу между моделью, в которой некоторые регрессоры входят со степенью, отличной от 1, и моделью, в которой параметры изменяются во времени.

Отметим, что NAR модель можно представить в виде модели с переменным параметром

$$y_t = \underbrace{\tilde{t}(y_{t-1}, y_{t-2}, \dots)}_{\alpha_{1,t}} y_{t-1} + \varepsilon_t$$

1.2 Обобщенная AR модель

В свете сказанного выше хотелось бы несколько упростить модель[2]. Достичь этого можно при помощи разложения $f(\dots)$ в ряд Тейлора до какой-либо **разумной** степени.

Например, рассмотрим NLAR(2)

$$y_t = f(y_{t-1}, y_{t-2}) + \varepsilon_t$$

[1] С позиции внешнего вида формулы, но, отнюдь, не с позиций расчетов.

[2] И жизнь эконометриста...

и разложим f, допустим, до третьей степени:

$$\begin{aligned} y_t = {} & a_0 + a_1 y_{t-1} + a_2 y_{t-2} + \\ & + a_{11} y_{t-1}^2 + a_{22} y_{t-2}^2 + a_{12} y_{t-1} y_{t-2} + \\ & + a_{111} y_{t-1}^3 + a_{112} y_{t-1}^2 y_{t-2} + a_{122} y_{t-1} y_{t-2}^2 + a_{222} y_{t-2}^3 + \\ & + \varepsilon_t \end{aligned}$$

Для NLAR(p) нам понадобится запись покомпактнее

$$y_t = a_0 + \sum_{i=1}^{p} a_i y_{t-i} + \sum_{i=1}^{p} \sum_{j=i}^{p} \sum_{k=1}^{r} \sum_{l=1}^{s} a_{ijkl} y_{t-i}^k y_{t-j}^l + \varepsilon_t$$

Чтобы не поменять шило на мыло и не получить вместо нелинейной модели линейную, но с астрономическим числом коэффициентов, обычно вводят ограничение $s + r \leqslant 4$.

Для сокращения модели можно использовать весь инструментарий t- и F-тестов, однако из-за, очевидно, крайне высокой мультиколлинеарности, оптимальным будет использование информационных критериев.

1.3 Билинейная модель (BL)

По аналогии с ARMA-моделями можно **значительно** сократить модель, введя в нее лаги ошибки ε_t

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \beta_1 \varepsilon_{t-1} + \gamma_1 y_{t-1} \varepsilon_{t-1} + \varepsilon_t$$

Двумерные BL модели являются естественным расширением ARMA модели в том плане, что для учета нелинейности они включают произведение y_{t-i} и ε_{t-j}. В общем виде двумерная модель BL(p,q,r,s) равна

$$y_t = \alpha_0 + \sum_{i=1}^{p} \alpha_i y_{t-i} + \varepsilon_t + \sum_{i=1}^{q} \beta_i \varepsilon_{t-i} + \sum_{i=1}^{r} \sum_{j=1}^{s} c_{ij} y_{t-i} \varepsilon_{t-j}$$

Двумерную модель можно рассматривать как модель со стохастическими параметрами. Чтобы понять это, перепишем для примера BL модель

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + c_1 y_{t-1} \varepsilon_{t-1} + \varepsilon_t$$

в виде

$$y_t = \alpha_0 + \underbrace{(\alpha_1 + c_1 \varepsilon_{t-1})}_{\alpha_{1,t}} y_{t-1} + \varepsilon_t$$

1.4 Тестирование нелинейности

1.4.1 Анализ коррелограммы

Если построить ACF для **ряда**, то можно получить неверный результат. Пусть

$$y_t = \varepsilon_{t-1}^2 + \varepsilon_t, \varepsilon_t \sim WN(0,\sigma^2)$$

Очевидно, что

$$\mathrm{E}\, y_t = \mathrm{E}\, y_{t-1} = \sigma^2$$

Тогда

$$\begin{aligned}\gamma(i) &= \mathrm{E}\left(y_t - \sigma^2\right)\left(y_{t-i} - \sigma^2\right) = \\ &= \mathrm{E}\left(\varepsilon_{t-1}^2 + \varepsilon_t - \sigma^2\right)\left(\varepsilon_{t-1-i}^2 + \varepsilon_{t-i} - \sigma^2\right) = \\ &= \mathrm{E}\left(\varepsilon_{t-1}^2\varepsilon_{t-1-i}^2 + \varepsilon_{t-1}^2\varepsilon_{t-i} - \varepsilon_{t-1}^2\sigma^2 + \right. \\ &\quad + \varepsilon_t\varepsilon_{t-1-i}^2 + \varepsilon_t\varepsilon_{t-i} - \varepsilon_t\sigma^2 - \\ &\quad \left. -\sigma^2\varepsilon_{t-1-i}^2 - \sigma^2\varepsilon_{t-i} + \sigma^2\sigma^2\right)\end{aligned}$$

Так как

- $\mathrm{E}(\varepsilon_{t-i}^2\varepsilon_{t-j}^2) = \sigma^2\sigma^2, i \neq j$,
- $\mathrm{E}(\varepsilon_t\varepsilon_{t-j}^2) = \mathrm{E}\,\varepsilon_t\sigma^2 = 0, j \neq 0$,

то

$$\gamma(i) = \mathrm{E}\left[\varepsilon_{t-1}^2\varepsilon_{t-i}\right] = \begin{cases} 0 & i \neq 1 \\ 0 & i = 1, \varepsilon_t \sim N(0,\sigma^2) \end{cases}$$

Однако, анализ **квадратов** и **кубов** остатков может выявить наличие нелинейности.

Хороший пример приведен в [Enders, 2015].

Строго говоря, к квадратам остатков «наилучшей» линейной модели можно применять и тест Льюнг-Бокса, и тест МакЛеода-Ли.

1.4.2 RESET-тест

Тест на ошибочную спецификацию проверяет отсутствие связи между остатками модели и ее регрессорами или подобранными значениями.

1. Оцените «наилучшую» линейную модель и получите остатки $\{e_t\}$ и подобранные значения $\{\hat{y}_t\}$.
2. Оцените модель

$$e_t = \delta z_t + \sum_{h=2}^{H} \alpha_h \hat{y}_t^h + \nu_t, H \geqslant 2$$

где z_t — регрессоры линейной модели.

3. Протестируйте совместную гипотезу $\alpha_2 = \cdots = \alpha_H = 0$.

Тест прост, но имеет малую мощность для выявления асимметричных моделей.

1.4.3 Тест множителей Лагранжа (ML)

Описанные выше тесты не дают информацию о виде нелинейной модели! LM-тест позволяет тестировать гипотезу линейности против **конкретной** альтернативы.

Пусть $f(\dots)$ — нелинейная функция, α — параметры $f(\dots)$.

1. Оцените **линейную** часть $f(\dots)$ и получите остатки $\{e_t\}$.
2. Постройте частные производные $\frac{\partial f}{\partial \alpha}\Big|_{H_0}$ в предположении истинности нулевой гипотезы линейности. Оцените регрессию e_t на эти частные производные.
3. Статистика TR^2 имеет распределение χ^2 с числом степеней свободы, равным числу регрессоров на шаге 2[3].

Тест позволяет тестировать конкретную нелинейную альтернативу, поскольку мы вручную задаем вид $f(\dots)$ и считаем частные производные. Но и он не всесилен: если компоненты двух альтернативных моделей достаточно сильно коррелируют, то тест может не справиться с их разделением. Например,

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \alpha_3 y_{t-1} y_{t-2} + \varepsilon_t$$
$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \alpha_3 \varepsilon_{t-1} y_{t-2} + \varepsilon_t$$

Так как y_{t-1} и ε_{t-1}, очевидно, достаточно сильно коррелируют, то статистики для этих моделей могут быть достаточно близки.

2 Проблема Дэвиса

Вы можете подумать, что достаточно оценить нелинейную модель и наложить ограничения на ряд параметров, позволяющие протестировать модель на линейность. Однако, в случае нелинейных моделей сделать вывод, зачастую, достаточно сложно из-за «неизвестных зашумляющих параметров» или «проблемы Дэвиса». Проблема возникает тогда, когда один (или более) из параметров модели неидентифицируем при истинности нулевой гипотезы.

Рассмотрим нелинейную модель $y_t = \alpha_0 + \alpha_1 x_t^{\alpha_2} + \varepsilon_t$. Предположим, что вы оценили модель и хотите проверить гипотезу $\alpha_2 = 0$. Должно быть понятно, что при истинности нулевой гипотезы $\alpha_2 = 0$ значения α_0 и α_1 неидентифицируемы, так как модель вырождается в $y_t = \alpha_0 + \alpha_1 + \varepsilon_t$. Если эта сумма, например, равна 5, то любые два значения α_0 и α_1 являются удовлетворительными, покуда $\alpha_1 = 5 - \alpha_0$.

[3] На малых выборках используйте F-тест.

Следовательно, собственные значения α_0 и α_1 не идентифицированы при нулевой гипотезе $\alpha_2 = 0$. Аналогичные замечания справедливы и для $\alpha_1 = 0$. При нулевой гипотезе $\alpha_1 = 0$ подходит любое значение α_2. По сути функции правдоподобия безразлично значение α_2 при $\alpha_1 = 0$. Заметим, что гипотеза $\alpha_0 = 0$ не приводит в проблеме Дэвиса, так как α_1 и α_2 идентифицируемы даже при $\alpha_0 = 0$.

Строго говоря, рассмотрим модель с двумя параметрами такую, что функция логарифмического правдоподобия может быть записана как функция от параметров α_1 и α_2:

$$L\left(\alpha_1,\alpha_2\right)$$

В обычном случае, максимизация L по α_1 и α_2 приводит к неограниченным оценкам параметров[4]. Обозначим это максимизированное значение $L_a(\alpha_1,\alpha_2)$.

Предположим теперь, что мы накладываем ограничение $\alpha_1 = \bar{\alpha}_1$ и максимизируем L по α_2. При нулевой гипотезе максимизированное значение L равно $L_n(\bar{\alpha}_1,\alpha_2)$.

Статистика теста отношений правдоподобий равна

$$R = 2\left[L_a\left(\alpha_1,\alpha_2\right) - L_n\left(\bar{\alpha}_1,\alpha_2\right)\right] \sim \chi^2(1)$$

где число степеней свободы равно числу ограничений. В идеальной ситуации, при истинности гипотезы $\alpha_1 = \bar{\alpha}_1$ оценка α_2 должна быть такой же и при нулевой и при альтернативной гипотезе; поэтому должно выполняться

$$L_a\left(\alpha_1,\alpha_2\right) = L_n\left(\bar{\alpha}_1,\alpha_2\right)$$

Предположим, что под нулевой гипотезой значение α_2 неидентифицируемо. Другими словами, предположим, что $\partial L_n/\partial\alpha_2 = 0,\ \forall\alpha_2$. В сущности, при справедливости нулевой гипотезы α_2 не влияет на функцию правдоподобия, то есть значение r становится равным

$$r = 2\left[L_a\left(\alpha_1,\alpha_2\right) - L_n\left(\bar{\alpha}_1\right)\right]$$

В этом случае разность между $L_a\left(\alpha_1,\alpha_2\right)$ и $L_n\left(\bar{\alpha}_1\right)$ будет зависеть от значения α_2; статистика $R \nsim \chi^2(1)$.

Дэвис [Davies, 1987] предложил использовать **супремум** тест: рассчитать критические значения при помощи таких значений зашумляющих параметров, при которых отвержение становится наиболее сложным. Для получения критических значений можно воспользоваться следующим методом Монте-Карло:

1. Сгенерируйте ряд $\{y_t\}$ при нулевой гипотезе (можно использовать бутстрап, если создавать $\{y_t\}$ на базе реальных остатков линейной модели).

2. Оцените наилучшую нелинейную модель.

[4] В смысле, что на них не накладываются ограничения.

3. Получите t-статистику (или F-статистику, или статистику χ^2) для нулевой гипотезы о равенстве нулю коэффициентов уравнения.

4. Повторяйте эту процедуру много раз для получения распределения интересующей нас статистики. Для заданного p-значения — например 5% для двухстороннего t-теста — выборочную t-статистику можно сравнивать с 2,5% и 97,5% перцентилями сгенерированного распределения.

3 Пороговые модели

В многорежимных моделях $\{y_t\}$ зависит от состояния системы. Например, во время рецессии безработица растет быстрее, чем она же падает во время бума. То есть модель может находиться в одном из **режимов**.

Такие модели, обычно, оценивать достаточно тяжело. Статистические пакеты обычно включают только простейшие модели.

3.1 TAR модель

Простейшая TAR модель имеет следующий вид [Tong, Lim, 1980][5]

$$y_t = \begin{cases} a_1 y_{t-1} + \varepsilon_{1t} & y_{t-1} > 0 \\ a_2 y_{t-1} + \varepsilon_{2t} & y_{t-1} \leqslant 0 \end{cases}$$

Если $\operatorname{Var} \varepsilon_{1t} = \operatorname{Var} \varepsilon_{2t}$, то можно переписать модель в виде

$$y_t = a_1 I_t y_{t-1} + a_2 \left(1 - I_t\right) y_{t-1} + \varepsilon_t$$
$$I_t = \begin{cases} 1 & y_{t-1} > 0 \\ 0 & y_{t-1} \leqslant 0 \end{cases}$$

В более общем виде модель записывается как

$$y_t = \begin{cases} \alpha_{10} + \sum_{i=1}^{p} \alpha_{1i} y_{t-i} + \varepsilon_{1t} & y_{t-1} > 0 \\ \alpha_{20} + \sum_{i=1}^{r} \alpha_{2i} y_{t-i} + \varepsilon_{2t} & y_{t-1} \leqslant 0 \end{cases}, \quad \operatorname{Var} \varepsilon_{1t} \neq \operatorname{Var} \varepsilon_{2t}$$

[5] Данный вид модели также называется самовозбуждающейся TAR (SETAR).

или

$$y_t = I_t \left[\alpha_{10} + \sum_{i=1}^{p} \alpha_{1i} y_{t-i} \right] + (1 - I_t) \left[\alpha_{20} + \sum_{i=1}^{r} \alpha_{2i} y_{t-i} \right] + \varepsilon_t$$

$$I_t = \begin{cases} 1 & y_{t-1} > \tau \\ 0 & y_{t-1} \leqslant \tau \end{cases}$$

$$\text{Var}\, \varepsilon_{1t} = \text{Var}\, \varepsilon_{2t}$$

TAR модель легко оценивается при помощи обычного МНК.

Если пороговое значение τ неизвестно, то Чан [Chan, 1993] предложил способ получения его состоятельной оценки:

1. Определите допустимые границы для порогового значения. Не забудьте оставить достаточно наблюдений для оценивания коэффициентов в каждом из режимов.
2. Для **каждого** значения y_t в заданных пределах оцените TAR с $\tau = y_t$.
3. Состоятельной оценкой τ будет $\arg\min_\tau RSS(\tau)$.

3.1.1 Модификации TAR

Произвольная глубина запаздывания в качестве определяющей переменной можно использовать произвольный лаг y_{t-d}. d можно оценить аналогично τ: последовательным перебором и взятием $d = \arg\min RSS$.

Несколько режимов (band-TAR)

$$y_t = \alpha_{10} + \sum_{i=1}^{p_1} \alpha_{1i} y_{t-i} + \varepsilon_{1t}, \qquad y_{t-1} \leqslant \tau_1$$

$$y_t = \alpha_{20} + \sum_{i=1}^{p_2} \alpha_{2i} y_{t-i} + \varepsilon_{2t}, \qquad \tau_1 < y_{t-1} \leqslant \tau_2$$

$$\ldots$$

$$y_t = \alpha_{n0} + \sum_{i=1}^{p_n} \alpha_{ni} y_{t-i} + \varepsilon_{nt}, \qquad \tau_{n-1} < y_{t-1}$$

Модель регрессии с порогом перенос идеи TAR на регрессионные модели с объясняющими переменными.

$$y_t = a_0 + (a_1 + b_1 I_t)\, x_t + \varepsilon_t$$

$$I_t = \begin{cases} 1 & y_{t-d} > \tau \\ 0 & y_{t-d} \leqslant \tau \end{cases}$$

Инерционная TAR (M-TAR) отличается определение I_t

$$I_t = \begin{cases} 1 & \Delta y_{t-1} > 0 \\ 0 & \Delta y_{t-1} \leqslant 0 \end{cases}$$

3.1.2 Тестирование TAR

TAR-модель недифференцируема в точке τ, следовательно LM-тесты не подходят.

Можно воспользоваться сумремум тестом Дэвиса. Также можно применить F-тест

$$F = \frac{(RSS_r - RSS_u)/n}{RSS_u/(T-2n)}$$

где RSS_r — RSS линейной модели (H_0), RSS_u — RSS TAR-модели.

Однако мы не можем использовать табличные значения! Хансен [Hansen, 1997] предложил следующую процедуру:

1. Сгенерируйте последовательность $\{\varepsilon_t\}$, $\varepsilon_t \sim N(0,1)$ длины T.
2. Оцените линейную и TAR-модели с $\{\varepsilon_t\}$ в левой части. В правой должны быть y_t! Получите RSS_r^* и RSS_u^*, соответственно.
3. Рассчитайте F^*.
4. Повторяя шаги 1–3 большое количество раз набираем выборочную функцию распределения статистики.

3.2 Тесты на наличие единичного корня и TAR модели

Предположим, что вы уверены в том, что $\mathbf{y}_t$ имеет TAR природу. Перед оцениванием TAR модели вы, возможно, захотите определить, возвращается ли ряд к своему долгосрочному равновесному значению. [Pippenger, Goering, 1993; Balke, Fomby, 1997] показали, что стандартные тесты на единичный корень обладают низкой мощностью в отношении рядов, порожденных нелинейными моделями.

[Enders, Granger, 1998] предложили расширение теста на наличие единичных корней при альтернативе TAR модели. Рассмотрим модель

$$\Delta y_t = I_t \rho_1 (y_{t-1} - \tau) + (1 - I_t) \rho_2 (y_{t-1} - \tau) + \sum_{i=1}^{p} \alpha_i \Delta y_{t-i} + \varepsilon_t$$

$$I_t = \begin{cases} 1 & \text{если } y_{t-1} \geqslant \tau \\ 0 & \text{если } y_{t-1} < \tau \end{cases} \quad \text{или} \quad I_t = \begin{cases} 1 & \text{если } \Delta y_{t-1} \geqslant \tau \\ 0 & \text{если } \Delta y_{t-1} < \tau \end{cases}$$

Заметим, что если $\rho_1 = \rho_2 = 0$, то процесс является случайным блужданием. Достаточным условием стационарности последовательности $\{y_t\}$ является $-2 < (\rho_1, \rho_2) <$

0[6].

Для проведения теста следует сделать следующее:

1. Если значение τ и вид TAR модели вам известны, то оцените приведенную выше модель.

   - Если значение τ вам не известно, то воспользуйтесь процедурой [Chan, 1993].
   - Если вы не уверены насчет вида модели — TAR или M-TAR — то воспользуйтесь процедурой [Там же] для обоих случаев и выберите наилучшую из моделей TAR или M-TAR при помощи информационных критериев.

2. Воспользуйтесь выбранной моделью для расчета F-статистики для нулевой гипотезы $\rho_1 = \rho_2 = 0$. Для TAR модели сравните эту статистику с соответствующим критическим значением из таблицы [Enders, 2015, прил. G]:

   - Используйте часть A, если вы оцениваете τ для TAR модели, и часть B — для M-TAR модели.
   - Если вам известно пороговое значение, и вы оцениваете M-TAR модель, то используйте часть C.
   - В случае TAR модели с известным порогом тест имеет более низкую мощность по сравнению с тестом Дики-Фуллера. Критические значения для этого случая не приведены.

3. Если альтернативная гипотеза не отвергается (то есть при наличии «аттрактора»), то возможно провести тестирование симметричности коррекции, так как совместное асимптотичесоке распределение ρ_1 и ρ_2 сходится к многомерному нормальному. То есть, нулевая гипотеза $\rho_1 = \rho_2$ может быть проверено с использованием метода бутсрапа Хансена [Hansen, 1997] или, приблизительно, с использованием стандартного F-теста.

3.3 Модели с плавной сменой режимов

Вернемся к TAR модели

$$y_t = a_1 I_t y_{t-1} + a_2 (1 - I_t) y_{t-1} + \varepsilon_t$$

Если заменить I_t на некую непрерывную функцию $G(s_t; \gamma, c)$, то получим простейшую STAR-модель

$$y_t = a_1 y_{t-1} G(s_t; \gamma, c) + a_2 [1 - G(s_t; \gamma, c)] y_{t-1} + \varepsilon_t$$

[6] Петручелли и Вулфорд [Petruccelli, Woolford, 1984] показали, что более слабыми достаточными условиями стационарности $\{y_t\}$ являются $\rho_1 < 0$, $\rho_2 < 0$ и $(1 + \rho_1)(1 + \rho_2) < 1$.

$$y_t = \underbrace{\left(a_{10} + \sum_{i=1}^{p} a_{1i} y_{t-i}\right)}_{a_1' x_t} G\left(s_t; \gamma, c\right) + \left(a_{20} + \sum_{i=1}^{p} a_{2i} y_{t-i}\right) \left[1 - G\left(s_t; \gamma, c\right)\right] + \varepsilon_t$$

где γ — крутизна перехода, c — пороговое значение.

Функция $G(\dots)$ должна быть ограничена между 0 и 1. На практике используются две:

- $G\left(s_t; \gamma, c\right) = \frac{1}{1+\exp[-\gamma(s_t - c)]}, \quad \gamma > 0$ — LSTAR-модель;
- $G(s_t; \gamma, c) = 1 - \exp\left[-\gamma\left(s_t - c\right)^2\right], \quad \gamma > 0$ — ESTAR-модель.

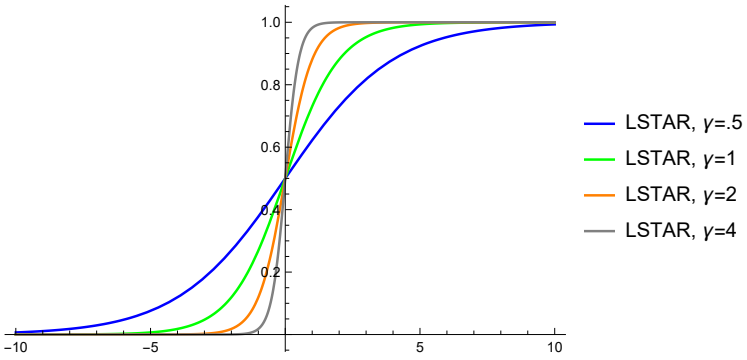


Рис. 2: LSTAR

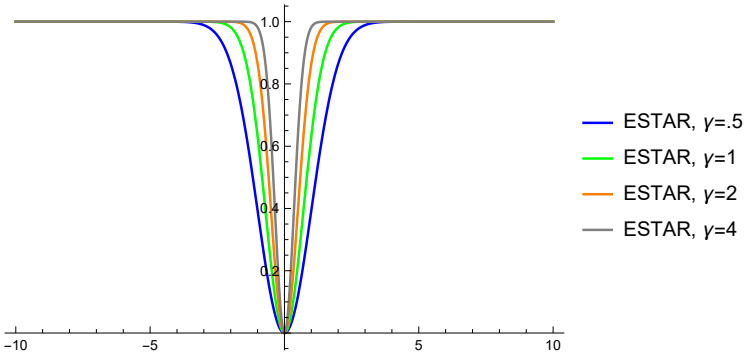


Рис. 3: ESTAR

Нетрудно заметить, что

- при $\gamma \to \infty$, LSTAR превращается в TAR,
- при $\gamma \to 0$, LSTAR превращается в линейную модель,
- ESTAR в обоих случаях превращается в линейную модель.

В качестве определяющей переменной s_t можно использовать практически что угодно: лаги y_t, экзогенную переменную, тренд...

Многорежимные STAR-модели имеют вид [D. v. Dijk, Teräsvirta, P. H. Franses, 2000]

$$y_t = \sum_{i=1}^{M} \left[G_i(s_t) - G_{i+1}(s_t)\right] \underbrace{\left(a_{i0} + \sum_{j=1}^{p} a_{ij} y_{t-j}\right)}_{a_i' x_t} + \varepsilon_t \tag{1}$$

$$\begin{aligned} G_i\left(s_t\right) &:= G\left(s_t;\gamma,c\right) \\ G_1 = 1 &\iff c_1 \to -\infty \\ G_{M+1} = 0 &\iff c_{M+1} \to \infty \\ a_i &= \left(a_{i0},a_{i1},a_{i2},\ldots\right)' \\ x_t &= \left(1,y_{t-1},y_{t-2},\ldots\right)' \end{aligned}$$

или

$$y_t = a_1' x_t + \left(a_2' - a_1'\right) x_t G\left(s_t;\gamma_2,c_2\right) + \cdots + \left(a_M' - a_{M-1}'\right) x_t G\left(s_t;\gamma_M,c_M\right) + \varepsilon_t \tag{2}$$

На рисунке 4 на примере трехрежимной модели показано, почему многорежимная STAR-модель задается выражением (1). Для каждого значения s_t можно рассчитать значения G^0,G^1,G^2,G^3. Данные значения в совокупности должны определить веса, с которыми отдельные авторегрессионные модели входят в общую модель при заданном значении s_t. Очевидно, что в сумме эти веса должны составлять единицу.

Именно это и отражено на рисунке. Фигурные скобки показывают интервалы, равные по своей длине весу соответствующего режима: от первого до последнего сверху вниз. Длины интервалов рассчитываются в полном соответствии с формулой (1)[7].

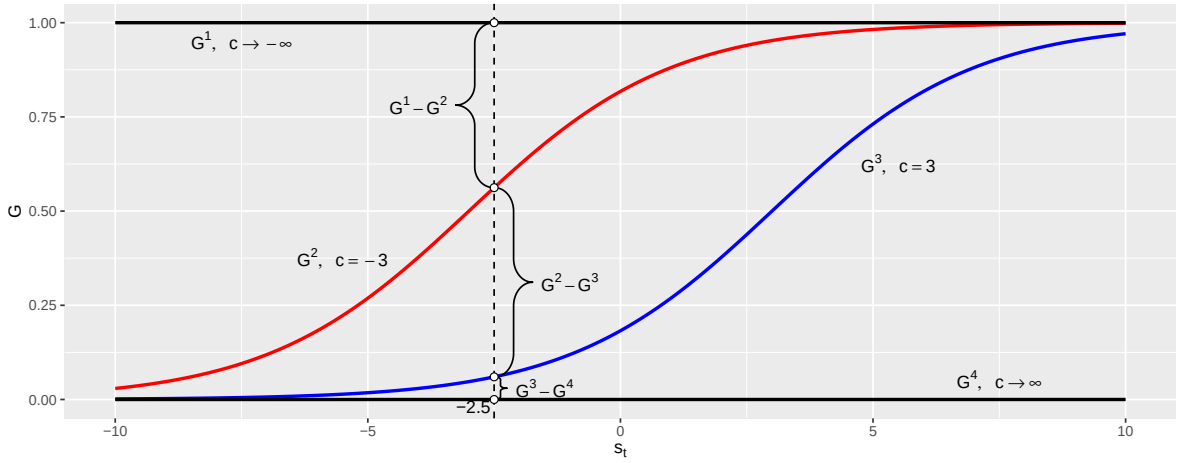


Рис. 4: Интерпретация формулы (1)

[7]Вспомните эконометрику межобъектных данных. На ней вам должны были рассказывать об особенностях интерпретации коэффициентов в модели с бинарными объясняющими переменными. Данный материал поможет вам понять, как связаны между собой (1) и (2).

3.3.1 Тестирование STAR

Вы уже должны догадаться, что LM-тесты нам не подходят. Терясвирта [Teräsvirta, Yang, 2014b] предложил простой тест, позволяющий не только выявить STAR, но и определить его тип: LSTAR или ESTAR.

Для описания общей идеи обозначим $x = -\gamma (s_t - c)$. Тогда

$$G(s_t; \gamma, c) = G(x) \approx G(0) + G'(0)x + \frac{G''(0)}{2!}x^2 + \frac{G'''(0)}{3!}x^3$$

Можно показать, что

$$\begin{aligned} &\text{LSTAR}: \quad G(x) \approx \frac{x}{4} - \frac{x^3}{48} \\ &\text{ESTAR}: \quad G(x) \approx x^2 \end{aligned}$$

LSTAR-модель примет вид

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \cdots + (\beta_0 + \beta_1 y_{t-1} + \dots) \left(\frac{x}{4} - \frac{x^3}{48} \right) + \varepsilon_t$$

ESTAR-модель примет вид

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \cdots + (\beta_0 + \beta_1 y_{t-1} + \dots) x^2 + \varepsilon_t$$

После обратной подстановки x получим для LSTAR

$$y_t = a' x_t + \beta_1' s_t x_t + \beta_2' s_t^2 x_t + \beta_3' s_t^3 x_t + \varepsilon_t$$

и для ESTAR

$$y_t = a' x_t + \beta_1' s_t x_t + \beta_2' s_t^2 x_t + \varepsilon_t$$

то есть аппроксимация ESTAR входит в LSTAR.

[Escribano, Jordá, 1999] предлагают раскладывать G для ESTAR до 4 степени, тогда имеем

$$y_t = a' x_t + \beta_1' s_t x_t + \beta_2' s_t^2 x_t + \beta_3' s_t^3 x_t + \beta_4' s_t^4 x_t + \varepsilon_t$$

Для тестирования LSTAR нужно оценить полученную приближенную модель и протестировать $H_0: \ \beta_1 = \beta_2 = \beta_3 = 0$:

- $TR^2 \sim \chi^2 (3(p+1))$
- $F \sim F(3(p+1); T - 4(p+1))$

Для ESTAR:

- $TR^2 \sim \chi^2 (4(p+1))$
- $F \sim F(4(p+1); T - 5(p+1))$

3.3.2 Оценивание и диагностика STAR

Оценивание STAR моделей при помощи МНК невозможно из-за мультипликативности коэффициентов[8]. Поэтому используем нелинейный МНК или метод максимального правдоподобия.

Также следует отметить, что из-за потенциальной возможности попадания в область, в которой функция правдоподобия будет достаточно «плоской», одновременная оценка γ и c обычно невозможна. Хагган и Одзаки [Haggan, Ozaki, 1981] предложили искать γ по сетке с одновременным оцениванием остальных коэффициентов нелинейным МНК.

Остаточная нелинейность Эйтрхайм и Терясвирта [Eitrheim, Teräsvirta, 1996] предложили тест на двухрежимный LSTAR процесс против трехрежимного. Идея аналогична тесту на STAR: раскладываем в ряд Тейлора $G(s_t;\gamma_2,c_2) \Rightarrow$ LSTAR с набором дополнительных регрессоров

$$
\begin{aligned}
y_t &= \alpha_0' x_t + G(s_t;\gamma_1,c_1)\,\alpha_1' x_t + \beta_1 \bar{w}_t s_t + \beta_2 \bar{w}_t s_t^2 + \beta_3 \bar{w}_t s_t^3 + \nu_t \\
\bar{w}_t &= (y_{t-1},y_{t-2},\dots)'
\end{aligned}
$$

Тестируемая гипотеза $H_0:\ \beta_1 = \beta_2 = \beta_3 = \mathbf{0}$.

Остаточная автокорреляция Можем воспользоваться LM-тестом:

1. Оцените модель и получите остатки $\{e_t\}$. На основе этих остатков рассчитайте RSS_0.
2. Оцените значения $\nabla y_t = \frac{\partial y_t}{\partial \theta}$, где под y_t для краткости понимаем модель, θ — совокупность всех оцениваемых параметров.
3. Оцените регрессию e_t на ∇y_t и $e_{t-1},\dots,e_{t-q}$. В [Там же] приводится эквивалентная форма этого выражения, в которой оценивается регрессия e_t на x_t, $x_t G(s_t;\gamma_1,c_1)$, $\frac{\partial G}{\partial \gamma}(s_t;\gamma_1,c_1)\,a_1' x_t$, $\frac{\partial G}{\partial c}(s_t;\gamma_1,c_1)\,a_1' x_t$ и $e_{t-1},\dots,e_{t-q}$. Для данной регрессии рассчитайте RSS.
4. Рассчитайте статистику

$$
\begin{aligned}
F &= \frac{(RSS_0 - RSS)/q}{RSS/_{T-n-q}} \sim F(q,T-n-q) \\
TR^2 &\sim \chi^2(q)
\end{aligned}
$$

где n — число переменных в ∇y_t.

[8] На самом деле это не совсем так. [Teräsvirta, Yang, 2014b] показывают, что если зафиксировать параметры G, то получившаяся модель оенивается обычным МНК.

4 Векторные модели с переключением режимов

4.1 TAR модели

Подробно останавливаться на TAR модели не стоит, так как принципиально ничего в их отношении не меняется.

$$\mathbf{y}_t = I_t \left[A_{10} + \sum_{i=1}^{p} A_{1i}\mathbf{y}_{t-i} \right] + (1 - I_t) \left[A_{20} + \sum_{i=1}^{r} A_{2i}\mathbf{y}_{t-i} \right] + \boldsymbol{\varepsilon}_t$$

$$I_t = \begin{cases} 1 & s_{t-1} > \tau \\ 0 & s_{t-1} \leqslant \tau \end{cases}$$

$$A_{i0} \sim (k \times 1)\,, i = 1{,}2$$

$$A_{ij} \sim (k \times k)\,, i = 1{,}2,\, j = 1, \dots, \{p{,}r\}$$

4.2 VSTAR модели

VSTAR модель — многомерное обобщение одномерной STAR модели, простейшая форма которой имеет вид [D. v. Dijk, Teräsvirta, P. H. Franses, 2000; Teräsvirta, Yang, 2014b]

$$\mathbf{y}_t = \phi_1' \mathbf{x}_t + (\phi_2 - \phi_1)' \mathbf{x}_t g(s_t \mid \gamma{,}c) + \varepsilon_t$$

где $\mathbf{x}_t$ — вектор **всех** регрессоров, включая лаги $\mathbf{y}_t$, экзогенные Согласно [Rothman, D. J. C. v. Dijk, P. H. B. F. Franses, 1999], коинтеграционное отношение также может быть включено в список экзогенных переменных.

Очевидным обобщением является многорежимная STAR модель

$$\mathbf{y}_t = \phi_1' \mathbf{y}_t + \tilde{\phi}_2' \mathbf{y}_t g(s_t \mid \gamma_1{,}c_1) + \tilde{\phi}_3' \mathbf{y}_t g(s_t \mid \gamma_2{,}c_2) + \dots + \varepsilon_t$$

где подразумевается, что $c_1 < c_2 < c_3 < \dots$.

Если пойти дальше, то следующим очевидным обобщением STAR будет многомерная, или векторная STAR [Camacho, 2004]. Начнем с модели VAR(p) с одним режимом

$$\mathbf{y}_t = A_1' \mathbf{y}_{t-1} + A_2' \mathbf{y}_{t-2} + \dots + A_p' \mathbf{y}_{t-p} + \Phi' d_t + \varepsilon_t \tag{3}$$

где $\mathbf{y}_t \sim (k \times 1)$ — вектор эндогенных переменных, $d_t \sim (q \times 1)$ — вектор всех детерминированных компонентов, $A_i \sim (k \times k)\,, \Phi \sim (q \times k)$ — матрицы соответствующих коэффициентов.

Модель (3) можно записать в более компактной форме. Если принять

$$F = \left(A_1', A_2', \dots, A_p', \Phi'\right)' \qquad \{(pk + q) \times k\}$$

$$\mathbf{x}_t = \left(\mathbf{y}_{t-1}', \mathbf{y}_{t-2}', \dots, \mathbf{y}_{t-p}', d_t'\right) \quad \{(pk + 1) \times 1\}$$

тогда (3) примет следующий вид

$$\mathbf{y}_t = F'\mathbf{x}_t + \varepsilon_t \tag{4}$$

При помощи модели (4) многомерная STAR модель может быть записана как

$$\begin{aligned}
\mathbf{y}_t &= \left[\sum_{i=1}^{M} \left(G_t^i - G_t^{i+1}\right) F_i'\right] \mathbf{x}_t + \varepsilon_t \\
\varepsilon_t &\sim WN(0,\Omega) \\
G_t^i &= \text{diag}\left\{g\left(s_{1it} \mid \gamma_{i1},c_{i1}\right),\dots,g\left(s_{kit} \mid \gamma_{ik},c_{ik}\right)\right\} \\
G_t^1 &= I_k \\
G_t^{M+1} &= 0
\end{aligned} \tag{5}$$

(5) можно перепараметризовать в виде

$$\begin{aligned}
\mathbf{y}_t &= \left(\mathbf{B}_1' + G_t^1\mathbf{B}_2' + \cdots + G_t^{m-1}\mathbf{B}_m'\right)\mathbf{x}_t + \varepsilon_t \\
\varepsilon_t &\sim WN(0,\Omega) \\
G_t^i &= \text{diag}\left\{g\left(s_{1it} \mid \gamma_{i1},c_{i1}\right),\dots,g\left(s_{kit} \mid \gamma_{ik},c_{ik}\right)\right\} \\
\mathbf{B}_1 &= F_1 \\
\mathbf{B}_i &= F_i - F_{i-1}
\end{aligned} \tag{6}$$

Если принять $\mathbf{\Psi}_t = \left(I_k,G_t^1,\dots,G_t^{m-1}\right)'$ и $\mathbf{B} = (\mathbf{B}_1,\mathbf{B}_2,\dots,\mathbf{B}_m)$, то (6) примет вид

$$\mathbf{y}_t = \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t + \varepsilon_t \tag{7}$$

Мы должны сделать важное замечание. В самом общем случае **каждая** функция перехода g для **каждого** режима имеет свои собственные γ_{ij} и c_{ij} для **каждого** уравнения в системе! Хотя это самая общая и гибкая спецификация, ее может быть трудно оценить из-за того, что γ_{ij} и c_{ij} обычно оцениваются с помощью нелинейного МНК, а соответствующие начальные значения получаются с помощью поиска по сетке. Поэтому было бы лучше уменьшить количество γ_{ij} и c_{ij} настолько, насколько это возможно.

Самый простой, но подходящий в большинстве случаев способ — принять $\gamma_{m1} = \gamma_{m2} = \cdots = \gamma_{mk} = \gamma_m$ и $c_{m1} = c_{m2} = \cdots = c_{mk} = c_m$ для любого заданного режима m. Это означает, что все уравнения системы будут иметь одну и ту же функцию перехода для любого заданного режима m. Другими словами, матрица G_t^m примет следующий вид

$$G_t^m = I_k g\left(s_t \mid \gamma_m,c_m\right)$$

4.3 Оценивание VSTAR

Если мы соберем все параметры из (7), которые мы должны оценить, то получим

$$\theta = \{\mathbf{B},\Omega,\Gamma,C\}$$

где $\mathbf{B} = (\mathbf{B}_1,\mathbf{B}_2,\dots,\mathbf{B}_m)$, $\Gamma = \{\gamma_{ij}\}$, $C = \{c_{ij}\}$.

В работе [Camacho, 2004] предлагается оценивать параметры при помощи метода максимального правдопообия. [Teräsvirta, 1994; Teräsvirta, Yang, 2014a,b] для этой цели используют нелинейный МНК.

$$\hat{\theta} = \arg\min_{\theta} \sum_{t=1}^{T} \left(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \left(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right) \tag{8}$$

Однако [Teräsvirta, Yang, 2014b] отмечают, что если зафиксировать значения Γ и C, т. е. значения параметров функции перехода, то система (7) превращается в линейную VAR-модель, которую можно оценить обычным МНК. Поэтому стратегия оценки следующая:

1. Построить сетку значений Γ и C, используя адекватные границы и плотность сетки.

2. В каждой точке сетки оценить систему по уравнениям МНК, используя соответствующие значения параметров переходной функции. Получить $\hat{\beta}_j$, т. е. оценки коэффициентов для каждого уравнения, и вычислить SSR системы.

3. Взять точку сетки с минимальным значением SSR.

4. Использовать полученные оценки в качестве начальных значений для NLM.

Мы можем легко показать, что условие первого порядка для (8) — это

$$\sum_{t=1}^{T} \mathbf{x}_t \left(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \mathbf{\Psi}_t' = 0 \tag{9}$$

или

$$\sum_{t=1}^{T} \mathbf{x}_t\mathbf{y}_t'\mathbf{\Psi}_t' = \sum_{t=1}^{T} \mathbf{x}_t\mathbf{x}_t'\mathbf{B}\mathbf{\Psi}_t\mathbf{\Psi}_t'$$

Тогда для фиксированных Γ и C мы получим

$$\operatorname{vec}\hat{\mathbf{B}} = \left[T^{-1}\sum_{t=1}^{T}\left(\mathbf{\Psi}_t\mathbf{\Psi}_t'\right)\otimes\left(\mathbf{x}_t\mathbf{x}_t'\right)\right]^{-1}\left[T^{-1}\sum_{t=1}^{T}\operatorname{vec}\left(\mathbf{x}_t\mathbf{y}_t'\mathbf{\Psi}_t'\right)\right]$$

что можно упростить до

$$\begin{aligned} \operatorname{vec}\hat{\mathbf{B}} &= (M'M)^{-1}M'\operatorname{vec}(Y') && (10)\\ M &= (\Upsilon_1,\dots,\Upsilon_t)' && \{Tk \times mk(pk+q)\}\\ \Upsilon_t &= \mathbf{\Psi}_t \otimes \mathbf{x}_t && \{mk(pk+q)\times k\} \end{aligned}$$

Ковариационная матрица Ω оценивается следующим образом

$$\begin{aligned} \hat{\Omega} &= T^{-1}\hat{E}'\hat{E}\\ \hat{E} &= (\hat{\varepsilon}_1,\dots,\hat{\varepsilon}_t)'\\ \hat{\varepsilon}_t &= \mathbf{y}_t - \mathbf{\Psi}_t'\hat{\mathbf{B}}'\mathbf{x}_t \end{aligned}$$

После того, как мы получим начальные значения, мы можем получить окончательные оценки с помощью следующего итерационного процесса:

1. При заданной оценке $\hat{\mathbf{B}}$ оцените Γ и C при помощи NLS.
2. Используя эти вновь полученные Γ и C, переоцените $\hat{\mathbf{B}}$.
3. Продолжайте, пока не будет достигнута сходимость.

5 Тесты на адекватность модели

В работе [Teräsvirta, Yang, 2014a] авторы приводят ряд тестов на адекватность оцененной LVSTAR модели. Рассмотрим их поподробнее.

В основе этих тестов лежит функция правдоподобия

$$\begin{aligned} \ln L(\theta \mid \mathbf{Y}) = -\frac{Tp}{2}\ln 2\pi - \frac{T}{2}\ln|\Omega| - \\ -\frac{1}{2}\sum_{t=1}^{T}(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)'\mathbf{\Omega}^{-1}(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t) \end{aligned}$$

5.1 Тест на линейность

Является многомерным обобщением теста [Teräsvirta, Yang, 2014b]. В основе лежит LVSTAR модель с одним переходом

$$\mathbf{y}_t = \mathbf{B}_1'\mathbf{x}_t + \mathbf{G}_t\mathbf{B}_2'\mathbf{x}_t + \boldsymbol{\varepsilon}_t$$

1. Оцените линейную модель регрессии $\mathbf{Y}$ на $\mathbf{X}$. Получите остатки $\bar{\mathbf{E}}$ и рассчитайте $\mathbf{RSS}_0 = \bar{\mathbf{E}}'\bar{\mathbf{E}}$.

2. Постройте матрицу $\mathbf{Z}_n$

$$\mathbf{Z}_n = \begin{bmatrix} \mathbf{x}_1' s_1 & \mathbf{x}_1' s_1^2 & \cdots & \mathbf{x}_1' s_1^n \\ \mathbf{x}_2' s_2 & \mathbf{x}_2' s_2^2 & \cdots & \mathbf{x}_2' s_2^n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{x}_T' s_T & \mathbf{x}_T' s_T^2 & \cdots & \mathbf{x}_T' s_T^n \end{bmatrix}$$

Оцените регрессию $\bar{\mathbf{E}}$ на $(\mathbf{X},\mathbf{Z}_n)$. Получите остатки $\bar{\mathbf{\Xi}}$ и рассчитайте $\mathbf{RSS}_1 = \bar{\mathbf{\Xi}}'\bar{\mathbf{\Xi}}$.

3. Рассчитайте статистику

$$\begin{aligned} LM_n &= T \operatorname{tr}\{\mathbf{RSS}_0^{-1}(\mathbf{RSS}_0 - \mathbf{RSS}_1)\} = \\ &= T(p - \operatorname{tr}\{\mathbf{RSS}_0^{-1}\mathbf{RSS}_1\}) \sim \chi^2\left(np\left(kp+q\right)\right) \end{aligned}$$

где k — размер $\mathbf{y}_t$, p — порядок авторегрессии, q — число детерминированных компонент.

Если для разных уравнений используются разные s_{it}, формирующие матрицы $\mathbf{S}_t = \operatorname{diag}(s_{1,t},\dots,s_{p,t})$, то тот же тест можно провести с использованием матрицы

$$\mathbf{Z}_n^s = \begin{bmatrix} \operatorname{vec}(\mathbf{S}_1 \otimes \mathbf{x}_1)' & \operatorname{vec}(\mathbf{S}_1^2 \otimes \mathbf{x}_1)' & \cdots & \operatorname{vec}(\mathbf{S}_1^n \otimes \mathbf{x}_1)' \\ \operatorname{vec}(\mathbf{S}_2 \otimes \mathbf{x}_2)' & \operatorname{vec}(\mathbf{S}_2^2 \otimes \mathbf{x}_2)' & \cdots & \operatorname{vec}(\mathbf{S}_2^n \otimes \mathbf{x}_2)' \\ \vdots & \vdots & \ddots & \vdots \\ \operatorname{vec}(\mathbf{S}_T \otimes \mathbf{x}_T)' & \operatorname{vec}(\mathbf{S}_T^2 \otimes \mathbf{x}_T)' & \cdots & \operatorname{vec}(\mathbf{S}_T^n \otimes \mathbf{x}_T)' \end{bmatrix}$$

Единственный минус — для этого варианта теста неизвестно распределение статистики.

5.1.1 Улучшение размера теста

Перемасштабированная LM-статистика

$$F = \frac{pT - K}{q \times pT} LM \sim F\left(q,pT-K\right)$$

где q — число ограничений, K — число оцениваемых параметров.

Аппроксимация Бартлетта статистики Уилкса

$$\begin{aligned} \Lambda &= \frac{|\mathbf{RSS}_1|}{|\mathbf{RSS}_0|} \sim \mathcal{L}(p,m,n) \\ \lambda &= \left\{\frac{1}{2}\left[p + \operatorname{cd}\left(\mathbf{Z}\right) + 1\right] + \operatorname{cd}\left(\mathbf{X}\right) - T\right\} \ln\Lambda \sim \chi^2\left(\operatorname{cd}\left(\mathbf{Z}\right) p\right) \end{aligned}$$

где $\operatorname{cd}(\dots)$ — число столбцов матрицы.

Статистика Рао

$$F_{Rao} = \left[\left(\frac{|\mathbf{RSS}_0|}{|\mathbf{RSS}_1|} \right)^{1/s} - 1 \right] \frac{Ns - \frac{1}{2}\text{cd}(\mathbf{Z})\, p + 1}{\text{cd}(\mathbf{Z})\, p} \sim F(\text{cd}(\mathbf{Z})\, p, Ns - \frac{1}{2}\text{cd}(\mathbf{Z})\, p + 1)$$

$$N = T - \text{cd}(\mathbf{X}) - \frac{1}{2}(p + \text{cd}(\mathbf{Z}) + 1)$$

$$s = \sqrt{\frac{p^2 \text{cd}^2(\mathbf{Z}) - 4}{p^2 + \text{cd}^2(\mathbf{Z}) - 5}}$$

5.2 Тест на остаточную автокорреляцию

1. Оцените LVSTAR модель без ограничений и соберите векторы остатков. Выберите глубину запаздываний J. Постойте матрицу $\bar{\mathbf{U}} = (\bar{\mathbf{u}}_{J+1}, \dots, \bar{\mathbf{u}}_T)'$ и рассчитайте[9] $\mathbf{RSS}_0 = \bar{\mathbf{U}}'\bar{\mathbf{U}}$.

   Также сформируйте матрицу $\bar{\mathbf{Z}} = (\bar{\mathbf{z}}_{J+1}, \dots, \bar{\mathbf{z}}_T)'$, где $\bar{\mathbf{z}}_t = (\bar{\mathbf{u}}'_{t-1}, \dots, \bar{\mathbf{u}}'_{t-J})'$.

   Рассчитайте матрицу

$$\bar{\mathbf{K}} = \begin{bmatrix} \text{vec}\left[\partial\left(\bar{\mathbf{\Psi}}'_{J+1}\bar{\mathbf{B}}'\mathbf{x}_{J+1}\right)/\partial\theta\right]' \\ \text{vec}\left[\partial\left(\bar{\mathbf{\Psi}}'_{J+2}\bar{\mathbf{B}}'\mathbf{x}_{J+2}\right)/\partial\theta\right]' \\ \vdots \\ \text{vec}\left[\partial\left(\bar{\mathbf{\Psi}}'_{T}\bar{\mathbf{B}}'\mathbf{x}_{T}\right)/\partial\theta\right]' \end{bmatrix}$$

2. Оцените регрессию $\bar{\mathbf{U}}$ на $(\bar{\mathbf{K}}, \bar{\mathbf{Z}})$. Получите остатки $\bar{\mathbf{\Xi}}$ и рассчитайте $\mathbf{RSS}_1 = \bar{\mathbf{\Xi}}'\bar{\mathbf{\Xi}}$.

3. Рассчитайте статистику[10]

$$\begin{aligned} LM_n &= (T - J)\,\text{tr}\left\{\mathbf{RSS}_0^{-1}(\mathbf{RSS}_0 - \mathbf{RSS}_1)\right\} = \\ &= (T - J)\left(p - \text{tr}\left\{\mathbf{RSS}_0^{-1}\mathbf{RSS}_1\right\}\right) \sim \chi^2(Jp^2) \end{aligned}$$

5.3 Аддитивная нелинейность

По-другому, тест на остаточную нелинейность.

1. Оцените LVSTAR модель без ограничений и соберите векторы остатков $\bar{\mathbf{E}}$. Оцените регрессию остатков $\bar{\mathbf{E}}$ на $\bar{\mathbf{K}}$ и соберите остатки $\bar{\mathbf{V}}$. Рассчитайте $\mathbf{RSS}_0 = \bar{\mathbf{V}}'\bar{\mathbf{V}}$.

2. Оцените регрессию $\bar{\mathbf{V}}$ на $(\bar{\mathbf{K}}, \bar{\mathbf{Z}}_N)$, где N — степень разложения g в ряд Тейлора. Получите остатки $\bar{\mathbf{\Xi}}$ и рассчитайте $\mathbf{RSS}_1 = \bar{\mathbf{\Xi}}'\bar{\mathbf{\Xi}}$.

[9] [Eitrheim, Teräsvirta, 1996] предлагают использовать вместо $\bar{\mathbf{U}}$ остатки регрессии $\bar{\mathbf{U}}$ на $\bar{\mathbf{K}}$.

[10] К этой и последующим статистикам можно применить методы увеличения размера.

3. Рассчитайте статистику

$$\begin{aligned} LM_n &= T\,\text{tr}\{\mathbf{RSS}_0^{-1}(\mathbf{RSS}_0 - \mathbf{RSS}_1)\} = \\ &= T(p - \text{tr}\{\mathbf{RSS}_0^{-1}\mathbf{RSS}_1\}) \sim \chi^2(pN(kp+q)) \end{aligned}$$

5.4 Тест на постоянство параметров

1. Оцените LVSTAR модель без ограничений и соберите векторы остатков $\bar{\mathbf{E}}$. Оцените регрессию остатков $\bar{\mathbf{E}}$ на $\bar{\mathbf{K}}$ и соберите остатки $\bar{\mathbf{V}}$. Рассчитайте $\mathbf{RSS}_0 = \bar{\mathbf{V}}'\bar{\mathbf{V}}$.

   Также постойте матрицы

$$\bar{\mathbf{Z}} = \begin{bmatrix} \text{vec}(\bar{\mathbf{\Psi}}_1 \otimes \mathbf{x}_1\tau_1)' \\ \text{vec}(\bar{\mathbf{\Psi}}_2 \otimes \mathbf{x}_2\tau_2)' \\ \vdots \\ \text{vec}(\bar{\mathbf{\Psi}}_T \otimes \mathbf{x}_T\tau_T)' \end{bmatrix}$$

   где $\tau_t = t/T$, и

$$\bar{\mathbf{K}} = \begin{bmatrix} \text{vec}[\partial(\bar{\mathbf{\Psi}}_1'\bar{\mathbf{B}}'\mathbf{x}_1)/\partial\theta]' \\ \text{vec}[\partial(\bar{\mathbf{\Psi}}_2'\bar{\mathbf{B}}'\mathbf{x}_2)/\partial\theta]' \\ \vdots \\ \text{vec}[\partial(\bar{\mathbf{\Psi}}_T'\bar{\mathbf{B}}'\mathbf{x}_T)/\partial\theta]' \end{bmatrix}$$

2. Оцените регрессию $\bar{\mathbf{V}}$ на $(\bar{\mathbf{K}},\bar{\mathbf{Z}})$, где N — степень разложения g в ряд Тейлора. Получите остатки $\bar{\mathbf{\Xi}}$ и рассчитайте $\mathbf{RSS}_1 = \bar{\mathbf{\Xi}}'\bar{\mathbf{\Xi}}$.

3. Рассчитайте статистику

$$\begin{aligned} LM_n &= T\,\text{tr}\{\mathbf{RSS}_0^{-1}(\mathbf{RSS}_0 - \mathbf{RSS}_1)\} = \\ &= T(p - \text{tr}\{\mathbf{RSS}_0^{-1}\mathbf{RSS}_1\}) \sim \chi^2\left(mp^2\left(kp+q\right)\right) \end{aligned}$$

6 Функции импульсных откликов

Рассмотрим «обычную» однорежимную VAR модель

$$\mathbf{y}_t = A_0 + A_1\mathbf{y}_{t-1} + \cdots + A_p\mathbf{y}_{t-p} + \varepsilon_t$$

Как показано, например, в [Lütkepohl, 2005], эту модель можно переписать в виде

$$\mathbf{y}_t = A_0 + \sum_{i=0}^{\infty}\Phi_i\varepsilon_{t-i}$$

или

$$\mathbf{y}_t = A_0 + \sum_{i=0}^{\infty} \Theta_i w_{t-i}$$

где $\Theta_i = \Phi_i P$, $w_t = \varepsilon_t P$, $\Phi_0 = I$, $\Phi_i = \sum_{j=1}^{i} \Phi_{i-j} A_j$. Φ_i и Θ_i интерпретируют как импульсные отклики.

В силу того, что в нелинейных моделях **возможна** смена режимов и, соответственно, коэффициентов, то подобный фокус в них неприменим. Для построения графиков функций импульсных откликов была предложена методология **обобщенных** IRF [Koop, Pesaran, Potter, 1996].

Основная формула

$$GI_{\mathbf{y}}(n, v_t, \omega_{t-1}) = \mathrm{E}[\mathbf{y}_{t+n} \mid v_t, \omega_{t-1}] - \mathrm{E}[\mathbf{y}_{t+n} \mid \omega_{t-1}]$$

или, если предположить, что GI_Y порождается тем же процессом, что и $\mathbf{y}_t$,

$$GI_{\mathbf{y}}(n, V_t, \Omega_{t-1}) = \mathrm{E}[\mathbf{y}_{t+n} \mid V_t, \Omega_{t-1}] - \mathrm{E}[\mathbf{y}_{t+n} \mid \Omega_{t-1}]$$

Свойства GI_Y:

1. $\mathrm{E}\left[GI_{\mathbf{y}}(n, V_t, \Omega_{t-1})\right] = \mathbf{0}$ — безусловное матожидание;
2. $\mathrm{E}\left[GI_{\mathbf{y}}(n, V_t, \omega_{t-1})\right] = \mathbf{0}$ — матожидание, условное относительно истории;
3. $\mathrm{E}\left[GI_{\mathbf{y}}(n, v_t, \Omega_{t-1})\right] = \mathrm{E}[\mathbf{y}_{t+n} \mid v_t] - \mathrm{E}[\mathbf{y}_{t+n}]$ — матожидание, условное относительно шока.

Список литературы

Balke N. S., *Fomby T. B.* Threshold Cointegration // International Economic Review. — 1997. — Т. 38, № 3. — С. 627—645.

Camacho M. Vector Smooth Transition Regression Models for US GDP and the Composite Index of Leading Indicators // Journal of Forecasting. — 2004. — Т. 23, № 3. — С. 173—196.

Chan K. S. Consistency and Limiting Distribution of the Least Squares Estimator of a Threshold Autoregressive Model // The Annals of Statistics. — 1993. — Т. 21, № 1. — С. 520—533.

Davies R. B. Hypothesis Testing When a Nuisance Parameter Is Present Only Under the Alternatives // Biometrika. — 1987. — Т. 74, № 1. — С. 33—43.

Dijk D. v., *Teräsvirta T.*, *Franses P. H.* Smooth Transition Autoregressive Models - A Survey of Recent Developments. — 2000. — 9 июня.

Eitrheim Ø., *Teräsvirta T.* Testing the Adequacy of Smooth Transition Autoregressive Models // Journal of Econometrics. — 1996. — 1 сент. — Т. 74, № 1. — С. 59—75.

Enders W. Applied Econometric Time Series. — Hoboken, NJ : Wiley, 2015. — 485 c.

Enders W., *Granger C. W. J.* Unit-Root Tests and Asymmetric Adjustment with an Example Using the Term Structure of Interest Rates // Journal of Business & Economic Statistics. — 1998. — Т. 16, № 3. — С. 304—311.

Escribano A., *Jordá O.* Improved Testing and Specification of Smooth Transition Regression Models // Nonlinear Time Series Analysis of Economic and Financial Data. — Boston, MA : Springer US, 1999. — С. 289—319.

Gentle J. E. Matrix Algebra: Theory, Computations and Applications in Statistics. — Cham : Springer International Publishing : Imprint: Springer, 2017. — 648 с.

Haggan V., *Ozaki T.* Modelling Nonlinear Random Vibrations Using an Amplitude-Dependent Autoregressive Time Series Model // Biometrika. — 1981. — Т. 68, № 1. — С. 189—196.

Hansen B. E. Inference in TAR Models // Studies in Nonlinear Dynamics & Econometrics. — 1997. — Т. 2, № 1.

Koop G., *Pesaran M. H.*, *Potter S. M.* Impulse Response Analysis in Nonlinear Multivariate Models // Journal of Econometrics. — 1996. — Т. 74, № 1. — С. 119—147.

Lütkepohl H. New Introduction to Multiple Time Series Analysis. — Berlin, Heidelberg : Springer, 2005.

Magnus J. R., *Neudecker H.* Matrix Differential Calculus with Applications in Statistics and Econometrics. — Hoboken, NJ : Wiley, 2019. — 1 с.

Petruccelli J. D., *Woolford S. W.* A Threshold AR(1) Model // Journal of Applied Probability. — 1984. — Т. 21, № 2. — С. 270—286.

Pippenger M. K., *Goering G. E.* Practitioners Corner: A Note on the Empirical Power of Unit Root Tests under Threshold Processes // Oxford Bulletin of Economics and Statistics. — 1993. — Т. 55, № 4. — С. 473—481.

Rothman P., *Dijk D. J. C. v.*, *Franses P. H. B. F.* A Multivariate STAR Analysis of the Relationship Between Money and Output. — 12.11.1999. — EI 9945—/A.

Teräsvirta T. Specification, Estimation, and Evaluation of Smooth Transition Autoregressive Models // Journal of the American Statistical Association. — 1994. — Т. 89, № 425. — С. 208—218.

Teräsvirta T., *Yang Y.* Linearity and Misspecification Tests for Vector Smooth Transition Regression Models. — 07.02.2014a. — № 2014—04.

Teräsvirta T., *Yang Y.* Specification, Estimation and Evaluation of Vector Smooth Transition Autoregressive Models with Applications. — 21.03.2014b. — № 2014—08.

Tong H., *Lim K. S.* Threshold Autoregression, Limit Cycles and Cyclical Data // Journal of the Royal Statistical Society. Series B (Methodological). — 1980. — Т. 42, № 3. — С. 245—292.

A Вывод (9)

The equation (9) derivation is pretty straightforward[11].

First, from [Gentle, 2017; Magnus, Neudecker, 2019] we know, that

$$df = \text{tr}\left[\left(\frac{df}{dA}\right)' dA\right]$$
$$df = d(\text{tr}\, f) = \text{tr}\,(df)$$

where tr is the trace function, i.e. the sum of the diagonal elements of a matrix, A is a matrix, f is a scalar function.

We have

$$f = \sum_{t=1}^{T} (\mathbf{y}_t - \mathbf{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' (\mathbf{y}_t - \mathbf{\Psi}_t' \mathbf{B}' \mathbf{x}_t)$$

Using the following properties of differential and trace

$$dA = (da_{ij})$$
$$d(AB) = dA\, B + A\, dB$$
$$d\text{tr}\, A = \text{tr}\,(dA)$$
$$dA' = (dA)'$$
$$\text{tr}\, A = \text{tr}\, A'$$
$$\text{tr}\,(AB) = \text{tr}\,(BA)$$
$$\text{tr}\,(A + B) = \text{tr}\, A + \text{tr}\, B$$

[11] Текст оставлен на английском, но он понятен и так.

we get the following chain of expressions

$$
\begin{aligned}
df &= \operatorname{tr}\left(d\sum_{t=1}^{T} \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right) = \\
&= \operatorname{tr}\sum_{t=1}^{T} d\left[\left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right] = \\
&= \sum_{t=1}^{T} \operatorname{tr} d\left[\left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right] = \\
&= \sum_{t=1}^{T} \operatorname{tr}\left[d\left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right) + \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' d\left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right] = \\
&= -\sum_{t=1}^{T} \operatorname{tr}\left[d\left(\boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right) + \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' d\left(\boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right] = \\
&= -\sum_{t=1}^{T} \left\{\operatorname{tr}\left[d\left(\boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right] + \operatorname{tr}\left[\left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' d\left(\boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right]\right\} = \\
&= -\sum_{t=1}^{T} \left\{\operatorname{tr}\left[\left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' d\left(\boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right] + \operatorname{tr}\left[\left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' d\left(\boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right]\right\} = \\
&= -2\operatorname{tr}\left[\sum_{t=1}^{T} \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' d\left(\boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right] = *
\end{aligned}
$$

Here we use $*$ to mark the break in the expression chain.

To proceed, let's simplify the differential inside the sum

$$
\begin{aligned}
d(\boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t) &= d\boldsymbol{\Psi}_t' \left(\mathbf{B}'\mathbf{x}_t\right) + \boldsymbol{\Psi}_t' \, d(\mathbf{B}'\mathbf{x}_t) = \\
&= \boldsymbol{\Psi}_t' \left(d\mathbf{B}'\mathbf{x}_t + \mathbf{B}' \, d\mathbf{x}_t\right) = \\
&= \boldsymbol{\Psi}_t' \, d\mathbf{B}' \, \mathbf{x}_t.
\end{aligned}
$$

For every t we can consider $\boldsymbol{\Psi}_t$ and $\mathbf{x}_t$ as constants, hence their differentials are zero.

With that, we get

$$
\begin{aligned}
* &= -2\operatorname{tr}\left[\sum_{t=1}^{T} \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)' \boldsymbol{\Psi}_t' \, d\mathbf{B}'\mathbf{x}_t\right] = \\
&= -2\operatorname{tr}\left[\sum_{t=1}^{T} \mathbf{x}_t' \, d\mathbf{B}_t \, \boldsymbol{\Psi}_t \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\right] = *
\end{aligned}
$$

From $\operatorname{tr}(AB) = \operatorname{tr}(BA)$ it follows that $\operatorname{tr}(A_1 A_2 \dots A_n) = \operatorname{tr}(A_n A_1 \dots A_{n-1})$. Then we have

$$
\begin{aligned}
* &= -2\operatorname{tr}\left[\sum_{t=1}^{T} \boldsymbol{\Psi}_t \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right) \mathbf{x}_t' \, d\mathbf{B}\right] = \\
&= \operatorname{tr}\left\{\left[-2\sum_{t=1}^{T} \boldsymbol{\Psi}_t \left(\mathbf{y}_t - \boldsymbol{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right) \mathbf{x}_t'\right] d\mathbf{B}\right\}.
\end{aligned}
$$

Hence, we get

$$\frac{df}{d\mathbf{B}} = \left[-2\sum_{t=1}^{T}\mathbf{\Psi}_t\left(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)\mathbf{x}_t'\right]' = -2\sum_{t=1}^{T}\mathbf{x}_t\left(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t\right)'\mathbf{\Psi}_t'$$

B Вывод (10)

Let's go back to

$$\operatorname{vec}\hat{\mathbf{B}} = \left[T^{-1}\sum_{t=1}^{T}\left(\mathbf{\Psi}_t\mathbf{\Psi}_t'\right)\otimes\left(\mathbf{x}_t\mathbf{x}_t'\right)\right]^{-1}\left[T^{-1}\sum_{t=1}^{T}\operatorname{vec}\left(\mathbf{x}_t\mathbf{y}_t'\mathbf{\Psi}_t'\right)\right] = *$$

From [Gentle, 2017] we can get the following properties of Kronecker product

$$\begin{gathered}(A\otimes B)' = A'\otimes B'\\ (A\otimes B)(C\otimes D) = (AC)\otimes(BD)\\ \operatorname{vec}(ABC) = (C'\otimes A)\operatorname{vec}B\end{gathered}$$

The corresponding matrix products should exist.

Then we have

$$* = \left[T^{-1}\sum_{t=1}^{T}\left(\mathbf{\Psi}_t\otimes\mathbf{x}_t\right)\left(\mathbf{\Psi}_t'\otimes\mathbf{x}_t'\right)\right]^{-1}\left[T^{-1}\sum_{t=1}^{T}\left(\mathbf{\Psi}_t\otimes\mathbf{x}_t\right)\operatorname{vec}\mathbf{x}_t'\right] = *$$

As $\mathbf{y}_t$ is already a vector then $\operatorname{vec}\mathbf{y}_t' = \operatorname{vec}\mathbf{y}_t$. Hence we have

$$\begin{aligned}* &= \left[\sum_{t=1}^{T}\left(\mathbf{\Psi}_t\otimes\mathbf{x}_t\right)\left(\mathbf{\Psi}_t'\otimes\mathbf{x}_t'\right)\right]^{-1}\left[\sum_{t=1}^{T}\left(\mathbf{\Psi}_t\otimes\mathbf{x}_t\right)\operatorname{vec}\mathbf{y}_t\right] =\\ &= \left[\sum_{t=1}^{T}\Upsilon_t\Upsilon_t'\right]^{-1}\left[\sum_{t=1}^{T}\Upsilon_t\operatorname{vec}\mathbf{y}_t\right]\end{aligned}$$

Setting $M = (\Upsilon_1, \Upsilon_2, \dots, \Upsilon_T)'$ we can see that

$$\sum_{t=1}^{T}\Upsilon_t\Upsilon_t' = M'M$$

Setting $\mathbf{Y} = (\mathbf{y}_1', \dots, \mathbf{y}_Y')'$ we can get

$$\sum_{t=1}^{T}\Upsilon_t\operatorname{vec}\mathbf{y}_t = M'\operatorname{vec}(\mathbf{Y}')$$

Hence, we get (10).

In the package[12] the matrix M is built in more vectorized form to avoid loops as much as possible.

The matrix M is defined as follows

$$M = \left[\left(\begin{array}{c|ccc} 1 & g_1(s_1) & \dots & g_{m-1}(s_1) \\ \vdots & \vdots & & \vdots \\ 1 & g_1(s_T) & \dots & g_{m-1}(s_T) \end{array} \right) \otimes I_k \otimes e'_{kp+q} \right] \circ [e'_{km} \otimes \mathbf{X} \otimes e_k]$$

where $g_k(s) = g\left(s \mid \gamma_k, c_k\right)$, $e_N = (\underbrace{1, \dots, 1}_{N})'$. $\circ$ denotes Hadamard (element-wize) product.

C Таблицы для теста Эндерса-Грейнджера

Таблица 1: Критические значения для пороговых тестов на единичные корни

(А) Состоятельные оценки порога с применением TAR модели

T	Нет лагов приращений				1 лаг приращений				4 лага приращений			
	90%	95%	97.5%	99%	90%	95%	97.5%	99%	90%	95%	97.5%	99%
50	5.15	6.19	7.25	8.64	5.55	6.62	7.66	9.10	5.49	6.55	7.59	9.00
100	5.08	6.06	6.93	8.19	5.39	6.34	7.30	8.54	5.38	6.32	7.29	8.56
250	5.11	6.03	6.88	8.04	5.26	6.12	6.99	8.14	5.36	6.29	7.15	8.35

(Б) Состоятельные оценки порога с применением M-TAR модели

T	Нет лагов приращений				1 лаг приращений				4 лага приращений			
	90%	95%	97.5%	99%	90%	95%	97.5%	99%	90%	95%	97.5%	99%
50	5.02	6.05	7.09	8.59	4.98	6.07	7.15	8.56	4.93	5.96	7.01	8.48
100	4.81	5.77	6.73	7.99	4.77	5.71	6.56	7.90	4.74	5.70	6.67	7.97
250	4.70	5.64	6.51	7.64	4.64	5.54	6.40	7.56	4.64	5.54	6.39	7.61

(В) Известное значение порога в M-TAR модели

T	Нет лагов приращений				1 лаг приращений				4 лага приращений			
	90%	95%	97.5%	99%	90%	95%	97.5%	99%	90%	95%	97.5%	99%
50	4.21	5.19	6.15	7.55	4.12	5.11	6.05	7.25	3.82	4.73	5.65	6.84
100	4.11	5.04	5.96	7.10	4.08	4.97	5.87	7.06	3.81	4.72	5.63	6.83
250	4.08	4.97	5.83	6.91	4.05	4.93	5.78	6.83	3.69	4.71	5.63	6.78

[12] Данный текст взят из виньетки пакета, который лектор писал для своих нужд при написании своей диссертации. Лектору хотелось разобраться в формулах из статьи [Teräsvirta, Yang, 2014b]. На сегодняшний день этот пакет уже не нужен, так как в феврале 2024 был опубликован более адекватно написанный пакет...