Модели с переключением режимов

Зямалов В.Е.

Подробнее можно посмотреть в (Enders 2015, гл. 7).

Линейные модели

Рассмотрим простую AR(1) модель

$$y_t = a_0 + a_1 y_{t-1} + \varepsilon_t, \qquad 0 < a_1 < 1$$

Обозначив математическое ожидание y_t как $\overline{y} = \frac{a_0}{1-a_1}$, можно переписать это уравнение как

$$y_t - \overline{y} = a_1\left(y_{t-1} - \overline{y}\right) + \varepsilon_t$$

Если $y_t \neq \overline{y}$, то a_1-я часть отклонения перейдет в следующий период. Причем отметим, что вне зависимости ни от каких условий, в следующий период перейдет именно a_1-я часть отклонения y_t от своего математического ожидания.

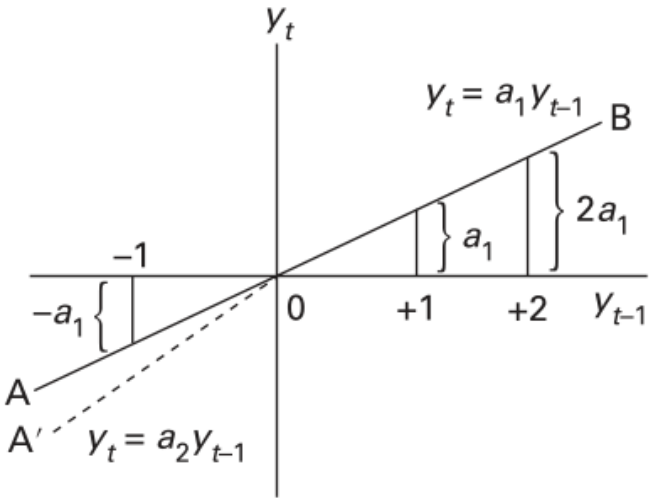


Рис. 1. Нелинейность модели

Однако имеются свидетельства того, что переходящая часть может зависеть от знака отклонения!

$$y_t - \overline{y} = \begin{cases} a_1(y_{t-1} - \overline{y}) + \varepsilon_t y_{t-1} > \overline{y} \\ a_2(y_{t-1} - \overline{y}) + \varepsilon_t y_{t-1} \leqslant \overline{y} \end{cases}$$

NLAR модель

Рассмотрим простейший[1] вид модели, который может моделировать подобное поведение — нелинейную AR (NLAR) модель

$$y_t = f(y_{t-1}, y_{t-2}, \ldots) + \varepsilon_t$$

где $f(\ldots)$ — некоторая скалярная нелинейная функция. Очевидно, что данная модель обладает крайне большой

[1] С позиции внешнего вида формулы, но, отнюдь, не с позиций расчетов.

гибкостью, позволяющей моделировать самое разное поведение.

Однако, не менее очевидно, что оценивать данную модель может быть крайне сложно; так как оценивание будет проводиться либо методом максимального правдоподобия, либо нелинейным МНК, то вид функции может привести к катастрофическому усложнению вычислительных процедур. Также, если функциональная форма $f(\dots)$ неизвестна, то сложно разделить нелинейность в параметрах от нелинейности в переменных. Для статистических тестов может быть сложным увидеть разницу между моделью, в которой некоторые регрессоры входят со степенью, отличной от 1, и моделью, в которой параметры изменяются во времени.

Отметим, что NAR модель можно представить в виде модели с переменным параметром

$$y_t = \underbrace{\tilde{f}(y_{t-1}, y_{t-2}, \dots)}_{\alpha_{1,t}} y_{t-1} + \varepsilon_t$$

Обобщенная AR модель

В свете сказанного выше хотелось бы несколько упростить модель[2]. Достичь этого можно при помощи разложения $f(\dots)$ в ряд Тейлора до какой-либо **разумной** степени.

Например, рассмотрим NLAR(2)

[2]И жизнь эконометриста...

$$y_t = f(y_{t-1}, y_{t-2}) + \varepsilon_t$$

и разложим f, допустим, до третьей степени:

$$\begin{aligned} y_t = {} & a_0 + a_1 y_{t-1} + a_2 y_{t-2} + \\ & + a_{11} y_{t-1}^2 + a_{22} y_{t-2}^2 + a_{12} y_{t-1} y_{t-2} + \\ & + a_{111} y_{t-1}^3 + a_{112} y_{t-1}^2 y_{t-2} + a_{122} y_{t-1} y_{t-2}^2 + a_{222} y_{t-2}^3 + \\ & + \varepsilon_t \end{aligned}$$

Для NLAR(p) нам понадобится запись покомпактнее

$$y_t = a_0 + \sum_{i=1}^{p} a_i y_{t-i} + \sum_{i=1}^{p} \sum_{j=i}^{p} \sum_{k=1}^{r} \sum_{l=1}^{s} a_{ijkl} y_{t-i}^k y_{t-j}^l + \varepsilon_t$$

Чтобы не поменять шило на мыло и не получить вместо нелинейной модели линейную, но с астрономическим числом коэффициентов, обычно вводят ограничение $s + r \leqslant 4$.

Для сокращения модели можно использовать весь инструментарий t- и F-тестов, однако из-за, очевидно, крайне высокой мультиколлинеарности, оптимальным будет использование информационных критериев.

Билинейная модель (BL)

По аналогии с ARMA-моделями можно **значительно** сократить модель, введя в нее лаги ошибки ε_t

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \beta_1 \varepsilon_{t-1} + \gamma_1 y_{t-1} \varepsilon_{t-1} + \varepsilon_t$$

Двумерные BL модели являются естественным расширением ARMA модели в том плане, что для учета нелинейности они включают произведение y_{t-i} и ε_{t-j}.

В общем виде двумерная модель BL(p, q, r, s) равна

$$y_t = a_0 + \sum_{i=1}^{p} a_i y_{t-i} + \varepsilon_t + \sum_{i=1}^{q} \beta_i \varepsilon_{t-i} + \sum_{i=1}^{r} \sum_{j=1}^{s} c_{ij} y_{t-i} \varepsilon_{t-j}$$

Двумерную модель можно рассматривать как модель со стохастическими параметрами. Чтобы понять это, перепишем для примера BL модель

$$y_t = a_0 + a_1 y_{t-1} + c_1 y_{t-1} \varepsilon_{t-1} + \varepsilon_t$$

в виде

$$y_t = a_0 + \underbrace{(a_1 + c_1 \varepsilon_{t-1})}_{a_{1,t}} y_{t-1} + \varepsilon_t$$

Тестирование нелинейности

Анализ коррелограммы

Если построить ACF для **ряда**, то можно получить неверный результат. Пусть

$$y_t = \varepsilon_{t-1}^2 + \varepsilon_t, \varepsilon_t \sim \mathrm{WN}(0, \sigma^2)$$

Очевидно, что

$$\mathrm{E}\, y_t = \mathrm{E}\, y_{t-1} = \sigma^2$$

Тогда

$$\gamma(i) = \mathrm{E}(y_t - \sigma^2)(y_{t-i} - \sigma^2) =$$

$$= \mathrm{E}\left(\varepsilon_{t-1}^2 + \varepsilon_t - \sigma^2\right)\left(\varepsilon_{t-1-i}^2 + \varepsilon_{t-i} - \sigma^2\right) =$$
$$= \mathrm{E}\left(\varepsilon_{t-1}^2\varepsilon_{t-1-i}^2 + \varepsilon_{t-1}^2\varepsilon_{t-i} - \varepsilon_{t-1}^2\sigma^2 + \right.$$
$$+\varepsilon_t\varepsilon_{t-1-i}^2 + \varepsilon_t\varepsilon_{t-i} - \varepsilon_t\sigma^2 -$$
$$\left.-\sigma^2\varepsilon_{t-1-i}^2 - \sigma^2\varepsilon_{t-i} + \sigma^2\sigma^2\right)$$

Так как

- $\mathrm{E}\left(\varepsilon_{t-i}^2\varepsilon_{t-j}^2\right) = \sigma^2\sigma^2, i \neq j,$
- $\mathrm{E}\left(\varepsilon_t\varepsilon_{t-j}^2\right) = \mathrm{E}\,\varepsilon_t\sigma^2 = 0, j \neq 0,$

то

$$\gamma(i) = \mathrm{E}\left[\varepsilon_{t-1}^2\varepsilon_{t-i}\right] = \begin{cases} 0 i \neq 1 \\ 0 i = 1, \varepsilon_t \sim N(0, \sigma^2) \end{cases}$$

Однако, анализ **квадратов** и **кубов** остатков может выявить наличие нелинейности. Хороший пример приведен в (Enders 2015). Строго говоря, к квадратам остатков «наилучшей» линейной модели можно применять и тест Льюнг-Бокса, и тест МакЛеода-Ли.

RESET-тест

Тест на ошибочную спецификацию проверяет отсутствие связи между остатками модели и ее регрессорами или подобранными значениями.

1. Оцените «наилучшую» линейную модель и получите остатки $\{e_t\}$ и подобранные значения $\{\hat{y}_t\}$.
2. Оцените модель

$$e_t = \delta z_t + \sum_{h=2}^{H} \alpha_h \hat{y}_t^h + \nu_t, H \geqslant 2$$

где z_t — регрессоры линейной модели.

3. Протестируйте совместную гипотезу $\alpha_2 = \ldots = \alpha_H = 0$.

Тест прост, но имеет малую мощность для выявления асимметричных моделей.

Тест множителей Лагранжа (ML)

Описанные выше тесты не дают информацию о виде нелинейной модели! LM-тест позволяет тестировать гипотезу линейности против **конкретной** альтернативы.

Пусть $f(\ldots)$ — нелинейная функция, α — параметры $f(\ldots)$.

1. Оцените **линейную** часть $f(\ldots)$ и получите остатки $\{e_t\}$.
2. Постройте частные производные $\frac{tialf}{\partial \alpha} \mid_{H_0}$ в предположении истинности нулевой гипотезы линейности. Оцените регрессию e_t на эти частные производные.
3. Статистика $T R^2$ имеет распределение χ^2 с числом степеней свободы, равным числу регрессоров на шаге 2[3].

Тест позволяет тестировать конкретную нелинейную альтернативу, поскольку мы вручную задаем вид $f(\ldots)$ и

[3]На малых выборках используйте F-тест.

считаем частные производные. Но и он не всесилен: если компоненты двух альтернативных моделей достаточно сильно коррелируют, то тест может не справиться с их разделением.

Например,

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \alpha_3 y_{t-1} y_{t-2} + \varepsilon_t$$
$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \alpha_3 \varepsilon_{t-1} y_{t-2} + \varepsilon_t$$

Так как y_{t-1} и ε_{t-1}, очевидно, достаточно сильно коррелируют, то статистики для этих моделей могут быть достаточно близки.

Проблема Дэвиса

Вы можете подумать, что достаточно оценить нелинейную модель и наложить ограничения на ряд параметров, позволяющие протестировать модель на линейность. Однако, в случае нелинейных моделей сделать вывод, зачастую, достаточно сложно из-за «неизвестных зашумляющих параметров» или «проблемы Дэвиса». Проблема возникает тогда, когда один (или более) из параметров модели неидентифицируем при истинности нулевой гипотезы.

Рассмотрим нелинейную модель $y_t = \alpha_0 + \alpha_1 x_t^{\alpha_2} + \varepsilon_t$. Предположим, что вы оценили модель и хотите проверить гипотезу $\alpha_2 = 0$. Должно быть понятно, что при истинности

нулевой гипотезы $a_2 = 0$ значения a_0 и a_1 неидентифицируемы, так как модель вырождается в $y_t = a_0 + a_1 + \varepsilon_t$. Если эта сумма, например, равна 5, то любые два значения a_0 и a_1 являются удовлетворительными, покуда $a_1 = 5 - a_0$.

Следовательно, собственные значения a_0 и a_1 не идентифицированы при нулевой гипотезе $a_2 = 0$. Аналогичные замечания справедливы и для $a_1 = 0$. При нулевой гипотезе $a_1 = 0$ подходит любое значение a_2. По сути функции правдоподобия безразлично значение a_2 при $a_1 = 0$.

Заметим, что гипотеза $a_0 = 0$ не приводит в проблеме Дэвиса, так как a_1 и a_2 идентифицируемы даже при $a_0 = 0$.

Строго говоря, рассмотрим модель с двумя параметрами такую, что функция логарифмического правдоподобия может быть записана как функция от параметров a_1 и a_2:

$$L(a_1, a_2)$$

В обычном случае, максимизация L по a_1 и a_2 приводит к неограниченным оценкам параметров[4]. Обозначим это максимизированное значение $L_a(a_1, a_2)$.

Предположим теперь, что мы накладываем ограничение $a_1 = \overline{a}_1$ и максимизируем L по a_2. При нулевой гипотезе максимизированное значение L равно $L_n(\overline{a}_1, a_2)$. Статистика теста отношений правдоподобий равна

[4]В смысле, что на них не накладываются ограничения.

$$R = 2\left[L_a(a_1, a_2) - L_n(\overline{a}_1, a_2)\right] \sim \chi^2(1)$$

где число степеней свободы равно числу ограничений.

В идеальной ситуации, при истинности гипотезы $a_1 = \overline{a}_1$ оценка a_2 должна быть такой же и при нулевой и при альтернативной гипотезе; поэтому должно выполняться

$$L_a(a_1, a_2) = L_n(\overline{a}_1, a_2)$$

Предположим, что под нулевой гипотезой значение a_2 неидентифицируемо. Другими словами, предположим, что $\partial L_n / \partial a_2 = 0, \forall a_2$. В сущности, при справедливости нулевой гипотезы a_2 не влияет на функцию правдоподобия, то есть значение r становится равным

$$r = 2\left[L_a(a_1, a_2) - L_n(\overline{a}_1)\right]$$

В этом случае разность между $L_a(a_1, a_2)$ и $L_n(\overline{a}_1)$ будет зависеть от значения a_2; статистика $R \nsim \chi^2(1)$.

Дэвис (Davies 1987) предложил использовать **супремум** тест: рассчитать критические значения при помощи таких значений зашумляющих параметров, при которых отвержение становится наиболее сложным. Для получения критических значений можно воспользоваться следующим методом Монте-Карло:

1. Сгенерируйте ряд $\{y_t\}$ при нулевой гипотезе (можно использовать бутстрап, если создавать $\{y_t\}$ на базе реальных остатков линейной модели).

2. Оцените наилучшую нелинейную модель.
3. Получите t-статистику (или F-статистику, или статистику χ^2) для нулевой гипотезы о равенстве нулю коэффициентов уравнения.
4. Повторяйте эту процедуру много раз для получения распределения интереующей нас статистики.

Для заданного p-значения — например 5% для двухстороннего t-теста — выборочную t-статистику можно сравнивать с 2,5% и 97,5% перцентилями сгенерированного распределения.

Пороговые модели

В многорежимных моделях $\{y_t\}$ зависит от состояния системы. Например, во время рецессии безработица растет быстрее, чем она же падает во время бума. То есть модель может находиться в одном из **режимов**. Такие модели, обычно, оценивать достаточно тяжело. Статистические пакеты обычно включают только простейшие модели.

TAR модель

Простейшая TAR модель имеет следующий вид (Tong и Lim 1980)[5]

[5]Данный вид модели также называется самовозбуждающейся TAR (SETAR).

Модели с переключением режимов

$$y_t = \begin{cases} a_1 y_{t-1} + \varepsilon_{1t} y_{t-1} > 0 \\ a_2 y_{t-1} + \varepsilon_{2t} y_{t-1} \leqslant 0 \end{cases}$$

Если $\text{Var}\,\varepsilon_{1t} = \text{Var}\,\varepsilon_{2t}$, то можно переписать модель в виде

$$y_t = a_1 I_t y_{t-1} + a_2 (1 - I_t) y_{t-1} + \varepsilon_t$$

$$I_t = \begin{cases} 1 \, y_{t-1} > 0 \\ 0 \, y_{t-1} \leqslant 0 \end{cases}$$

В более общем виде модель записывается как

$$y_t = \begin{cases} a_{10} + \sum_{i=1}^{p} a_{1i} y_{t-i} + \varepsilon_{1t} y_{t-1} > 0 \\ a_{20} + \sum_{i=1}^{r} a_{2i} y_{t-i} + \varepsilon_{2t} y_{t-1} \leqslant 0' \end{cases} \quad \text{Var}\,\varepsilon_{1t} \neq \text{Var}\,\varepsilon_{2t}$$

или

$$y_t = I_t \left[a_{10} + \sum_{i=1}^{p} a_{1i} y_{t-i} \right] + (1 - I_t) \left[a_{20} + \sum_{i=1}^{r} a_{2i} y_{t-i} \right] + \varepsilon_t$$

$$I_t = \begin{cases} 1 \, y_{t-1} > \tau \\ 0 \, y_{t-1} \leqslant \tau \end{cases}$$

$$\text{Var}\,\varepsilon_{1t} = \text{Var}\,\varepsilon_{2t}$$

TAR-модель легко оценивается при помощи обычного МНК. Если пороговое значение τ неизвестно, то Чан (Chan 1993) предложил способ получения его состоятельной оценки:

1. Определите допустимые границы для порогового значения. Не забудьте оставить достаточно наблюдений для оценивания коэффициентов в каждом из режимов.

2. Для **каждого** значения y_t в заданных пределах оцените TAR с $\tau = y_t$.
3. Состоятельной оценкой τ будет $\arg\min_\tau RSS(\tau)$.

Модификации TAR

Произвольная глубина запаздывания в качестве определяющей переменной можно использовать произвольный лаг y_{t-d}. d можно оценить аналогично τ: последовательным перебором и взятием $d = \arg\min RSS$.

Несколько режимов (band-TAR)

$$y_t = \alpha_{10} + \sum_{i=1}^{p_1} \alpha_{1i} y_{t-i} + \varepsilon_{1t}, \quad y_{t-1} \leqslant \tau_1$$

$$y_t = \alpha_{20} + \sum_{i=1}^{p_2} \alpha_{2i} y_{t-i} + \varepsilon_{2t}, \qquad \tau_1 < y_{t-1} \leqslant \tau_2$$

$$\dots$$

$$y_t = \alpha_{n0} + \sum_{i=1}^{p_n} \alpha_{ni} y_{t-i} + \varepsilon_{nt}, \qquad \tau_{n-1} < y_{t-1}$$

Модель регрессии с порогом перенос идеи TAR на регрессионные модели с объясняющими переменными.

$$y_t = a_0 + (a_1 + b_1 I_t) x_t + \varepsilon_t$$

$$I_t = \begin{cases} 1 \, y_{t-d} > \tau \\ 0 \, y_{t-d} \leqslant \tau \end{cases}$$

Инерционная TAR (M-TAR) отличается определение I_t

$$I_t = \begin{cases} 1 \, \Delta y_{t-1} > 0 \\ 0 \, \Delta y_{t-1} \leqslant 0 \end{cases}$$

Тестирование TAR

TAR-модель недифференцируема в точке τ, следовательно LM-тесты не подходят. Можно воспользоваться супремум тестом Дэвиса.

Также можно применить F-тест

$$F = \frac{\frac{RSS_r - RSS_u}{n}}{\frac{RSS_u}{T-2n}}$$

где RSS_r — RSS линейной модели (H_0), RSS_u — RSS TAR-модели.

Однако мы не можем использовать табличные значения! Хансен (Hansen 1997) предложил следующую процедуру:

1. Сгенерируйте последовательность $\{\varepsilon_t\}, \varepsilon_t \sim N(0,1)$ длины T.
2. Оцените линейную и TAR-модели с $\{\varepsilon_t\}$ в левой части. В правой должны быть y_t! Получите RSS_r^* и RSS_u^*, соответственно.
3. Рассчитайте F^*.
4. Повторяя шаги 1–3 большое количество раз набираем выборочную функцию распределения статистики.

Тесты на наличие единичного корня и TAR модели

Предположим, что вы уверены в том, что $\mathbf{y}_t$ имеет TAR природу. Перед оцениванием TAR модели вы, возможно, захотите определить, возвращается ли ряд к своему долгосрочному равновесному значению.

(Pippenger и Goering 1993; Balke и Fomby 1997) показали, что стандартные тесты на единичный корень обладают низкой мощностью в отношении рядов, порожденных нелинейными моделями. (Enders и Granger 1998) предложили расширение теста на наличие единичных корней при альтернативе TAR модели.

Рассмотрим модель

$$\Delta y_t = I_t \rho_1 (y_{t-1} - \tau) + (1 - I_t)\rho_2 (y_{t-1} - \tau) + \sum_{i=1}^{p} \alpha_i \Delta y_{t-i} + \varepsilon_t$$

$$I_t = \begin{cases} 1 \text{ если } y_{t-1} \geqslant \tau \\ 0 \text{ если } y_{t-1} < \tau \end{cases} \quad \text{или} \quad I_t = \begin{cases} 1 \text{ если } \Delta y_{t-1} \geqslant \tau \\ 0 \text{ если } \Delta y_{t-1} < \tau \end{cases}$$

Заметим, что если $\rho_1 = \rho_2 = 0$, то процесс является случайным блужданием.

Достаточным условием стационарности последовательности $\{y_t\}$ является $-2 < (\rho_1, \rho_2) < 0$[6].

[6]Петручелли и Вулфорд (Petruccelli и Woolford 1984) показали, что более слабыми достаточными условиями стационарности $\{y_t\}$ являются $\rho_1 < 0$, $\rho_2 < 0$ и $(1 + \rho_1)(1 + \rho_2) < 1$.

Для проведения теста следует сделать следующее:

1. Если значение τ и вид TAR модели вам известны, то оцените приведенную выше модель.
    - Если значение τ вам не известно, то воспользуйтесь процедурой (Chan 1993).
    - Если вы не уверены насчет вида модели — TAR или M-TAR — то воспользуйтесь процедурой (Chan 1993) для обоих случаев и выберите наилучшую из моделей TAR или M-TAR при помощи информационных критериев.
2. Воспользуйтесь выбранной моделью для расчета F-статистики для нулевой гипотезы $\rho_1 = \rho_2 = 0$. Для TAR модели сравните эту статистику с соответствующим критическим значением из таблицы (Enders 2015, прил. G):
    - Используйте часть A, если вы оцениваете τ для TAR модели, и часть B — для M-TAR модели.
    - Если вам известно пороговое значение, и вы оцениваете M-TAR модель, то используйте часть C.
    - В случае TAR модели с известным порогом тест имеет более низкую мощность по сравнению с тестом Дики-Фуллера. Критические значения для этого случая не приведены.

3. Если альтернативная гипотеза не отвергается (то есть при наличии «аттрактора»), то возможно провести тестирование симметричности коррекции, так как совместное асимптотичесоке распределение ρ_1 и ρ_2 сходится к многомерному нормальному. То есть, нулевая гипотеза $\rho_1 = \rho_2$ может быть проверена с использованием метода бутсрапа Хансена (Hansen 1997) или, приблизительно, с использованием стандартного *F*-теста.

Модели с плавной сменой режимов

Вернемся к TAR модели

$$y_t = a_1 I_t y_{t-1} + a_2(1 - I_t)y_{t-1} + \varepsilon_t$$

Если заменить I_t на некую непрерывную функцию $G(s_t; \gamma, c)$, то получим простейшую STAR-модель

$$y_t = a_1 y_{t-1} G(s_t; \gamma, c) + a_2[1 - G(s_t; \gamma, c)]y_{t-1} + \varepsilon_t$$

$$y_t = \underbrace{\left(a_{10} + \sum_{i=1}^{p} a_{1i} y_{t-i}\right)}_{a_1' x_t} G(s_t; \gamma, c) + \left(a_{20} + \sum_{i=1}^{p} a_{2i} y_{t-i}\right)[1 - G(s_t; \gamma, c)] + \varepsilon_t$$

где γ — крутизна перехода, c — пороговое значение.

Функция $G(\ldots)$ должна быть ограничена между 0 и 1. На практике используются две:

- $G(s_t; \gamma, c) = \frac{1}{1 + \exp[-\gamma(s_t - c)]}$, $\gamma > 0$ — LSTAR-модель;
- $G(s_t; \gamma, c) = 1 - \exp\left[-\gamma(s_t - c)^2\right]$, $\gamma > 0$ — ESTAR-модель.

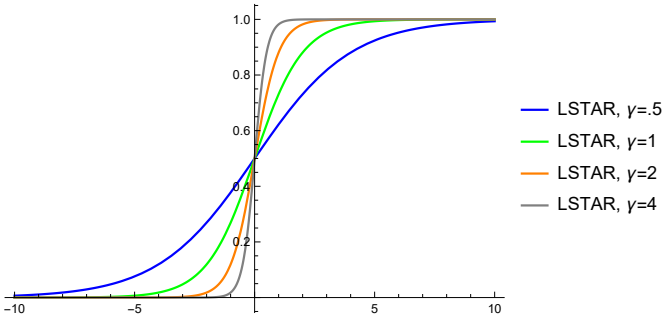


Рис. 2. LSTAR

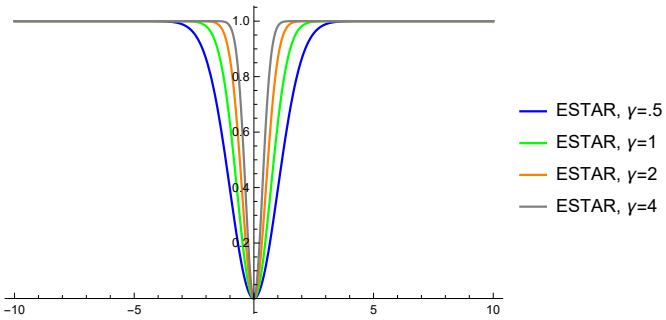


Рис. 3. ESTAR

Нетрудно заметить, что

- при $\gamma \to \infty$, LSTAR превращается в TAR,
- при $\gamma \to 0$, LSTAR превращается в линейную модель,
- ESTAR в обоих случаях превращается в линейную модель.

В качестве определяющей переменной s_t можно использовать практически что угодно: лаги y_t, экзогенную переменную, тренд…

Многорежимные STAR-модели имеют вид (Dijk и др. 2000)

$$y_t = \sum_{i=1}^{M} [G_i(s_t) - G_{i+1}(s_t)] \underbrace{\left(a_{i0} + \sum_{j=1}^{p} a_{ij} y_{t-j} \right)}_{a_i' x_t} + \varepsilon_t \qquad (1)$$

$$G_i(s_t) \coloneqq G(s_t; \gamma, c)$$
$$G_1 = 1 \Leftrightarrow c_1 \to -\infty$$
$$G_{M+1} = 0 \Leftrightarrow c_{M+1} \to \infty$$
$$a_i = (a_{i0}, a_{i1}, a_{i2}, \ldots)'$$
$$x_t = (1, y_{t-1}, y_{t-2}, \ldots)'$$

или

$$\begin{aligned} y_t = a_1' x_t + \\ +(a_2' - a_1') x_t G(s_t; \gamma_2, c_2) + \ldots + \\ +(a_M' - a_{M-1}') x_t G(s_t; \gamma_M, c_M) + \varepsilon_t \end{aligned} \qquad (2)$$

На рисунке Рис. 4 на примере трехрежимной модели показано, почему многорежимная STAR-модель задается выражением (1). Для каждого значения s_t можно рассчитать значения G^0, G^1, G^2, G^3. Данные значения в совокупности должны определить веса, с которыми отдельные авторегрессионные модели входят в общую модель при заданном значении s_t. Очевидно, что в сумме эти веса должны составлять единицу. Именно это и отражено на рисунке. Фигурные скобки показывают интервалы, равные по своей длине весу соответствующего режима: от первого до последнего сверху вниз. Длины интервалов рассчитываются

в полном соответствии с формулой (1)[7].

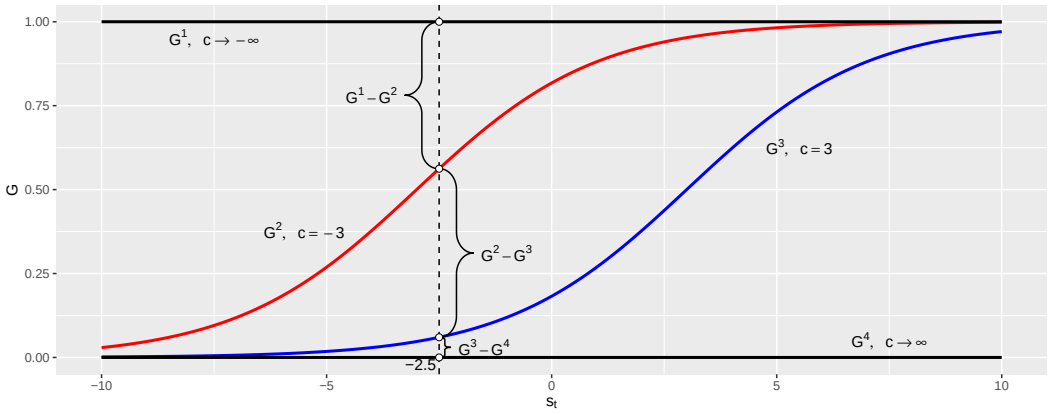


Рис. 4. Интерпретация формулы {star-multi}

Тестирование STAR

Вы уже должны догадаться, что LM-тесты нам не подходят. Терясвирта (Teräsvirta и Yang 2014a) предложил простой тест, позволяющий не только выявить STAR, но и определить его тип: LSTAR или ESTAR.

Для описания общей идеи обозначим $x = -\gamma(s_t - c)$. Тогда

$$G(s_t; \gamma, c) = G(x) \approx G(0) + G'(0)x + \frac{G''(0)}{2!}x^2 + \frac{G'''(0)}{3!}x^3$$

Можно показать, что

[7]Вспомните эконометрику межобъектных данных. На ней вам должны были рассказывать об особенностях интерпретации коэффициентов в модели с бинарными объясняющими переменными. Данный материал поможет вам понять, как связаны между собой (1) и (2).

$$\text{LSTAR} : G(x) \approx \frac{x}{4} - \frac{x^3}{48}$$

$$\text{ESTAR} : G(x) \approx x^2$$

LSTAR-модель примет вид

$$y_t = a_0 + a_1 y_{t-1} + \ldots + (\beta_0 + \beta_1 y_{t-1} + \ldots)\left(\frac{x}{4} - \frac{x^3}{48}\right) + \varepsilon_t$$

ESTAR-модель примет вид

$$y_t = a_0 + a_1 y_{t-1} + \ldots + (\beta_0 + \beta_1 y_{t-1} + \ldots)x^2 + \varepsilon_t$$

После обратной подстановки x получим для LSTAR

$$y_t = a' x_t + \beta_1' s_t x_t + \beta_2' s_t^2 x_t + \beta_3' s_t^3 x_t + \varepsilon_t$$

и для ESTAR

$$y_t = a' x_t + \beta_1' s_t x_t + \beta_2' s_t^2 x_t + \varepsilon_t$$

то есть аппроксимация ESTAR входит в LSTAR.

(Escribano и Jordá 1999) предлагают раскладывать G для ESTAR до 4 степени, тогда имеем

$$y_t = a' x_t + \beta_1' s_t x_t + \beta_2' s_t^2 x_t + \beta_3' s_t^3 x_t + \beta_4' s_t^4 x_t + \varepsilon_t$$

Для тестирования LSTAR нужно оценить полученную приближенную модель и протестировать $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$:

- $TR^2 \sim \chi^2(3(p+1))$
- $F \sim F(3(p+1); T - 4(p+1))$

Для ESTAR:

- $TR^2 \sim \chi^2(4(p+1))$
- $F \sim F(4(p+1); T - 5(p+1))$

Оценивание и диагностика STAR

Оценивание STAR моделей при помощи МНК невозможно из-за мультипликативности коэффициентов[8]. Поэтому используем нелинейный МНК или метод максимального правдоподобия.

Также следует отметить, что из-за потенциальной возможности попадания в область, в которой функция правдоподобия будет достаточно «плоской», одновременная оценка γ и c обычно невозможна. Хагган и Одзаки (Haggan и Ozaki 1981) предложили искать γ по сетке с одновременным оцениванием остальных коэффициентов нелинейным МНК.

Остаточная нелинейность Эйтрхайм и Терясвирта (Eitrheim и Teräsvirta 1996) предложили тест на двухрежимный LSTAR процесс против трехрежимного. Идея аналогична тесту на STAR: раскладываем в ряд Тейлора $G(s_t; \gamma_2, c_2) \Rightarrow$ LSTAR с набором дополнительных регрессоров

$$y_t = \alpha_0' x_t + G(s_t; \gamma_1, c_1)\alpha_1' x_t + \beta_1 \overline{w}_t s_t + \beta_2 \overline{w}_t s_t^2 + \beta_3 \overline{w}_t s_t^3 + \nu_t$$
$$\overline{w}_t = (y_{t-1}, y_{t-2}, \ldots)'$$

[8]На самом деле это не совсем так. (Teräsvirta и Yang 2014a) показывают, что если зафиксировать параметры G, то получившаяся модель оценивается обычным МНК.

Тестируемая гипотеза $H_0 : \beta_1 = \beta_2 = \beta_3 = \mathbf{0}$.

Остаточная автокорреляция Можем воспользоваться LM-тестом:

1. Оцените модель и получите остатки $\{e_t\}$. На основе этих остатков рассчитайте RSS_0.
2. Оцените значения $\nabla y_t = \frac{\partial y_t}{\partial \theta}$, где под y_t для краткости понимаем модель, θ — совокупность всех оцениваемых параметров.
3. Оцените регрессию e_t на ∇y_t и $e_{t-1}, \ldots, e_{t-q}$. В (Eitrheim и Teräsvirta 1996) приводится эквивалентная форма этого выражения, в которой оценивается регрессия e_t на x_t, $x_t G(s_t; \gamma_1, c_1)$, $\frac{\partial G}{\partial \gamma}(s_t; \gamma_1, c_1) a_1' x_t$, $\frac{\partial G}{\partial c}(s_t; \gamma_1, c_1) a_1' x_t$ и $e_{t-1}, \ldots, e_{t-q}$. Для данной регрессии рассчитайте RSS.
4. Рассчитайте статистику

$$F = \frac{(RSS_0 - RSS)/q}{RSS/(T - n - q)} \sim F(q, T - n - q)$$

$$TR^2 \sim \chi^2(q)$$

где n — число переменных в ∇y_t.

Векторные модели с переключением режимов

TAR модели

Подробно останавливаться на TAR модели не стоит, так как принципиально ничего в их отношении не меняется.

$$\mathbf{y}_t = I_t\left[A_{10} + \sum_{i=1}^{p} A_{1i}\mathbf{y}_{t-i}\right] + (1 - I_t)\left[A_{20} + \sum_{i=1}^{r} A_{2i}\mathbf{y}_{t-i}\right] + \boldsymbol{\varepsilon}_t$$

$$I_t = \begin{cases} 1 s_{t-1} > \tau \\ 0 s_{t-1} \leqslant \tau \end{cases}$$

$$A_{i0} \sim (k \times 1), i = 1, 2$$

$$A_{ij} \sim (k \times k), i = 1, 2, j = 1, \ldots, \{p, r\}$$

VSTAR модели

VSTAR модель — многомерное обобщение одномерной STAR модели, простейшая форма которой имеет вид (Teräsvirta и Yang 2014a; Dijk и др. 2000)

$$\mathbf{y}_t = \phi_1'\mathbf{x}_t + (\phi_2 - \phi_1)'\mathbf{x}_t g(s_t \mid \gamma, c) + \varepsilon_t$$

где $\mathbf{x}_t$ — вектор **всех** регрессоров, включая лаги $\mathbf{y}_t$, экзогенные. Согласно (Rothman и др. 1999), коинтеграционное отношение также может быть включено в список экзогенных переменных.

Очевидным обобщением является многорежимная STAR модель

$$\mathbf{y}_t = \phi_1'\mathbf{y}_t + \tilde{\phi}_2'\mathbf{y}_t g(s_t \mid \gamma_1, c_1) + \tilde{\phi}_3'\mathbf{y}_t g(s_t \mid \gamma_2, c_2) + \ldots + \varepsilon_t$$

где подразумевается, что $c_1 < c_2 < c_3 < \ldots$.

Если пойти дальше, то следующим очевидным обобщением STAR будет многомерная, или векторная STAR (Camacho 2004). Начнем с модели VAR(p) с одним режимом

$$\mathbf{y}_t = A_1'\mathbf{y}_{t-1} + A_2'\mathbf{y}_{t-2} + \ldots + A_p'\mathbf{y}_{t-p} + \Phi' d_t + \varepsilon_t \tag{3}$$

где $\mathbf{y}_t \sim (k \times 1)$ — вектор эндогенных переменных, $d_t \sim (q \times 1)$ — вектор всех детерминированных компонентов, $A_i \sim (k \times k)$, $\Phi \sim (q \times k)$ — матрицы соответствующих коэффициентов.

Модель (3) можно записать в более компактной форме. Если принять

$$F = \left(A_1', A_2', \ldots, A_p', \Phi'\right)' \quad \{(pk + q) \times k\}$$
$$\mathbf{x}_t = \left(\mathbf{y}_{t-1}', \mathbf{y}_{t-2}', \ldots, \mathbf{y}_{t-p}', d_t'\right)\{(pk + 1) \times 1\}$$

тогда (3) примет следующий вид

$$\mathbf{y}_t = F'\mathbf{x}_t + \varepsilon_t \tag{4}$$

При помощи модели (4) многомерная STAR модель может быть записана как

$$\mathbf{y}_t = \left[\sum_{i=1}^{M}\left(G_t^i - G_t^{i+1}\right)F_i'\right]\mathbf{x}_t + \varepsilon_t \tag{5}$$

$$\varepsilon_t \sim \mathrm{WN}(0, \Omega) \tag{6}$$

$$G_t^i = \mathrm{diag}\{g(s_{1it} \mid \gamma_{i1}, c_{i1}), \ldots, g(s_{kit} \mid \gamma_{ik}, c_{ik})\} \tag{7}$$

$$G_t^1 = I_k \tag{8}$$

$$G_t^{M+1} = 0 \tag{9}$$

(5) можно перепараметризовать в виде

$$\begin{aligned}
\mathbf{y}_t &= \left(\mathbf{B}_1' + G_t^1 \mathbf{B}_2' + \ldots + G_t^{m-1} \mathbf{B}_m'\right)\mathbf{x}_t + \varepsilon_t \\
\varepsilon_t &\sim \text{WN}(0, \Omega) \\
G_t^i &= \text{diag}\{g(s_{1it} \mid \gamma_{i1}, c_{i1}), \ldots, g(s_{kit} \mid \gamma_{ik}, c_{ik})\} \\
\mathbf{B}_1 &= F_1 \\
\mathbf{B}_i &= F_i - F_{i-1}
\end{aligned} \tag{10}$$

Если принять $\mathbf{\Psi}_t = \left(I_k, G_t^1, \ldots, G_t^{m-1}\right)'$ и $\mathbf{B} = (\mathbf{B}_1, \mathbf{B}_2, \ldots, \mathbf{B}_m)$, то (10) примет вид

$$\mathbf{y}_t = \mathbf{\Psi}_t' \mathbf{B}' \mathbf{x}_t + \varepsilon_t \tag{11}$$

Мы должны сделать важное замечание. В самом общем случае **каждая** функция перехода g для **каждого** режима имеет свои собственные γ_{ij} и c_{ij} для **каждого** уравнения в системе! Хотя это самая общая и гибкая спецификация, ее может быть трудно оценить из-за того, что γ_{ij} и c_{ij} обычно оцениваются с помощью нелинейного МНК, а соответствующие начальные значения получаются с помощью поиска по сетке.

Поэтому было бы лучше уменьшить количество γ_{ij} и c_{ij} настолько, насколько это возможно. Самый простой, но подходящий в большинстве случаев способ — принять $\gamma_{m1} = \gamma_{m2} = \ldots = \gamma_{mk} = \gamma_m$ и $c_{m1} = c_{m2} = \ldots = c_{mk} = c_m$ для любого заданного режима m. Это означает, что все уравнения си-

стемы будут иметь одну и ту же функцию перехода для любого заданного режима m.

Другими словами, матрица G_t^m примет следующий вид

$$G_t^m = I_k g(s_t \mid \gamma_m, c_m)$$

Оценивание VSTAR

Если мы соберем все параметры из (11), которые мы должны оценить, то получим

$$\theta = \{\mathbf{B}, \Omega, \Gamma, C\}$$

где $\mathbf{B} = (\mathbf{B}_1, \mathbf{B}_2, ..., \mathbf{B}_m)$, $\Gamma = \{\gamma_{ij}\}$, $C = \{c_{ij}\}$.

В работе (Camacho 2004) предлагается оценивать параметры при помощи метода максимального правдоподобия. (Teräsvirta 1994; Teräsvirta и Yang 2014a; 2014b) для этой цели используют нелинейный МНК.

$$\hat{\theta} = \arg\min_{\theta} \sum_{t=1}^{T} (\mathbf{y}_t - \mathbf{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' (\mathbf{y}_t - \mathbf{\Psi}_t' \mathbf{B}' \mathbf{x}_t) \tag{12}$$

Однако (Teräsvirta и Yang 2014a) отмечают, что если зафиксировать значения Γ и C, то есть значения параметров функции перехода, то система (11) превращается в линейную VAR-модель, которую можно оценить обычным МНК.

Поэтому стратегия оценки следующая:

1. Построить сетку значений Γ и C, используя адекватные границы и плотность сетки.

2. В каждой точке сетки оценить систему по уравнениям МНК, используя соответствующие значения параметров переходной функции. Получить $\hat{\beta}_j$, то есть оценки коэффициентов для каждого уравнения, и вычислить SSR системы.
3. Взять точку сетки с минимальным значением SSR.
4. Использовать полученные оценки в качестве начальных значений для NLM.

Мы можем легко показать, что условие первого порядка для (12) — это

$$\sum_{t=1}^{T} \mathbf{x}_t(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)'\mathbf{\Psi}_t' = 0 \tag{13}$$

или

$$\sum_{t=1}^{T} \mathbf{x}_t\mathbf{y}_t'\mathbf{\Psi}_t' = \sum_{t=1}^{T} \mathbf{x}_t\mathbf{x}_t'\mathbf{B}\mathbf{\Psi}_t\mathbf{\Psi}_t'$$

Тогда для фиксированных Γ и C мы получим

$$\operatorname{vec}\hat{\mathbf{B}} = \left[T^{-1}\sum_{t=1}^{T}(\mathbf{\Psi}_t\mathbf{\Psi}_t') \otimes (\mathbf{x}_t\mathbf{x}_t')\right]^{-1}\left[T^{-1}\sum_{t=1}^{T}\operatorname{vec}(\mathbf{x}_t\mathbf{y}_t'\mathbf{\Psi}_t')\right]$$

что можно упростить до

$$\operatorname{vec}\hat{\mathbf{B}} = (M'M)^{-1}M'\operatorname{vec}(Y') \tag{14}$$

$$M = (\mathrm{Y}_1, \ldots, \mathrm{Y}_t)' \qquad \{Tk \times mk(pk+q)\}$$

$$\mathrm{Y}_t = \mathbf{\Psi}_t \otimes \mathbf{x}_t \qquad \{mk(pk+q) \times k\}$$

Ковариационная матрица Ω оценивается следующим образом

$$\hat{\Omega} = T^{-1}\hat{E}'\hat{E}$$
$$\hat{E} = (\hat{\varepsilon}_1, ..., \hat{\varepsilon}_t)'$$
$$\hat{\varepsilon}_t = \mathbf{y}_t - \mathbf{\Psi}_t'\hat{\mathbf{B}}'\mathbf{x}_t$$

После того, как мы получим начальные значения, мы можем получить окончательные оценки с помощью следующего итерационного процесса:

1. При заданной оценке $\hat{\mathbf{B}}$ оцените Γ и C при помощи NLS.
2. Используя эти вновь полученные Γ и C, переоцените $\hat{\mathbf{B}}$.
3. Продолжайте, пока не будет достигнута сходимость.

Тесты на адекватность модели

В работе (Teräsvirta и Yang 2014b) авторы приводят ряд тестов на адекватность оцененной LVSTAR модели. Рассмотрим их поподробнее.

В основе этих тестов лежит функция правдоподобия

$$\ln L(\theta \mid \mathbf{Y}) = -\frac{Tp}{2}\ln 2\pi - \frac{T}{2}\ln|\Omega| -$$
$$-\frac{1}{2}\sum_{t=1}^{T}(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)'\mathbf{\Omega}^{-1}(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)$$

Тест на линейность

Является многомерным обобщением теста (Teräsvirta и Yang 2014a). В основе лежит LVSTAR модель с одним переходом

$$\mathbf{y}_t = \mathbf{B}_1'\mathbf{x}_t + \mathbf{G}_t\mathbf{B}_2'\mathbf{x}_t + \boldsymbol{\varepsilon}_t$$

1. Оцените линейную модель регрессии $\mathbf{Y}$ на $\mathbf{X}$. Получите остатки $\overline{\mathbf{E}}$ и рассчитайте $RSS_0 = \overline{\mathbf{E}}'\overline{\mathbf{E}}$.
2. Постройте матрицу $\mathbf{Z}_n$

$$\mathbf{Z}_n = \begin{bmatrix} \mathbf{x}_1' s_1 & \mathbf{x}_1' s_1^2 & \cdots & \mathbf{x}_1' s_1^n \\ \mathbf{x}_2' s_2 & \mathbf{x}_2' s_2^2 & \cdots & \mathbf{x}_2' s_2^n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{x}_t' s_T & \mathbf{x}_t' s_T^2 & \cdots & \mathbf{x}_t' s_T^n \end{bmatrix}$$

3. Оцените регрессию $\overline{\mathbf{E}}$ на $(\mathbf{X}, \mathbf{Z}_n)$. Получите остатки $\overline{\overline{\boldsymbol{\Xi}}}$ и рассчитайте $RSS_1 = \overline{\overline{\boldsymbol{\Xi}}}'\overline{\overline{\boldsymbol{\Xi}}}$.
4. Рассчитайте статистику

$$LM_n = T\,\mathrm{tr}\{RSS_0^{-1}(RSS_0 - RSS_1)\} = \\ = T\left(p - \mathrm{tr}\{RSS_0^{-1}RSS_1\}\right) \sim \chi^2(np(kp+q))$$

где k — размер $\mathbf{y}_t$, p — порядок авторегрессии, q — число детерминированных компонент.

Если для разных уравнений используются разные s_{it}, формирующие матрицы $\mathbf{S}_t = \mathrm{diag}(s_{1,t}, \ldots, s_{p,t})$, то тот же тест можно провести с использованием матрицы

$$\mathbf{Z}_n^s = \begin{bmatrix} \operatorname{vec}(\mathbf{S}_1 \otimes \mathbf{x}_1)' & \operatorname{vec}(\mathbf{S}_1^2 \otimes \mathbf{x}_1)' & \cdots & \operatorname{vec}(\mathbf{S}_1^n \otimes \mathbf{x}_1)' \\ \operatorname{vec}(\mathbf{S}_2 \otimes \mathbf{x}_2)' & \operatorname{vec}(\mathbf{S}_2^2 \otimes \mathbf{x}_2)' & \cdots & \operatorname{vec}(\mathbf{S}_2^n \otimes \mathbf{x}_2)' \\ \vdots & \vdots & \ddots & \vdots \\ \operatorname{vec}(\mathbf{S}_T \otimes \mathbf{x}_T)' & \operatorname{vec}(\mathbf{S}_T^2 \otimes \mathbf{x}_T)' & \cdots & \operatorname{vec}(\mathbf{S}_T^n \otimes \mathbf{x}_T)' \end{bmatrix}$$

Единственный минус — для этого варианта теста неизвестно распределение статистики.

Улучшение размера теста

Перемасштабированная LM-статистика

$$F = \frac{pT - K}{q \times pT} \, LM \sim F(q, pT - K)$$

где q — число ограничений, K — число оцениваемых параметров.

Аппроксимация Бартлетта статистики Уилкса

$$\Lambda = \frac{|RSS_1|}{|RSS_0|} \sim \mathcal{L}(p, m, n)$$

$$\lambda = \left\{ \frac{1}{2}[p + \operatorname{cd}(\mathbf{Z}) + 1] + \operatorname{cd}(\mathbf{X}) - T \right\} \ln \Lambda \sim \chi^2(\operatorname{cd}(\mathbf{Z})p)$$

где cd(...) — число столбцов матрицы.

Статистика Рао

$$F_{Rao} = \left[\left(\frac{|RSS_0|}{|RSS_1|} \right)^{1/s} - 1 \right] \frac{Ns - \frac{1}{2}\operatorname{cd}(\mathbf{Z})p + 1}{\operatorname{cd}(\mathbf{Z})p} \sim$$

$$\sim F\left(\operatorname{cd}(\mathbf{Z})p, Ns - \frac{1}{2}\operatorname{cd}(\mathbf{Z})p + 1 \right)$$

$$N = T - \mathrm{cd}(\mathbf{X}) - \frac{1}{2}(p + \mathrm{cd}(\mathbf{Z}) + 1)$$

$$s = \sqrt{\frac{p^2 \mathrm{cd}^2(\mathbf{Z}) - 4}{p^2 + \mathrm{cd}^2(\mathbf{Z}) - 5}}$$

Тест на остаточную автокорреляцию

1. Оцените LVSTAR модель без ограничений и соберите векторы остатков. Выберите глубину запаздываний J. Постойте матрицу $\overline{\mathbf{U}} = \left(\overline{\mathbf{u}}_{J+1}, ..., \overline{\mathbf{u}}_T\right)'$ и рассчитайте[9] $RSS_0 = \overline{\mathbf{U}}'\overline{\mathbf{U}}$. Также сформируйте матрицу $\overline{\mathbf{Z}} = \left(\overline{\mathbf{z}}_{J+1}, ..., \overline{\mathbf{z}}_T\right)'$, где $\overline{\mathbf{z}}_t = \left(\overline{\mathbf{u}}'_{t-1}, ..., \overline{\mathbf{u}}'_{t-J}\right)'$. Рассчитайте матрицу

$$\overline{\mathbf{K}} = \begin{bmatrix} \mathrm{vec}\left[\partial\left(\overline{\mathbf{\Psi}}'_{J+1}\overline{\mathbf{B}}'\mathbf{x}_{J+1}\right)/\partial\theta\right]' \\ \mathrm{vec}\left[\partial\left(\overline{\mathbf{\Psi}}'_{J+2}\overline{\mathbf{B}}'\mathbf{x}_{J+2}\right)/\partial\theta\right]' \\ \vdots \\ \mathrm{vec}\left[\partial\left(\overline{\mathbf{\Psi}}'_{T}\overline{\mathbf{B}}'\mathbf{x}_{T}\right)/\partial\theta\right]' \end{bmatrix}$$

2. Оцените регрессию $\overline{\mathbf{U}}$ на $\left(\overline{\mathbf{K}}, \overline{\mathbf{Z}}\right)$. Получите остатки $\overline{\mathbf{\Xi}}$ и рассчитайте $RSS_1 = \overline{\mathbf{\Xi}}'\overline{\mathbf{\Xi}}$.
3. Рассчитайте статистику[10]

[9](Eitrheim и Teräsvirta 1996) предлагают использовать вместо $\overline{\mathbf{U}}$ остатки регрессии $\overline{\mathbf{U}}$ на $\overline{\mathbf{K}}$.

[10]К этой и последующим статистикам можно применить методы увеличения размера.

$$LM_n = (T - J)\,\mathrm{tr}\{RSS_0^{-1}(RSS_0 - RSS_1)\} =$$
$$= (T - J)\left(p - \mathrm{tr}\{RSS_0^{-1}RSS_1\}\right) \sim \chi^2\left(Jp^2\right)$$

Аддитивная нелинейность

По-другому, тест на остаточную нелинейность.

1. Оцените LVSTAR модель без ограничений и соберите векторы остатков $\overline{\mathbf{E}}$. Оцените регрессию остатков $\overline{\mathbf{E}}$ на $\overline{\mathbf{K}}$ и соберите остатки $\overline{\mathbf{V}}$. Рассчитайте $RSS_0 = \overline{\mathbf{V}}'\overline{\mathbf{V}}$.
2. Оцените регрессию $\overline{\mathbf{V}}$ на $\left(\overline{\mathbf{K}}, \overline{\mathbf{Z}}_N\right)$, где N — степень разложения g в ряд Тейлора. Получите остатки $\overline{\overline{\mathbf{\Xi}}}$ и рассчитайте $RSS_1 = \overline{\overline{\mathbf{\Xi}}}'\overline{\overline{\mathbf{\Xi}}}$.
3. Рассчитайте статистику

$$LM_n = T\,\mathrm{tr}\{RSS_0^{-1}(RSS_0 - RSS_1)\} =$$
$$= T\left(p - \mathrm{tr}\{RSS_0^{-1}RSS_1\}\right) \sim \chi^2(pN(kp + q))$$

Тест на постоянство параметров

1. Оцените LVSTAR модель без ограничений и соберите векторы остатков $\overline{\mathbf{E}}$. Оцените регрессию остатков $\overline{\mathbf{E}}$ на $\overline{\mathbf{K}}$ и соберите остатки $\overline{\mathbf{V}}$. Рассчитайте $RSS_0 = \overline{\mathbf{V}}'\overline{\mathbf{V}}$. Также постойте матрицы

$$\overline{\mathbf{Z}} = \begin{bmatrix} \operatorname{vec}\left(\overline{\mathbf{\Psi}}_1 \otimes \mathbf{x}_1 \tau_1\right)' \\ \operatorname{vec}\left(\overline{\mathbf{\Psi}}_2 \otimes \mathbf{x}_2 \tau_2\right)' \\ \vdots \\ \operatorname{vec}\left(\overline{\mathbf{\Psi}}_T \otimes \mathbf{x}_T \tau_T\right)' \end{bmatrix}$$

где $\tau_t = t/T$, и

$$\overline{\mathbf{K}} = \begin{bmatrix} \operatorname{vec}\left[\partial\left(\overline{\mathbf{\Psi}}_1' \overline{\mathbf{B}}' \mathbf{x}_1\right)/\partial\theta\right]' \\ \operatorname{vec}\left[\partial\left(\overline{\mathbf{\Psi}}_2' \overline{\mathbf{B}}' \mathbf{x}_2\right)/\partial\theta\right]' \\ \vdots \\ \operatorname{vec}\left[\partial\left(\overline{\mathbf{\Psi}}_T' \overline{\mathbf{B}}' \mathbf{x}_T\right)/\partial\theta\right]' \end{bmatrix}$$

Оцените регрессию $\overline{\mathbf{V}}$ на $\left(\overline{\mathbf{K}}, \overline{\mathbf{Z}}\right)$, где N — степень разложения g в ряд Тейлора. Получите остатки $\overline{\overline{\mathbf{\Xi}}}$ и рассчитайте $RSS_1 = \overline{\overline{\mathbf{\Xi}}}' \overline{\overline{\mathbf{\Xi}}}$.

2. Рассчитайте статистику

$$LM_n = T \operatorname{tr}\left\{RSS_0^{-1}(RSS_0 - RSS_1)\right\} =$$
$$= T\left(p - \operatorname{tr}\left\{RSS_0^{-1} RSS_1\right\}\right) \sim \chi^2\left(mp^2(kp + q)\right)$$

Функции импульсных откликов

Рассмотрим «обычную» однорежимную VAR модель

$$\mathbf{y}_t = A_0 + A_1 \mathbf{y}_{t-1} + \ldots + A_p \mathbf{y}_{t-p} + \varepsilon_t$$

Как показано, например, в (Lütkepohl 2005), эту модель можно переписать в виде

$$\mathbf{y}_t = A_0 + \sum_{i=0}^{\infty} \Phi_i \varepsilon_{t-i}$$

или

$$\mathbf{y}_t = A_0 + \sum_{i=0}^{\infty} \Theta_i w_{t-i}$$

где $\Theta_i = \Phi_i P$, $w_t = \varepsilon_t P$, $\Phi_0 = I$, $\Phi_i = \sum_{j=1}^{i} \Phi_{i-j} A_j$. Φ_i и Θ_i интерпретируют как импульсные отклики.

В силу того, что в нелинейных моделях **возможна** смена режимов и, соответственно, коэффициентов, то подобный фокус в них неприменим. Для построения графиков функций импульсных откликов была предложена методология **обобщенных** IRF (Koop и др. 1996). Основная формула

$$GI_{\mathbf{y}}(n, v_t, \omega_{t-1}) = \mathrm{E}[\mathbf{y}_{t+n} \mid v_t, \omega_{t-1}] - \mathrm{E}[\mathbf{y}_{t+n} \mid \omega_{t-1}]$$

или, если предположить, что GI_Y порождается тем же процессом, что и $\mathbf{y}_t$,

$$GI_{\mathbf{y}}(n, V_t, \Omega_{t-1}) = \mathrm{E}[\mathbf{y}_{t+n} \mid V_t, \Omega_{t-1}] - \mathrm{E}[\mathbf{y}_{t+n} \mid \Omega_{t-1}]$$

Свойства GI_Y:

1. $\mathrm{E}\big[GI_{\mathbf{y}}(n, V_t, \Omega_{t-1})\big] = \mathbf{0}$ — безусловное матожидание;
2. $\mathrm{E}\big[GI_{\mathbf{y}}(n, V_t, \omega_{t-1})\big] = \mathbf{0}$ — матожидание, условное относительно истории;

3. $\mathrm{E}\left[GI_{\mathbf{y}}(n, v_t, \Omega_{t-1})\right] = \mathrm{E}[\mathbf{y}_{t+n} \mid v_t] - \mathrm{E}[\mathbf{y}_{t+n}]$ — матожидание, условное относительно шока.

Библиография

[1] W. Enders, *Applied Econometric Time Series*, Fourth edition. Hoboken, NJ: Wiley, 2015.

[2] R. B. Davies, «Hypothesis Testing When a Nuisance Parameter Is Present Only Under the Alternatives», *Biometrika*, т. 74, вып. 1, сс. 33–43, 1987, doi: 10.2307/2336019.

[3] H. Tong и K. S. Lim, «Threshold Autoregression, Limit Cycles and Cyclical Data», *Journal of the Royal Statistical Society. Series B (Methodological)*, т. 42, вып. 3, сс. 245–292, 1980, doi: 10.1111/j.2517-6161.1980.tb01126.x.

[4] K. S. Chan, «Consistency and Limiting Distribution of the Least Squares Estimator of a Threshold Autoregressive Model», *The Annals of Statistics*, т. 21, вып. 1, сс. 520–533, 1993, Просмотрено: 6 март 2020 г. [Онлайн]. Доступно на: https://www.jstor.org/stable/3035605

[5] B. E. Hansen, «Inference in TAR Models», *Studies in Nonlinear Dynamics & Econometrics*, т. 2, вып. 1, 1997, doi: 10.2202/1558-3708.1024.

[6] M. K. Pippenger и G. E. Goering, «Practitioners Corner: A Note on the Empirical Power of Unit Root Tests under

Threshold Processes», *Oxford Bulletin of Economics and Statistics*, т. 55, вып. 4, сс. 473–481, 1993.

[7] N. S. Balke и T. B. Fomby, «Threshold Cointegration», *International Economic Review*, т. 38, вып. 3, сс. 627–645, 1997.

[8] W. Enders и C. W. J. Granger, «Unit-Root Tests and Asymmetric Adjustment with an Example Using the Term Structure of Interest Rates», *Journal of Business & Economic Statistics*, т. 16, вып. 3, сс. 304–311, 1998.

[9] J. D. Petruccelli и S. W. Woolford, «A Threshold AR(1) Model», *Journal of Applied Probability*, т. 21, вып. 2, сс. 270–286, 1984.

[10] D. van Dijk, T. Teräsvirta, и P. H. Franses, «Smooth Transition Autoregressive Models - A Survey of Recent Developments», вып. EI 2000–23/A, июн. 2000, Просмотрено: 6 июнь 2023 г. [Онлайн]. Доступно на: https://repub.eur.nl/pub/1656

[11] T. Teräsvirta и Y. Yang, «Specification, Estimation and Evaluation of Vector Smooth Transition Autoregressive Models with Applications», Department of Economics and Business Economics, Aarhus University, 2014–8, мар. 2014a. Просмотрено: 26 февраль 2020 г. [Онлайн]. Доступно на: https://ideas.repec.org/p/aah/create/2014-08.html

[12] A. Escribano и O. Jordá, «Improved Testing and Specification of Smooth Transition Regression Models», в *Nonlinear Time Series Analysis of Economic and Financial Data*, P. Rothman, Ред., в Dynamic Modeling and Econometrics in Economics and Finance., Boston, MA: Springer US, 1999, сс. 289–319. doi: 10.1007/978-1-4615-5129-4_14.

[13] V. Haggan и T. Ozaki, «Modelling Nonlinear Random Vibrations Using an Amplitude-Dependent Autoregressive Time Series Model», *Biometrika*, т. 68, вып. 1, сс. 189–196, 1981, doi: 10.2307/2335819.

[14] Ø. Eitrheim и T. Teräsvirta, «Testing the Adequacy of Smooth Transition Autoregressive Models», *Journal of Econometrics*, т. 74, вып. 1, сс. 59–75, сен. 1996, doi: 10.1016/0304-4076(95)01751-8.

[15] P. Rothman, D. J. C. van Dijk, и P. H. B. F. Franses, «A Multivariate STAR Analysis of the Relationship Between Money and Output», Erasmus University Rotterdam, Erasmus School of Economics (ESE) , Econometric Institute, EI 9945-/A, ноя. 1999. Просмотрено: 26 февраль 2020 г. [Онлайн]. Доступно на: https://ideas.repec.org/p/ems/eureir/1616.html

[16] M. Camacho, «Vector Smooth Transition Regression Models for US GDP and the Composite Index of Leading

Indicators», *Journal of Forecasting*, т. 23, вып. 3, сс. 173–196, 2004, doi: 10.1002/for.912.

[17] T. Teräsvirta, «Specification, Estimation, and Evaluation of Smooth Transition Autoregressive Models», *Journal of the American Statistical Association*, т. 89, вып. 425, сс. 208–218, 1994, doi: 10.2307/2291217.

[18] T. Teräsvirta и Y. Yang, «Linearity and Misspecification Tests for Vector Smooth Transition Regression Models», Department of Economics and Business Economics, Aarhus University, 2014–4, фев. 2014b. Просмотрено: 26 февраль 2020 г. [Онлайн]. Доступно на: https://ideas.repec.org/p/aah/create/2014-04.html

[19] H. Lütkepohl, *New Introduction to Multiple Time Series Analysis*. Berlin, Heidelberg: Springer, 2005.

[20] G. Koop, M. H. Pesaran, и S. M. Potter, «Impulse Response Analysis in Nonlinear Multivariate Models», *Journal of Econometrics*, т. 74, вып. 1, сс. 119–147, 1996.

[21] J. E. Gentle, *Matrix Algebra: Theory, Computations and Applications in Statistics*, 2nd ed. 2017. в Springer Texts in Statistics. Cham: Springer International Publishing : Imprint: Springer, 2017. doi: 10.1007/978-3-319-64867-5.

[22] J. R. Magnus и H. Neudecker, *Matrix Differential Calculus with Applications in Statistics and Econometrics*, Third

edition. в Wiley series in probability and statistics. Hoboken, NJ: Wiley, 2019.

A Вывод (13)

The equation (13) derivation is pretty straightforward[11]. First, from (Gentle 2017; Magnus и Neudecker 2019) we know, that

$$\mathrm{d}f = \mathrm{tr}\left[\left(\frac{df}{dA}\right)' \mathrm{d}A\right]$$

$$\mathrm{d}f = \mathrm{d}(\mathrm{tr}\, f) = \mathrm{tr}(\mathrm{d}f)$$

where tr is the trace function, i.e. the sum of the diagonal elements of a matrix, A is a matrix, f is a scalar function. We have

$$f = \sum_{t=1}^{T} (\mathbf{y}_t - \mathbf{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' (\mathbf{y}_t - \mathbf{\Psi}_t' \mathbf{B}' \mathbf{x}_t)$$

Using the following properties of differential and trace

$$\mathrm{d}A = \left(\mathrm{d}a_{ij}\right)$$

$$\mathrm{d}(AB) = \mathrm{d}A\, B + A\, \mathrm{d}B$$

$$\mathrm{d}\,\mathrm{tr}\, A = \mathrm{tr}(\mathrm{d}A)$$

$$\mathrm{d}A' = (\mathrm{d}A)'$$

$$\mathrm{tr}\, A = \mathrm{tr}\, A'$$

$$\mathrm{tr}(AB) = \mathrm{tr}(BA))$$

$$\mathrm{tr}(A + B) = \mathrm{tr}\, A + \mathrm{tr}\, B$$

[11]Текст оставлен на английском, но он понятен и так.

we get the following chain of expressions

$$
\begin{aligned}
\mathrm{d}f &= \operatorname{tr}\left(\mathrm{d} \sum_{t=1}^{T} (\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)'(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t) \right) = \\
&= \operatorname{tr} \sum_{t=1}^{T} \mathrm{d}\left[(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)'(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)\right] = \\
&= \sum_{t=1}^{T} \operatorname{tr} \mathrm{d}\left[(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)'(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)\right] = \\
&= \sum_{t=1}^{T} \operatorname{tr}\left[\mathrm{d}(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)'(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t) + (\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' \mathrm{d}(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)\right] = \\
&= -\sum_{t=1}^{T} \operatorname{tr}\left[\mathrm{d}(\boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)'(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t) + (\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' \mathrm{d}(\boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)\right] = \\
&= -\sum_{t=1}^{T} \left\{ \operatorname{tr}\left[\mathrm{d}(\boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)'(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)\right] + \operatorname{tr}\left[(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' \mathrm{d}(\boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)\right] \right\} = \\
&= -\sum_{t=1}^{T} \left\{ \operatorname{tr}\left[(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' \mathrm{d}(\boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)\right] + \operatorname{tr}\left[(\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' \mathrm{d}(\boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)\right] \right\} = \\
&= -2 \operatorname{tr}\left[\sum_{t=1}^{T} (\mathbf{y}_t - \boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t)' \mathrm{d}(\boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t) \right] = *
\end{aligned}
$$

Here we use $*$ to mark the break in the expression chain. To proceed, let's simplify the differential inside the sum

$$
\begin{aligned}
\mathrm{d}(\boldsymbol{\Psi}_t' \mathbf{B}' \mathbf{x}_t) &= \mathrm{d}\boldsymbol{\Psi}_t'(\mathbf{B}' \mathbf{x}_t) + \boldsymbol{\Psi}_t' \mathrm{d}(\mathbf{B}' \mathbf{x}_t) = \\
&= \boldsymbol{\Psi}_t'(\mathrm{d}\mathbf{B}' \mathbf{x}_t + \mathbf{B}' \mathrm{d}\mathbf{x}_t) = \\
&= \boldsymbol{\Psi}_t' \mathrm{d}\mathbf{B}' \mathbf{x}_t.
\end{aligned}
$$

For every t we can consider $\boldsymbol{\Psi}_t$ and $\mathbf{x}_t$ as constants, hence their differentials are zero. With that, we get

$$* = -2\,\mathrm{tr}\left[\sum_{t=1}^{T}(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)'\mathbf{\Psi}_t'\,\mathrm{d}\mathbf{B}'\mathbf{x}_t\right] =$$

$$= -2\,\mathrm{tr}\left[\sum_{t=1}^{T}\mathbf{x}_t'\,\mathrm{d}\mathbf{B}_t\,\mathbf{\Psi}_t(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)\right] = *$$

From $\mathrm{tr}(AB) = \mathrm{tr}(BA)$ it follows that $\mathrm{tr}(A_1A_2\ldots A_n) = \mathrm{tr}(A_nA_1\ldots A_{n-1})$. Then we have

$$* = -2\,\mathrm{tr}\left[\sum_{t=1}^{T}\mathbf{\Psi}_t(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)\mathbf{x}_t'\,\mathrm{d}\mathbf{B}\right] =$$

$$= \mathrm{tr}\left\{\left[-2\sum_{t=1}^{T}\mathbf{\Psi}_t(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)\mathbf{x}_t'\right]\mathrm{d}\mathbf{B}\right\}.$$

Hence, we get

$$\frac{df}{d\mathbf{B}} = \left[-2\sum_{t=1}^{T}\mathbf{\Psi}_t(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)\mathbf{x}_t'\right]' = -2\sum_{t=1}^{T}\mathbf{x}_t(\mathbf{y}_t - \mathbf{\Psi}_t'\mathbf{B}'\mathbf{x}_t)'\mathbf{\Psi}_t'$$

В Вывод (14)

Let’s go back to

$$\mathrm{vec}\,\hat{\mathbf{B}} = \left[T^{-1}\sum_{t=1}^{T}(\mathbf{\Psi}_t\mathbf{\Psi}_t')\otimes(\mathbf{x}_t\mathbf{x}_t')\right]^{-1}\left[T^{-1}\sum_{t=1}^{T}\mathrm{vec}(\mathbf{x}_t\mathbf{y}_t'\mathbf{\Psi}_t')\right] = *$$

From (Gentle 2017) we can get the following properties of Kronecker product

$$(A\otimes B)' = A'\otimes B'$$

$$(A\otimes B)(C\otimes D) = (AC)\otimes(BD)$$

$$\mathrm{vec}(ABC) = (C'\otimes A)\,\mathrm{vec}\,B$$

The corresponding matrix products should exist. Then we have

$$* = \left[T^{-1}\sum_{t=1}^{T}(\mathbf{\Psi}_t \otimes \mathbf{x}_t)(\mathbf{\Psi}_t' \otimes \mathbf{x}_t')\right]^{-1}\left[T^{-1}\sum_{t=1}^{T}(\mathbf{\Psi}_t \otimes \mathbf{x}_t)\operatorname{vec}\mathbf{x}_t'\right] = *$$

As $\mathbf{y}_t$ is already a vector then $\operatorname{vec}\mathbf{y}_t' = \operatorname{vec}\mathbf{y}_t$. Hence we have

$$* = \left[\sum_{t=1}^{T}(\mathbf{\Psi}_t \otimes \mathbf{x}_t)(\mathbf{\Psi}_t' \otimes \mathbf{x}_t')\right]^{-1}\left[\sum_{t=1}^{T}(\mathbf{\Psi}_t \otimes \mathbf{x}_t)\operatorname{vec}\mathbf{y}_t\right] =$$

$$= \left[\sum_{t=1}^{T}\mathrm{Y}_t\mathrm{Y}_t'\right]^{-1}\left[\sum_{t=1}^{T}\mathrm{Y}_t\operatorname{vec}\mathbf{y}_t\right]$$

Setting $M = (\mathrm{Y}_1, \mathrm{Y}_2, \ldots, \mathrm{Y}_T)'$ we can see that

$$\sum_{t=1}^{T}\mathrm{Y}_t\mathrm{Y}_t' = M'M$$

Setting $\mathbf{Y} = (\mathbf{y}_1', \ldots, \mathbf{y}_T')'$ we can get

$$\sum_{t=1}^{T}\mathrm{Y}_t\operatorname{vec}\mathbf{y}_t = M'\operatorname{vec}(\mathbf{Y}')$$

Hence, we get (14). In the package[12] the matrix M is built in more vectorized form to avoid loops as much as possible. The matrix M is defined as follows

[12]Данный текст взят из виньетки пакета, который лектор писал для своих нужд при написании своей диссертации. Лектору хотелось разобраться в формулах из статьи (Teräsvirta и Yang 2014a). На сегодняшний день этот пакет уже не нужен, так как в феврале 2024 был опубликован более адекватно написанный пакет...

$$M = \left[\begin{pmatrix} 1 & g_1(s_1) & \dots & g_{m-1}(s_1) \\ \vdots & \vdots & & \vdots \\ 1 & g_1(s_T) & \dots & g_{m-1}(s_T) \end{pmatrix} \otimes I_k \otimes e'_{kp+q} \right] \odot [e'_{km} \otimes \mathbf{X} \otimes e_k]$$

where $g_k(s) = g(s \mid \gamma_k, c_k)$, $e_N = \left(\underbrace{1, \dots, 1}_{N} \right)'$. $\odot$ denotes Hadamard (element-wize) product.