Лекция 3

Методы оценивания

Зямалов В.Е.

Основные источники: учебники Хаяши [Hayashi, 2000; Хайяши, 2017] и Гамильтона [Hamilton, 1994].

Хаяши выделяет два класса так называемых «экстремальных» оценок:

- M-оценки, получаемые из задачи, целевая функция которой имеет вид

$$Q_T(\theta) = \frac{1}{T}\sum_{t=1}^{T} m(y_t \mid \theta)$$

  где $m(y_t \mid \theta)$ — некоторая функция $\mathbf{Y} \times \Theta \to \mathbb{R}$.
- GMM, получаемые из задачи, целевая функция которой имеет вид

$$Q_T(\theta) = -\frac{1}{2}\mathbf{g}_T(\theta)'\hat{\mathbf{W}}\mathbf{g}_T(\theta)$$

  где $\mathbf{g}_T(\theta) = \frac{1}{T}\sum_{t=1}^{T} \mathbf{g}(y_t \mid \theta)$.

1. Метод максимального правдоподобия

Рассмотрим следующую задачу. У нас есть некоторый набор наблюдений $\{y_t\}$, полученный из генеральной совокупности с набором некоторых параметров θ, которые нам нужно оценить.

Для решения этой задачи можно воспользоваться **методом максимального правдоподобия**. Предположим, что наблюдения являются независимыми и одинаково распределенными, причем вид распределения нам **известен**[1].

Для данных наблюдений можно записать плотность распределения каждого из них с учетом значений вектора параметров θ — $f(y_t; \theta)$. Так как все наблюдения считаются независимыми, то достаточно легко можно вычислить совместную плотность распределения всего набора наблюдений

$$f(y_1, y_2, \dots, y_T \mid \theta) = \prod_{t=1}^{T} f(y_t \mid \theta)$$

Полученное выражение и задает нам **функцию правдоподобия**. Формально можно записать, что

$$L(\theta \mid \mathbf{y}) = \mathrm{P}(\mathbf{y} \mid \theta)$$

[1] Это утверждение приведено в учебнике [Хайяши, 2017], хотя, как мы увидим далее, это не обязательное требование. Главное, чтобы мы **знали** распределения отдельных наблюдений.

что означает, что значение функции правдоподобия, вычисленной на данном наборе параметров с учетом текущей выборки, численно совпадает с вероятностью получить данную выборку при данном наборе параметров.

Оптимальной оценкой θ

$$\arg\max_{\theta \in \Theta} L(\theta \mid \mathbf{y})$$

Для упрощения функцию правдоподобия часто берут в логарифмах

$$l(\theta \mid \mathbf{y}) = \sum_{t=1}^{T} \ln f(y_t \mid \theta)$$

Необходимым условием экстремума для решения задачи является равенство нулю градиента функции правдоподобия

$$\nabla l(\theta \mid \mathbf{y})\big|_{\theta=\hat{\theta}} = \frac{\partial l}{\partial \theta}(\hat{\theta}) = \mathbf{0}$$

Достаточным условием является отрицательная определенность матрицы Гессе

$$H(\theta \mid \mathbf{y}) = \left(\frac{\partial^2 l}{\partial \theta \partial \theta'}\right)(\theta \mid \mathbf{y})$$

Как отмечает Хаяши [Хайяши, 2017], при выполнении достаточно простых условий ML-оценки являются состоятельными:

- функция правдоподобия должна быть вогнутой на пространстве параметров Θ;
- функция правдоподобия измерима на пространстве данных для любого $\theta \in \Theta$.
- стационарный процесс $\{y_t\}$ эргодичен.

1.1. Линейная регрессия

Рассмотрим пример оценивания линейной регрессии [Магнус, Катышев, Пересецкий, 2021]. Допустим, что мы ищем оценку параметров модели

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t$$

Предположим, что выполняются все предпосылки МНК, а также дополнительное предположение гауссовости случайных ошибок

$$\varepsilon_t \sim WN(0,\sigma^2)$$

что эквивалентно[2]

$$y_t \sim N(\beta_0 + \beta_1 x_t,\sigma^2)$$

[2] В примере подразумевается детерминированность x_t.

Для решения данной задачи имеет смысл рассмотреть так называемый **условный метод максимального правдоподобия**. Смысл метода заключается в том, что исходный набор наблюдений разбивается на две части, причем исследователя интересует влияние одной части данных — в нашем случае x_t — на условное матожидание других — y_t.

Плотность можно разложить следующим образом

$$f(y_t,x_t \mid \theta,\psi) = f(y_t \mid x_t;\theta)f(x_t;\psi)$$

где ψ — параметры распределения x_t.

В итоге функция правдоподобия примет вид

$$l(\theta \mid y_t,x_t) = \frac{1}{T}\sum_{t=1}^{T} \ln f(y_t \mid x_t;\theta) + \frac{1}{T}\sum_{t=1}^{T} f(x_t;\psi)$$

Очевидно, что при поиске оптимального значения $\hat{\theta}$ максимизироваться будет только первая часть; вторая часть игнорируется.

Вернемся к примеру. Запишем функцию правдоподобия

$$L(\beta_0,\beta_1,\sigma^2 \mid y_1,\dots,y_T) = \mathrm{P}(y_1,\dots,y_T \mid x_1,\dots,x_T,\beta_0,\beta_1,\sigma^2) =$$
$$= (2\pi)^{-T/2}(\sigma^2)^{-T/2}\exp\left(-\frac{1}{2\sigma^2}\sum_{t=1}^{T}(y_t-\beta_0-\beta_1 x_t)^2\right)$$

или

$$\ln L(\beta_0,\beta_1,\sigma^2 \mid y_1,\dots,y_T) = -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}\sum_{t=1}^{T}(y_t-\beta_0-\beta_1 x_t)^2$$

Найдем необходимые условия первого порядка максимизации функции

$$\frac{\partial \ln L}{\partial \beta_0} = \frac{1}{\sigma^2}\sum_{t=1}^{T}(y_t-\beta_0-\beta_1 x_t) = 0$$

$$\frac{\partial \ln L}{\partial \beta_1} = \frac{1}{\sigma^2}\sum_{t=1}^{T} x_t(y_t-\beta_0-\beta_1 x_t) = 0$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2}\frac{1}{\sigma^2} + \frac{1}{2\sigma^4}\sum_{t=1}^{T}(y_t-\beta_0-\beta_1 x_t)^2 = 0$$

Нетрудно завметить, что первые два уравнения дают нам оценки

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$$
$$\hat{\beta}_1 = \frac{\sum(x_t-\bar{x})(y_t-\bar{y})}{\sum(x_t-\bar{x})^2}$$
$$\hat{\sigma}^2 = \frac{1}{n}\sum e_t^2$$

То есть полученные оценки коэффициентов совпадают с МНК оценками. При этом оценка σ^2 оказывается состоятельной, но смещенной.

1.2. AR(p)

Рассмотрим функцию правдоподобия для процесса AR(p)

$$Y_t = c + \alpha_1 Y_{t-1} + \cdots + \alpha_p Y_{t-p} + \varepsilon_t$$

где $\varepsilon \sim WN(0,\sigma^2)$. Оцениваемый вектор параметров $\theta = (c,\alpha_1,\dots,\alpha_p,\sigma^2)$.

Очевидно, что с описанием данного процесса есть сложность, связанная с первыми p наблюдениями. Гамильтон [Hamilton, 1994] использует способ разделения функции на две части.

Первая часть определяет первые p наблюдений как реализацию p-мерной Гауссовой случайной величины с математическим ожиданием

$$\mu = \frac{c}{1 - \sum_{i=1}^{p} \alpha_i}$$

Ковариационная матрица $(y_1,\dots,y_p)$ равна

$$\sigma^2 \mathbf{V}_p = \begin{bmatrix} \mathrm{E}(Y_1-\mu)^2 & \mathrm{E}(Y_1-\mu)(Y_2-\mu) & \cdots & \mathrm{E}(Y_1-\mu)(Y_p-\mu) \\ \mathrm{E}(Y_2-\mu)(Y_1-\mu) & \mathrm{E}(Y_2-\mu)^2 & \cdots & \mathrm{E}(Y_2-\mu)(Y_p-\mu) \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{E}(Y_p-\mu)(Y_1-\mu) & \mathrm{E}(Y_p-\mu)(Y_2-\mu) & \cdots & \mathrm{E}(Y_p-\mu)^2 \end{bmatrix} = \begin{bmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{p-1} \\ \gamma_1 & \gamma_0 & \cdots & \gamma_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{p-1} & \gamma_{p-2} & \cdots & \gamma_0 \end{bmatrix}$$

Отсюда совместная плотность первых p наблюдений равна

$$\begin{aligned} f_{Y_p,Y_{p-1},\dots,Y_1}(y_p,\dots,y_1;\theta) &= (2\pi)^{-p/2}|\sigma^{-2}\mathbf{V}_p^{-1}|^{1/2} \exp\left[-\frac{1}{2\sigma^2}(\mathrm{y}_p - \boldsymbol{\mu}_p)'\mathbf{V}_p^{-1}(\mathrm{y}_p - \boldsymbol{\mu}_p)\right] = \\ &= (2\pi)^{-p/2}(\sigma^{-2})^{p/2}|\mathbf{V}_p^{-1}|^{1/2} \exp\left[-\frac{1}{2\sigma^2}(\mathrm{y}_p - \boldsymbol{\mu}_p)'\mathbf{V}_p^{-1}(\mathrm{y}_p - \boldsymbol{\mu}_p)\right] \end{aligned}$$

[R. F. Galbraith, J. I. Galbraith, 1974] показали, что элемент ij матрицы $\mathbf{V}_p^{-1}$ равен

$$v^{ij} = v^{ji} = \left[\sum_{k=0}^{i-1} \alpha_k \alpha_{k+j-i} - \sum_{k=p+1-j}^{p+i-j} \alpha_k \alpha_{k+j-i}\right]$$

причем $\alpha_0 = -1$[3].

Для оставшейся части выборки поступают следующим образом. Для наблюдения t математическое ожидание зависит **только** от предыдущих p наблюдений, то есть

$$\mathrm{E}(Y_t \mid Y_{t-1},\dots,Y_1) = \mathrm{E}(Y_t \mid Y_{t-1},\dots,Y_{t-p}) = \alpha_0 + \sum_{i=1}^{p} \alpha_i y_{t-i}$$

При этом дисперсия равна σ^2.

[3] В исходном тексте свободный член в модели обозначается как c, чтобы избежать коллизии с v^{ij}.

Поэтому для второй части плотность Y_t имеет вид

$$f_{Y_t|Y_{t-1},\dots,Y_{t-p}}(y_t \mid y_{t-1},\dots,y_{t-p};\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_t - \alpha_0 - \sum_{i=1}^{p} \alpha_i y_{t-i})^2}{2\sigma^2}\right]$$

А совокупная плотность **всей** выборки равна

$$f_{Y_T,\dots,Y_1}(y_T,\dots,y_1;\theta) = f_{Y_p,Y_{p-1},\dots,Y_1}(y_p,\dots,y_1;\theta) \times \prod_{t=p+1}^{T} f_{Y_t|Y_{t-1},\dots,Y_{t-p}}(y_t \mid y_{t-1},\dots,y_{t-p};\theta)$$

А функция правдоподобия

$$\begin{aligned}\ln L(\theta \mid \mathbf{y}) = &-\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln(\sigma^2) + \frac{1}{2}\ln|\mathbf{V}_p^{-1}| - \\ &- \frac{1}{2\sigma^2}(\mathrm{y}_p - \boldsymbol{\mu}_p)'\mathbf{V}_p^{-1}(\mathrm{y}_p - \boldsymbol{\mu}_p) - \\ &- \sum_{t=p+1}^{T} \frac{\left(y_t - \alpha_0 - \sum_{i=1}^{p} \alpha_i y_{t-i}\right)^2}{2\sigma^2}\end{aligned}$$

Если проигнорировать первые p наблюдений, что допускается на больших выборках, то функция правдоподобия примет вид

$$\ln L(\theta \mid y_T,\dots,y_{p+1}) = -\frac{T-p}{2}\ln(2\pi) - \frac{T-p}{2}\ln(\sigma^2) - \sum_{t=p+1}^{T} \frac{(y_t - \alpha_0 - \sum_{i=1}^{p} \alpha_i y_{t-i})^2}{2\sigma^2}$$

Эта функция дает нам в итоге МНК-оценки коэффициентов. Оценка σ^2 равна

$$\hat{\sigma}^2 = \frac{1}{T-p}\sum_{t=p+1}^{T} e_t^2$$

1.3. MA(1)

Рассмотрим процесс

$$Y_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}$$

где $\varepsilon \sim WN(0,\sigma^2)$. Оцениваемый вектор параметров $\theta = (\mu,\theta,\sigma^2)$.

Если бы мы точно знали ε_{t-1}, то

$$\begin{aligned}Y_t \mid \varepsilon_{t-1} &\sim N(\mu + \theta\varepsilon_{t-1},\sigma^2) \\ f_{Y_t|\varepsilon_{t-1}} &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_t - \mu - \theta\varepsilon_{t-1})^2}{2\sigma^2}\right]\end{aligned}$$

Далее следим за руками. Предположим, что мы **знаем**, что $\varepsilon_0 = 0$. Тогда

$$Y_1 \mid \varepsilon_0 \sim N(\mu,\sigma^2)$$

Более того, мы **достоверно**[4] знаем $\varepsilon_1 = y_1 - \mu$; это позволяет нам записать

$$f_{Y_2|Y_1,\varepsilon_0} = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_2 - \mu - \theta\varepsilon_1)^2}{2\sigma^2}\right]$$

Вообще, знание $\varepsilon_0 = 0$ позволяет нам достоверно рассчитать $\{\varepsilon_t\}$. Так как $\varepsilon_t = y_t - \mu - \theta\varepsilon_{t-1}$, то итоговая функция правдоподобия имеет вид

$$\ln L(\theta) = -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln(\sigma^2) - \sum_{t=1}^{T}\frac{\varepsilon_t^2}{2\sigma^2}$$

Кстати, именно на данном этапе проявляется роль обратимости MA-процесса: если $|\theta| \ll 1$, то эффект весьма произвольного выбора ε_0 крайне быстро затухает. Если при численном решении задачи получается значение $\hat{\theta}$ больше 1, то оно должно быть отброшено, а процесс подбора начат заново с $1/\hat{\theta}$ в качестве начального значения.

С другой стороны мы можем записать точное значение функции правдоподобия **без** волюнтаристических предположений. Ковариационная матрица выборки из процесса MA(1)

$$\mathbf{\Omega} = \mathrm{E}(\mathbf{Y} - \boldsymbol{\mu})(\mathbf{Y} - \boldsymbol{\mu})'$$

имеет вид

$$\mathbf{\Omega} = \sigma^2 \begin{bmatrix} (1+\theta^2) & \theta & 0 & \cdots & 0 \\ \theta & (1+\theta^2) & \theta & \cdots & 0 \\ 0 & \theta & (1+\theta^2) & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & (1+\theta^2) \end{bmatrix}$$

А функция правдоподобия

$$\ln L(\theta) = -\frac{T}{2}\ln(2\pi) - \frac{1}{2}\ln|\mathbf{\Omega}| - \frac{1}{2}(\mathrm{y} - \boldsymbol{\mu})'\mathbf{\Omega}^{-1}(\mathrm{y} - \boldsymbol{\mu}) \tag{1}$$

1.3.1. Треугольное разложение

Гамильтон [Hamilton, 1994] рассматривает следующую модификацию (1). Известно[5], что любая симметрическая положительно определенная матрица $\mathbf{\Omega}$ единственным образом раскладывается следующим образом

$$\mathbf{\Omega} = \mathbf{ADA}'$$

где $\mathbf{A}$ — нижняя унитреугольная матрица[6], $\mathbf{D}$ — диагональная матрица.

Из этого разложения следует, что

$$|\mathbf{\Omega}| = |\mathbf{A}| \times |\mathbf{D}| \times |\mathbf{A}'| = |\mathbf{D}|$$

[4] С точностью до **неизвестного** параметра μ.

[5] См. [Там же, стр. 87].

[6] Треугольная матрица с единицами на главной диагонали.

Также можно ввести следующие переменные

$$\tilde{\mathbf{y}} = \mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu})$$

С учетом этого (1) примет вид

$$\ln L(\theta) = -\frac{T}{2}\ln(2\pi) - \frac{1}{2}\ln|\mathbf{D}| - \frac{1}{2}\tilde{\mathbf{y}}'\mathbf{D}^{-1}\tilde{\mathbf{y}}$$

Если обратить внимание на то, что

$$\mathbf{ADA}' = \underbrace{\mathbf{AD}^{1/2}}_{\mathbf{L}}\underbrace{\mathbf{D}^{1/2}\mathbf{A}'}_{\mathbf{L}'}$$

где $\mathbf{L}$ — матрица разложения Холецкого, $\mathbf{D}^{1/2}$ — матрица, состоящая из корней элементов матрицы $\mathbf{D}$, и ввести переменную

$$\tilde{\mathbf{y}} = \mathbf{L}^{-1}(\mathbf{y} - \boldsymbol{\mu})$$

то (1) примет вид

$$\ln L(\theta) = -\frac{T}{2}\ln(2\pi) - \frac{1}{2}\ln|\mathbf{L}| - \frac{1}{2}\tilde{\mathbf{y}}'\tilde{\mathbf{y}}$$

1.4. ARMA(p, q)

Как ни странно, но ARMA(p, q) по построению функции правдоподобия ближе к процессам скользящего среднего.

Если взять начальные значения $\mathbf{y}_0 = (y_0, y_{-1}, \dots, y_{-p+1})'$ и $\boldsymbol{\varepsilon}_0 = (\varepsilon_0, \varepsilon_{-1}, \dots, \varepsilon_{-q+1})'$, то последовательность $\{\varepsilon_t\}$ может быть «достоверно» рассчитана

$$\varepsilon_t = y_t - \alpha_0 - \sum_{i=1}^{p}\alpha_i y_{t-i} - \sum_{j=1}^{q}\theta_j\varepsilon_{t-j}$$

что дает нам

$$\ln L(\theta) = \ln f_{Y_T, Y_{T-1}, \dots, Y_1 | Y_0, \varepsilon_0}(y_t, \dots, y_1 \mid \mathbf{y}_0, \boldsymbol{\varepsilon}_0; \theta) =$$
$$= -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln(\sigma^2) - \sum_{t=1}^{T}\frac{\varepsilon_t^2}{2\sigma^2}$$

В качестве начальных значений можно взять:

- математические ожидания, то есть

$$y_t = \frac{\alpha_0}{1 - \sum_{i=1}^{p}\alpha_i}, \quad t = 0, -1, \dots, -p+1$$
$$\varepsilon_t = 0 \qquad\qquad t = 0, -1, \dots, -q+1$$

- Бокс и Дженкинс [Box (и др.), 2016] предложили брать в качестве y_0 первые p значений y_t, а в качестве $\boldsymbol{\varepsilon}_0$ — $\varepsilon_t = 0, t = p, \dots, p-q+1$. Понятно, что расчет последовательности $\{\varepsilon_t\}$ будет проходить на наблюдениях $p+1, \dots, T$; соответствующим образом меняется функция правдоподобия

$$\ln L(\theta) = \ln f_{Y_T, Y_{T-1}, \dots, Y_{p+1} | Y_0, \varepsilon_0}(y_t, \dots, y_{p+1} \mid \mathrm{y}_0, \boldsymbol{\varepsilon}_0; \theta) =$$
$$= -\frac{T-p}{2} \ln(2\pi) - \frac{T-p}{2} \ln(\sigma^2) - \sum_{t=p+1}^{T} \frac{\varepsilon_t^2}{2\sigma^2}$$

2. GMM

Обобщенный метод моментов является, как понятно из названия, обобщением метода моментов. Опишем этот метод согласно обзорной работе Хансена [Hansen, 2007].

Рассмотрим наши данные, которые являются конечной реализацией процесса $\{y_t\}_{t=1}^T$. Сама модель определяется следующим простым выражением

$$\mathrm{E}\, f(y_T; \beta_0) = 0$$

где $\beta_0 \in \mathbb{P} \subset \mathbb{R}^k$ — истинные значения параметров модели[7], а $f(\dots)$ — вектор-функция, имеющая r компонент. Для того, чтобы решение задачи было единственным, необходимо выполнение условия

$$\mathrm{E}\, f(y_t; \beta) = 0 \iff \beta = \beta_0$$

$f(\dots)$ называют моментной функцией.

Реальное оценивание производится на выборочном аналоге матожидания

$$g_T(\beta) = \frac{1}{T} \sum_{t=1}^{T} f(y_t; \beta)$$

В литературе показано, что

$$\sqrt{T} g_T(\beta_0) \xrightarrow{d} N(0, V)$$

где

$$V = \sum_{j=-\infty}^{\infty} \mathrm{E}[f(y_t; \beta_0) f(y_{t+j}; \beta_0)']$$

То есть V — спектральная плотность на нулевой частоте.

Если

- $r < k$, то модель недоопределена; оценки в данном случае получить нельзя.
- $r = k$, то модель определена точно; у модели **может** быть решение. Это традиционный метод моментов.

[7] Обычно к GMM прибегают в случае полупараметрических моделей, когда функцию правдоподобия записать «затруднительно».

- $r > k$, то модель переопределена; в общем случае решения также нет. Но возможно найти не точное, а максимально к нему приближенное решение. Это и есть обобщенный метод моментов.

2.1. Оценивание модели

Одним из подходов к оцениванию является минимизация квадратичной формы

$$J(\beta) = g_T(\beta)' \mathbf{W} g_T(\beta)$$

то есть оценка равна

$$b_{GMM} = \arg\min_{\beta \in \mathbb{P}} J(\beta)$$

Данный подход обосновывается тем, что $J(\beta)$ является выборочным аналогом

$$\mathrm{E}\, f(y_t; \beta)' \mathbf{W}\, \mathrm{E}\, f(y_t; \beta)$$

Полученная оценка является состоятельной; в работе [Hansen, 1982] было показано, что если процесс порождения данных стационарен и эргодичен, то выполняется специальная форма закона больших чисел, по которой

$$\sup_{\beta \in \mathbb{P}} |g_T(\beta) - \mathrm{E}\, f(y_t; \beta)| = 0$$

причем $\mathbb{P}$ компактно[8]. Свойство компактности важно для «хорошего» поведения функции «вдали» от β_0.

В качестве $\mathbf{W}$ часто предпочитают брать $\mathbf{V}^{-1}$, так как в этом случае

$$T g_T(\beta)' \mathbf{V}^{-1} g_T(\beta) \xrightarrow{d} \chi^2(r)$$

Оценкой ковариационной матрицы b_{GMM} является [*Generalized Method of Moments Estimation*, 1999, гл. 2]

$$\hat{\Sigma}_{b_{GMM}} = \frac{1}{T}[F_T' V_T^{-1} F_T]^{-1}$$

$$F_T = \frac{1}{T} \sum_{t=1}^{T} \left. \frac{\partial f(y_t; \beta)}{\partial \beta'} \right|_{\beta = b_{GMM}}$$

а $\mathbf{V}_T$ — оценка $\mathbf{V}$.

На практике для оценивания модели используется следующая последовательная процедура:

1. Задайте начальное значение $\mathbf{W}_0$. Удобно для этой цели взять единичную матрицу.

[8] Компактное пространство — топологическое пространство, в любом покрытии которого открытыми множествами найдётся конечное подпокрытие.

2. Минимизируйте $J(\beta; \mathbf{W}_0)$

$$b_1 = \arg\min_{\beta \in \mathbb{P}} g_T(\beta)' \mathbf{W}_0 g_T(\beta)$$

3. Найдите новое значение $\mathbf{W}_1$

$$\mathbf{W}_1 = \left\{ \frac{1}{T} \sum_{t=1}^{T} g_T(b_1) g_T(b_1)' \right\}^{-1}$$

4. Повторяйте шаги 2–3 до достижения сходимости.

2.2. Примеры

2.2.1. Линейная регрессия

Рассмотрим пример линейной регрессии

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t} + \varepsilon_t$$

где выполняются все предпосылки МНК и условия теоремы Гаусса-Маркова.

Из курса эконометрики известно, что для МНК оценок модели[9] выполняется

$$\sum_{t=1}^{T} x_{j,t} e_t = \sum_{t=1}^{T} x_{j,t} \left(y_t - \hat{\beta}_0 - \sum_{i=1}^{k} \beta_i x_{i,t} \right) = 0, \, j = 1, \ldots, k$$

Очевидно, что в качестве моментных функций можно взять

$$x_{j,t} \left(y_t - \hat{\beta}_0 - \sum_{i=1}^{k} \beta_i x_{i,t} \right)$$

2.2.2. Инструментальные переменные

Из теории метода инструментальных переменных известно, что инструменты должны удовлетворять двум свойствам:

1. релевантности, то есть $\mathrm{Cov}(z_t, x_t) \neq 0$,
2. экзогенности, то есть $\mathrm{Cov}(z_t, \varepsilon_t) = 0$.

Выборочный аналог второго свойства принимает вид

$$\sum_{t=1}^{T} z_t (y_t - \beta_0 - \beta_1 x_t) = 0$$

То есть в качестве моментных функций можно взять

$$z_t (y_t - \beta_0 - \beta_1 x_t)$$

[9] В том числе **без** свободного члена.

2.2.3. ARMA(2, 1)

Взято из блога Янга (Аллена) Вонга.

Рассмотрим модель ARMA(2,1)

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \underbrace{\varepsilon_t + \theta_1 \varepsilon_t}_{\nu_t}$$

где $\varepsilon_t \sim WN(0,1)$.

Данная модель дает нам следующие кандидаты в моментные функции:

1. $\mathrm{E}(\nu_t) = 0$;
2. $\mathrm{Var}(\nu_t) = (1 + \theta_1^2)$;
3. $\mathrm{Cov}(\nu_t, \nu_{t-1}) = \theta_1$;
4. $\mathrm{Cov}(\nu_t, \nu_{t-j}) = 0,\ j \geqslant 2$.

Если ограничиться этими условиями, то $f(y_t; \beta)$ можно записать в виде

$$f(y_t; \beta) = \begin{bmatrix} y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2} \\ (y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2})^2 - (1 + \theta_1^2) \\ (y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2})(y_{t-1} - \alpha_1 y_{t-2} - \alpha_2 y_{t-3}) - \theta_1 \\ (y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2})(y_{t-2} - \alpha_1 y_{t-3} - \alpha_2 y_{t-4}) \end{bmatrix}$$

Откуда

$$\mathrm{E}\, f(y_t, \hat{\beta}) = 0$$

Для расчета ковариационной матрицы и для целей процедуры оценивания рассчитаем частные производные $f(y_t; \beta)$:

$$\frac{\partial f}{\partial \theta'} = \begin{bmatrix} \mathscr{E}_1 & \mathscr{E}_2 & \mathscr{E}_3 \end{bmatrix}$$

$$\mathscr{E}_1 = \begin{bmatrix} -y_{t-1} \\ -2y_{t-1}(y_t - \alpha_1 y_{t-1} - \alpha_2 x_{t-2}) \\ -y_{t-1}(y_{t-1} - \alpha_1 y_{t-2} - \alpha_2 y_{t-3}) - y_{t-2}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \\ -y_{t-1}(y_{t-2} - \alpha_1 y_{t-3} - \alpha_2 y_{t-4}) - y_{t-3}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \end{bmatrix}$$

$$\mathscr{E}_2 = \begin{bmatrix} -y_{t-2} \\ -2y_{t-2}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \\ -y_{t-2}(y_{t-1} - \alpha_1 y_{t-2} - \alpha_2 y_{t-3}) - y_{t-3}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \\ -y_{t-2}(y_{t-2} - \alpha_1 y_{t-3} - \alpha_2 y_{t-4}) - y_{t-4}(y_t - \alpha_1 y_{t-1} - \alpha_2 y_{t-2}) \end{bmatrix}$$

$$\mathscr{E}_3 = \begin{bmatrix} 0 \\ -2\theta_1 \\ -1 \\ 0 \end{bmatrix}$$

Список литературы

Box G. E. P. [и др.]. Time Series Analysis: Forecasting and Control. — Hoboken, New Jersey : John Wiley & Sons, Inc, 2016. — 1 с.

Galbraith R. F., *Galbraith J. I.* On the Inverses of Some Patterned Matrices Arising in the Theory of Stationary Time Series // Journal of Applied Probability. — 1974. — Т. 11, № 1. — С. 63—71.

Generalized Method of Moments Estimation. — USA : Cambridge University Press, 06.1999. — 310 с.

Hamilton J. D. Time Series Analysis. — Princeton, N.J : Princeton University Press, 1994. — 799 с.

Hansen L. P. Large Sample Properties of Generalized Method of Moments Estimators // Econometrica. — 1982. — Т. 50, № 4. — С. 1029—1054.

Hansen L. P. Generalized Method of Moments Estimation // The New Palgrave Dictionary of Economics. — Basingstoke, Hampshire : Palgrave Macmillan, 2007.

Hayashi F. Econometrics. — Princeton : Princeton University Press, 2000. — 683 с.

Магнус Я. Р., *Катышев П. К.*, *Пересецкий А. А.* Эконометрика. Начальный курс. Учебник. 9-е издание. — Москва : Издательский дом «Дело» РАНХиГС, 2021.

Хайяши Ф. Эконометрика. — Москва : Дело, 2017. — 725 с.