Контрольные и инструментальные переменные

Контрольные переменные

Наша цель — получить несмещенные оценки интересующего нас коэффициента при постоянстве факторов, на которые мы не можем влиять. В наблюдаемых (не экспериментальных) данных u_i зависит от всех прочих факторов.

- Если мы можем наблюдать эти прочие факторы, то мы включаем эти переменные в регрессию.
- *Очень часто мы не наблюдаем прочие факторы*; например, вовлеченность родителей в образовательный процесс. В этом случае можно включить «контрольные переменные», которые коррелированы с пропущенными факторами, влияющими на зависимую переменную, но сами факторами, влияющими на зависимую переменную, могут не являться.

Контрольная переменная W это переменная, которая коррелирована с пропущенным фактором («контролирует на него») в регрессии Y на X, но сама не обязательно вызывает изменения в Y.

Три характеристики эффективности контрольной переменной:

1. Эффективная контрольная переменная при включении в регрессию делает интересующую нас переменную не коррелированной со случайной ошибкой.
2. В предположении постоянства контрольной(ых) переменной(ых) интересующая нас переменная «как бы» случайно задана.
3. Среди объектов с одинаковыми значениями контрольной(ых) переменной(ых), интересующая нас переменная не коррелирована с пропущенными факторами, влияющими на Y.

Независимость условного среднего

Так как контрольная переменная **коррелирована** со случайной ошибкой u_i, то очевидно, что первая пердпосылка МНК не выполняется, то есть, в общем случае, коэффициент при контрольной переменной *смещен*!

Поэтому при использовании контрольных переменных первую предпосылку МНК меняют на следующее утверждение:

> W_i — *эффективная контрольная переменная*, если выполняется условие независимости условного среднего:

$$\mathrm{E}[u_i \mid X_i, W_i] = \mathrm{E}[u_i \mid W_i]$$

Свойства оценок коэффициентов

Рассмотрим модель

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 W_i + u_i$$

где X_i — интересующая нас переменная, а W_i — эффективная контрольная переменная.

При выполнении условия независимости условного среднего и 2–4 предположений МНК

1. β_1 имеет причинно-следственную интерпретацию,

Доказательство. Ожидаемое изменение Y — результат изменения X при постоянстве W, т.е.

$$\begin{aligned}
&\mathrm{E}[Y \mid X = x + \Delta x, W = w] - \mathrm{E}[Y \mid X = x, W = w] = \\
&= \{\beta_0 + \beta_1(x + \Delta x) + \beta_2 w + \mathrm{E}[u \mid X = x + \Delta x, W = w]\} - \\
&\qquad - \{\beta_0 + \beta_1 x + \beta_2 w + \mathrm{E}[u \mid X = x, W = w]\} = \\
&= \beta_1 \Delta x + \{\mathrm{E}[u \mid X = x + \Delta x, W = w] - \mathrm{E}[u \mid X = x, W = w]\} = \beta_1 \Delta x
\end{aligned}$$

□

2. $\hat{\beta}_1$ не смещена,

3. $\hat{\beta}_2$, в общем случае, смещена.

Доказательство. Пусть (для удобства) $\mathrm{E}[u_i \mid X_i, W_i] = \mathrm{E}[u_i \mid W_i] = \gamma_0 + \gamma_2 W_i$.

Пусть $\nu_i = u_i - \mathrm{E}[u_i \mid X_i, W_i]$. Тогда $\mathrm{E}[\nu_i \mid X_i, W_i] = 0$.

$$u_i = \mathrm{E}[u_i \mid X_i, W_i] + \nu_i = \gamma_0 + \gamma_2 W_i + \nu_i$$

Подставляя это выражение в исходную модель получаем

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 X_i + \beta_2 W_i + \gamma_0 + \gamma_2 W_i + \nu_i = \\ &= (\beta_0 + \gamma_0) + \beta_1 X_i + (\beta_2 + \gamma_2) W_i + \nu_i = \\ &= \delta_0 + \beta_1 X_i + \delta_2 W_i + \nu_i \end{aligned}$$

Так как $\mathrm{E}[\nu_i \mid X_i, W_i] = 0$, то уравнение полученное уравнение удовлетворяет первому условию МНК, следовательно МНК оценки δ_0, β_1 и δ_2 не смещены.

Поскольку регрессоры в исходной и преобразованной модели одинаковы, то *de facto* оценивается именно последняя модель, то есть

$$\mathrm{E}\left[\hat{\beta}_1\right] = \beta_1$$
$$\mathrm{E}\left[\hat{\beta}_2\right] = \delta_2 = \beta_2 + \gamma_2 \neq \beta_2$$

□

Экзогенность и эндогенность

Экзогенная переменная переменная, которая не коррелирует со случайной ошибкой (определяется вне модели).

Эндогенная переменная переменная, которая коррелирует со случайной ошибкой (определяется внутри модели).

Смещение из-за пропущенной переменной

Смещение вследствие пропущенных переменных — это смещение в МНК-оценке, которое появляется, если регрессор X коррелирован с пропущенной переменной. Для того чтобы смещение возникло, должны быть выполнены два условия:

1. Объясняющая переменная X коррелирована с пропущенной переменной,
2. Пропущенная переменная влияет на зависимую переменную Y.

Пример 1. Процент изучающих английский язык коррелирован с соотношением учеников и учителей, влияет на результаты тестов ⇒ Возникает смещение.

Пример 2. Время проведения теста не коррелировано с соотношением учеников и учителей, влияет на результаты тестов ⇒ Смещение не возникает.

Пример 3. Парковочное пространство на одного ученика коррелировано с соотношением учеников и учителей, не влияет на результаты тестов ⇒ Смещение не возникает.

Вспомним, что

$$\hat{\beta}_1 = \beta_1 + \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})u_i}{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Из 2 и 3 предположений МНК и ЗБЧ следует, что

$$\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 \xrightarrow{p} \sigma_x^2$$

$$\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})u_i \xrightarrow{p} \mathrm{Cov}(u_i, x_i) = \rho_{xu}\sigma_u\sigma_x$$

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 + \frac{\rho_{xu}\sigma_u\sigma_x}{\sigma_x^2} = \beta_1 + \underbrace{\rho_{xu}\frac{\sigma_u}{\sigma_x}}_{\substack{\text{величина} \\ \text{смещения}}}$$

где $\rho_{xu} = \mathrm{Corr}(u_i, x_i)$.

- Смещение из-за пропущенных переменных является проблемой, независимо от его величины.
- Величина смещения зависит от величины корреляции.
- Направление смещения зависит от знака корреляции.

Смещение из-за ошибок измерения

Данные ошибки возникают по причине

- ошибок ввода данных,
- ошибок обработки данных,
- «неудобных» вопросов или намеренной лжи.

Ошибки в регрессоре

Введем так называемую *Классическую модель с ошибками измерения*:

$$y_i = \beta_0 + \beta_1 x_i + u_i$$
$$\tilde{x}_i = x_i + \omega_i$$
$$\text{Corr}[\omega_i, x_i] = 0$$
$$\text{Corr}[\omega_i, u_i] = 0$$

Во-первых, если X измерена с ошибкой, то в реальности мы оцениваем следующую модель

$$y_i = \beta_0 + \beta_1 \tilde{x}_i + \underbrace{\beta_i(x_i - \tilde{x}_i) + u_i}_{\nu_i = -\beta_1 \omega_i + u_i}$$

Вспомним, что

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})\nu_i}{\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})^2} = \beta_1 + \frac{\frac{1}{n}\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})\nu_i}{\frac{1}{n}\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})^2}$$

Во-вторых, из свойств оценок следует, что

$$\frac{1}{n}\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})\nu_i \xrightarrow{p} \text{Cov}[\nu, \tilde{x}] = -\beta_1 \sigma_\omega^2$$
$$\frac{1}{n}\sum_{i=1}^n (\tilde{x}_i - \bar{\tilde{x}})^2 \xrightarrow{p} \sigma_{\tilde{x}}^2 = \sigma_x^2 + \sigma_\omega^2$$

Отсюда

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 - \beta_1 \frac{\sigma_\omega^2}{\sigma_x^2 + \sigma_\omega^2}$$

То есть $\hat{\beta}_1$ смещена вниз относительно β_1, разумеется, по абсолютному значению.

Как можно это исправить:

- Найти точную меру x;

- Регрессия с инструментальными переменными. В основе лежит использование другой переменной, которая коррелирована с фактическим значением, но некоррелирована с ошибками измерения.
- Разработка математической модели с ошибками измерения и, если возможно, в использовании полученных формул для коррекции оценок.

Ошибки в регрессанде

Пусть

$$\tilde{y}_i = y_i + \omega_i$$
$$\mathrm{E}[\omega_i] = 0$$
$$(\omega_i, x_i) \sim \text{i.i.d.}$$
$$\mathrm{E}[\omega \mid x_i] = 0$$

Тогда

$$\tilde{y}_i = \beta_0 + \beta_1 x_i + \underbrace{u_i + \omega_i}_{\nu_i}$$

Отсюда имеем

$$\mathrm{E}[\omega_i \mid x_i] = 0 \Rightarrow \mathrm{E}[\nu_i \mid x_i] = \mathrm{E}[u_i \mid x_i] + \mathrm{E}[\omega_i \mid x_i] = 0$$

То есть $\hat{\beta}_1$ — несмещенная оценка. Но

$$\mathrm{Var}[\nu_i] = \mathrm{Var}[u_i] + \mathrm{Var}[\omega_i] > \mathrm{Var}[u_i]$$

То есть $\hat{\beta}_1$ — не эффективная оценка.

Смещение из-за одновременной причинности

Одной из причин возникновения эндогенности является ситуация, когда не только X влияет на Y, но и наоборот. Данная ситуация называется «одновременной причинностью». В этом случае возникает корреляция между регрессором и ошибкой и, соответственно, смещение.

Рассмотрим следующую модель

$$\begin{cases} y_i = \beta_0 + \beta_1 x_i + u_i \\ x_i = \gamma_0 + \gamma_1 y_i + \nu_i \end{cases}$$

$$\text{Cov}[u_i, \nu_i] = 0$$

Отсюда нетрудно получить

$$\begin{aligned} \text{Cov}[x_i, u_i] &= \text{Cov}[\gamma_0 + \gamma_1 y_i + \nu_i, u_i] = \\ &= \text{Cov}[\gamma_1(\beta_0 + \beta_1 x_i + u_i), u_i] = \\ &= \gamma_1 \beta_1 \,\text{Cov}[x_i, u_i] + \gamma_1 \sigma_u^2 \end{aligned}$$

то есть

$$\text{Cov}[x_i, u_i] = \frac{\gamma_1}{1 - \gamma_1 \beta_1} \sigma_u^2$$

Поэтому

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 + \frac{\gamma_1}{1 - \gamma_1 \beta_1} \frac{\sigma_u^2}{\sigma_x^2}$$

Как можно это исправить:

- Регрессия с инструментальными переменными.
- Системы одновременных уравнений.

- Случайный управляемый эксперимент.

Метод инструментальных переменных

Предложен Филиппом Райтом (Wright 1928). Позволяет получить *состоятельные* оценки коэффициентов при наличии корреляции между регрессором и случайной ошибкой.

Парная регрессия с инструментальной переменной

$$y_i = \beta_0 + \beta_1 x_i + u_i, i = 1, ..., n$$
$$\text{Corr}[u_i, x_i] \neq 0$$

$\hat{\beta}_1$ — смещенная и несостоятельная оценка β_1.

Что можно сделать? Райт предложил ввести *инструмент* z_i, позволяющий «изолировать» часть x_i, коррелированную с u_i. Инструментальная переменная z_i называется *подходящей* или *допустимой*, если она удовлетворяет условиям:

1. релевантности, то есть инструмент должен быть коррелирован с эндогенной переменной: $\text{Corr}[x_i, z_i] \neq 0$;
2. экзогенности, то есть инструмент не должен быть коррелирован со случайной ошибкой: $\text{Corr}[u_i, z_i] = 0$.

Двухшаговый МНК

1. Разложим x_i на 2 части: коррелированную и некоррелированную с ошибкой.

$$x_i = \pi_0 + \pi_1 z_i + v_t$$
$$\hat{x}_i = \hat{\pi}_0 + \hat{\pi}_1 z_i$$

Так как $\text{Corr}[u_i, z_i] = 0$, и поскольку $\hat{x}_i$ полностью определяется z_i, имеем $\text{Corr}[u_i, \hat{x}_i] = 0$. Отметим, что

$$\hat{\pi}_1 = \frac{\sum_{i=1}^{N}(z_i - \bar{z})(x_i - \bar{x})}{\sum_{i=1}^{N}(z_i - \bar{z})^2}$$
$$\hat{x}_i = \bar{x} + \hat{\pi}_1(z_i - \bar{z})$$
$$\bar{\hat{x}} = \bar{x}$$

2. Заменим в исходной модели x_i на $\hat{x}_i$

$$y_i = \beta_0 + \beta_1 \hat{x}_i + u_i$$

Так как $\hat{x}_i$ не коррелирует с ошибкой, то для данной регрессии будут выполняться все предпосылки МНК. Имеем

$$\hat{\beta}_1^{\text{TSLS}} = \frac{\sum_{i=1}^{N}(\hat{x}_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{N}(\hat{x}_i - \bar{x})^2} = \frac{\sum_{i=1}^{N}[\hat{\pi}_1(z_i - \bar{z})](y_i - \bar{y})}{\sum_{i=1}^{N}[\hat{\pi}_1(z_i - \bar{z})]^2} =$$
$$= \frac{\sum_{i=1}^{N}(z_i - \bar{z})(y_i - \bar{y})}{\hat{\pi}_1 \sum_{i=1}^{N}(z_i - \bar{z})^2} = \frac{\sum_{i=1}^{N}(z_i - \bar{z})^2 \sum_{i=1}^{N}(z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^{N}(z_i - \bar{z})(x_i - \bar{x}) \sum_{i=1}^{N}(z_i - \bar{z})^2} =$$
$$= \frac{\sum_{i=1}^{N}(z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^{N}(z_i - \bar{z})(x_i - \bar{x})} = \frac{s_{zy}}{s_{zx}}$$

Выборочное распределение оценки

Для случая *парной* регрессии с *одним* допустимым инструментом в больших выборках имеем

$$\hat{\beta}_1^{\text{TSLS}} = \frac{s_{zy}}{s_{zx}} \xrightarrow{p} \frac{\text{Cov}[z_i, y_i]}{\text{Cov}[z_i, x_i]} = \beta_1$$

$$\hat{\beta}_1^{\text{TSLS}} \sim N\left(\beta_1, \sigma^2_{\hat{\beta}_1^{\text{TSLS}}}\right)$$

$$\sigma^2_{\hat{\beta}_1^{\text{TSLS}}} = \frac{1}{n} \frac{\text{Var}[(z_i - \mu_z)u_i]}{[\text{Cov}(z_i, x_i)]^2}$$

то есть мы можем использовать t-статистики и т.д.

Обобщенная IV регрессия

Также как и в случае парной регрессии, мы можем перейти к модели с несколькими регрессорами и инструментальными переменными.

$$y_i = \beta_0 + \beta_1 x_{1i} + \ldots + \beta_{m_x} x_{m_x i} + \beta_{m_x+1} w_{1i} + \ldots + \beta_{m_x+m_w} w_{m_w i} + u_i,\ i = 1, \ldots, n$$

где

- y_i — зависимая переменная,
- $x_{1i}, \ldots, x_{m_x i}$ — эндогенные регрессоры, которые могут коррелировать с u_i,
- $w_{1i}, \ldots, w_{m_w i}$ — экзогенные регрессоры, не коррелированные с u_i,
- u_i — ошибка регрессии,
- $z_{1i}, \ldots, z_{m_z i}$ — инструментальные переменные.

Если

- $m_z = m_x$ — коэффициенты регрессии *точно определены*,
- $m_z > m_x$ — коэффициенты регрессии *переопределены*,
- $m_z < m_x$ — коэффициенты регрессии *недоопределены*.

Мы можем оценивать обобщенную регрессию с инструментальными переменными, только если коэффициенты точно или переопределены, в противном случае мы получим модель с мультиколлинеарностью.

Инструменты z_{ji} для допустимости должны удовлетворять двум требованиям:

1. релевантность — переменные $\hat{x}_{1i}, \ldots, \hat{x}_{m_x i}, w_{1i}, \ldots, w_{m_w i}$ и константа не должны быть совершенно мультиколлинеарными,
2. экзогенность — инструменты не должны быть коррелированы с ошибкой: $\mathrm{Corr}[u_i, z_{ji}] = 0$.

Если $k = 1$, то для релевантности необходимо, чтобы в регрессии первого шага был хотя бы один ненулевой коэффициент.

Двухшаговый МНК

1. «очистка» эндогенных переменных: оцениваем при помощи МНК регрессии **каждого** x_{ji} на константу, все инструменты z_{ji} и все экзогенные переменные

w_{ji}. В результате получаем «очищенные» подобранные значения $\hat{x}_{ji}$.

На практике производится оценивание модели вида

$$\mathbf{X}^* = \mathbf{Z}^*\mathbf{\Pi} + \mathbf{e}$$

где $\mathbf{X}^* = [\mathbf{X}, \mathbf{W}]$ — матрица, включающая в себя эндогенные $\mathbf{X}$ и *экзогенные* переменные $\mathbf{W}$ (в том числе свободный член); $\mathbf{Z}^* = [\mathbf{W}, \mathbf{Z}]$ — матрица, включающая в себя экзогенные (в том числе свободный член) и инструментальные переменные.

Включение экзогенных переменных в матрицу $\mathbf{X}$ не противоречит приведенному выше описанию первого шага, так как при получении МНК-оценок

$$\hat{\mathbf{\Pi}} = (\mathbf{Z}^{*\prime}\mathbf{Z}^*)^{-1}\mathbf{Z}^{*\prime}\mathbf{X}^*$$

в соответствующем столбце матрицы оцененных коэффициентов $\hat{\mathbf{\Pi}}$ будут нули с единственной единицей, соответствующей экзогенной переменной.

Это видно на следующем простейшем примере[1]:

[1] К сожалению, Numpy поддерживает и поощряет неаккуратное отношение к размерностям перемножаемых массивов. В частности, в нашем случае на определенном этапе мы перемножаем двумерную матрицу с одномерным массивом, получая на выходе одномерный массив. Это может помочь вам «выстрелить себе в ногу», будьте внимательны!

```
import numpy as np
np.random.seed(31415926)

# 150 нормально распределенных значений с дисперсией 0.01.
u = np.random.normal(size=150, scale=0.1)

# Матрица 150 x 3, первый столбец состоит из единиц,
# второй и третий столбцы --- N(0, 1).
Z = np.empty((150, 3))
Z[:, 0] = 1.
Z[:, 1:] = np.random.normal(size=(150, 2))

# Матрица 150 x 3.
# Второй и третий столбцы Z и X совпадают.
# Первый столбец равен:
# X = 0.5 + 1. * Z[1] + 2. * Z[2] + u
X = Z.copy()
X[:, 0] = Z @ np.array([0.5, 1, 2]) + u

print(np.round(
    np.linalg.inv(Z.T @ Z) @ Z.T @ X,
    6)
)
```

```
[[ 0.499924 -0.       -0.      ]
 [ 1.000069  1.        0.      ]
 [ 1.988546  0.        1.      ]]
```

Обратите внимание на оцененные коэффициенты, близкие к заданным нами, в первом столбце и нули с единицами во втором и третьем столбцах.

Подобранные значения равны

$$\hat{\mathbf{X}}^* = \mathbf{Z}^*\hat{\mathbf{\Pi}} = \mathbf{Z}^*(\mathbf{Z}^{*\prime}\mathbf{Z}^*)^{-1}\mathbf{Z}^{*\prime}\mathbf{X}^* = \mathbf{P}_Z\mathbf{X}^*$$

Отметим, что матрица $\mathbf{P}_Z$ симметрична и идемпотентна, то есть $\mathbf{P}_Z\mathbf{P}_Z = \mathbf{P}_Z$.

2. При помощи МНК оцениваем

$$y_i = \beta_0 + \beta_1\hat{x}_{1i} + \ldots + \beta_{m_x}\hat{x}_{m_x i} + \beta_{m_x+1}w_{1i} + \ldots + \beta_{k+r}w_{ri} + u_i$$

или

$$\mathbf{Y} = \hat{\mathbf{X}}^*\boldsymbol{\beta} + \mathbf{u}$$

С учетом сказанного выше оценка $\hat{\boldsymbol{\beta}}^{TSLS}$ равна

$$\hat{\boldsymbol{\beta}}^{TSLS} = \left(\hat{\mathbf{X}}^{*\prime}\hat{\mathbf{X}}^*\right)^{-1}\hat{\mathbf{X}}^{*\prime}\mathbf{Y} =$$

$$= (\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{X}^*)^{-1}\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{Y} = *$$

Если модель определена *точно*, то матрицы $\mathbf{X}^{*\prime}\mathbf{Z}^*$ и $\mathbf{Z}^{*\prime}\mathbf{X}^*$ квадратные и, следовательно, потенциально обратимые. В этом случае выражение для $\hat{\boldsymbol{\beta}}^{TSLS}$ можно упростить

$$* = \left[\mathbf{X}^{*\prime}\mathbf{Z}^*(\mathbf{Z}^{*\prime}\mathbf{Z}^*)^{-1}\mathbf{Z}^{*\prime}\mathbf{Z}^*\right]^{-1}\mathbf{X}^{*\prime}\mathbf{Z}^*(\mathbf{Z}^{*\prime}\mathbf{Z}^*)^{-1}\mathbf{Z}^{*\prime}\mathbf{Y} =$$

$$= (\mathbf{Z}^{*\prime}\mathbf{X}^*)^{-1}(\mathbf{Z}^{*\prime}\mathbf{Z}^*)(\mathbf{X}^{*\prime}\mathbf{Z}^*)^{-1}(\mathbf{X}^{*\prime}\mathbf{Z}^*)(\mathbf{Z}^{*\prime}\mathbf{Z}^*)^{-1}\mathbf{Z}^{*\prime}\mathbf{Y} =$$

$$= (\mathbf{Z}^{*\prime}\mathbf{X}^*)^{-1}\mathbf{Z}^{*\prime}\mathbf{Y}$$

Ковариационная матрица $\hat{\boldsymbol{\beta}}^{TSLS}$ примерно равна (Цыплаков 2007)

$$\mathrm{Var}\left[\hat{\boldsymbol{\beta}}^{TSLS}\right] \approx \hat{\sigma}_u^2\left(\hat{\mathbf{X}}^{*\prime}\hat{\mathbf{X}}^*\right)^{-1} = \hat{\sigma}_u^2(\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{X}^*)^{-1}$$

где $\hat{\sigma}_u^2$ — оценка дисперсии $\mathrm{Var}[u_t]$. Для оценивания $\hat{\sigma}_u^2$ нельзя использовать остатки второго шага 2МНК, остатки нужно рассчитывать самостоятельно как $\hat{\mathbf{u}} = \mathbf{y} - \mathbf{X}^*\hat{\boldsymbol{\beta}}^{\mathrm{TSLS}}$.

На больших выборках имеем

$$\hat{\boldsymbol{\beta}}^{\mathrm{TSLS}} = (\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{X}^*)^{-1}\mathbf{X}^{*\prime}\mathbf{P}_Z(\mathbf{X}^*\boldsymbol{\beta} + \mathbf{u}) = \boldsymbol{\beta} + (\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{X}^*)^{-1}\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{u}$$

$$\frac{1}{n}\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{X}^* \xrightarrow[n\to\infty]{p} \boldsymbol{\Sigma}_{\hat{X}}$$

$$\frac{1}{n}\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{u} \xrightarrow[n\to\infty]{p} \boldsymbol{\Sigma}_{\hat{X}u} = \mathbf{0}$$

$$\hat{\boldsymbol{\beta}}^{\mathrm{TSLS}} \xrightarrow[n\to\infty]{p} = \boldsymbol{\beta}$$

Предположения обобщенной регрессии с инструментальными переменными

1. $\mathrm{E}[u_i \mid w_{1i}, \ldots, w_{m_w i}] = 0$;
2. $(x_{1i}, \ldots, x_{m_x i}, w_{1i}, \ldots, w_{m_w i}, z_{1i}, \ldots, z_{m_z i}, y_i) \sim$ i.i.d.;
3. Большие выбросы маловероятны: $x_{ij}, y_i, z_{ij}, w_{ij}$ имеют ненулевые конечные четвертые моменты;
4. **Выполняются условия допустимости инструментов**.

При выполнении этих предположений IV-оценки коэффициентов состоятельны и нормально распределены в больших выборках.

Тестирование

Тестирование гипотез о коэффициентах

Для тестирования гипотез о коэффициентах, в силу того, что оценки имеют асимптотически нормальное распределение, можно использовать статистику Вальда (Цыплаков 2007)

$$W = (\mathbf{R}\boldsymbol{\beta}_{IV} - \mathbf{r})'\left[\mathbf{R}\,\widehat{\mathrm{Var}}[\boldsymbol{\beta}_{IV}]\mathbf{R}'\right]^{-1}(\mathbf{R}\boldsymbol{\beta}_{IV} - \mathbf{r}) \sim \chi^2_r$$

где $\widehat{\mathrm{Var}}\left[\hat{\boldsymbol{\beta}}_{IV}\right] = \hat{\sigma}^2_u(\mathbf{X}^{*\prime}\mathbf{P}_z\mathbf{X}^*)^{-1} = \hat{\sigma}^2_u\left(\hat{\mathbf{X}}^{*\prime}\hat{\mathbf{X}}^*\right)^{-1}$, r — число ограничений.

Если $r = 1$, то удобнее воспользоваться z-статистикой, имеющей асимптотически нормальное распределение. Например, для гипотезы $\beta_j = \beta^*_j$

$$z = \frac{\beta_j - \beta^*_j}{\sqrt{\widehat{\mathrm{Var}}\left[\boldsymbol{\beta}_{IV}\right]_{jj}}} \sim N(0, 1)$$

Тестирование спецификации — тест Дарбина-Ву-Хаусмана

Очевидно, что если в модели нет эндогенных регрессоров, то использование метода инструментальных переменных лишено смысла, так как обычные МНК оценки будут более точными В этом случае, записав регрессии первого шага как

$$\mathbf{x} = \mathbf{z}^*\mathbf{\Pi} + \mathbf{v}$$

где $\mathbf{x}$, $\mathbf{z}^*$, $\mathbf{v}$ — соответствующие друг-другу строки соответствующих матриц. Отсюда следует, что если $\mathbf{x}$ не коррелирует с u, то $\mathrm{E}[\mathbf{v}u] = \mathbf{0}$. Из последнего следует, что в модели

$$u = \mathbf{v}\tau + \zeta$$

$\tau = \mathbf{0}$. Итого имеем

$$y = \mathbf{x}\beta^x + \mathbf{w}\beta^w + \mathbf{v}\tau + \zeta = \mathbf{x}^*\beta + \mathbf{v}\tau + \zeta$$

Таким образом, тестирование спецификации можно провести по следующей процедуре (Цыплаков 2007):

1. Оценим регрессию $\mathbf{X}$ на $\mathbf{Z}^*$ и получаем остатки $\hat{\mathbf{V}} = \mathbf{M}_{\mathbf{Z}^*}\mathbf{X}$;
2. Строим регрессию $\mathbf{y} = \mathbf{X}^*\beta + \hat{\mathbf{V}}\tau + \boldsymbol{\zeta}$ и тестируем при помощи стандартной F-статистики гипотезу $\tau = \mathbf{0}$. Если мы не можем отвергнуть эту гипотезу, то следует использовать обычный МНК.

В изначальном своем виде статистика теста имеет вид (Hausman 1978)

$$H = \left(\hat{\beta}_{IV} - \hat{\beta}_{OLS}\right)' \widehat{\mathrm{Var}}\left(\hat{\beta}_{IV} - \hat{\beta}_{OLS}\right)^{-1}\left(\hat{\beta}_{IV} - \hat{\beta}_{OLS}\right) \sim \chi^2_{m_x}$$

Оценка $\widehat{\mathrm{Var}}\left[\hat{\beta}_{IV} - \hat{\beta}_{OLS}\right]$ имеет вид

$$\widehat{\mathrm{Var}}\left[\hat{\beta}_{IV} - \hat{\beta}_{OLS}\right] = \widehat{\mathrm{Var}}\left[\hat{\beta}_{IV}\right] - \widehat{\mathrm{Var}}\left[\hat{\beta}_{OLS}\right]$$

Оценки ковариационных матриц можно рассчитать по формулам

$$\widehat{\mathrm{Var}}\left[\hat{\boldsymbol{\beta}}_{OLS}\right] = \hat{\sigma}_u^2(\mathbf{X}^{*\prime}\mathbf{X}^{*})^{-1}$$

$$\widehat{\mathrm{Var}}\left[\hat{\boldsymbol{\beta}}_{IV}\right] = \hat{\sigma}_u^2(\mathbf{X}^{*\prime}\mathbf{P}_Z\mathbf{X}^{*})^{-1} = \hat{\sigma}_u^2\left(\hat{\mathbf{X}}^{*\prime}\hat{\mathbf{X}}^{*}\right)^{-1}$$

где $\hat{\sigma}_u^2$ — оценка дисперсии ошибок, рассчитанная либо на основе МНК оценок (что является более предпочтительным способом), либо на основе IV-оценок.

Тестирование слабых инструментов

Слабые инструменты — объясняющие малую часть изменений X. В этом случае 2МНК оценки имеют смещение и не имеют нормального распределения.

Если в модели всего *один* эндогенный регрессор, то для проведения теста на слабость инструментов достаточно провести тестирование гипотезы о равенстве нулю всех коэффициентов при инструментах в регрессии первого шага 2МНК. Если соответствующая F-статистика *меньше* 10, то набор инструментов — слабый (Цыплаков 2007).

Если же эндогенных инструментов *больше* одного, то рассмотрения отдельных регрессий первого шага может оказаться недостаточно. Для этого случая Крэг и Дональд (Cragg и Donald 1993) предложили рассматривать собственные значения следующей матрицы (Цыплаков 2007):

$$\hat{\boldsymbol{\Sigma}}_{ee}^{-1/2}\mathbf{X}^{\prime}(\mathbf{M}_{\mathbf{W}} - \mathbf{M}_{\mathbf{Z}^{*}})\mathbf{X}\hat{\boldsymbol{\Sigma}}_{ee}^{-1/2}/m \qquad (1)$$

где $\hat{\mathbf{\Sigma}}_{ee} = \dfrac{\mathbf{X}'\mathbf{M}_{Z^*}\mathbf{X}}{N - (m_z + m_w)}$ — ковариационная матрица регрессий первого шага 2МНК, не включающих экзогенные регрессоры в качестве объясняемых переменных. В работе Стока и Його (Stock и Yogo 2005) приведена эквивалентная формула

$$\hat{\mathbf{\Sigma}}_{ee}^{-1/2}\mathbf{X}^{\perp\prime}\mathbf{P}_{Z^\perp}\mathbf{X}^{\perp}\hat{\mathbf{\Sigma}}_{ee}^{-1/2}$$

где элементы с индексом $\perp$ являются остатками соответствующих регрессий на $\mathbf{W}$. Тестовой статистикой в этом случае является *минимальное* собственное значение матрицы, критические значения для которой приведены в (Stock и Yogo 2005).

Тестирование сверхидентифицирующих ограничений — тест Саргана

Пусть $\hat{u}_i^{\text{TSLS}}$ — остатки 2МНК регрессии, полученные с использованием $\mathbf{X}^*$,

$$\hat{\mathbf{u}}^{\text{TSLS}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}^{\text{TSLS}}$$

Оценим вспомогательную регрессию

$$\hat{\mathbf{u}}^{\text{TSLS}} = \mathbf{Z}^*\begin{pmatrix}\boldsymbol{\gamma}\\ \boldsymbol{\delta}\end{pmatrix} + \mathbf{e} = \mathbf{W}\boldsymbol{\gamma} + \mathbf{Z}\boldsymbol{\delta} + \mathbf{e}$$

Рассмотрим F-статистику для тестирования ограничения $\boldsymbol{\delta} = \mathbf{0}$.

Тогда

$$J = m_z F \sim \chi^2(m_z - m_x)$$

является статистикой для тестирования сверхидентифицирующих ограничений, $m_z - m_x$ — «степень сверхидентификации» (Картаев 2019).

Другой возможной статистикой является (Verbeek 2017)

$$J = TR^2 \sim \chi^2(m_z - m_x)$$

где R^2 — коэффициент детерминации оцененной выше вспомогательной регрессии.

Если значение той или иной статистики «слишком большое», то это означает, что *некоторые* из использованных инструментов на самом деле *эндогенны*.

Очевидно, что тест можно провести только в случае *переопределенной* модели.

Библиография

[1] P. G. Wright, *The Tariff on Animal and Vegetable Oils*, вып. 26. Macmillan, 1928.

[2] А. Цыплаков, «Экскурс в мир инструментальных переменных», *Квантиль*, т. 2, сс. 21–48, мар. 2007.

[3] J. A. Hausman, «Specification Tests in Econometrics», *Econometrica*, т. 46, вып. 6, сс. 1251–1271, 1978, doi: 10.2307/1913827.

[4] J. G. Cragg и S. G. Donald, «Testing Identifiability and Specification in Instrumental Variable Models», *Econometric Theory*, т. 9, вып. 2, сс. 222–240, апр. 1993, doi: 10.1017/S0266466600007519.

[5] J. H. Stock и M. Yogo, «Testing for weak instruments in Linear Iv regression», в *Identification and Inference for Econometric Models: Essays in Honor of Thomas Rothenberg*, D. W. K. Andrews, Ред., Cambridge University Press, 2005, сс. 80–108. doi: 10.1017/CBO9780511614491.006.

[6] Ф. С. Картаев, *Введение в эконометрику*. Москва: Экономический факультет МГУ имени М. В. Ломоносова, 2019.

[7] M. Verbeek, *A Guide to Modern Econometrics*, Fifth edition. Hoboken, NJ: Wiley, 2017.