Парная линейная регрессия

После тестирования гипотез о равенстве средних нас может заинтересовать вопрос: как изменится одна из переменных при изменении какой-либо другой? Очевидным будет получение оценки следующего параметра

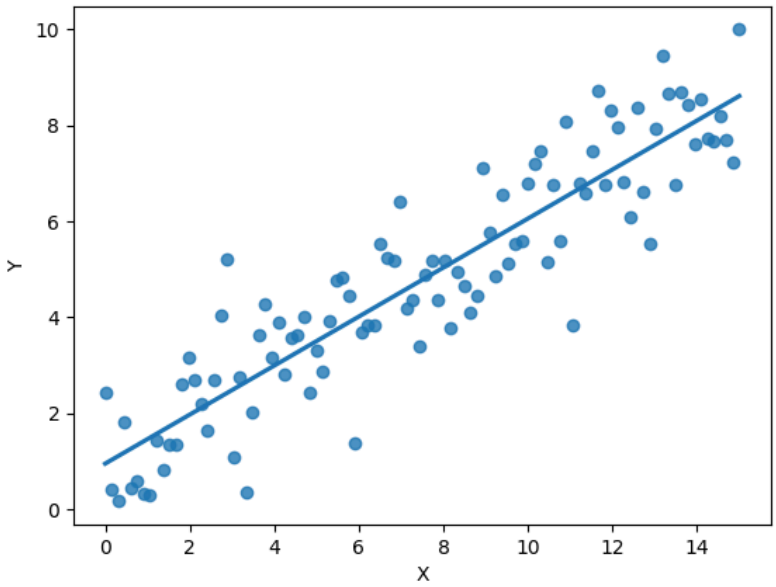
$$\beta_1 = \frac{\Delta Y}{\Delta X}$$

Нетрудно увидеть, что данный параметр является частью уравнения прямой

$$Y = \beta_0 + \beta_1 X$$

где $\beta_0 = Y_0 - \beta_1 X_0$.

Этими несложными рассуждениями мы практически ввели то, что мы будем называть моделью **парной линейной регрессии**. Для окончательного определения модели нам надо посмотреть на то, как данные выглядят в реальной жизни.



На графике представлены сгенерированные, но вполне возможные в реальности данные и линия, «наилучшим» способом их описывающая. Как можно увидеть, реальные данные не лежат идеально на построенной линии. Тем самым можно предположить, что в данных, помимо связи между переменными, есть еще что-то. Так как отклонения не несут систематического характера, то мы можем рассматривать их как **случайное возмущение**.

Таким образом, для каждого конкретного наблюдения уравнение прямой примет вид

$$Y_i = \beta_0 + \beta_1 X_i + u_i \tag{1}$$

где

Y_i объясняемая переменная. Иногда, очень редко, ее называют *регрессанд*.

X_i объясняющая переменная. Очень часто ее называют *регрессор*.

u_i случайное возмущение, называемое обычно *случайной ошибкой*.

Само уравнение называется **моделью парной линейной регрессии** или **моделью наблюдений**.

Приведенное выше уравнение

$$Y = \beta_0 + \beta_1 X$$

называется **линией теоретической регрессии** или **моделью связи**.

Оценивание коэффициентов модели

Как же нам оценить параметры модели?

Рассмотрим модель связи. В **идеале** все точки из нашей выборки должны удовлетворять этой модели, то есть должно выполняться

$$Y_i = \beta_0 + \beta_1 X_i, \quad \forall i$$

Тем самым мы получаем систему n уравнений с **двумя** неизвестными. В общем случае такая система не имеет точного решения, однако возможно найти решение *приблизительное*.

Для этого посмотрим на невязку, равную $Y_i - \beta_0 - \beta_1 X_i, \quad \forall i$. Попробуем подобрать значения параметров β_0 и β_1 так, чтобы некое агрегированное значение этих невязок было минимальным. На практике часто используют сумму квадратов, получая следующую задачу

$$\hat{\beta}_0, \hat{\beta}_1 = \arg\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^{n} \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i\right)^2 =: \arg\min_{\hat{\beta}_0, \hat{\beta}_1} Q$$

Данная задача решается элементарно: достаточно взять частные производные по неизвестным параметрам, приравнять их нулю и решить полученную систему

$$\frac{\partial Q}{\partial \hat{\beta}_0} = -2 \sum_{i=1}^{n} \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i\right) \quad = 0$$

Парная линейная регрессия

$$\frac{\partial Q}{\partial \hat{\beta}_1} = -2\sum_{i=1}^{n} X_i\left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i\right) = 0$$

Нетрудно получить, что

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(Y_i - \bar{Y})(X_i - \bar{X})}{\sum_{i=1}^{n}(X_i - \bar{X})^2} = \frac{s_{YX}}{s_X^2} = \beta_1 + \frac{\sum_{i=1}^{n}(X_i - \bar{X})u_i}{\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

После оценивания модели получим **линию выборочной регрессии**

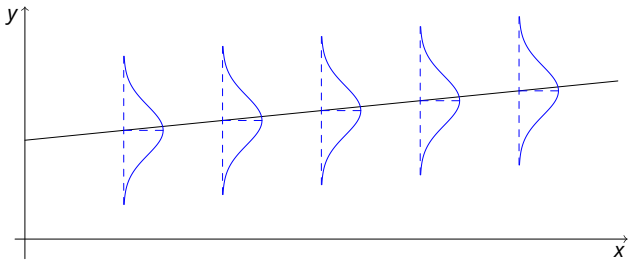
$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{u}_i$$

где $\hat{u}_i$ — **остаток** регрессии.

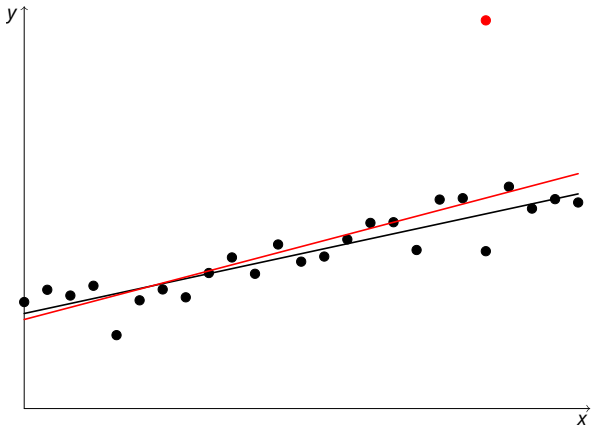
Предпосылки МНК

Полученные выше оценки являются <> при выполнении следующих предпосылок.

0. Мы **действительно** имеем дело с линейной моделью!
1. $\mathrm{E}(u_i \mid X_i) = 0$. Данная предпосылка говорит о том, что наблюдения могут отклоняться от линии регрессии в моменте, но в среднем эти отклонения должны быть нулевыми.



2. $(Y_i, X_i) \sim \mathrm{iid}$. Данная предпосылка означает, что выборка должны быть случайной и независимой.
3. Y_i и X_i должны иметь конечные четвертые моменты. Иначе это формулируется как отсутствие сильных выбросов.



При выполнении этих предпосылок,

1. $\sqrt{n}\left(\hat{\beta}_1 - \beta_1\right) \underset{\text{asy}}{\sim} N\left(0, \sigma^2_{\hat{\beta}_1}\right)$ где

$$\sigma^2_{\hat{\beta}_1} = \frac{1}{n}\frac{\text{Var}[(X_i - \text{E}(X))u_i]}{[\text{Var}(X_i)]^2}$$

2. $\sqrt{n}\left(\hat{\beta}_0 - \beta_0\right) \underset{\text{asy}}{\sim} N\left(0, \sigma^2_{\hat{\beta}_0}\right)$ где

$$\sigma^2_{\hat{\beta}_0} = \frac{1}{n}\frac{\text{Var}(H_i u_i)}{\left(\text{E}[H_i^2]\right)^2}$$

$$H_i = 1 - \frac{\text{E}(X)}{\text{E}\left(X_i^2\right)}X_i$$

Свойства МНК-оценок

1. $\sum_{i=1}^{n} \hat{u}_i = 0$ Данное свойство следует из условия первого порядка для $\frac{\partial Q}{\partial \hat{\beta}_0}$. Иначе его справедливость можно показать следующим образом:

$$\begin{aligned}\sum_{i=1}^{n} \hat{u}_i &= \sum_{i=1}^{n}\left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i\right) = \\ &= n\bar{Y} - n\hat{\beta}_0 - n\hat{\beta}_1\bar{X} = \\ &= n\left[\bar{Y} - \left(\bar{Y} - \hat{\beta}_1\bar{X}\right) - \hat{\beta}_1\bar{X}\right] = 0\end{aligned}$$

2. $\sum_{i=1}^{n} \hat{u}_i X_i = 0$. Отсюда, а также из первого свойства, следует, что $s_{\hat{u}X} = 0$. Само это свойство является вторым условием первого порядка для $\frac{\partial Q}{\partial \hat{\beta}_1}$.

3. $\frac{1}{n} \sum_{i=1}^{n} \hat{Y} = \bar{Y}$.

$$\frac{1}{n} \sum_{i=1}^{n} \hat{Y} = \frac{1}{n} \sum_{i=1}^{n} \left(\hat{\beta}_0 + \hat{\beta}_1 X_i \right) =$$
$$= \hat{\beta}_0 + \hat{\beta}_1 \bar{X} =$$
$$= \bar{Y} - \hat{\beta}_1 \bar{X} + \hat{\beta}_1 \bar{X} = \bar{Y}$$

4. $\left(\bar{Y}, \bar{X} \right) \in \hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$.

5. $TSS = ESS + RSS$, где

   - $TSS = \sum_{i=1}^{n} \left(Y_i - \bar{Y} \right)^2$ — полная сумма квадратов (total sum of squares);
   - $ESS = \sum_{i=1}^{n} \left(\hat{Y}_i - \bar{Y} \right)^2$ — объясненная сумма квадратов (explained sum of squares);
   - $RSS = \sum_{i=1}^{n} \left(Y_i - \hat{Y}_i \right)^2 = \sum_{i=1}^{n} \hat{u}_i^2$ — остаточная сумма квадратов или кумма квадратов остатков (residual sum of squares).

$$TSS = \sum_{i=1}^{n} \left(Y_i - \bar{Y} \right)^2 = \sum_{i=1}^{n} \left[\left(Y_i - \hat{Y} \right) + \left(\hat{Y} - \bar{Y} \right) \right]^2 =$$
$$= \underbrace{\sum_{i=1}^{n} \left(Y_i - \hat{Y} \right)^2}_{RSS} + \underbrace{\sum_{i=1}^{n} \left(\hat{Y} - \bar{Y} \right)^2}_{ESS} + 2 \sum_{i=1}^{n} \left(Y_i - \hat{Y} \right) \left(\hat{Y} - \bar{Y} \right) = *$$

$$\hat{Y}_i - \bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_i - \bar{Y} =$$
$$= \bar{Y} - \hat{\beta}_1 \bar{X} + \hat{\beta}_1 X_i - \bar{Y} =$$
$$= \hat{\beta}_1 \left(X_i - \bar{X} \right)$$

$$* = RSS + ESS + 2\hat{\beta}_1 \sum_{i=1}^{n} \hat{u}_i (X_i - \bar{X}) =$$

$$= RSS + ESS + 2\hat{\beta}_1 \Big(\underbrace{\sum_{i=1}^{n} \hat{u}_i X_i}_{=0} - \bar{X} \underbrace{\sum_{i=1}^{n} \hat{u}_i}_{=0} \Big) =$$

$$= RSS + ESS$$

Графическая интерпретация

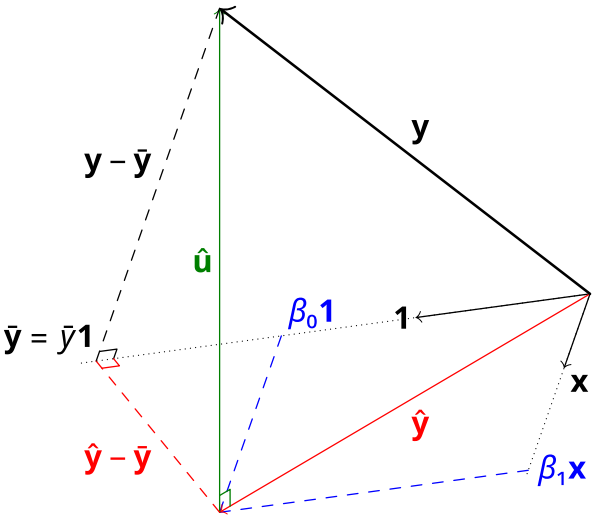
Представим (1) в следующем виде

$$\underbrace{\begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix}}_{\mathbf{y}} = \beta_0 \underbrace{\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}}_{\mathbf{1}} + \beta_1 \underbrace{\begin{pmatrix} x_1 \\ \vdots \\ x_N \end{pmatrix}}_{\mathbf{x}} + \underbrace{\begin{pmatrix} u_1 \\ \vdots \\ u_N \end{pmatrix}}_{\mathbf{u}}$$

то есть в виде линейной комбинации векторов. Аналогично

$$\hat{\mathbf{y}} = \hat{\beta}_0 \mathbf{1} + \hat{\beta}_1 \mathbf{x}$$

Так как в задаче поиска МНК оценок мы минимизируем суммарное квадратичное отклонение $y_i - \hat{y}_i$, равное квадрату длины вектора $\mathbf{y} - \hat{\mathbf{y}}$, причем вектор $\hat{\mathbf{y}}$ лежит в плоскости, определяемой векторами $\mathbf{1}$ и $\mathbf{x}$, то можно увидеть, что задача эквивалентна задаче поиска ортогональной проекции $\mathbf{y}$ на данную плоскость. При этом $\hat{\mathbf{y}}$ — проекция $\mathbf{y}$, $\hat{\mathbf{u}} = \mathbf{y} - \hat{\mathbf{y}}$. Нетрудно показать, что $\bar{y}$ является длиной проекции векторов $\mathbf{y}$ и $\hat{\mathbf{y}}$ на $\mathbf{1}$.



Отобразив все приведенные выше факты на графике, мы получим то, что $TSS = ESS + RSS$ является теоремой Пифагора.

Критерии качества оценивания

Для сравнения качества приближения реальных данных моделью введем два показателя: коэффициент детерминации R^2 и стандартную ошибку регрессии SER.

Коэффициент детерминации — доля выборочной дисперсии Y, которая объясняется оцененной моделью.

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

Несложно показать, что

- $0 \le R^2 \le 1$;
- $R^2 = \hat{\beta}_1^2 \frac{s_X^2}{s_Y^2} = \frac{s_{YX}^2}{s_X^2 s_Y^2} = r_{YX}^2$;
- $R^2 = 0 \Leftrightarrow \hat{\beta}_1 = 0$.

Стандартная ошибка регрессии — оценка стандартного отклонения случайных ошибок регрессии u_i.

$$SER = s_{\hat{u}_i} = \sqrt{\frac{1}{n-2}\sum_{i=1}^{n}\hat{u}_i^2}$$

Тестирование гипотез

После оценивания модели и проверки того, что получаемые оценки **BLUE**, нам бы хотелось бы протестировать некоторые гипотезы относительно **истинных** значений параметров генеральной совокупности.

Допустим, мы хотим проверить утверждение, что истинное значение β_1 равно некоторому значению $\beta_{1,0}$; то есть протестировать нулевую гипотезу

$$H_0 : \beta_1 = \beta_{1,0}$$

против

- двухсторонней альтернативы $H_a : \beta_1 \neq \beta_{1,0}$ или
- левосторонней альтернативы $H_a : \beta_1 < \beta_{1,0}$ или
- правосторонней альтернативы $H_a : \beta_1 > \beta_{1,0}$.

Тестирование данной гипотезы проводится при помощи t-теста, о котором вы можете почитать в ликбезе про тестирование гипотез. Для проведения теста нам нужно получить оценки стандартных ошибок оценок коэффициентов. Их можно получить при помощи следующих формул:

$$\widehat{Var}\left(\hat{\beta}_1 \mid X_1, \ldots\right) = \underbrace{\frac{s_u^2}{\sum_{i=1}^n \left(X_i - \bar{X}\right)^2}}_{\sigma_u^2 = \text{ const}} = \underbrace{\frac{1}{n} \times \frac{\frac{1}{n-2}\sum_{i=1}^n \left(X_i - \bar{X}\right)^2 \hat{u}_i^2}{\left[\frac{1}{n}\sum_{i=1}^n \left(X_i - \bar{X}\right)^2\right]^2}}_{\sigma_u^2 \neq \text{ const}}$$

Доказательство.

$$\hat{\beta}_1 - \beta_1 = \sum_i \hat{a}_i u_i$$

$$\text{Var}\left[\hat{\beta}_1 \mid X_1, \ldots\right] = \text{E}\left[\left(\hat{\beta}_1 - \beta_1\right)^2 \mid X_1, \ldots\right] = E\left[\sum_i \hat{a}_i u_i\right] =$$

$$= \sigma_u^2 \sum_i \hat{a}_i^2 = \sigma_u^2 \sum \frac{\left(X_i - \bar{X}\right)^2}{\sum \left(X_i - \bar{X}\right)^2} = \frac{\sigma_u^2}{\sum \left(X_i - \bar{X}\right)^2}$$

□

$$\widehat{Var}\left(\hat{\beta}_0 \mid X_1, \ldots\right) = \underbrace{\frac{\left(\frac{1}{n}\sum_{i=1}^n X_i^2\right) s_u^2}{\sum_{i=1}^n \left(X_i - \bar{X}\right)^2}}_{\sigma_u^2 = \text{ const}} = \underbrace{\frac{1}{n} \times \frac{\frac{1}{n-2}\sum_{i=1}^n \hat{H}_i^2 \hat{u}_i^2}{\left[\frac{1}{n}\sum_{i=1}^n \hat{H}_i^2\right]^2}}_{\sigma_u^2 \neq \text{ const}}$$

$$\hat{H}_i = 1 - \frac{\bar{X}}{\frac{1}{n}\sum_{i=1}^{n} X_i^2} X_i$$

Доказательство.

$$\begin{aligned}
\operatorname{Var}\left[\hat{\beta}_0 \mid X_1, \ldots\right] &= \operatorname{Var}\left[\bar{Y} - \hat{\beta}_1 \bar{X} \mid X_1, \ldots\right] = \\
&= \operatorname{Var}_x \bar{Y} + \bar{X} \operatorname{Var}_x \hat{\beta}_1 + 2 \operatorname{Cov}_x\left(\bar{Y}, \bar{\beta}_1\right) = * \\
\operatorname{Var}_x \bar{Y} &= \operatorname{Var}_x\left[\frac{1}{n}\sum(\beta_0 + \beta_1 X_i + u_i)\right] = \frac{1}{n^2}\operatorname{Var}_x\left(\sum u_i\right) = \frac{1}{n}\sigma_u^2 \\
\operatorname{Cov}_x\left(\bar{Y}, \bar{\beta}_1\right) &= \frac{1}{n}\operatorname{Cov}_x\left[\sum Y_i, \sum \hat{a}_i Y_i\right] = \\
&= \frac{1}{n}\sum\sum \hat{a}_i \underbrace{\operatorname{Cov}_x\left[Y_i, Y_j\right]}_{=0,\, i \neq j} = \sigma_Y^2 \sum \hat{a}_i = 0 \\
* &= \sigma_u^2\left[\frac{1}{n} + \frac{\bar{X}}{\sum\left(X_i - \bar{X}\right)^2}\right] = \sigma_u^2 \frac{\sum\left(X_i - \bar{X}\right)^2 + n\bar{X}}{n\sum\left(X_i - \bar{X}\right)^2} = \\
&= \sigma_u^2 \frac{\sum X_i^2}{n\sum\left(X_i - \bar{X}\right)^2}
\end{aligned}$$

□

Доверительный интервал для ΔY

В соответствии с интерпретацией коэффициента наклона регрессии, при изменении X на ΔX Y изменяется на $\beta_1 \Delta X$. Доверительный интервал для изменения ΔY равен

$$\left[\left(\hat{\beta}_1 - \operatorname{SE}\hat{\beta}_1 \times t^{\text{crit}}\right)\Delta X; \left(\hat{\beta}_1 + \operatorname{SE}\hat{\beta}_1 \times t^{\text{crit}}\right)\Delta X\right]$$

Специальные виды регрессий

Рассмотрим некоторые виды моделей, имеющих особенности в оценивании и интерпретации

Регрессия без свободного члена

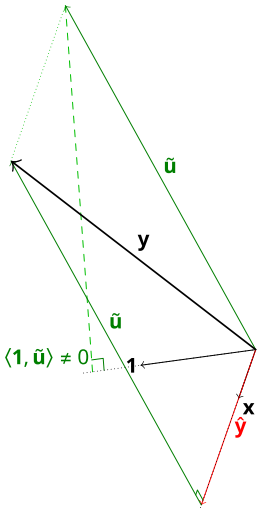
Если в регрессии нет свободного члена, то есть она имеет вид

$$Y_i = \beta_1 X_i + u_i$$

то:

- $\hat{\beta}_1 \neq \frac{s_{YX}}{s_X^2}$;
- $\sum_{i=1}^{n} \hat{u}_i \neq 0$;
- $(\bar{Y}, \bar{X}) \notin \hat{Y} = \hat{\beta}_1 X$;
- $TSS \neq ESS + RSS$, то есть R^2 не работает! В этом случае используем нецентрированный R^2

$$R_u^2 = 1 - \frac{RSS}{\sum_{i=1}^{n} Y_i^2}$$



Регрессия с бинарной объясняющей переменной

Рассмотрим вопрос интерпретации коэффициента при бинарной переменной, то есть принимающей два значения: 0 и 1. Для этого предположим, что в нашей выборке размера n переменная $X_i \in \{0, 1\}$, причем число единиц равно n_1.

Рассмотрим модель следующего вида

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

Нетрудно увидеть, что $\sum_{i=1}^{n} X_i = n_1$, и $\bar{X} = \frac{n_1}{n}$. Также очевидно, что $\sum_{i=1}^{n} X_i^2 = n_1$. Тогда

$$\sum_{i=1}^{n} (X_i - \bar{X})^2 = \sum_{i=1}^{n} X_i^2 - n\bar{X} =$$

$$= n_1 - n\frac{n_1^2}{n^2} = \frac{n_1(n - n_1)}{n} = \frac{n_0 n_1}{n}$$

$$\sum_{i=1}^{n} (X_i - \bar{X})^2 = \sum_{i=1}^{n} X_i^2 - n\bar{X} =$$

$$= n_1 - n\frac{n_1^2}{n^2} = \frac{n_1(n-n_1)}{n} = \frac{n_0 n_1}{n}$$

$$\sum_{i=1}^{n}(X - \bar{X})(Y_i - \bar{Y}) = \sum_{i=1}^{n} X_i(Y_i - \bar{Y}) =$$

$$= \sum_{i=1}^{n} X_i Y_i - \bar{Y}\sum_{i=1}^{n} X_i = \sum_{i=1}^{n} X_i Y_i - n_1\bar{Y} =$$

$$= n_1\bar{Y}_1 - n_1\bar{Y}$$

где $\bar{Y}_1$ — выборочное среднее Y_i, соответствующих $X_i = 1$.

Тогда имеем

$$\hat{\beta}_1 = \frac{n_1(\bar{Y}_1 - \bar{Y})}{n_0 n_1/n} = \frac{n}{n_0}(\bar{Y}_1 - \bar{Y}) =$$

$$= \frac{n}{n_0}\left(\bar{Y}_1 \underbrace{- \frac{n_1}{n}\bar{Y}_1 - \frac{n_0}{n}\bar{Y}_0}_{\bar{Y} = \frac{1}{n}\left(\sum_{X_i=1} Y_i + \sum_{X_i=0} Y_i\right)}\right) = \bar{Y}_1 - \bar{Y}_0$$

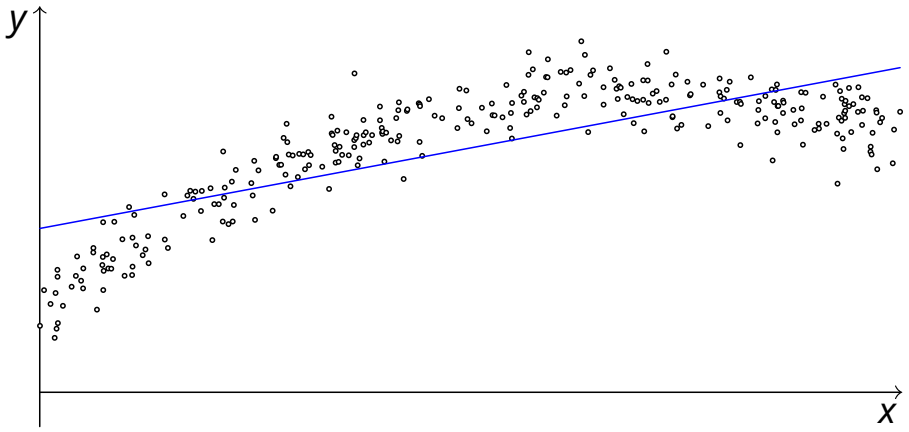
$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1\bar{X} = \bar{Y} - (\bar{Y}_1 - \bar{Y}_0)\frac{n_1}{n} =$$

$$= \frac{n_1}{n}\bar{Y}_1 + \frac{n_0}{n}\bar{Y}_0 - \frac{n_1}{n}\bar{Y}_1 + \frac{n_1}{n}\bar{Y}_0 = \bar{Y}_0$$

То есть в такой модели оценка свободного члена равна выборочному среднему Y_i для $X_i = 0$; это значение можно интерпретировать как «базовый» случай. Оценка коэффициента при X_i равна разнице выборочных средних Y_i для «небазового» и «базового» уровней.

Регрессии с логарифмированными переменными

Часто приходится иметь дело со следующей картиной.



Понятно, что «нулевая» предпосылка МНК о линейности модели здесь не работает. Часто спасти ситуацию помогает логарифмирование регрессора и/или регрессанда, приводящее нас в изменной выборке, на которой предположение о линейной связи выполняется.

Вспомним, что для малых x выполняется примерное равенство

$$\ln(1+x) \approx x \Rightarrow \ln\left(\frac{x+\Delta x}{x}\right) \approx \frac{\Delta x}{x}$$

С учетом этого меняются интерпретации коэффициентов регрессии:

- Линейно-логарифмическая модель

  $$Y_i = \beta_0 + \beta_1 \ln X_i + u_i$$

  1%-ное изменение X приводит к изменению Y на $0.01\beta_1$.

- Логарифмически-линейная модель

  $$\ln Y_i = \beta_0 + \beta_1 X_i + u_i$$

  Единичное изменение X (то есть $\Delta X = 1$) приводит к изменению Y на $100\beta_1\%$.

  Важно отметить, что в данном случае нужно быть осторожным с интерпретацией коэффициентов, больших, чем 0.1. Действительно

β_1	$\exp\{\beta_1\}$
0.01	1.01005

β_1	$\exp\{\beta_1\}$
0.02	1.02020
0.03	1.03046
0.05	1.05127
0.09	1.09417
0.1	1.10520
0.2	1.22140
0.3	1.35000
0.5	1.65000

- Модель, линейная в логарифмах

$$\ln Y_i = \beta_0 + \beta_1 \ln X_i + u_i$$

1%-ное изменение X приводит к изменению Y на β_1%.