Множественная линейная регрессия

Смещение из-за пропущенной переменной

Это пример нарушения **первого** условия Гаусса-Маркова: $\mathrm{E}[u_i \mid X_1, \ldots, X_n] = 0$.

Так как u_i включает в себя переменные, **не включенные** в модель, то если в u_i входит Z такая, что $\mathrm{Cov}[X, Z] \neq 0$, то

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 + \rho_{Xu}\frac{\sigma_u}{\sigma_X}$$

где $\rho_{Xu} = \mathrm{Corr}[u_i, X_i]$.

Доказательство. Справедливость данной формулы можно показать при помощи следующих рассуждений. Ранее мы показали, что

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^{N}(X_i - \bar{X})u_i \frac{1}{N-1}}{\sum_{i=1}^{N}(X_i - \bar{X})^2 \frac{1}{N-1}}$$

Разделив числитель и знаменатель на $N - 1$ и устремив $N \to \infty$, мы получим, что

- $\frac{1}{N-1}\sum_{i=1}^{N}(X_i - \bar{X})u_i \xrightarrow{p} \mathrm{Cov}[X, u]$,
- $\frac{1}{N-1}\sum_{i=1}^{N}(X_i - \bar{X})^2 \xrightarrow{p} \mathrm{Var}[X]$,

то есть

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 + \frac{\mathrm{Cov}[X, u]}{\mathrm{Var}[X]} = \beta_1 + \frac{\sigma_{Xu}}{\sigma_X^2}\frac{\sigma_u}{\sigma_u} = \beta_1 + \rho_{Xu}\frac{\sigma_u}{\sigma_X}$$

□

Модель множественной регрессии

Модель множественной регрессии имеет следующий вид

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \ldots + \beta_k X_{ki} + u_i$$

где все обозначения аналогичны таковым для парной регрессии.

Оценивание МНК

Решается следующая задача:

$$\min_{\hat{\beta}_0,\hat{\beta}_1,\dots,\hat{\beta}_k} \sum_{i=1}^{n} \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \dots - \hat{\beta}_k X_{ki}\right)^2$$

Принцип решения не изменяется:

- Находим частные производные целевой функции по переменным минимизации;
- Приравниваем полученные частные производные 0 и решаем получившуюся систему уравнений.

Не составляет труда понять, что работа с моделями множественой регрессии в терминах сумм становится, мягко говоря, неудобной уже при двух-трех объясняющих переменных.

Пример 1. Если рассмотреть модель с двумя регрессорами

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$$

и попытаться ее честно решить руками по аналогии с парной регрессией, то мы упремся в систему уравнений

$$\begin{cases} \sum_{i=1}^{N}\left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \hat{\beta}_2 X_{2i}\right) = 0 \\ \sum_{i=1}^{N}\left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \hat{\beta}_2 X_{2i}\right) X_{1i} = 0 \\ \sum_{i=1}^{N}\left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \hat{\beta}_2 X_{2i}\right) X_{2i} = 0 \end{cases}$$

которая, подстановкой $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \hat{\beta}_2 \bar{X}_2$ приводится к виду

$$\begin{cases} \sum_{i=1}^{N}(Y_i - \bar{Y})(X_{1i} - \bar{X}_1) - \hat{\beta}_1 \sum_{i=1}^{N}(X_{1i} - \bar{X}_1)^2 - \hat{\beta}_2 \sum_{i=1}^{N}(X_{1i} - \bar{X}_1)(X_{2i} - \bar{X}_2) = 0 \\ \sum_{i=1}^{N}(Y_i - \bar{Y})(X_{2i} - \bar{X}_2) - \hat{\beta}_1 \sum_{i=1}^{N}(X_{1i} - \bar{X}_1)(X_{2i} - \bar{X}_2) - \hat{\beta}_2 \sum_{i=1}^{N}(X_{2i} - \bar{X}_2)^2 = 0 \end{cases}$$

Откуда относительно «легко» можно получить ответ

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{N}(Y_i - \bar{Y})(X_{1i} - \bar{X}_1)\sum_{i=1}^{N}(X_{2i} - \bar{X}_2)^2 - \sum_{i=1}^{N}(Y_i - \bar{Y})(X_{2i} - \bar{X}_2)\sum_{i=1}^{N}(X_{1i} - \bar{X}_1)(X_{2i} - \bar{X}_2)}{\sum_{i=1}^{N}(X_{1i} - \bar{X}_1)^2 \sum_{i=1}^{N}(X_{2i} - \bar{X}_2)^2 - \left[\sum_{i=1}^{N}(X_{1i} - \bar{X}_1)(X_{2i} - \bar{X}_2)\right]^2}$$

$$\hat{\beta}_2 = \frac{\sum_{i=1}^{N}(Y_i - \bar{Y})(X_{2i} - \bar{X}_2)\sum_{i=1}^{N}(X_{1i} - \bar{X}_1)^2 - \sum_{i=1}^{N}(Y_i - \bar{Y})(X_{1i} - \bar{X}_1)\sum_{i=1}^{N}(X_{1i} - \bar{X}_1)(X_{2i} - \bar{X}_2)}{\sum_{i=1}^{N}(X_{1i} - \bar{X}_1)^2 \sum_{i=1}^{N}(X_{2i} - \bar{X}_2)^2 - \left[\sum_{i=1}^{N}(X_{1i} - \bar{X}_1)(X_{2i} - \bar{X}_2)\right]^2}$$

Поэтому общепринятой является матрично-векторное представление модели

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$$

где

$$\mathbf{Y} = (Y_1, Y_2, \ldots, Y_n)'$$

$$\mathbf{X}_{n\times(k+1)} = \begin{pmatrix} 1 & X_{1,1} & X_{2,1} & \ldots & X_{k,1} \\ 1 & X_{1,2} & X_{2,2} & \ldots & X_{k,2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1,n} & X_{2,n} & \ldots & X_{k,n} \end{pmatrix}$$

$$\boldsymbol{\beta} = (\beta_0, \beta_1, \ldots, \beta_k)'$$

$$\mathbf{u} = (u_1, u_2 \ldots, u_n)'$$

Первый столбец матрицы **X**, состоящий из единиц, отвечает за свободный член. Разумеется, в зависимости от задачи, его может и не быть. Однако рекомендуем его оставлять в модели по той же самой причине, что и в парной регрессии: наличие свободного члена в модели способствует работе большого количества формул, таких как R^2.

МНК-оценки получаются решением следующей задачи:

$$\min_{\boldsymbol{\beta}} \left(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}\right)'\left(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}\right)$$

Дифференцируя по **β**, получим

$$\begin{aligned} \mathrm{d}\mathbf{Q} &= \mathrm{d}\left[(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\right](\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) + (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\,\mathrm{d}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \\ &= [\mathrm{d}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})]'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) + (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\,\mathrm{d}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \\ &= (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\,\mathrm{d}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) + (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\,\mathrm{d}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \\ &= -2(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\mathbf{X}\,\mathrm{d}\boldsymbol{\beta} \end{aligned}$$

При выводе мы воспользовались тем, что **Q** — скаляр, а, значит, скалярами являются оба слагаемых в первом равенстве. А для скаляра, очевидно, справедливо $x' = x$.

То есть в точке оптимума

$$\nabla \mathbf{Q} \propto (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'\mathbf{X} = \mathbf{0}$$

откуда элементарными преобразованиями получаем

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

Предположения МНК в модели множественной регрессии

1. $\mathrm{E}[u_i \mid X_{1i}, \ldots, X_{ki}] = 0$.
2. $(X_{1i}, \ldots, X_{ki}, Y_i) \sim \mathrm{iid}$.
3. $(X_{1i}, \ldots, X_{ki}, Y_i)$ имеют конечные четвертые моменты — большие выбросы маловероятны.
4. **Отсутствует совершенная мультиколлинеарность**.

Совершенная мультиколлинеарность наличие **точной** линейной связи между двумя и более переменными. Приводит к невозможности получений МНК оценок:

- математически: из-за необратимости матрицы $\mathbf{X}'\mathbf{X}$,
- идеологически: абсолютная неопределенность распределения влияния между связанными переменными.

Несовершенная мультиколлинеарность наличие сильной корреляции между одной или несколькими переменными. Делает оценки коэффициентов при затронутых переменных:

- несмещенными,
- состоятельными,
- но **не эффективными** — завышение оценок стандартных ошибок.

Последнее приводит к эффекту, когда оценки при затронутых коэффициентах незначимы по отдельности, но **значимы** в совокупности! Также, при добавлении новой коллинеарной переменной оценки при затронутых переменных могут сильно меняться.

Критерии качества оценивания

Коэффициент детерминации — доля выборочной дисперсии Y, которая объясняется оцененной моделью.

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

В контексте множественной регрессии следует помнить о том, что R^2, вообще говоря, не убывает при добавлении в модель новой переменной. Если добавленная переменная хоть на малейшую долю но объясняет Y, то R^2 строго возрастет. Это приводит к тому, что, ориентируясь на коэффициент детерминации, мы легко можем включить в модель слишком много переменных.

Для борьбы с этим используют скорректированный коэффициент R^2_{adj}

$$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}\frac{RSS}{TSS}$$

Смысл коррекции заключается в том, что

- если новая переменная дает большой вклад в объяснение Y, то уменьшение RSS будет превалировать над уменьшением знаменателя корректирующего множителя, и коэффициент детерминации вырастет;
- в противном случае уменьшение знаменателя пересилит снижение RSS, и коэффициент детерминации **уменьшится**.

Стандартная ошибка регрессии — оценка стандартного отклонения случайных ошибок регрессии u_i.

$$SER = s_{\hat{u}_i} = \sqrt{\frac{1}{n-k-1}\sum_{i=1}^{n}\hat{u}_i^2}$$

Информационные критерии служат для выбора между разными спецификациями модели. **Важно**: эти критерии (как, на самом деле и R^2) можно использовать для сравнения моделей только в том случае, когда в

левой части стоит **одна и та же** объясняемая переменная с **одним и тем же** итоговым набором наблюдений.

Акаике $\mathrm{AIC} = \ln \frac{RSS_k}{n} + \frac{2(k+1)}{n} + 1 + \ln 2\pi$

Шварца (байесовский) $\mathrm{BIC} = \ln \frac{RSS_k}{n} + (k+1)\frac{\ln n}{n} + 1 + \ln 2\pi$

Тестирование гипотез

Тестирование гипотез для одного коэффициента **ничем** не отличается от парной регрессии.

Формула для коинтеграционной матрицы вектора коэффициентов $\hat{\beta}$ в условиях гомоскедастичности ошибок имеет вид

$$\Sigma_{\hat{\boldsymbol{\beta}}} = \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}$$
$$\hat{\Sigma}_{\hat{\boldsymbol{\beta}}} = s_{\hat{u}}^2(\mathbf{X}'\mathbf{X})^{-1}$$

Доказательство.

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) = \\ &= \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\end{aligned}$$

По определению

$$\begin{aligned}\Sigma_{\hat{\boldsymbol{\beta}}} &= \mathrm{E}\left[\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}\right)' \,\middle|\, \mathbf{X}\right] = \\ &= \mathrm{E}\left[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\mathbf{u}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \,\middle|\, \mathbf{X}\right] = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\,\mathrm{E}[\mathbf{u}\mathbf{u}' \mid \mathbf{X}]\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{I}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}\end{aligned}$$

□

Проверим справедливость этой формулы на примере парной регрессии. Посмотрим на матрицу

$$X = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}$$

Первый столбец отвечает за свободный член, а второй — за X.

Легко показать, что

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix}$$

$$\det(\mathbf{X}'\mathbf{X}) = n\sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i\right)^2 = n\sum_{i=1}^n \left(x_i - \overline{x}\right)^2$$

$$(\mathbf{X}'\mathbf{X})^{-1} = \frac{1}{n}\frac{1}{\sum_{i=1}^n \left(x_i - \overline{x}\right)^2}\begin{pmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{pmatrix}$$

Если внимательно посмотреть на главную диагональ, то мы увидим знакомые формулы.

В случае гетероскедастичности ковариационная матрица имеет вид

$$\Sigma_{\hat{\boldsymbol{\beta}}} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\Sigma_u\mathbf{X})(\mathbf{X}'\mathbf{X})^{-1}$$

$$\hat{\Sigma}_{\hat{\boldsymbol{\beta}}}^{HC} = (\mathbf{X}'\mathbf{X})^{-1}\left(\mathbf{X}'\,\mathrm{diag}\{\hat{u}_1^2, \ldots, \hat{u}_n^2\}\mathbf{X}\right)(\mathbf{X}'\mathbf{X})^{-1}$$

Последняя формула — стандартные ошибки Уайта.

Тестирование множественных гипотез

Под множественной гипотезой мы понимаем гипотезу, в рамках которой **одновременно** тестируется несколько ограничений. Тут с тестированием не все так однозначно. Хочется упростить себе жизнь и тестровать такую гипотезу с использованием отдельных t-статистик.

Это неправильно, так как мы будем слишком часто отвергать нулевую гипотезу.

Пусть t_1 и t_2 — независимые (для простоты) t-статистики для двух коэффициентов регрессии. Мы решили отвергать $H_0 : \beta_1 = \beta_2 = 0$ на уровне значимости 0.05 если хотя бы одна статистика по абсолютному значению превышает критический уровень 1.96.

Получим

$$\begin{aligned} P_{H_0}(|t_1| > 1.96 \text{ и/или } |t_2| > 1.96) = \\ = 1 - P_{H_0}(|t_1| \le 1.96 \text{ и } |t_2| \le 1.96) = \\ = 1 - P_{H_0}(|t_1| \le 1.96) \times P_{H_0}(|t_2| \le 1.96) = \\ = 1 - 0.95 \times 0.95 = 0.0975 = 9.75\% \neq 5\% \end{aligned}$$

Если очень нужно использовать для тестирования значения t-статистик, то следует применить поправку Бонферрони: нужно для каждого отдельной t-статистики использовать критическое значение не для уровня значимости a, а a/q, где q — число ограничений.

Но лучше пользоваться F-тестом. Для данного примера F-статистика имеет вид

$$F = \frac{1}{n}\left(\frac{t_1^2 + t_2^2 - 2\hat{\rho}_{t_1,t_2} t_1 t_2}{1 - \hat{\rho}^2_{t_1,t_2}}\right)$$

В больших выборках $F \overset{\text{asy.}}{\sim} \chi^2_q/q$.

Если ошибки гомоскедастичны, то

$$F = \frac{\left(R^2_{\text{UR}} - R^2_{\text{R}}\right)/q}{\left(1 - R^2_{\text{UR}}\right)/(n-k-1)} = \frac{(RSS_{\text{R}} - RSS_{\text{UR}})/q}{RSS_{\text{UR}}/(n-k-1)}$$

где R^2_R, RSS_R — R^2 и RSS в модели с ограничениями, R^2_{UR}, RSS_{UR} — R^2 и RSS в модели без ограничений, k — число переменных в модели без ограничений. На малых выборках $F \sim F(q, n-k-1)$.

Если ошибки гетероскедастичны, то $F \nsim \chi^2_q/q$; нужно использовать статистику Вальда, устойчивую к гетероскедастичности

$$F = \frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)'\left(\mathbf{R}\hat{\Sigma}^{HC}_{\hat{\boldsymbol{\beta}}}\mathbf{R}'\right)^{-1}\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}\right)}{q}$$

где $\mathbf{R}$ и $\mathbf{r}$ задают линейные ограничения на коэффициенты модели

$$\mathbf{R}\hat{\boldsymbol{\beta}} = \mathbf{r}$$

Тестирование наличия мультиколлинеарности

VIF — фактор возрастания дисперсии (Variance Inflation Factor)

$$\mathrm{VIF}(X_j) = \frac{1}{1 - R_j^2}$$

где R_j^2 коэффициент детерминации в регрессии X_j на остальные переменные.

Доказательство. При выполнении условий теоремы Гаусса-Маркова

$$\mathrm{Var}\left[\hat{\boldsymbol{\beta}} \mid \mathbf{X}\right] = \sigma_u^2(\mathbf{X}'\mathbf{X})^{-1}$$

откуда

$$\mathrm{Var}\left[\hat{\boldsymbol{\beta}}_k \mid \mathbf{X}\right] = \sigma_u^2\left[(\mathbf{X}'\mathbf{X})^{-1}\right]_{kk}$$

Для простоты, перестановкой столбцов матрицы $\mathbf{X}$ поставим k-й регрессор на 1-е место. Также предположим, что все столбцы матрицы центрированы. Тогда, воспользовавшись формулами для частичной регрессии, получим

$$\left[(\mathbf{X}'\mathbf{X})^{-1}\right]_{11} = (\mathbf{X}_1'\mathbf{M}_{-1}\mathbf{X}_1)^{-1} = *$$

где $\mathbf{M}_{-1} = \mathbf{I} - \mathbf{X}_{-1}(\mathbf{X}_{-1}'\mathbf{X}_{-1})^{-1}\mathbf{X}_{-1}'$ — матрица, порождающая остатки регрессии на все столбцы $\mathbf{X}$, кроме первого.

Так как $\left[(\mathbf{X}'\mathbf{X})^{-1}\right]_{11}$ — скаляр, то

$$\begin{aligned} * &= \frac{1}{\mathbf{X}_1'\mathbf{M}_{-1}\mathbf{X}_1} = \\ &= \frac{1}{\mathbf{X}_1'\mathbf{M}_{-1}\mathbf{M}_{-1}\mathbf{X}_1} = \\ &= \frac{1}{(\mathbf{M}_{-1}\mathbf{X}_1)'\mathbf{M}_{-1}\mathbf{X}_1} = \frac{1}{\eta'\eta} \end{aligned}$$

где η — остатки регрессии $\mathbf{X}_1$ на $\mathbf{X}_{-1}$. Тогда

$$R_1^2 = 1 - \frac{\eta'\eta}{\mathbf{X}_1'\mathbf{X}_1}$$

$$\eta'\eta = \mathbf{X}_1'\mathbf{X}_1\left(1 - R_1^2\right)$$

$$\frac{1}{\eta'\eta} = (\mathbf{X}_1'\mathbf{X}_1)^{-1}\frac{1}{1 - R_1^2}$$

$$\operatorname{Var}\left[\hat{\boldsymbol{\beta}}_1 \mid \mathbf{X}\right] = \sigma_u^2(\mathbf{X}_1'\mathbf{X}_1)^{-1}\frac{1}{1 - R_1^2}$$

При этом, если бы $\mathbf{X}_1$ и $\mathbf{X}_{-1}$ были ортогональны, то

$$\operatorname{Var}\left[\hat{\boldsymbol{\beta}}_1 \mid \mathbf{X}\right] = \sigma_u^2(\mathbf{X}_1'\mathbf{X}_1)^{-1}$$

То есть VIF показывает, во сколько раз увеличится дисперсия коэффициента $\hat{\beta}_1$ из-за его коррелированности с прочими регрессорами. □

Если $\operatorname{VIF}(X_j) > 10$, то мы можем говорить о мультиколлинеарности.

Как бороться с мультиколлинеарностью?

1. Изменить спецификацию модели:
    - исключить одну (или более) переменных,
    - подобрать более подходящие регрессоры.
2. Изменить (увеличить) размер выборки.
3. Увеличить вариацию регрессоров.
4. Снизить размерность: метод главных компонент и т. д.
5. Преобразовать коллинеарные переменные:
    - агрегаты,
    - очистка от взаимного влияния,
    - нелинейные модели,
    - модель в разностях.
6. Ввести теоретические ограничения на коэффициенты.
7. Не делать ничего!

А Регрессия по частям

Рассмотрим модель

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{u} = \begin{pmatrix}\mathbf{X}_1 & \mathbf{X}_2\end{pmatrix}\begin{pmatrix}\boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_2\end{pmatrix} + \mathbf{u}$$

где $\mathbf{X}_1$ и $\mathbf{X}_2$ представляют собой разбиение матрицы $\mathbf{X}$ по столбцам, причем столбцы в этих матрицах (а) не пересекаются, и (б) включают в себя все столбцы исходной матрицы.

Для дальнейшего повествования нам понадобятся формулы для матрицы, обратной к блочной:

$$\begin{pmatrix}\mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D}\end{pmatrix}^{-1} = \begin{pmatrix}\tilde{\mathbf{A}} & -\tilde{\mathbf{A}}\mathbf{B}\mathbf{D}^{-1} \\ -\mathbf{D}^{-1}\mathbf{C}\tilde{\mathbf{A}} & \mathbf{D}^{-1} + \mathbf{D}^{-1}\mathbf{C}\tilde{\mathbf{A}}\mathbf{B}\mathbf{D}^{-1}\end{pmatrix} =$$

$$= \begin{pmatrix}\mathbf{A}^{-1} + \mathbf{A}^{-1}\mathbf{B}\tilde{\mathbf{D}}\mathbf{C}\mathbf{A}^{-1} & -\mathbf{A}^{-1}\mathbf{B}\tilde{\mathbf{D}} \\ -\tilde{\mathbf{D}}\mathbf{C}\mathbf{A}^{-1} & \tilde{\mathbf{D}}\end{pmatrix}$$

где $\tilde{\mathbf{A}} = \left(\mathbf{A} - \mathbf{B}\mathbf{D}^{-1}\mathbf{C}\right)^{-1}$, $\tilde{\mathbf{D}} = \left(\mathbf{D} - \mathbf{C}\mathbf{A}^{-1}\mathbf{B}\right)^{-1}$.

Оценка $\hat{\boldsymbol{\beta}}$ равна

$$\begin{pmatrix}\hat{\boldsymbol{\beta}}_1 \\ \hat{\boldsymbol{\beta}}_2\end{pmatrix} = (\mathbf{X}'\mathbf{X})^{-1}\begin{pmatrix}\mathbf{X}_1\mathbf{y} \\ \mathbf{X}_2\mathbf{y}\end{pmatrix}$$

Найдем $\hat{\boldsymbol{\beta}}_1$. Так как

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix}\mathbf{X}_1'\mathbf{X}_1 & \mathbf{X}_1'\mathbf{X}_2 \\ \mathbf{X}_2'\mathbf{X}_1 & \mathbf{X}_2'\mathbf{X}_2\end{pmatrix}$$

то

$$(\mathbf{X}'\mathbf{X})^{-1} = \begin{pmatrix}\tilde{\mathbf{X}} & -\tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1} \\ -(\mathbf{X}_2'\mathbf{X}_2)\mathbf{X}_2'\mathbf{X}_1\tilde{\mathbf{X}} & (\mathbf{X}_2'\mathbf{X}_2)^{-1} + (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1\tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\end{pmatrix}$$

где

$$\tilde{\mathbf{X}} = \left[\mathbf{X}_1'\mathbf{X}_1 - \mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1\right]^{-1} =$$

$$= \left\{\mathbf{X}_1'\underbrace{\left[\mathbf{I}_N - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\right]}_{\mathbf{M}_2}\mathbf{X}_1'\right\}^{-1}$$

Таким образом

$$\hat{\boldsymbol{\beta}}_1 = \tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{y} - \tilde{\mathbf{X}}\mathbf{X}_1'\mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{y} =$$

$$= \tilde{\mathbf{X}}\mathbf{X}_1'\left[\mathbf{I}_N - \mathbf{X}_2(\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\right]\mathbf{y} =$$

$$= (\mathbf{X}_1'\mathbf{M}_2\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{M}_2\mathbf{y} =$$

$$= (\mathbf{X}_1'\mathbf{M}_2\mathbf{M}_2\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{M}_2\mathbf{M}_2\mathbf{y} =$$

$$= \left(\hat{\mathbf{X}}_1'\hat{\mathbf{X}}_1\right)^{-1}\hat{\mathbf{X}}_1'\hat{\mathbf{y}}$$

где $\hat{\mathbf{X}}_1$ и $\hat{\mathbf{y}}$ — остатки регрессий $\mathbf{X}_1$ и $\mathbf{y}$ на $\mathbf{X}_2$, соответственно. Аналогично показывается, что

$$\hat{\boldsymbol{\beta}}_2 = (\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{y}$$