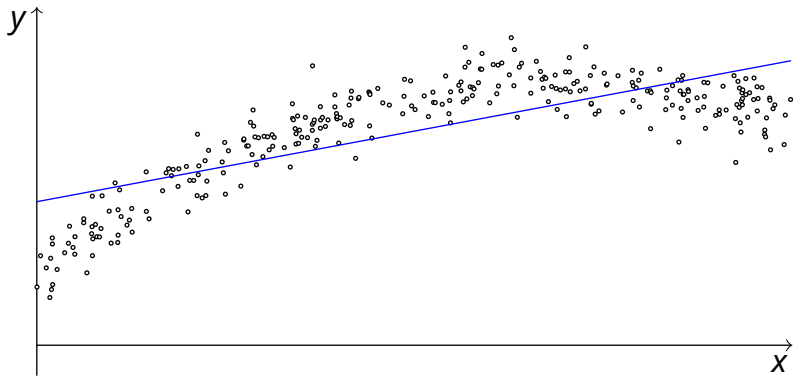
# Нелинейные регрессионные модели

Нелинейность в регрессионных моделях обычно появляется двумя путями:

1. $Y$ является нелинейной функцией от $X$.
2. $X$ по-разному влияет на $Y$ в зависимости от третьей переменной $Z$.




Предположим, что кривая имеет больший наклон при небольших значениях доходов, и меньший — при более высоких; например, квадратичная зависимость:

$$TestScore_i = \beta_0 + \beta_1 Income_i + \beta_2 Income_i^2 + u_i \qquad (1)$$

Здесь $\mathrm{E}(TestScore \mid Income) = \beta_0 + \beta_1 Income_i + \beta_2 Income_i^2$ — квадратичная функция, а (1) — обычная множественная регрессия!

Для тестирования нелинейности, то есть для тестирования следующего набора гипотез

$$H_0 : \text{линейная модель}$$
$$H_a : \text{нелинейная модель}$$

достаточно представить их в виде

$$H_0 : \beta_2 = 0$$
$$H_a : \beta_2 \neq 0$$

## Общий вид функции нелинейной теоретической регрессии

$$Y_i = f(X_{1i}, ..., X_{ki}) + u_i, i = 1, ..., n$$

где $f(X_{1i}, ..., X_{ki})$ — **теоретическая функция нелинейной регрессии**.

Например:

$$f(Income_i) = \beta_0 + \beta_1 Income_i + \beta_2 Income_i^2$$

**Величина изменения** $Y$

$$\Delta Y = f(X_1 + \Delta X_1, X_2, ..., X_k) - f(X_1, X_2, ..., X_k)$$

Пусть $\hat{f}(X_1, X_2, ..., X_k)$ — предсказанное значение $Y$, полученное на основе оценки $\hat{f}$ функции теоретической регрессии. Тогда

$$\Delta\hat{Y} = \hat{f}(X_1 + \Delta X_1, X_2, ..., X_k) - \hat{f}(X_1, X_2, ..., X_k)$$

*Пример 1.*

$$\widehat{TestScore} = \underset{(2.9)}{607.3} + \underset{(0.27)}{3.85} Income_i - \underset{(0.0048)}{0.0423} Income_i^2, R^2 = 0.554$$

$$\Delta\hat{Y} = \left(\hat{\beta}_0 + \hat{\beta}_1 \times 11 + \hat{\beta}_2 \times 11^2\right) - \left(\hat{\beta}_0 + \hat{\beta}_1 \times 10 + \hat{\beta}_2 \times 10^2\right) =$$

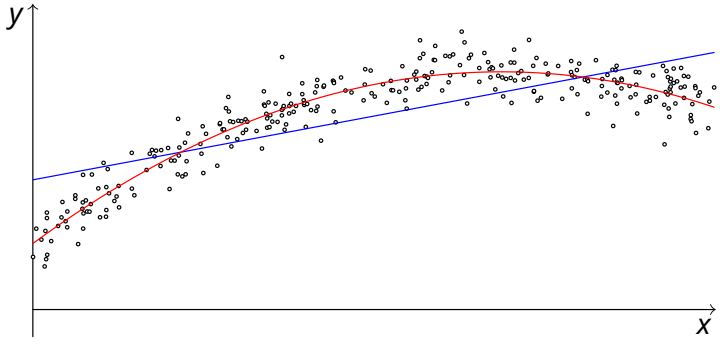
$$= \left(607.3 + 3.85 \times 11 - 0.0423 \times 11^2\right) - \left(607.3 + 3.85 \times 10 - 0.0423 \times 10^2\right) =$$

$$= 644.53 - 641.57 = 2.96$$

$$\Delta\hat{Y} = \left(\hat{\beta}_0 + \hat{\beta}_1 \times 41 + \hat{\beta}_2 \times 41^2\right) - \left(\hat{\beta}_0 + \hat{\beta}_1 \times 40 + \hat{\beta}_2 \times 40^2\right) =$$

$$= \left(607.3 + 3.85 \times 41 - 0.0423 \times 41^2\right) - \left(607.3 + 3.85 \times 40 - 0.0423 \times 40^2\right) =$$

$$= 694.04 - 693.62 = 0.42$$



**Стандартная ошибка ожидаемого изменения**

$$\Delta\hat{Y} = \left(\hat{\beta}_0 + \hat{\beta}_1 \times 11 + \hat{\beta}_2 \times 11^2\right) - \left(\hat{\beta}_0 + \hat{\beta}_1 \times 10 + \hat{\beta}_2 \times 10^2\right) = \hat{\beta}_1 + 21\hat{\beta}_2$$

$$\text{SE}\left[\Delta\hat{Y}\right] = \text{SE}\left[\hat{\beta}_1 + 21\hat{\beta}_2\right]$$

Как вычислить?

**Подход 1** Вычислить $F$-статистику для проверки гипотезы $\beta_1 + 21\beta_2 = 0$. Тогда

$$\text{SE}\left[\Delta\hat{Y}\right] = \frac{\left|\Delta\hat{Y}\right|}{\sqrt{F}}$$

*Пример 2.* для регрессии $F = 299.94$, $\Delta\hat{Y} = 2.96 \Rightarrow \text{SE}\left[\Delta\hat{Y}\right] = \frac{2.96}{\sqrt{299.94}} = 0.17$

**Подход 2** Преобразовать модель так, чтобы один из коэффициентов был равен $\beta_1 + 21\beta_2$, оценить преобразованную регрессию, использовать $t$ -статистику для проверки гипотезы $\beta_1 + 21\beta_2 = 0$.

**Интерпретация коэффициентов**

$$TestScore_i = \beta_0 + \beta_1 Income_i + \beta_2 Income_i^2 + u_i$$

Можно ли интерпретировать коэффициент $\beta_1$ стандартным образом?

**Очевидно, нет!**

В нелинейных моделях лучше вычислять $\Delta\hat{Y}$ в зависимости от изменения одной или нескольких объясняющих переменных.

## Общий подход к моделированию нелинейности

1. Идентифицируйте возможное нелинейное соотношение.
2. Специфицируйте нелинейную функцию и оцените ее параметры при помощи МНК.
3. Определите, улучшает ли нелинейная модель линейную.
4. Изобразите графически оцененную функцию.
5. Оцените изменение $Y$ в зависимости от изменения $X$.

# Функции парных нелинейных регрессий

Рассмотрим 2 метода (они не единственные): полиномиальные регрессии и логарифмические модели.

## Полиномиальная регрессия

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \cdots + \beta_r X_i^r + u_i$$

- $r = 2$ — квадратичная регрессия,
- $r = 3$ — кубическая регрессия.

Метод оценки: МНК.

Тестирование гипотезы линейности:

$$H_0 : \beta_2 = \beta_3 = \cdots = \beta_r = 0$$
$$H_a : \exists j = 2, \ldots, r : \beta_j \neq 0$$

или

$$H_a : \sum_{j=2}^{r} \beta_j^2 > 0$$

Применяется $F$-статистика.

Чем больше $r$, тем более гибкая модель, но тогда больше регрессоров и, следовательно, меньше точность оценок коэффициентов.

1. Выберите максимальное $r$, оцените регрессию.
2. Используйте $t$-статистику для тестирования значимости коэффициента при самой большой степени.
3. Если не отвергаете $H_0$ на шаге 2, оцените регрессию степени $r - 1$. Проверьте значимость последнего коэффициента.
4. Если не отвергаете $H_0$ на шаге 3, продолжайте до первой значимой степени.

*Пример 1.*

$$\widehat{TestScore} = \underset{(5.1)}{600.1} + \underset{(0.71)}{5.02} Income_i - \underset{(0.029)}{0.096} Income_i^2 + \underset{(0.00069)}{0.00035} Income_i^3, \overline{R}^2 = 0.555$$

Искомая $t$-статистика (при $Income_i^3$) равна 1.97 $\Rightarrow$ отвергаем. $F$-статистика для проверки незначимости коэффициентов при $Income_i^2$ и $Income_i^3$ равна 37.5 $\Rightarrow$ отвергаем нулевую гипотезу линейности.

## Логарифмические регрессии

Вспомним, что для малых $x$ выполняется примерное равенство

$$\ln(1 + x) \approx x \Rightarrow \ln\left(\frac{x + \Delta x}{x}\right) \approx \frac{\Delta x}{x}$$

С учетом этого меняются интерпретации коэффициентов регрессии:

- Линейно-логарифмическая модель

  $$Y_i = \beta_0 + \beta_1 \ln X_i + u_i$$

  1%-ное изменение $X$ приводит к изменению $Y$ на $0.01\beta_1$.

- Логарифмически-линейная модель

  $$\ln Y_i = \beta_0 + \beta_1 X_i + u_i$$

  Единичное изменение $X$ (то есть $\Delta X = 1$) приводит к изменению $Y$ на $100\beta_1$%.

  Важно отметить, что в данном случае нужно быть осторожным с интерпретацией коэффициентов, больших, чем 0.1. Действительно

| $\beta_1$ | $\exp\{\beta_1\}$ |
|---|---|
| 0.01 | 1.01005 |
| 0.02 | 1.02020 |
| 0.03 | 1.03046 |
| 0.05 | 1.05127 |
| 0.09 | 1.09417 |
| 0.1 | 1.10520 |
| 0.2 | 1.22140 |
| 0.3 | 1.35000 |
| 0.5 | 1.65000 |

- Модель, линейная в логарифмах

$$\ln Y_i = \beta_0 + \beta_1 \ln X_i + u_i$$

1%-ное изменение $X$ приводит к изменению $Y$ на $\beta_1$%.

**Эластичности**

| Модель регрессии по $X$ | Теоретическая модель | Эластичность $E[Y \mid X]$ |
|---|---|---|
| Линейная | $Y = \beta_0 + \beta_1 X + u$ | $\frac{\beta_1 \Delta X}{\beta_0 + \beta_1 X}$ |
| Линейно-логарифмическая | $Y = \beta_0 + \beta_1 \ln X + u$ | $\frac{\beta_1}{\beta_0 + \beta_1 \ln X}$ |
| Логарифмически-линейная | $\ln Y = \beta_0 + \beta_1 X + u$ | $\beta_1 \Delta X$ |
| Линейная в логарифмах | $\ln Y = \beta_0 + \beta_1 \ln X + u$ | $\beta_1$ |

## Сравнение моделей

**Используя критерии качества подгонки моделей, можно сравнивать модели, у которых одинаковый $Y$!**

- Можно сравнивать логарифмически-линейную и линейную в логарифмах модель.
- Можно сравнивать линейно-логарифмическую и полиномиальные модели.

# Моделирование эффектов взаимодействия

3 случая (модель с двумя объясняющими переменными):

1. Обе переменные — бинарные.
2. Одна переменная — бинарная, вторая — непрерывная.
3. Обе переменные — непрерывные.

## Две бинарные переменные

$$Y_i = \beta_0 + \beta_1 D_{1i} + \beta_2 D_{2i} + u_i$$

где $D_{1i}, D_{2i}$ — бинарные переменные.

*Пример 1.*

Например:

- $D_{1i} = 1$, если индивид — женщина, 0 — если мужчина.
- $D_{2i} = 1$, если у индивида есть высшее образование, 0 — если нет.

$$Y_i = \beta_0 + \beta_1 D_{1i} + \beta_2 D_{2i} + \beta_3 D_{1i} \times D_{2i} + u_i \quad (2)$$

Регрессор $D_{1i} \times D_{2i}$ — **компонента (регрессор) взаимодействия**.

Модель регрессии (2) — **модель регрессии с бинарной компонентой взаимодействия**.

$$\mathrm{E}[Y_i \mid D_{1i}, D_{2i}] = \begin{cases} \beta_0, & \text{при } D_{1i} = 0, D_{2i} = 0 \\ \beta_0 + \beta_1, & \text{при } D_{1i} = 1, D_{2i} = 0 \\ \beta_0 + \beta_2, & \text{при } D_{1i} = 0, D_{2i} = 1 \\ \beta_0 + \beta_1 + \beta_2 + \beta_3, & \text{при } D_{1i} = 1, D_{2i} = 1 \end{cases}$$

## Непрерывная и бинарная переменные

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + u_i$$

*Пример 1.*

- $D_i = 1$, если у индивида есть высшее образование, 0 — если нет.
- $X_i$ — трудовой стаж.

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 D_i \times X_i + u_i$$

Регрессор $D_i \times X_i$ — **компонента (регрессор) взаимодействия**.

## Две непрерывные переменные

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{1i} \times X_{2i} + u_i$$

Регрессор $X_{1i} \times X_{2i}$ — **компонента (регрессор) взаимодействия**.

$\frac{\Delta Y}{\Delta X_1} = \beta_1 + \beta_3 X_2$ — эффект влияния изменения $X_1$ на $Y$ при постоянном $X_2$.

### Пример моделирования эффектов взаимодействия

| Объясняющая переменная | (1) | (2) | (3) | (4) | (5) | (6) | (7) |
|---|---|---|---|---|---|---|---|
| *STR* | −1.00** | −0.73** | −0.97 | −0.53 | 64.33** | 83.70** | 65.29** |
| | (0.27) | (0.26) | (0.59) | (0.34) | (24.86) | (28.5) | (25.26) |
| $STR^2$ | | | | | −3.42** | −4.38** | −3.47** |
| | | | | | (1.25) | (1.44) | (1.27) |
| $STR^3$ | | | | | 0.059** | 0.075** | 0.060** |
| | | | | | (0.021) | (0.024) | (0.021) |

| Объясняющая переменная | (1) | (2) | (3) | (4) | (5) | (6) | (7) |
|---|---|---|---|---|---|---|---|
| *PctEL* | −0.122** | −0.176** | | | | | −0.166 |
| | (0.033) | (0.034) | | | | | (0.034) |
| *HiEL* = *I*(*PctEL* ≥ 10%) | | | 5.64 | 5.5 | −5.47** | 816.1* | |
| | | | (19.51) | (9.8) | (1.03) | (327.7) | |
| *HiEL* × *STR* | | | −1.28 | −0.58 | | −123.3* | |
| | | | (0.97) | (0.5) | | (50.2) | |
| *HiEL* × $STR^2$ | | | | | | 6.12* | |
| | | | | | | (2.54) | |
| *HiEL* × $STR^3$ | | | | | | −0.101* | |
| | | | | | | (0.043) | |
| *LchPct* | −0.547** | −0.398** | | −0.411** | −0.420** | −0.418** | −0.402** |
| | (0.024) | (0.033) | | (0.029) | (0.029) | (0.029) | (0.033) |
| ln *Income* | | 11.57** | | 12.12** | 11.75** | 11.80** | 11.51** |
| | | (1.81) | | (1.8) | (1.78) | (1.78) | (1.81) |
| Константа | 700.2** | 658.6** | 682.2** | 653.6** | 252 | 122.3 | 244.8 |
| | (5.6) | (8.6) | (11.9) | (9.9) | (163.6) | (185.5) | (165.7) |
| *F*-статистики и *p*-значения для проверки совместных гипотез | | | | | | | |
| $STR^{1,2,3} = 0$, *HiEL* × $STR^{1,2,3} = 0$ | | | 5.64 | 5.92 | 6.31 | 4.96 | 5.91 |
| | | | (0.004) | (0.003) | (< 0.001) | (< 0.001) | (0.001) |
| $STR^2, STR^3 = 0$ | | | | | 6.17 | 5.81 | 5.96 |
| | | | | | (< 0.001) | (0.003) | (0.003) |
| *HiEL* × $STR^{1,2,3} = 0$ | | | | | | 2.69 | |
| | | | | | | (0.046) | |
| *SER* | 9.08 | 8.64 | 15.88 | 8.63 | 8.56 | 8.55 | 8.57 |
| $R^2_{adj}$ | 0.773 | 0.794 | 0.305 | 0.795 | 0.798 | 0.799 | 0.798 |

## Тесты Бокса-Кокса (Box, Cox, 1964)

$$Y^* = \frac{Y^\lambda - 1}{\lambda} = \begin{cases} Y - 1, & \lambda = 1 \\ \to \log \lambda, \lambda \to 0 \end{cases}$$

- $\lambda = 1$ — линейное преобразование,
- $\lambda \to 0$ — логарифмическое преобразование.

Пусть

$$Y^* = \frac{Y^{\lambda_1} - 1}{\lambda_1}$$

$$X^* = \frac{X^{\lambda_2} - 1}{\lambda_2}$$

Рассмотрим

$$Y^* = \beta_0 + \beta_1 X^* + u \qquad (3)$$

$\beta_0, \beta_1$ оцениваются при помощи МНК.

**Но нужно оценить $\lambda_1$ и $\lambda_2$!** Как? Нелинейный МНК.

Тесты Бокса-Кокса — проверка гипотез о различных значениях $\lambda_1$ и $\lambda_2$. Как? Сравнить качество подгонки моделей с разными параметрами.

- При $\lambda_2 = 1$, если $\lambda_1 = 1$, то (3) — линейная модель.
- При $\lambda_2 = 0$, если $\lambda_1 = 1$, то (3) — логарифмически-линейная модель.

## Тест Зарембки (Zarembka, 1968)

Среднее геометрическое $Y$ равно экспоненте среднего арифметического $\ln Y$:

$$e^{\frac{1}{n}\sum_{i=1}^{n}\ln Y_i} = e^{\frac{1}{n}\ln(Y_1\times\cdots\times Y_n)} = e^{\ln(Y_1\times\cdots\times Y_n)^{1/n}} = (Y_1 \times \cdots \times Y_n)^{\frac{1}{n}}$$

1. Вычислите среднее геометрическое $Y$.
2. Рассчитайте $Y^* = \frac{Y_i}{\text{ср. геом. } Y}$, $i = 1, \ldots, n$.
3. Оцените регрессии $Y_i^*$ и $\ln Y_i^*$ на регрессоры исходной модели и рассчитайте $SSR$ обоих моделей. Лучше та модель, $SSR$ которой меньше.
4. Пусть $SSR_1 > SSR_2$, тогда

$$\frac{n}{2}\left|\ln\frac{SSR_1}{SSR_2}\right| \sim \chi^2(1)$$

**ВАЖНО!** Регрессии, оцененные в пункте 3, можно использовать только для принятия решения о том, какая модель предпочтительнее. Коэффициенты этих регрессий не интерпретируются. Для интерпретации надо рассматривать исходные модели (без масштабирования).

## Модели, нелинейные по параметрам

*Пример 1.* Модель Михаэлиса-Ментон

$$Inf = \frac{\theta_1\, UnJob}{\theta_2 + UnJob}$$

$$Y = \frac{1}{Inf} = \frac{1}{\theta_1} + \frac{\theta_2/\theta_1}{UnJob} = \alpha + \beta X$$

Общий вид:

$$Y_i = f(X_{1i}, X_{2i}, \ldots, X_{ki}; \beta_0, \ldots, \beta_m) + u_i, i = 1, \ldots, n$$

Как оценивать? **Нелинейный МНК**:

$$\min_{b_0,\ldots,b_m} \sum_{i=1}^{n} [Y_i - f(X_{1i}, X_{2i}, \ldots, X_{ki}; b_0, \ldots, b_m)]^2$$