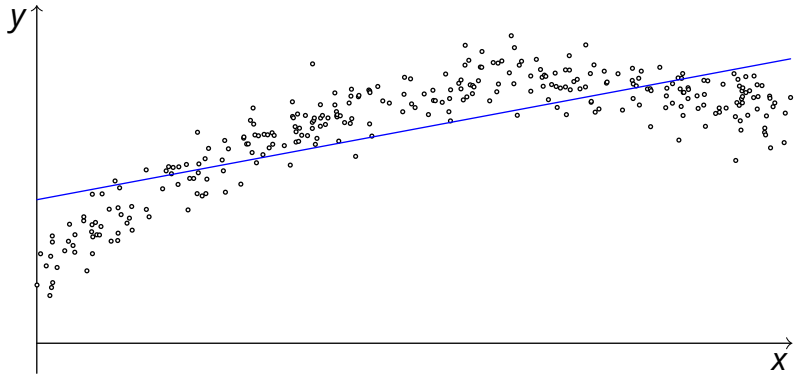
Нелинейные регрессионные модели

Нелинейность в регрессионных моделях обычно появляется двумя путями:

1. Y является нелинейной функцией от X.
2. X по-разному влияет на Y в зависимости от третьей переменной Z.



Предположим, что кривая имеет больший наклон при небольших значениях доходов, и меньший — при более высоких; например, квадратичная зависимость:

$$TestScore_i = \beta_0 + \beta_1 Income_i + \beta_2 Income_i^2 + u_i \qquad (1)$$

Здесь $\mathrm{E}(TestScore \mid Income) = \beta_0 + \beta_1 Income_i + \beta_2 Income_i^2$ — квадратичная функция, а (1) — обычная множественная регрессия!

Для тестирования нелинейности, то есть для тестирования следующего набора гипотез

$$H_0 : \text{линейная модель}$$
$$H_a : \text{нелинейная модель}$$

достаточно представить их в виде

$$H_0 : \beta_2 = 0$$
$$H_a : \beta_2 \neq 0$$

Общий вид функции нелинейной теоретической регрессии

$$Y_i = f(X_{1i}, ..., X_{ki}) + u_i, i = 1, ..., n$$

где $f(X_{1i}, ..., X_{ki})$ — **теоретическая функция нелинейной регрессии**.

Например:

$$f(Income_i) = \beta_0 + \beta_1 Income_i + \beta_2 Income_i^2$$

Величина изменения Y

$$\Delta Y = f(X_1 + \Delta X_1, X_2, ..., X_k) - f(X_1, X_2, ..., X_k)$$

Пусть $\hat{f}(X_1, X_2, ..., X_k)$ — предсказанное значение Y, полученное на основе оценки $\hat{f}$ функции теоретической регрессии. Тогда

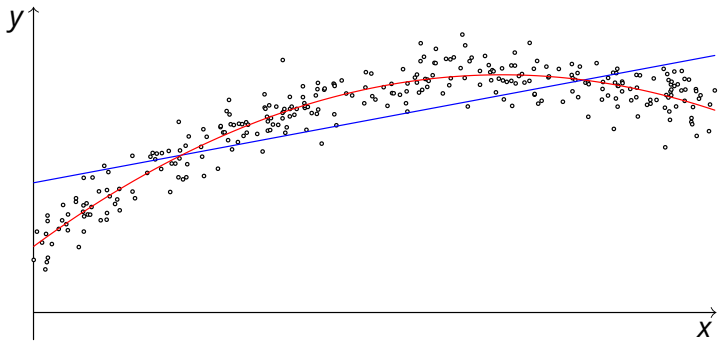
$$\Delta \hat{Y} = \hat{f}(X_1 + \Delta X_1, X_2, ..., X_k) - \hat{f}(X_1, X_2, ..., X_k)$$

Пример 1.

$$\underset{}{\widehat{TestScore}} = \underset{(2.9)}{607.3} + \underset{(0.27)}{3.85} Income_i - \underset{(0.0048)}{0.0423} Income_i^2, R^2 = 0.554$$

$$\Delta \hat{Y} = \left(\hat{\beta}_0 + \hat{\beta}_1 \times 11 + \hat{\beta}_2 \times 11^2\right) - \left(\hat{\beta}_0 + \hat{\beta}_1 \times 10 + \hat{\beta}_2 \times 10^2\right) =$$
$$= \left(607.3 + 3.85 \times 11 - 0.0423 \times 11^2\right) - \left(607.3 + 3.85 \times 10 - 0.0423 \times 10^2\right) =$$
$$= 644.53 - 641.57 = 2.96$$

$$\Delta \hat{Y} = \left(\hat{\beta}_0 + \hat{\beta}_1 \times 41 + \hat{\beta}_2 \times 41^2\right) - \left(\hat{\beta}_0 + \hat{\beta}_1 \times 40 + \hat{\beta}_2 \times 40^2\right) =$$
$$= \left(607.3 + 3.85 \times 41 - 0.0423 \times 41^2\right) - \left(607.3 + 3.85 \times 40 - 0.0423 \times 40^2\right) =$$
$$= 694.04 - 693.62 = 0.42$$



Стандартная ошибка ожидаемого изменения

$$\Delta\hat{Y} = \left(\hat{\beta}_0 + \hat{\beta}_1 \times 11 + \hat{\beta}_2 \times 11^2\right) - \left(\hat{\beta}_0 + \hat{\beta}_1 \times 10 + \hat{\beta}_2 \times 10^2\right) = \hat{\beta}_1 + 21\hat{\beta}_2$$

$$\text{SE}\left[\Delta\hat{Y}\right] = \text{SE}\left[\hat{\beta}_1 + 21\hat{\beta}_2\right]$$

Как вычислить?

Подход 1 Вычислить F-статистику для проверки гипотезы $\beta_1 + 21\beta_2 = 0$.

Тогда

$$\text{SE}\left[\Delta\hat{Y}\right] = \frac{\left|\Delta\hat{Y}\right|}{\sqrt{F}}$$

Пример 2. для регрессии $F = 299.94$, $\Delta\hat{Y} = 2.96 \Rightarrow \text{SE}\left[\Delta\hat{Y}\right] = \frac{2.96}{\sqrt{299.94}} = 0.17$

Подход 2 Преобразовать модель так, чтобы один из коэффициентов был равен $\beta_1 + 21\beta_2$, оценить преобразованную регрессию, использовать t-статистику для проверки гипотезы $\beta_1 + 21\beta_2 = 0$.

Интерпретация коэффициентов

$$TestScore_i = \beta_0 + \beta_1 Income_i + \beta_2 Income_i^2 + u_i$$

Можно ли интерпретировать коэффициент β_1 стандартным образом?

Очевидно, нет!

В нелинейных моделях лучше вычислять $\Delta\hat{Y}$ в зависимости от изменения одной или нескольких объясняющих переменных.

Общий подход к моделированию нелинейности

1. Идентифицируйте возможное нелинейное соотношение.
2. Специфицируйте нелинейную функцию и оцените ее параметры при помощи МНК.
3. Определите, улучшает ли нелинейная модель линейную.
4. Изобразите графически оцененную функцию.
5. Оцените изменение Y в зависимости от изменения X.

Функции парных нелинейных регрессий

Рассмотрим 2 метода (они не единственные): полиномиальные регрессии и логарифмические модели.

Полиномиальная регрессия

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \cdots + \beta_r X_i^r + u_i$$

- $r = 2$ — квадратичная регрессия,
- $r = 3$ — кубическая регрессия.

Метод оценки: МНК.

Тестирование гипотезы линейности:

$$H_0 : \beta_2 = \beta_3 = \cdots = \beta_r = 0$$
$$H_a : \exists j = 2, \ldots, r : \beta_j \neq 0$$

или

$$H_a : \sum_{j=2}^{r} \beta_j^2 > 0$$

Применяется F-статистика.

Чем больше r, тем более гибкая модель, но тогда больше регрессоров и, следовательно, меньше точность оценок коэффициентов.

1. Выберите максимальное r, оцените регрессию.

2. Используйте t-статистику для тестирования значимости коэффициента при самой большой степени.
3. Если не отвергаете H_0 на шаге 2, оцените регрессию степени $r - 1$. Проверьте значимость последнего коэффициента.
4. Если не отвергаете H_0 на шаге 3, продолжайте до первой значимой степени.

Пример 1.

$$\widehat{TestScore} = \underset{(5.1)}{600.1} + \underset{(0.71)}{5.02} Income_i - \underset{(0.029)}{0.096} Income_i^2 + \underset{(0.00069)}{0.00035} Income_i^3, \overline{R}^2 = 0.555$$

Искомая t-статистика (при $Income_i^3$) равна 1.97 $\Rightarrow$ отвергаем. F-статистика для проверки незначимости коэффициентов при $Income_i^2$ и $Income_i^3$ равна 37.5 $\Rightarrow$ отвергаем нулевую гипотезу линейности.

Логарифмические регрессии

Вспомним, что для малых x выполняется примерное равенство

$$\ln(1 + x) \approx x \Rightarrow \ln\left(\frac{x + \Delta x}{x}\right) \approx \frac{\Delta x}{x}$$

С учетом этого меняются интерпретации коэффициентов регрессии:

- Линейно-логарифмическая модель

  $$Y_i = \beta_0 + \beta_1 \ln X_i + u_i$$

  1%-ное изменение X приводит к изменению Y на $0.01\beta_1$.
- Логарифмически-линейная модель

  $$\ln Y_i = \beta_0 + \beta_1 X_i + u_i$$

  Единичное изменение X (то есть $\Delta X = 1$) приводит к изменению Y на $100\beta_1$%.

  Важно отметить, что в данном случае нужно быть осторожным с интерпретацией коэффициентов, больших, чем 0.1. Действительно

β_1	$\exp\{\beta_1\}$
0.01	1.01005
0.02	1.02020
0.03	1.03046
0.05	1.05127
0.09	1.09417
0.1	1.10520
0.2	1.22140
0.3	1.35000
0.5	1.65000

- Модель, линейная в логарифмах

$$\ln Y_i = \beta_0 + \beta_1 \ln X_i + u_i$$

1%-ное изменение X приводит к изменению Y на β_1%.

Эластичности

Модель регрессии по X	Теоретическая модель	Эластичность $\mathrm{E}[Y \mid X]$
Линейная	$Y = \beta_0 + \beta_1 X + u$	$\frac{\beta_1 \Delta X}{\beta_0 + \beta_1 X}$
Линейно-логарифмическая	$Y = \beta_0 + \beta_1 \ln X + u$	$\frac{\beta_1}{\beta_0 + \beta_1 \ln X}$
Логарифмически-линейная	$\ln Y = \beta_0 + \beta_1 X + u$	$\beta_1 \Delta X$
Линейная в логарифмах	$\ln Y = \beta_0 + \beta_1 \ln X + u$	β_1

Сравнение моделей

Используя критерии качества подгонки моделей, можно сравнивать модели, у которых одинаковый Y!

- Можно сравнивать логарифмически-линейную и линейную в логарифмах модель.

- Можно сравнивать линейно-логарифмическую и полиномиальные модели.

Моделирование эффектов взаимодействия

3 случая (модель с двумя объясняющими переменными):

1. Обе переменные — бинарные.
2. Одна переменная — бинарная, вторая — непрерывная.
3. Обе переменные — непрерывные.

Две бинарные переменные

$$Y_i = \beta_0 + \beta_1 D_{1i} + \beta_2 D_{2i} + u_i$$

где D_{1i}, D_{2i} — бинарные переменные.

Пример 1.

Например:

- $D_{1i} = 1$, если индивид — женщина, 0 — если мужчина.
- $D_{2i} = 1$, если у индивида есть высшее образование, 0 — если нет.

$$Y_i = \beta_0 + \beta_1 D_{1i} + \beta_2 D_{2i} + \beta_3 D_{1i} \times D_{2i} + u_i \qquad (2)$$

Регрессор $D_{1i} \times D_{2i}$ — **компонента (регрессор) взаимодействия**.

Модель регрессии (2) — **модель регрессии с бинарной компонентой взаимодействия**.

$$\mathrm{E}[Y_i \mid D_{1i}, D_{2i}] = \begin{cases} \beta_0, & \text{при } D_{1i} = 0, D_{2i} = 0 \\ \beta_0 + \beta_1, & \text{при } D_{1i} = 1, D_{2i} = 0 \\ \beta_0 + \beta_2, & \text{при } D_{1i} = 0, D_{2i} = 1 \\ \beta_0 + \beta_1 + \beta_2 + \beta_3, & \text{при } D_{1i} = 1, D_{2i} = 1 \end{cases}$$

Непрерывная и бинарная переменные

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + u_i$$

Пример 1.

- $D_i = 1$, если у индивида есть высшее образование, 0 — если нет.
- X_i — трудовой стаж.

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 D_i \times X_i + u_i$$

Регрессор $D_i \times X_i$ — **компонента (регрессор) взаимодействия**.

Две непрерывные переменные

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{1i} \times X_{2i} + u_i$$

Регрессор $X_{1i} \times X_{2i}$ — **компонента (регрессор) взаимодействия**.

$\frac{\Delta Y}{\Delta X_1} = \beta_1 + \beta_3 X_2$ — эффект влияния изменения X_1 на Y при постоянном X_2.

Пример моделирования эффектов взаимодействия

Объясняющая переменная	(1)	(2)	(3)	(4)	(5)	(6)	(7)
STR	−1.00**	−0.73**	−0.97	−0.53	64.33**	83.70**	65.29**
	(0.27)	(0.26)	(0.59)	(0.34)	(24.86)	(28.5)	(25.26)
STR^2					−3.42**	−4.38**	−3.47**
					(1.25)	(1.44)	(1.27)
STR^3					0.059**	0.075**	0.060**
					(0.021)	(0.024)	(0.021)
PctEL	−0.122**	−0.176**					−0.166
	(0.033)	(0.034)					(0.034)
HiEL = *I*(*PctEL* ≥ 10%)			5.64	5.5	−5.47**	816.1*	
			(19.51)	(9.8)	(1.03)	(327.7)	
HiEL × *STR*			−1.28	−0.58		−123.3*	
			(0.97)	(0.5)		(50.2)	
HiEL × STR^2						6.12*	
						(2.54)	
HiEL × STR^3						−0.101*	
						(0.043)	
LchPct	−0.547**	−0.398**		−0.411**	−0.420**	−0.418**	−0.402**
	(0.024)	(0.033)		(0.029)	(0.029)	(0.029)	(0.033)
ln *Income*		11.57**		12.12**	11.75**	11.80**	11.51**
		(1.81)		(1.8)	(1.78)	(1.78)	(1.81)
Константа	700.2**	658.6**	682.2**	653.6**	252	122.3	244.8
	(5.6)	(8.6)	(11.9)	(9.9)	(163.6)	(185.5)	(165.7)
F-статистики и *p*-значения для проверки совместных гипотез							
$STR^{1,2,3} = 0$, *HiEL* × $STR^{1,2,3} = 0$			5.64	5.92	6.31	4.96	5.91
			(0.004)	(0.003)	(< 0.001)	(< 0.001)	(0.001)
$STR^2, STR^3 = 0$					6.17	5.81	5.96
					(< 0.001)	(0.003)	(0.003)

Объясняющая переменная	(1)	(2)	(3)	(4)	(5)	(6)	(7)
$HiEL \times STR^{1,2,3} = 0$						2.69	
						(0.046)	
SER	9.08	8.64	15.88	8.63	8.56	8.55	8.57
R^2_{adj}	0.773	0.794	0.305	0.795	0.798	0.799	0.798

Тесты Бокса-Кокса (Box, Cox, 1964)

$$Y^* = \frac{Y^\lambda - 1}{\lambda} = \begin{cases} Y - 1, & \lambda = 1 \\ \to \log \lambda, & \lambda \to 0 \end{cases}$$

- $\lambda = 1$ — линейное преобразование,
- $\lambda \to 0$ — логарифмическое преобразование.

Пусть

$$Y^* = \frac{Y^{\lambda_1} - 1}{\lambda_1}$$

$$X^* = \frac{X^{\lambda_2} - 1}{\lambda_2}$$

Рассмотрим

$$Y^* = \beta_0 + \beta_1 X^* + u \tag{3}$$

β_0, β_1 оцениваются при помощи МНК.

Но нужно оценить λ_1 и λ_2! Как? Нелинейный МНК.

Тесты Бокса-Кокса — проверка гипотез о различных значениях λ_1 и λ_2. Как? Сравнить качество подгонки моделей с разными параметрами.

- При $\lambda_2 = 1$, если $\lambda_1 = 1$, то (3) — линейная модель.
- При $\lambda_2 = 0$, если $\lambda_1 = 1$, то (3) — логарифмически-линейная модель.

Тест Зарембки (Zarembka, 1968)

Среднее геометрическое Y равно экспоненте среднего арифметического $\ln Y$:

$$e^{\frac{1}{n}\sum_{i=1}^{n} \ln Y_i} = e^{\frac{1}{n}\ln(Y_1 \times \cdots \times Y_n)} = e^{\ln(Y_1 \times \cdots \times Y_n)^{1/n}} = (Y_1 \times \cdots \times Y_n)^{\frac{1}{n}}$$

1. Вычислите среднее геометрическое Y.

2. Рассчитайте $Y^* = \frac{Y_i}{\text{ср. геом. } Y}$, $i = 1, \ldots, n$.
3. Оцените регрессии Y_i^* и $\ln Y_i^*$ на регрессоры исходной модели и рассчитайте SSR обоих моделей. Лучше та модель, SSR которой меньше.
4. Пусть $SSR_1 > SSR_2$, тогда

$$\frac{n}{2}\left|\ln \frac{SSR_1}{SSR_2}\right| \sim \chi^2(1)$$

ВАЖНО! Регрессии, оцененные в пункте 3, можно использовать только для принятия решения о том, какая модель предпочтительнее. Коэффициенты этих регрессий не интерпретируются. Для интерпретации надо рассматривать исходные модели (без масштабирования).

Модели, нелинейные по параметрам

Пример 1. Модель Михаэлиса-Ментон

$$Inf = \frac{\theta_1 \, UnJob}{\theta_2 + UnJob}$$

$$Y = \frac{1}{Inf} = \frac{1}{\theta_1} + \frac{\theta_2/\theta_1}{UnJob} = \alpha + \beta X$$

Общий вид:

$$Y_i = f(X_{1i}, X_{2i}, \ldots, X_{ki}; \beta_0, \ldots, \beta_m) + u_i, i = 1, \ldots, n$$

Как оценивать? **Нелинейный МНК**:

$$\min_{b_0,\ldots,b_m} \sum_{i=1}^{n} [Y_i - f(X_{1i}, X_{2i}, \ldots, X_{ki}; b_0, \ldots, b_m)]^2$$